UCAS • MACHINE LEARNING

机器学习课程教材

从概率基础到神经网络的十章自学教材

整理日期：2026-11-06

在线版：https://wly63227.github.io/UCAS-machine-learning/

课程整理版 · 来源边界与视觉核对状态见附录

目录

01 学习指南与统一符号

02 第一章 绪论：机器学习研究什么

03 第二章 贝叶斯学习：让证据改变判断

04 第三章 线性分类：几何、统计与概率的三个入口

05 第四章 非线性分类：划分、邻域、组合与核

06 第五章 回归：从最小二乘到正则化

07 第六章 聚类：相似结构由什么决定

08 第七章 特征选择与降维：保留什么，舍弃什么

09 第八章 信息论模型：不确定性、差异与约束

10 第九章 概率图模型：把联合分布拆成局部关系

11 第十章 神经网络与深度学习：可学习表示的组合

A1 练习与可复现计算

A2 核心知识点索引

A3 资料清单与版本说明

A4 来源覆盖与视觉核对记录

A5 建设与验收记录

A6 更新与维护

正文以 2026 主课件为优先来源，后续章节包含往年资料延伸。来源边界与验收状态见附录。

学习指南与统一符号

先建立三条主线

第一条是**概率主线**：先验、似然、后验 → 参数估计 → 回归中的噪声假设 → 概率图模型。第二章建立的贝叶斯公式会贯穿全书。

第二条是**几何与优化主线**：向量、内积和超平面 → 感知机、Fisher 判别和 logistic → 最大间隔与核方法 → 神经网络的反向传播。学习时要能同时说清“图上做什么”和“目标函数是什么”。

第三条是**表示主线**：原始数据变成特征 → 相似性与聚类 → 特征选择、PCA → 网络自动学习表示。特征不是问题的透明容器；单位、缩放、编码方式都会影响算法。

保留课件的十章结构。首次学习按目录顺序；第三章的模型评价先学，会帮助后续所有实验。第八章的熵也可在第四章决策树之前预读。第九章需要第二章与第八章，第十章的 BP 需要第三章的梯度下降。

前置知识如何自检

应当会求条件概率、期望和方差，会做向量内积、矩阵乘法、特征分解，并理解导数与链式法则。遇到矩阵逆时先问矩阵是否可逆；遇到概率乘积时先问独立性来自哪里。缺少这些基础时，先完成相关章节的二维或一维例子，再读一般形式。

统一符号

符号	对象与含义	维度或范围
N	训练样本数，已知整数	$N \geq 1$
d	原始特征维度	正整数
K	类别数或簇数，须由语境区分	正整数
$\mathbf{x}_i$	第 i 个已观测特征，列向量	$\mathbb{R}^d$
y_i	第 i 个标签或回归响应	分类标签 / 实数
D	训练数据集合	$\{(\mathbf{x}_i, y_i)\}_{i=1}^N$
$\mathbf{w}, b$	待学习的权重和偏置	$\mathbb{R}^d, \mathbb{R}$
X	按行放样本的设计矩阵	$N \times d$
$\boldsymbol{\mu}, \Sigma$	随机向量的均值、协方差	$d,\ d \times d$
S_W, S_B	类内、类间散度矩阵	$d \times d$
θ	一般待估参数；硬币例中为成功概率	由模型确定
$P(A)$	事件或离散结果概率	$[0, 1]$
$p(x)$	连续密度或一般概率模型	密度可大于 1
η	学习率	$\eta > 0$
λ	正则强度或特征值	局部重新说明

本书 X 按行放样本；部分课件按列放样本，出现转置差异时应检查维度，不能直接照搬公式。$\log$ 默认自然对数；以 2 为底的熵写作 $\log_2$，单位 bit。

公式在 Markdown 中用 `$...$` 和

$$...$$

。提示词建议的行间 `\(...\)` 通常是行内定界符，因此本项目采用能稳定渲染的标准行间形式。构建时使用本地 KaTeX，断网后仍可阅读数学公式。

一章的使用方法

先读问题与例子，再亲手写一次推导。完成练习时先遮住解答，说明假设、定义符号、写出目标、再计算。最后回到来源页段，分清课件已经讲过的内容与编者补充。

每次实验都记录训练 / 验证 / 测试的角色。测试集用于最后一次评估；标准化、PCA、特征选择与超参数选择必须只从训练流程中学习。随机数据须固定种子。本项目手算实验采用确定性小数据，不依赖一次随机运行来论证结论。

第一章 绪论：机器学习研究什么

> **课件主线**：本章严格沿 S01 的顺序展开：1.1 人工智能背景（PDF 8–31 页）→ 1.2 机器学习的发展（33–40 页）→ 1.3 机器学习研究的问题（42–54 页）→ 1.4 课程主要内容（56–63 页）→ 1.5 课程安排（4–6 页）。课件中的动态产品清单不作为已核实现状转载；正文的推导与泛化说明均显式标成“编者补充”。

课件段落	本文位置	处理方式
S01 8–31 页：人工智能背景	1.1	保留定义、弱人工智能定位与历史脉络；动态产品表只说明存在，不更新事实
S01 33–40 页：机器学习发展	1.1	保留“从经验改进算法”与统计学习主线
S01 42–54 页：研究问题与例子	1.2–1.3	原题、原数值与图示优先；其后再补定义和推导
S01 56–63 页：课程内容	1.5	对应全书目录，不扩张考核范围
S01 4–6 页：课程安排	1.5	只记录课件信息冲突，不替教师判断

1.1 人工智能背景与机器学习的发展

1.1.1 课件先回答：人工智能与机器学习是什么

S01 8–11 页从“让机器完成通常需要人的智能才能完成的任务”引出人工智能，并明确本课程讨论的是**弱人工智能**：针对特定任务建立可计算的方法，不把分类器或回归器等同于人的全部智能。S01 12–31 页用推理期、知识期、统计学习、深度学习和大模型串起人工智能的发展背景；这些历史页用于定位课程，不等于本课程要逐项讲授所有产品。

S01 33 页给出的共同核心是：机器学习研究**如何让计算机算法通过经验自动改进性能。**这里的“经验”通常由数据提供，“改进”必须由可检验的性能指标定义。S01 34–40 页进一步说明，机器学习从早期逻辑与知识驱动逐步发展到以统计学习为主，并服务于信息安全、识别、自然语言处理、生物信息等领域。

1.1.2 学习任务的三要素（编者补充）

为了把课件的定义变成可操作检查，可把一个学习任务拆成三个对象：

要素	含义	通用对应
任务（Task）	要解决的问题是什么	分类、回归、聚类等
经验（Experience）	从什么数据里学	已有训练样本及其标签（监督学习）
性能（Performance）	怎样算“学得好”	分类正确率、回归误差或任务特定指标

记住： 没有明确性能标准，“算法学得更好”就没有可检验的含义。我们后面评价任何模型，都必须先说清用哪个性能指标。

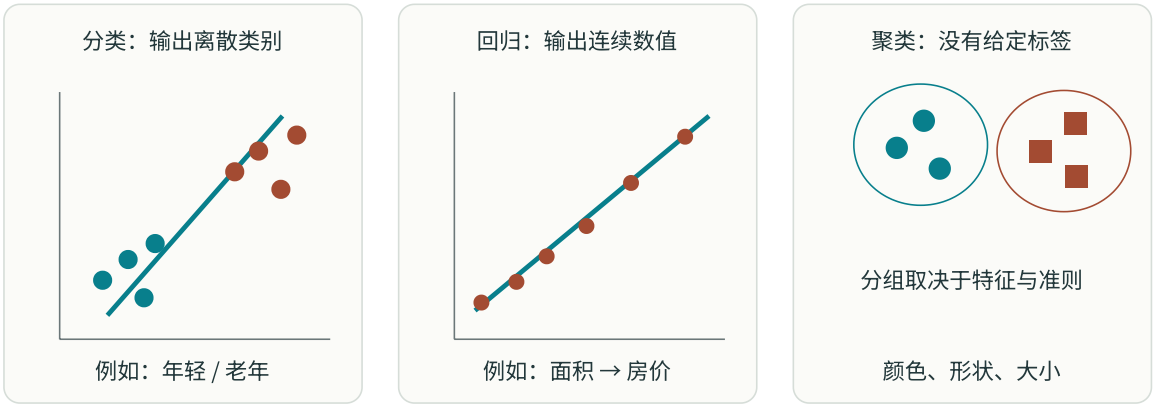
1.1.3 学习与非学习的边界（编者解释）

需要澄清的是：机器学习解决的是“从经验中自动改进性能”的问题。如果一个系统的每一条判断规则都是人写死的、不会因为新数据而改变，那它就不是机器学习系统，只是传统的程序。本课程关心的是“参数由数据决定”的那一类方法。

1.2 机器学习研究的问题：分类、回归与无监督学习

S01 44 页先区分监督学习、无监督学习与强化学习，随后 46–52 页用三个连续例子说明它们的输入输出差异。下面先保留课件例题，再补一般符号。

分类、回归与聚类的输出差异



1.2.1 监督学习的数据形式

监督学习的数据是 $D = \{(\mathbf{x}_i, y_i)\}_{i=1}^{N}$。其中：

- $\mathbf{x}_i \in \mathbb{R}^d$ 是第 i 个输入特征，是一个 d 维列向量（见符号表：d 为原始特征维度，正整数）；
- y_i 是第 i 个已知目标（标签）；
- N 是训练样本数（$N \geq 1$）。

我们要学习一个函数 $f : \mathbb{R}^d \to \mathcal{Y}$，使对**新的**输入 $\mathbf{x}_{\text{new}}$ 也能给出合理的输出 $f(\mathbf{x}_{\text{new}})$。注意：学习的目标不是记住训练集，而是对没见过的数据也能给出好结果（这一点在 1.4 节展开）。

1.2.2 分类 vs 回归：差别在输出 y_i 的含义

分类（classification） 中 y_i 表示离散类别，例如正常 / 异常、猫 / 狗 / 鸟。数字编码 0、1、2 只是类别的“名字”，不表示异常程度相差一个单位。

> **常见误区**：把类别编码成 0 和 1 之后，对它们做算术（例如算“平均类别 = 0.3”）是没有意义的。类别之间没有自然的“大小”或“距离”关系。

回归（regression） 中 y_i 是连续量，例如房价、温度、流量大小。此时预测 100 与预测 101 的数值差有实际意义——它代表“差了 1 个单位的响应量”。

关键结论：任务的区别取决于**输出 y_i 的含义**，不取决于输入 $\mathbf{x}_i$ 是不是连续。例如“根据一张图片预测温度”输入是连续像素、输出是连续温度，属于回归；“根据连续传感器读数判断是否故障”输入连续、输出离散，属于分类。

1.2.3 课件例题一：年轻人与老年人分类（S01 46 页）

课件把标签设为年轻人 $y = +1$、老年人 $y = -1$，特征为

$$\mathbf{x} = (x_1, x_2)^T \in \mathbb{R}^2,$$

其中 x_1 是黑头发比例，值域为 $(0,1)$；x_2 是行走速度，值域为 $(0,100)$ 米/分钟。课件给出部分训练样本：

类别	训练特征 (x_1, x_2)
年轻人 $y=+1$	$(1,99)$、$(0.9,80)$、$(0.80,100)$、.....
老年人 $y=-1$	$(0.2,30)$、$(0.5,50)$、$(0.4,30)$、.....

待测样本是 $\mathbf{x}_* = (0.85, 98)^T$，问题是预测 y_*。从课件散点图看，它更靠近“高黑发比例、高行走速度”的年轻人簇，因此按图示直觉会判为 $+1$；**课件该页只提出问题，没有给出教师标准算法或标准答案。**后续章节会分别用贝叶斯、线性分类器等方法把“靠近”变成明确规则。

1.2.4 课件例题二：房价回归（S01 47 页）

输入 x 是房屋面积（m²），输出 $y \geq 0$ 是房价（万元）。课件给出 13 个训练点：

面积 x	35	40	45	65	74	80	120	140	230	300	400	500	600
房价 y	150	170	190	200	224	245	320	400	640	780	900	1100	1300

课件提出：用 $y = ax + b$ 建模，面积 $x_* = 90$ 时房价是多少？该页没有给出教师答案。若按普通最小二乘拟合全部 13 点，编者复算得到

$$\hat{y} = 2.0560x + 93.3621, \qquad \hat{y}(90) \approx 278.40 \text{ 万元}.$$

这只是对课件问题的一种**编者计算**；若损失、异常点处理或模型形式不同，答案会变化。

1.2.5 课件例题三：颜色、形状、大小的聚类（S01 49–52 页）

课件给出若干颜色、形状和大小不同的物体，只给特征

$$\mathbf{x} = (\text{颜色}, \text{形状}, \text{大小}),$$

没有给标签 y，并连续展示多种可能分组：可以按形状分、按颜色与形状组合分、按大小分，甚至全部放成一组。这个例子要说明的不是“哪一种分法唯一正确”，而是：**无监督学习的结果取决于特征表示、相似性定义和聚类目标**；数据本身不会自动告诉我们哪种语义最重要。

1.2.6 一般定义与强化学习（编者补充）

无监督学习（unsupervised learning） 只有输入集合 $\{\mathbf{x}_i\}_{i=1}^N$，没有给定目标 y_i。典型任务包括：

- **聚类（clustering）**：把相似样本分到一组；
- **降维（dimensionality reduction）**：寻找数据的紧凑表示；
- **密度估计（density estimation）**：描述数据背后的分布。

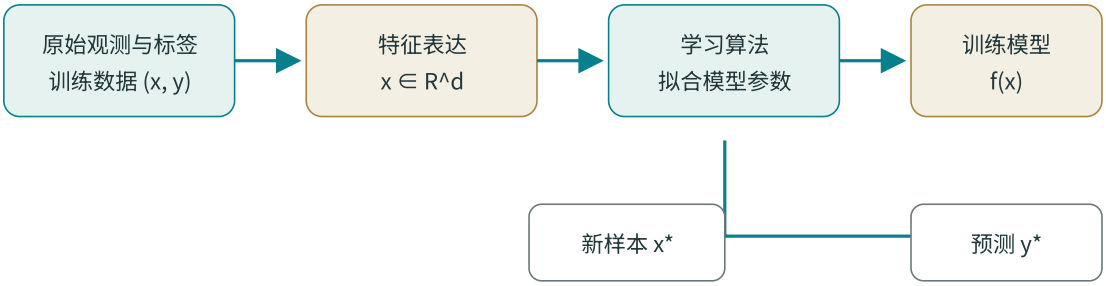
> **记住**：算法得到的簇**不自动等同于**真实语义类别。例如把动物按“体型大小”聚类，可能把“大象”和“河马”聚到一起，但它们并不是同一个物种类别。聚类结果的意义需要人来解释。

强化学习（reinforcement learning） 则通过与环境交互、接收奖励信号来学习行动策略。它的反馈方式（延迟的、稀疏的奖励）与监督学习“每条样本都有一个明确标签”不同；本课程只在概述和网络扩展中提及，不作为主线内容。

1.3 课件的建模过程：数据、模型、误差与学习

S01 42–43 页先给出“观测 → 特征提取与选择 → 分类器 → 决策”的模式识别流程；54 页再把建模过程写成“数据 → 模型与误差函数 → 学习参数 → 应用”。一个完整建模过程需要依次回答四个问题：**输入输出是什么？可选择的函数有哪些？什么预测算好？怎样找到参数？** 这四个问题对应“模型—损失—优化”三元组。

课件主线：从训练数据到新样本预测



训练阶段用已知标签学习参数；应用阶段只输入新样本，标签未知。

1.3.1 建模流程（从数据到应用）

从数据到应用依次经过：

1. **观测与标注**：收集原始数据并给出目标（监督学习需要标注）；
2. **特征表达**：把原始对象变成特征向量 $\mathbf{x}_i \in \mathbb{R}^d$；
3. **拟合模型**：选定函数族 $f(\cdot;\theta)$，用数据估计参数 θ；
4. **独立评估**：用未参与学习的数据评价性能；
5. **新样本预测**：把学到的 f 用于未来数据。

后续章节分别研究这些环节。

1.3.2 模型、损失、优化三者不可混为一谈

仍以预测房价为例。

- **模型（model）** 决定“函数长什么样”。例如取线性模型

$$f(x) = wx + b$$

  其中 x 是面积，w 是斜率，b 是截距。模型是一族函数，不是某个具体数字。
- **损失（loss）** 决定“什么样的预测算好”。例如用**平方误差**评价参数 (w, b)。
- **优化（optimization）** 决定“怎么找到最好的参数”。例如用梯度下降在 (w, b) 空间里求使损失最小的那个点。

关键结论：同一个模型可以使用不同损失（线性模型 + 平方误差，或线性模型 + 绝对误差）；同一个损失也可训练不同模型（平方误差既能训线性模型，也能训神经网络）。三者是正交的选择，不能混为一谈。

1.3.3 编者补充：平方误差损失的写法与单位（重点推导）

我们用平方误差作为学习准则。先写出最一般的形式，再做单位分析，最后给出逐步推导。

假设与符号（先对齐维度）

- 第 i 个样本：$\mathbf{x}_i \in \mathbb{R}^d$（列向量），$y_i \in \mathbb{R}$（标量响应）。
- 线性模型参数：$\mathbf{w} \in \mathbb{R}^d$，$b \in \mathbb{R}$（符号表约定）。
- 预测值 $\hat{y}_i = \mathbf{w}^\top \mathbf{x}_i + b \in \mathbb{R}$（$\mathbf{w}^\top \mathbf{x}_i$ 是向量内积，结果为标量，加上标量 b 仍是标量）。
- 残差（residual）$r_i = y_i - \hat{y}_i \in \mathbb{R}$，表示“真实值减去预测值”。

起始式（标量求和形式）

平方误差（均方误差，MSE）定义为残差平方的平均值：

$$J(\mathbf{w}, b) = \frac{1}{N} \sum_{i=1}^{N} (y_i - \hat{y}_i)^2 = \frac{1}{N} \sum_{i=1}^{N} \big(y_i - (\mathbf{w}^\top \mathbf{x}_i + b)\big)^2$$

紧凑的矩阵形式（对齐符号表）

令设计矩阵 $X \in \mathbb{R}^{N \times d}$（按行放样本，每行一个 $\mathbf{x}_i^\top$），$\mathbf{1} \in \mathbb{R}^N$ 为全 1 向量，$\mathbf{y} = (y_1, \ldots, y_N)^\top \in \mathbb{R}^N$。则

$$J(\mathbf{w}, b) = \frac{1}{N} \big\| \mathbf{y} - X\mathbf{w} - b\mathbf{1} \big\|^2$$

维度核对：X 是 $N \times d$，$\mathbf{w}$ 是 $d \times 1$，故 $X\mathbf{w}$ 是 $N \times 1$；$b\mathbf{1}$ 是 $N \times 1$；$\mathbf{y}$ 是 $N \times 1$；相减得 $N \times 1$ 向量，其 2-范数平方为标量。维度一致，公式成立。

过程讲解①：损失的“单位”从哪来（为什么 J 的单位不是 y 的单位）

设 x 的单位是“平方米（m²）”，y 的单位是“元”。

- 预测 $f(x) = wx + b$ 的量纲必须是元，所以：
  - w 的单位 = 元 / m²（每多一平方米，价格增加多少）；
  - b 的单位 = 元（面积为 0 时的基准价，截距）。
- 残差 $r_i = y_i - f(x_i)$ 的单位是元；
- r_i^2 的单位是元²；
- 平均之后 J 的单位仍是**元²**。

结论：平方误差 J 的单位是“响应量纲的平方”，和 y 本身不在同一尺度。因此**跨数据集比较 J 没有意义**（单位不同或量级不同）；比较模型好坏必须在同一数据集、同一损失定义下进行。

> **常见误区**：看到 $J = 0.05$ 就以为“误差只有 0.05 元”。实际上 J 的单位是元²，它的平方根（RMSE）才和 y 同单位。要报“平均误差大约多少”，应看 $\sqrt{J}$（均方根误差），而不是 J 本身。

过程讲解②：为什么“平方误差”是自然的（最优常数预测 = 样本均值）

平方误差不是一个随意的选择。我们可以证明：在“只允许输出一个常数 c”的最简单模型下，使平方误差最小的 c 恰好是样本均值 $\bar{y}$。这说明平方误差天然在“让预测贴近数据的中心”。

假设：固定目标 $y_1, \ldots, y_N$，只选一个常数 c 作预测；损失为

$$J(c) = \frac{1}{N} \sum_{i=1}^{N} (y_i - c)^2$$

起始式：对 c 求导并令其为 0。

步骤 1：写出导数（用链式法则，记 $\frac{d}{dc}(y_i-c)^2 = 2(y_i-c)\cdot(-1)$）：

$$\frac{dJ}{dc} = \frac{1}{N}\sum_{i=1}^{N} 2(y_i-c)(-1) = -\frac{2}{N}\sum_{i=1}^{N}(y_i-c)$$

步骤 2：把求和拆开：

$$\frac{dJ}{dc} = -\frac{2}{N}\Big(\sum_{i=1}^{N} y_i - \sum_{i=1}^{N} c\Big) = -\frac{2}{N}\Big(\sum_{i=1}^{N} y_i - Nc\Big)$$

步骤 3：令导数为 0 求极值点：

$$-\frac{2}{N}\Big(\sum_{i=1}^{N} y_i - Nc\Big) = 0 \quad\Longrightarrow\quad \sum_{i=1}^{N} y_i - Nc = 0 \quad\Longrightarrow\quad c = \frac{1}{N}\sum_{i=1}^{N} y_i = \bar{y}$$

步骤 4：验证是最小值（看二阶导数）：

$$\frac{d^2J}{dc^2} = \frac{2}{N} > 0$$

二阶导恒正，故 $c=\bar{y}$ 处取得**最小值**，而非最大值。

结论：在平方误差下，最优的常数预测就是样本均值。平方误差因此与“方差/离散程度”直接挂钩——它惩罚的是预测偏离数据中心的程度，且偏离越大惩罚越重（平方放大了大误差）。这正是平方误差被广泛采用的根本原因。

过程讲解③：梯度是什么（连接“优化”这一元）

对 1 维线性模型 $f(x)=wx+b$，平方误差为

$$J(w,b) = \frac{1}{N}\sum_{i=1}^{N}(y_i - wx_i - b)^2$$

记预测 $\hat{y}_i = wx_i+b$，残差 $r_i = y_i-\hat{y}_i$。

步骤 1：对 w 求偏导（链式法则，内层对 w 的导数是 $-x_i$）：

$$\frac{\partial J}{\partial w} = \frac{1}{N}\sum_{i=1}^{N} 2r_i(-x_i) = -\frac{2}{N}\sum_{i=1}^{N} x_i\, r_i$$

步骤 2：对 b 求偏导（内层对 b 的导数是 -1）：

$$\frac{\partial J}{\partial b} = \frac{1}{N}\sum_{i=1}^{N} 2r_i(-1) = -\frac{2}{N}\sum_{i=1}^{N} r_i$$

步骤 3：梯度下降更新（学习率 $\eta>0$，符号表约定）：

$$w \leftarrow w - \eta\frac{\partial J}{\partial w}, \qquad b \leftarrow b - \eta\frac{\partial J}{\partial b}$$

结论：只要能算出梯度（一阶偏导数），就能用梯度下降逐步降低 J。这正是后续章节（尤其是第十章反向传播）反复使用的同一套逻辑：定义损失 → 求梯度 → 沿负梯度更新参数。

1.3.4 一个自编数值例（把三元组走通）

自编数值例（确定性小数据，不依赖随机）

数据（面积 x（百 m²），房价 y（十万元））：

i	x_i	y_i
1	1	2
2	2	3
3	3	5

模型 $f(x)=wx+b$，平方误差 $J(w,b)=\frac{1}{N}\sum_{i=1}^{N}(y_i-wx_i-b)^2$，$N=3$。

(a) 直观对比两个参数——展示“更小的 J = 更好的拟合”：

- 取 $(w,b)=(1,0)$：预测 $\hat{y}=(1,2,3)$，残差 $r=(1,1,2)$，$r^2=(1,1,4)$，

$$J=\frac{1+1+4}{3}=2$$

- 取 $(w,b)=(1.5,0)$：预测 $\hat{y}=(1.5,3,4.5)$，残差 $r=(0.5,0,0.5)$，$r^2=(0.25,0,0.25)$，

$$J=\frac{0.25+0+0.25}{3}=0.5$$

J 从 2 降到 0.5，说明第二组参数拟合得更好。

(b) 求最优参数（优化环节）——把 1.3.3 的梯度置零条件写成方程组求解。

令偏导为 0（即正规方程）：

$$\frac{\partial J}{\partial w}=0\ \Rightarrow\ \sum x_i(y_i-\hat{y}_i)=0,\qquad \frac{\partial J}{\partial b}=0\ \Rightarrow\ \sum(y_i-\hat{y}_i)=0$$

代入数据（$\sum x_i=6,\ \sum y_i=10,\ \sum x_i^2=1+4+9=14,\ \sum x_iy_i=2+6+15=23$）：

步骤 1：由 $\sum(y_i-wx_i-b)=0$ 得

$$10-6w-3b=0\quad\Longrightarrow\quad 2w+b=\frac{10}{3}\tag{A}$$

步骤 2：由 $\sum x_i(y_i-wx_i-b)=0$ 得

$$23-14w-6b=0\quad\Longrightarrow\quad 14w+6b=23\tag{B}$$

步骤 3：由 (A) 得 $b=\frac{10}{3}-2w$，代入 (B)：

$$14w+6\Big(\frac{10}{3}-2w\Big)=23\ \Longrightarrow\ 14w+20-12w=23\ \Longrightarrow\ 2w=3\ \Longrightarrow\ w=1.5$$

步骤 4：代回得 $b=\frac{10}{3}-2\times1.5=\frac{1}{3}\approx0.333$。

结论（参考解）：最优参数为 $(w^*,b^*)=(1.5,\ 1/3)$。此时预测为 $(1.833,\ 3.333,\ 4.833)$，残差为 $(0.167,\ -0.333,\ 0.167)$，

$$J_{\min}=\frac{0.167^2+0.333^2+0.167^2}{3}\approx\frac{0.0278+0.1111+0.0278}{3}\approx0.0556$$

这就是在该线性模型下能达到的最小平方误差。注意三条点并不共线，所以 $J_{\min}>0$——直线无法完美穿过所有点，这正是“模型容量有限”与“用更复杂模型可降低训练误差”的雏形（也为 1.4 节的过拟合埋下伏笔）。

1.4 编者补充：为什么训练误差不够

> 本节不是 S01 绪论的独立课件小节，而是为解释“训练模型如何用于未见样本”补入的基础；其中数据划分内容与 S05 39–41 页相呼应。

1.4.1 过拟合的直觉

记住全部训练样本（或者说让模型复杂到能“背下”训练集）可能使训练错误为零，却无法预测新样本。泛化能力指模型在目标分布中**新数据**上的表现。模型越复杂，往往越能贴近已有数据，但也可能把偶然噪声一起记住——这就是**过拟合（overfitting）**。

> **通俗类比**：考试前把历年真题的答案全背下来，平时练习满分；但考题一换就傻眼。训练误差像“平时练习分”，泛化误差才像“真正考试分”。我们要的是后者。

1.4.2 泛化与数据划分的前提

要谈论“学得怎样”，必须先把数据分成不同角色：

- **训练集（training set）**：用来估计模型参数（做优化）。
- **验证集（validation set）**：用来选超参数、选模型（如选多项式阶数）。
- **测试集（test set）**：只在最后评估一次，用来报告最终性能。

记住：标准化、PCA、特征选择、超参数选择等所有“会用到数据分布信息”的步骤，都必须**只从训练流程中学习**，再把同样变换应用到验证/测试集。任何让验证或测试信息提前泄漏到训练中的做法，都会高估性能。

1.4.3 留出法（hold-out）

留出法将数据分成训练与评估两部分。需要调参时，应再区分验证集和最终测试集：先用训练集拟合，用验证集选方案，最后才用测试集报告。测试集一旦用于选模型，它就不再是“独立评估”，结果会偏乐观。

1.4.4 k 折交叉验证（k-fold CV）

k 折交叉验证将训练资料分成 k 份（折）。每次用其中一份作验证，其余 $k-1$ 份作训练，得到一个验证得分；重复 k 次（每份都当过一次验证），汇总 k 个结果（通常取平均）来选择方案。

- 优点：每个样本都既当过训练又当过验证，数据利用更充分；
- 代价：要训练 k 次模型，计算更贵；
- **重要顺序**：先在每折内部完成“训练+验证”来选方案，确定方案**以后**才访问最终测试集。

1.4.5 自助法（bootstrap）及其概率推导（重点）

自助法从 N 个样本中有放回抽取 N 次，得到一个同样大小为 N 的“自助样本”。我们要弄清：原样本中某个特定样本，有多大概率**一次都没被抽中**？

假设与符号

- 总体有 N 个样本，编号 $1,\dots,N$；
- 每次抽取独立、均匀，抽到任一号的概率都是 $1/N$；
- 共抽 N 次（有放回）。

过程讲解（逐步推导）

步骤 1：某一次抽取中，特定样本（比如第 1 号）**没被抽中**的概率：

$$P(\text{单次未抽中}) = 1 - \frac{1}{N}$$

步骤 2：因为有放回，各次独立。N 次全都未抽中该样本的概率为每次概率的乘积：

$$P(\text{全程未抽中}) = \underbrace{\left(1-\frac{1}{N}\right)\cdots\left(1-\frac{1}{N}\right)}_{N\text{ 次}} = \left(1-\frac{1}{N}\right)^N$$

步骤 3：看 N 很大时的极限。利用标准极限公式

$$\lim_{n\to\infty}\left(1+\frac{a}{n}\right)^n = e^a$$

令 $a=-1$，$n=N$，得到

$$\lim_{N\to\infty}\left(1-\frac{1}{N}\right)^N = e^{-1} \approx 0.3679$$

步骤 4：因此，当 N 较大时，任意一个原始样本约有 36.8% 的概率不出现在自助样本中；等价地，约 $1-e^{-1}\approx 63.2\%$ 的原始样本**至少出现一次**。自助样本虽然大小仍是 N，但其中约 36.8% 的位置是重复抽取得到的，只有约 63.2% 是“不重复的原始样本”（这些未出现的约 36.8% 可作**包外样本 out-of-bag，OOB** 用于评估）。

数值核对表（自编验证，说明 $(1-1/N)^N \to e^{-1}$）

N	$(1-1/N)^N$	含义（该样本被遗漏的概率）
10	$0.9^{10}\approx 0.3487$	约 34.9%
100	$0.99^{100}\approx 0.3660$	约 36.6%
1000	$0.999^{1000}\approx 0.3677$	约 36.8%
∞	$e^{-1}\approx 0.3679$	极限约 36.79%

可见随着 N 增大，数值稳定趋近于 e^{-1}，原课件结论 $(1-1/N)^N \to e^{-1}$ 成立。

结论与含义：自助样本含重复记录，不能当作 N 个新的独立来源。它适合样本量有限、难以划分训练/测试的场景（如集成学习中的 bagging）；其代价是引入了重复样本、丢失了约 36.8% 的原始信息。

1.4.6 数据泄漏反例（自编）

自编反例：先用**所有数据**挑选与标签最相关的特征，再做交叉验证。即使模型在每一折都重新训练，验证标签也已经参与了“特征选择”这一步——因为特征选择看过了全部样本的标签，验证集的信息提前泄漏进了建模流程。这是**数据泄漏（data leakage）**，会导致交叉验证分数虚高、上线后性能大跌。

正确做法：特征选择、标准化、PCA 等“看数据”的步骤，必须放在每一折的**训练侧**内部进行，验证集只用于给已经定好的流程打分。

1.5 课程主要内容与课程安排

S01 56 页把课程目标分成三层：理解监督学习与无监督学习问题；掌握最大似然、最小均方、梯度下降和随机梯度下降等统计与优化基础；掌握 Bayes、SVM、鉴别分析、Logistic、决策树等基础算法。57 页给出的十章顺序就是本书目录：

1. 绪论；2. 贝叶斯学习；3. 线性分类；4. 非线性分类；5. 回归分析；
2. 聚类分析；7. 特征降维；8. 信息论模型；9. 概率图模型；10. 深度学习。

当前本年度文件只到线性分类第二部分；第四至十章只能以往年课件为来源，并已在相应章首标明版本，不能据此推定本年度考核范围。

绪论 5 页写明“作业 + 课堂闭卷考试”，但同页“2026 年 1 月 15 日”早于课件学期；此处只记录原文冲突，不推定正确日期、成绩比例或考试范围。未来安排以教师更新通知为准。

复习时应能对一个新任务写清输入、输出、数据、模型、损失、优化和评估七项。只会说“用神经网络”还没有完成问题建模。

1.6 本章要点回顾：从七问到三元组

为方便复习，把全章收敛成两张“速查表”。

1.6.1 接到一个新任务，先回答七问

序号	问题	要写清的内容
1	输入是什么	特征 $\mathbf{x}_i \in \mathbb{R}^d$ 的含义与维度
2	输出是什么	类别（分类）还是连续量（回归）；y_i 的含义
3	数据从哪来	训练集 $D = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$，是否标注
4	模型选哪族	函数形式 $f(\cdot;\theta)$，如线性 $f = \mathbf{w}^\top \mathbf{x} + b$
5	损失怎么算	平方误差 $J = \frac{1}{N}\sum(y_i - \hat{y}_i)^2$ 等
6	怎么优化	梯度下降、正规方程等求使 J 最小的 θ
7	如何评估	留出 / k 折 / 自助；用验证集选、测试集最终报

1.6.2 全章关键公式速查

- **平方误差（线性模型）**

$$J(\mathbf{w}, b) = \frac{1}{N}\sum_{i=1}^{N}\big(y_i - (\mathbf{w}^\top \mathbf{x}_i + b)\big)^2 = \frac{1}{N}\|\mathbf{y} - X\mathbf{w} - b\mathbf{1}\|^2$$

  其中 $X \in \mathbb{R}^{N\times d}$（按行放样本），$\mathbf{w} \in \mathbb{R}^d$，$b \in \mathbb{R}$，$J$ 的单位是“响应量纲的平方”。

- **最优常数预测**（平方误差下）：$c^* = \bar{y} = \frac{1}{N}\sum y_i$。
- **梯度（1 维）**：$\frac{\partial J}{\partial w} = -\frac{2}{N}\sum x_i r_i$，$\frac{\partial J}{\partial b} = -\frac{2}{N}\sum r_i$。
- **自助法遗漏概率**：单样本全程未被抽中概率 $(1 - 1/N)^N \to e^{-1} \approx 0.3679$（$N \to \infty$）。

记住：训练误差低不等于泛化好；任何“看数据”的步骤都只能从训练流程中学习，否则就是数据泄漏。

第二章 贝叶斯学习：让证据改变判断

> **课件主线**：S02 4–10 页先用天气预报引出先验、证据与贝叶斯决策；S03 4–17 页依次讲判别函数、朴素贝叶斯和“西瓜”完整例题；19–30 页讨论三种高斯协方差情形；33–51 页讲参数估计。正文按这一顺序展开，编者推导与自编例另行标注。

本章是全书“概率主线”的起点。我们会反复用到一句话：**先验代表旧判断，似然代表新证据有多支持各假设，后验是证据修正后的新判断，证据（分母）只负责把概率归一化到 `[0,1]`。** 读完本章，你应该能独立写出：贝叶斯公式的来历、多类后验、MAP 决策为什么能删去证据、朴素贝叶斯的独立性假设、高斯分类器何时给出直线边界（并把 $\mathbf{w}$, b 推出来）、以及 MLE / 共轭先验 / MAP / 后验预测各自的推导与区别。

2.1 先验、似然、后验与证据

2.1.1 为什么这样想：用天气建立直觉

先不要急着背公式。设想你每天早晨想知道“今天是否晴天”。在**还没看任何征兆**（比如傍晚的晚霞）之前，你只能按历史频率猜：一年 365 天里有 265 天晴，于是你先入为主地认为“晴天”的可能性是 $265/365$。这个“还没看证据时的判断”就叫**先验（prior）**。

到了傍晚，你看到了“晚霞”。经验告诉你：晴天更容易出晚霞，阴天偶尔也出。于是“晚霞”这条**证据（evidence / observation）会改变你的判断，得到“看了晚霞之后晴天的把握”，这就是后验（posterior）**。而“在晴天假设下出现晚霞的可能性”描述的是证据与假设之间的关系，叫做**似然（likelihood）**。

记住这三者角色不同：**先验是旧信念，似然是证据对各假设的区分力，后验是修正后的新信念。**

2.1.2 贝叶斯公式的逐步推导（联合概率两种分解 → 除以 $P(B)$ → 全概率展开分母）

下面把贝叶斯公式从无到有推一遍，每一步都说明在做什么。

过程讲解

- **符号与假设**：设 A, B 为两个事件，且 $P(B) > 0$。$P(B) > 0$ 是公式成立的硬条件——分母不能为零，否则“在 B 发生条件下”没有意义。
- **起点（联合概率的两种分解）**：把“两件事同时发生”的概率按不同顺序展开，得到两个式子，它们都等于同一个联合概率 $P(A, B)$：

$$P(A, B) = P(B \mid A)P(A), \qquad P(A, B) = P(A \mid B)P(B).$$

  第一式是“先固定 A，再看 B 给 A 的条件概率”；第二式是“先固定 B，再看 A 给 B 的条件概率”。
- **步骤 1（两式相等）**：既然两式都等于 $P(A, B)$，于是

$$P(B \mid A)P(A) = P(A \mid B)P(B).$$

- **步骤 2（两边除以 $P(B)$）**：因为 $P(B) > 0$，可以除，得到后验的表达式

$$P(A \mid B) = \frac{P(B \mid A)P(A)}{P(B)}.$$

这就是贝叶斯公式的雏形：分子是“似然 × 先验”。

- **步骤 3（用全概率展开分母）**：分母 $P(B)$ 本身可以用对 A 及其补集 $\neg A$ 的全概率公式拆开：

$$P(B) = P(B \mid A)P(A) + P(B \mid \neg A)P(\neg A).$$

代回步骤 2，得到完整形式：

$$P(A \mid B) = \frac{P(B \mid A)P(A)}{P(B \mid A)P(A) + P(B \mid \neg A)P(\neg A)}.$$

- **结论**：后验 $= \dfrac{\text{似然} \times \text{先验}}{\text{证据}}$；证据 $P(B)$ 正好是所有假设下产生该证据的总概率之和，起归一化作用。
- **成立条件**：$P(B) > 0$。若 $P(B) = 0$（数据在已知假设下根本不可能出现），需要另行处理，不能机械套公式。

2.1.3 数值核对：晴天与晚霞

沿用 S02 的设定：一年 365 天有 265 天晴。令 $A =$ “明天晴”，$B =$ “今晚有晚霞”。

- 先验：$P(A) = 265/365$，$P(\neg A) = 100/365$。
- 似然（不同天气下出晚霞的可能）：$P(B \mid A) = 0.7$，$P(B \mid \neg A) = 0.1$。

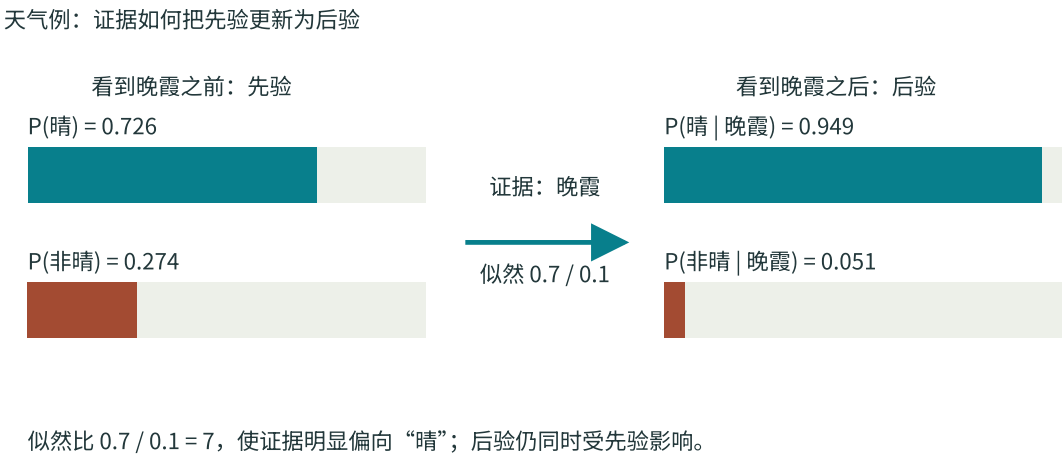
先算证据 $P(B)$（注意用未提前舍入的分数，最后再取整，避免累积误差）：

$$\begin{aligned} P(B) &= P(B \mid A)P(A) + P(B \mid \neg A)P(\neg A) \\ &= 0.7 \cdot \frac{265}{365} + 0.1 \cdot \frac{100}{365} = \frac{185.5 + 10}{365} = \frac{195.5}{365}. \end{aligned}$$

再算后验 $P(A \mid B)$：

$$P(A \mid B) = \frac{0.7 \cdot 265/365}{195.5/365} = \frac{185.5}{195.5} \approx 0.948849.$$

看到晚霞后，晴天的把握从先验的 $265/365 \approx 0.726$ 提升到约 0.949。



反例：没有晚霞时会怎样？ 这时证据换成 $\neg B$，$P(\neg B \mid A) = 1 - 0.7 = 0.3$，$P(\neg B \mid \neg A) = 1 - 0.1 = 0.9$：

$$P(\neg B) = 0.3 \cdot \frac{265}{365} + 0.9 \cdot \frac{100}{365} = \frac{79.5 + 90}{365} = \frac{169.5}{365},$$
$$P(A \mid \neg B) = \frac{79.5/365}{169.5/365} = \frac{79.5}{169.5} \approx 0.469027.$$

没有晚霞时，晴天的把握反而降到约 0.469，**预测方向会反转**。这个对比说明：后验的变化完全来自“证据对不同假设的支持程度不同”。

> **记住**：分子里明明是 $P(B \mid A)$（证据给假设），后验却是 $P(A \mid B)$（假设给证据）。两者**不能互换**——“晴天容易有晚霞”不等于“有晚霞多半是晴天”（还要看先验和另一类）。

2.1.4 多类后验与“证据归一化”

把二分类推广到 K 个类别。设类别 $C \in \{1, \dots, K\}$，已观测特征为 $\mathbf{x} \in \mathbb{R}^d$（列向量，维度 d）。

$$P(C = c \mid \mathbf{x}) = \frac{p(\mathbf{x} \mid C = c)P(C = c)}{\sum_{j=1}^{K} p(\mathbf{x} \mid C = j)P(C = j)}.$$

- **分子** $p(\mathbf{x} \mid c)P(c)$：第 c 类的似然乘先验。
- **分母** $\sum_{j=1}^{K} p(\mathbf{x} \mid j)P(j)$：把所有类别的“似然×先验”加起来，就是证据（也称边际似然），作用是把分子归一化，使所有类别的后验加起来等于 1。

过程讲解（为什么分母保证归一化）

- **起点**：对任意 $\mathbf{x}$，后验之和应为 1。
- **步骤**：把上式的分子对所有 c 求和：

$$\sum_{c=1}^{K} P(C = c \mid \mathbf{x}) = \frac{\sum_{c=1}^{K} p(\mathbf{x} \mid c)P(C = c)}{\sum_{j=1}^{K} p(\mathbf{x} \mid j)P(C = j)} = 1.$$

- **结论**：分母恰好等于分子之和，因此后验是一个合法的概率分布。比较“哪个类最大”时，这个归一化常数可以省掉（见 2.2）。

> **常见误区**：这里 $p(\mathbf{x} \mid c)$ 是**密度**（连续情形下单点概率为零），密度值可以大于 1。密度“大”只表示相对更可能，不等于“概率接近 1”。似然 $p(\mathbf{x} \mid c)$ 是“给定 c 时数据出现的可能性”的函数，它**不要求对参数/类别积分为 1**——这是似然与概率分布的根本区别。

2.2 从后验到决策

2.2.1 为什么这样想：分类就是“选最像的那个类”

分类器的任务是给新样本 $\mathbf{x}$ 一个类别标签。最朴素也最常用的准则：**选后验概率最大的类。**直觉上，既然后验是“证据修正后的判断”，那当然信最有可能那个。下面证明：在“错判代价相同”的前提下，这确实使错误率最小。

2.2.2 MAP 决策：删去证据只因它对所有类相同

过程讲解（最大后验分类 = 最小错误率）

- **符号与假设**：类别 $c = 1, \dots, K$。采用 0–1 损失：判错损失为 1，判对为 0。条件错误概率为 $1 - \max_c P(C = c \mid \mathbf{x})$。

- **起点**：要使错误率最小，等价于使 $\max_c P(C=c \mid \mathbf{x})$ 最大。
- **步骤**：由 2.1.4 的后验公式，

$$\arg\max_c P(C=c \mid \mathbf{x}) = \arg\max_c \frac{p(\mathbf{x} \mid c)P(c)}{\sum_{j=1}^{K} p(\mathbf{x} \mid j)P(j)}.$$

  分母 $\sum_{j=1}^{K} p(\mathbf{x} \mid j)P(j)$ 与 c **无关**（对所有候选类都相同），正数常数不影响“取最大”的位置，因此可删：

$$h(\mathbf{x}) = \arg\max_c P(C=c \mid \mathbf{x}) = \arg\max_c p(\mathbf{x} \mid c)P(c).$$

- **结论**：最大后验（MAP）决策只需比较“似然×先验”，无需算证据。
- **成立条件与边界**：删去证据**绝不表示证据等于 1**，只是它对所有类是常数。**只有对所有类共同的因子可以删**（例如共同的对数常数、共同协方差项）；某个类**自己独有的常数不能删。**

2.2.3 对数判别函数

因为对数 log（本章默认自然对数，见统一符号表）是严格单调递增函数，对正数取对数不改变大小顺序，于是可比较

$$g_c(\mathbf{x}) = \log p(\mathbf{x} \mid c) + \log P(c).$$

- **二分类写法**：令 $g(\mathbf{x}) = g_1(\mathbf{x}) - g_2(\mathbf{x})$。
  - $g > 0$：归第一类（因为 $g_1 > g_2$，即 $P(C=1 \mid \mathbf{x}) > P(C=2 \mid \mathbf{x})$）；
  - $g < 0$：归第二类；
  - $g = 0$：两类后验相等，平局，需**事先约定**平局规则（如固定归某一类）。
- **为什么用对数**：把乘积变加法，数值上更稳定（避免很多小于 1 的密度相乘导致下溢）。

> **记住**：只在“比较谁最大”时才能删常数。若你需要**输出真实后验概率**（比如要报告“有 95% 把握是晴天”），就必须保留分母把结果归一化。

2.2.4 编者扩展：错判代价不相等时的风险最小化

实际错判代价可能不同。令 $L(a, c)$ 为“采取动作 a、真实类别为 c”的损失，则**条件风险**为

$$R(a \mid \mathbf{x}) = \sum_c L(a, c)P(C=c \mid \mathbf{x}).$$

应选使风险最小的动作。最大后验分类只是 0–1 损失（$L(a,c) = 1 - \delta_{ac}$）下的特例，并非所有应用下的最优规则。例如“把健康人误判为有病”和“把病人误判为健康”的代价天差地别，此时必须用风险最小化而非单纯比后验。

2.3 朴素贝叶斯如何降低估计难度

2.3.1 为什么这样想：特征组合爆炸

直接估计整个 $p(\mathbf{x} \mid c)$ 意味着要刻画 d 个特征在所有类别下的联合分布。若每个特征有几种取值，组合数是指数级的，样本根本不够。朴素贝叶斯用一个大胆但常用的假设来“降维”：**给定类别之后，各特征相互独立。**这样就把联合密度拆成一维密度的乘积，估计难度从“指数”降到“线性”。

2.3.2 条件独立假设与判别函数

过程讲解

- **假设（关键）**：给定类别 c 后，特征 $x_1, \ldots, x_d$ 条件独立，即

$$p(\mathbf{x} \mid c) = p(x_1, \ldots, x_d \mid c) = \prod_{j=1}^{d} p(x_j \mid c).$$

- **步骤**：代入 2.2.3 的对数判别函数，

$$g_c(\mathbf{x}) = \log P(c) + \log \prod_{j=1}^{d} p(x_j \mid c) = \log P(c) + \sum_{j=1}^{d} \log p(x_j \mid c).$$

- **结论**：判别函数变成“类别先验的对数 + 各维条件密度的对数之和”，每个一维密度可独立从该类样本中估计。

> **常见误区**：这是“**给定类别以后**独立”，并不要求特征在总体上独立。两个特征可以都随类别变化（例如“颜色”和“形状”都随“水果种类”变），于是总体上它们相关；但一旦固定了类别，两者就互不提供额外信息。换句话说，朴素贝叶斯的独立性是**条件独立性**，不是边际独立性。

2.3.3 参数估计与平滑（拉普拉斯平滑）

- **类别先验**：用频率估计 $\widehat{P}(c) = N_c / N$，其中 N_c 是第 c 类样本数，N 是总样本数。
- **离散特征**：第 j 维有 m_j 个可能取值，某取值 v 在类 c 中出现 N_{cjv} 次，可用

$$\widehat{P}(x_j = v \mid c) = \frac{N_{cjv} + \alpha}{N_c + \alpha m_j}, \qquad \alpha > 0.$$

过程讲解（平滑为什么必要）

- **起点**：若某个取值 v 在类 c 中一次都没出现（$N_{cjv} = 0$），未平滑的估计为 0。
- **问题**：由于判别函数是各项对数之和，一项为 $\log 0 = -\infty$，会**让整类得分变成零**，即使其他特征都强烈支持该类。
- **步骤**：加 $\alpha > 0$ 的伪计数到分子，并在分母累计**所有候选取值**增加的伪计数 αm_j，得到上式。
- **结论**：平滑给未出现的取值留出正概率，避免“一票否决”。$\alpha = 1$ 即拉普拉斯平滑。

> **记住**：两类平滑的分母**不同**，因为候选对象不一样——类别先验的候选是“类别”（共 K 个），故可平滑为 $(N_c + \alpha)/(N + K\alpha)$；特征取值的候选是“该维的取值”（共 m_j 个），故分母是 $N_c + \alpha m_j$。混用分母会算错。

- **连续特征**：可在每一类、每个维度用一维高斯密度建模 $p(x_j \mid c)$。注意标准差必须为正；样本不足或某维零方差时需要正则处理（例如加一个小常数），否则密度无定义或退化为冲激。

2.3.4 一点点小数值例子（离散平滑）

设某类 c 有 $N_c = 10$ 个样本，特征第 j 维有 $m_j = 3$ 种取值，其中一种取值 v 在训练集里出现 0 次。

- 不平滑：$\widehat{P}(v \mid c) = 0/10 = 0$，一旦测试样本在该维取 v，整类对数得分 $-\infty$。
- 拉普拉斯平滑（$\alpha = 1$）：$\widehat{P}(v \mid c) = (0+1)/(10 + 1 \cdot 3) = 1/13 \approx 0.0769$，该类仍有机会被选中。

2.3.5 课件完整例题：用朴素贝叶斯判断“测 1”是不是好瓜（S03 13–17 页）

这道题不是编者另造的例子，而是课件连续 5 页的课堂例题。训练集有 17 个西瓜，前 8 个为好瓜、后 9 个为坏瓜；特征包含 6 个离散属性和 2 个连续属性：

| 编号 | 色泽 | 根蒂 | 敲声 | 纹理 | 脐部 | 触感 | 密度 | 含糖率 | 好瓜 | | --- | --- | --- | --- | --- | --- | --- | --- | ---: | ---: | --- | | 1 | 青绿 | 蜷缩 | 浊响 | 清晰 | 凹陷 | 硬滑 | 0.697 | 0.460 | 是 | | 2 | 乌黑 | 蜷缩 | 沉闷 | 清晰 | 凹陷 | 硬滑 | 0.774 | 0.376 | 是 | | 3 | 乌黑 | 蜷缩 | 浊响 | 清晰 | 凹陷 | 硬滑 | 0.634 | 0.264 | 是 | | 4 | 青绿 | 蜷缩 | 沉闷 | 清晰 | 凹陷 | 硬滑 | 0.608 | 0.318 | 是 | | 5 | 浅白 | 蜷缩 | 浊响 | 清晰 | 凹陷 | 硬滑 | 0.556 | 0.215 | 是 | | 6 | 青绿 | 稍蜷 | 浊响 | 清晰 | 稍凹 | 软粘 | 0.403 | 0.237 | 是 | | 7 | 乌黑 | 稍蜷 | 浊响 | 稍糊 | 稍凹 | 软粘 | 0.481 | 0.149 | 是 | | 8 | 乌黑 | 稍蜷 | 浊响 | 清晰 | 稍凹 | 硬滑 | 0.437 | 0.211 | 是 | | 9 | 乌黑 | 稍蜷 | 沉闷 | 稍糊 | 稍凹 | 硬滑 | 0.666 | 0.091 | 否 | | 10 | 青绿 | 硬挺 | 清脆 | 清晰 | 平坦 | 软粘 | 0.243 | 0.267 | 否 | | 11 | 浅白 | 硬挺 | 清脆 | 模糊 | 平坦 | 硬滑 | 0.245 | 0.057 | 否 | | 12 | 浅白 | 蜷缩 | 浊响 | 模糊 | 平坦 | 软粘 | 0.343 | 0.099 | 否 | | 13 | 青绿 | 稍蜷 | 浊响 | 稍糊 | 凹陷 | 硬滑 | 0.639 | 0.161 | 否 | | 14 | 浅白 | 稍蜷 | 沉闷 | 稍糊 | 凹陷 | 硬滑 | 0.657 | 0.198 | 否 | | 15 | 乌黑 | 稍蜷 | 浊响 | 清晰 | 稍凹 | 软粘 | 0.360 | 0.370 | 否 | | 16 | 浅白 | 蜷缩 | 浊响 | 模糊 | 平坦 | 硬滑 | 0.593 | 0.042 | 否 | | 17 | 青绿 | 蜷缩 | 沉闷 | 稍糊 | 稍凹 | 硬滑 | 0.719 | 0.103 | 否 |

测试样本“测 1”为

$$\mathbf{x}_* = (\text{青绿}, \text{蜷缩}, \text{浊响}, \text{清晰}, \text{凹陷}, \text{硬滑}, 0.697, 0.460)^T.$$

步骤 1：估计类别先验。 课件未做平滑，直接按频数估计：

$$P(\text{是}) = \frac{8}{17} \approx 0.471, \qquad P(\text{否}) = \frac{9}{17} \approx 0.529.$$

步骤 2：估计 6 个离散属性的条件概率。 对“测 1”实际出现的属性值，课件给出的频数为：

条件概率	好瓜“是”	好瓜“否”
色泽=青绿	$3/8 = 0.375$	$3/9 = 0.333$
根蒂=蜷缩	$5/8 = 0.625$	$3/9 = 0.333$
敲声=浊响	$6/8 = 0.750$	$4/9 = 0.444$
纹理=清晰	$7/8 = 0.875$	$2/9 = 0.222$
脐部=凹陷	$6/8 = 0.750$	$2/9 = 0.222$
触感=硬滑	$6/8 = 0.750$	$6/9 = 0.667$

步骤 3：对连续属性使用类条件高斯密度。 课件用各类样本的均值和标准差估计密度，得到

$$\begin{aligned} p(0.697 \mid \text{是}) &\approx 1.959, \quad p(0.697 \mid \text{否}) \approx 1.203, \\ p(0.460 \mid \text{是}) &\approx 0.788, \quad p(0.460 \mid \text{否}) \approx 0.066. \end{aligned}$$

注意这些是**概率密度**，不是单点概率，所以 $1.959 > 1$ 并不矛盾。

步骤 4：乘上先验并比较未归一化后验。 在朴素条件独立假设下：

$$\begin{aligned} s_{\text{是}} &= 0.471 \times 0.375 \times 0.625 \times 0.750 \times 0.875 \times 0.750 \times 0.750 \times 1.959 \times 0.788 \\ &\approx 0.0629, \\ s_{\text{否}} &= 0.529 \times 0.333 \times 0.333 \times 0.444 \times 0.222 \times 0.222 \times 0.667 \times 1.203 \times 0.066 \\ &\approx 6.8 \times 10^{-5}. \end{aligned}$$

> **课件数值核算记录**：S03 17 页把第一项写成约 0.038，但把 S03 14–16 页展示的全部因子按上式直接相乘，得到约 0.0629；第二项可复现为约 6.80×10^{-5}。0.038 与 0.0629 的差异远大于显示小数的舍入误差，当前无法仅凭课件页确定第一项为何不同。本文保留课件原值并同时报告独立复算值，不将其静默改成教师答案。

无论使用课件写出的 0.038 还是按显示因子复算的 0.0629，都有 $s_{\text{是}} > s_{\text{否}}$，因此课件把“测 1”判为**好瓜**，分类结论不变。这里比较的是共同证据分母消去后的未归一化分数；若要报告真正的后验概率，还需计算

$$P(\text{是} \mid \mathbf{x}_*) = \frac{s_{\text{是}}}{s_{\text{是}} + s_{\text{否}}}.$$

> **限制与误区**：本题直接使用频数，没有对未见取值做拉普拉斯平滑；一旦某个条件频数为 0，整类乘积会变成 0。另一个风险是 8 个属性未必真的条件独立，所以“朴素”是建模近似，不是数据事实。半朴素贝叶斯在 S03 1 页只被提及，课件没有展开其结构学习，本文不据标题补造考核内容。

2.4 高斯分类器：为什么边界有时是直线

2.4.1 为什么这样想：用“椭圆等高线”看图

每个类用一个高斯分布建模。若两类形状（协方差）相同，它们的概率等高线是**同向的椭圆**；比较两类后验时，二次项会相互抵消，只剩下 $\mathbf{x}$ 的一次项——决策边界就成了直线（超平面）。若两类形状不同，二次项消不掉，边界就是曲线（二次曲面）。下面把这件事严格推出来。

2.4.2 高斯密度与对数判别函数

符号与维度：设 $\mathbf{x} \in \mathbb{R}^d$（列向量），$d$ 维特征。类 c 的均值为 $\boldsymbol{\mu}_c \in \mathbb{R}^d$，协方差为 $\Sigma_c \in \mathbb{R}^{d \times d}$。我们假定 Σ_c **正定**（不是仅半正定）：

- 正定保证 Σ_c^{-1} 存在（可逆），$\det \Sigma_c > 0$（分母有意义），且全维高斯密度定义良好；
- “协方差必为半正定”是任何协方差矩阵的通性，但“可逆性”来自这里更强的正定假设，二者不可混为一谈（见 2.4.5 末的提醒）。

类条件密度（多元高斯）：

$$p(\mathbf{x} \mid c) = \frac{\exp\left[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_c)^T \Sigma_c^{-1} (\mathbf{x} - \boldsymbol{\mu}_c)\right]}{(2\pi)^{d/2} |\Sigma_c|^{1/2}}.$$

过程讲解（写出对数判别函数）

- **起点**：代入 2.2.3 的 $g_c(\mathbf{x}) = \log p(\mathbf{x} \mid c) + \log P(c)$。
- **步骤**：对密度取对数（注意 $\log \exp(\cdot)$ 抵消指数，$\log$ 把除法变减法）：

$$\begin{aligned} g_c(\mathbf{x}) &= \log p(\mathbf{x} \mid c) + \log P(c) \\ &= -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_c)^T \Sigma_c^{-1} (\mathbf{x} - \boldsymbol{\mu}_c) - \frac{d}{2}\log(2\pi) - \frac{1}{2}\log|\Sigma_c| + \log P(c). \end{aligned}$$

- **化简**：对所有类比较时，$-\frac{d}{2}\log(2\pi)$ 是公共常数，可暂略（属于“对所有类相同的项”），得到

$$g_c = -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_c)^T \Sigma_c^{-1} (\mathbf{x} - \boldsymbol{\mu}_c) - \frac{1}{2}\log|\Sigma_c| + \log P(c).$$

- **结论**：判别函数由“按协方差缩放的二次距离”加“协方差行列式项”加“先验对数”组成。

2.4.3 共同协方差下二次项如何抵消（得到线性）

过程讲解（二次型展开）

- **假设**：两类共享同一正定协方差 $\Sigma_c = \Sigma$（即 $\Sigma_1 = \Sigma_2 = \Sigma$）。
- **起点**：展开 $(\mathbf{x} - \boldsymbol{\mu}_c)^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_c)$。利用 Σ^{-1} 对称（故 $\mathbf{x}^T \Sigma^{-1} \boldsymbol{\mu}_c = \boldsymbol{\mu}_c^T \Sigma^{-1} \mathbf{x}$，二者都是标量、互为转置相等）：

$$\begin{aligned}(\mathbf{x} - \boldsymbol{\mu}_c)^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_c) &= (\mathbf{x}^T - \boldsymbol{\mu}_c^T) \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_c) \\ &= \mathbf{x}^T \Sigma^{-1} \mathbf{x} - \mathbf{x}^T \Sigma^{-1} \boldsymbol{\mu}_c - \boldsymbol{\mu}_c^T \Sigma^{-1} \mathbf{x} + \boldsymbol{\mu}_c^T \Sigma^{-1} \boldsymbol{\mu}_c \\ &= \mathbf{x}^T \Sigma^{-1} \mathbf{x} - 2 \boldsymbol{\mu}_c^T \Sigma^{-1} \mathbf{x} + \boldsymbol{\mu}_c^T \Sigma^{-1} \boldsymbol{\mu}_c .\end{aligned}$$

- **步骤**：代回 g_c 并略去公共项 $-\frac{1}{2}\mathbf{x}^T \Sigma^{-1} \mathbf{x}$（对所有类相同）和 $-\frac{1}{2}\log|\Sigma|$ 与 $-\frac{d}{2}\log(2\pi)$：

$$g_c = -\frac{1}{2}\mathbf{x}^T \Sigma^{-1} \mathbf{x} + \boldsymbol{\mu}_c^T \Sigma^{-1} \mathbf{x} - \frac{1}{2}\boldsymbol{\mu}_c^T \Sigma^{-1} \boldsymbol{\mu}_c + \log P(c).$$

- **结论**：保留下来的部分关于 $\mathbf{x}$ 是**一次（线性）**的（$-\frac{1}{2}\mathbf{x}^T \Sigma^{-1} \mathbf{x}$ 被抵消掉了）。因此两类比较时边界是直线。

2.4.4 边界 $\mathbf{w}$ 与 b 的逐步推导

这是本章重点，务必亲手推一遍。

过程讲解（由 $g_1 - g_2 = 0$ 得到 $\mathbf{w}, b$）

- **符号与假设**：二分类，$c \in \{1, 2\}$，共享正定协方差 Σ。记 $P(1), P(2)$ 为类先验，$\boldsymbol{\mu}_1, \boldsymbol{\mu}_2 \in \mathbb{R}^d$。
- **起点**：边界是使两类得分相等的点集：$g_1(\mathbf{x}) = g_2(\mathbf{x})$，即 $g_1 - g_2 = 0$。
- **步骤 1（写出差值）**：用 2.4.3 中化简后的 g_c，公共项 $-\frac{1}{2}\mathbf{x}^T \Sigma^{-1} \mathbf{x}$ 与 $-\frac{1}{2}\log|\Sigma|$ 相减时抵消：

$$\begin{aligned}g_1 - g_2 = &\left[\boldsymbol{\mu}_1^T \Sigma^{-1} \mathbf{x} - \tfrac{1}{2}\boldsymbol{\mu}_1^T \Sigma^{-1} \boldsymbol{\mu}_1 + \log P(1)\right] \\ &- \left[\boldsymbol{\mu}_2^T \Sigma^{-1} \mathbf{x} - \tfrac{1}{2}\boldsymbol{\mu}_2^T \Sigma^{-1} \boldsymbol{\mu}_2 + \log P(2)\right] \\ = &\,(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^T \Sigma^{-1} \mathbf{x} - \frac{1}{2}\left(\boldsymbol{\mu}_1^T \Sigma^{-1} \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2^T \Sigma^{-1} \boldsymbol{\mu}_2\right) + \log \frac{P(1)}{P(2)}.\end{aligned}$$

- **步骤 2（认出线性形式）**：因为 Σ^{-1} 对称，$(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^T \Sigma^{-1} \mathbf{x} = \left(\Sigma^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)\right)^T \mathbf{x}$。令

$$\mathbf{w} = \Sigma^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) \in \mathbb{R}^d, \qquad b = -\frac{1}{2}\left(\boldsymbol{\mu}_1^T \Sigma^{-1} \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2^T \Sigma^{-1} \boldsymbol{\mu}_2\right) + \log \frac{P(1)}{P(2)} \in \mathbb{R}.$$

  则 $g_1 - g_2 = \mathbf{w}^T \mathbf{x} + b$。
- **步骤 3（边界方程）**：令 $g_1 - g_2 = 0$，得决策边界

$$\mathbf{w}^T \mathbf{x} + b = 0,$$

  即一个超平面（一维时是点，二维时是直线）。
- **结论**：
  - 权重 $\mathbf{w} = \Sigma^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)$ 指向“两类均值差、并按共享协方差逆缩放”的方向；
  - 偏置 b 由两类的“按协方差加权的均值自相似度之差”和先验比共同决定。
- **成立条件**：共享协方差且正定（保证 Σ^{-1} 存在）；二分类设定。多类时可用“一对多”或“一对一”比较，或写成多类线性判别。

2.4.5 特例与边界情形

- **球形协方差 $\Sigma = \sigma^2 I$ 且先验相等**：$\mathbf{w} = (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)/\sigma^2$（方向就是均值差方向），边界是两类均值连线的中垂面，判别等价于比较**欧氏距离**。
- **共同但非球形协方差**：$\mathbf{w} = \Sigma^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)$，对应**马氏距离**（按协方差形状“压扁/旋转”后的距离）。
- **各类协方差不同**：二次项 $-\frac{1}{2}\mathbf{x}^T\Sigma_c^{-1}\mathbf{x}$ 对两类不同，**无法抵消**，通常得到二次边界（二次判别分析 QDA）。但也可能出现特殊退化情形（例如两类协方差虽不同却在该方向上投影相同），这时边界仍可能局部呈线性——不能想当然认为“协方差不同就一定是曲线”。
- **可逆性提醒**：我们说“协方差必为半正定”永远成立（协方差矩阵的通性）；但高斯判别要能写出 Σ^{-1}，需要的是**正定**（或更一般可逆）。低维流形上的退化高斯（奇异协方差）需另行处理，不能直接套本节公式。

2.4.6 自编一维例：先验如何移动边界

一维情形：$d = 1$，$\Sigma = \sigma^2 = 1$，两类均值 $\mu_1 = 0$，$\mu_2 = 2$。判别函数

$$g_c = -\frac{1}{2}\frac{(x-\mu_c)^2}{\sigma^2} + \log P(c) = -\frac{1}{2}(x-\mu_c)^2 + \log P(c).$$

等先验 $P(1) = P(2) = 0.5$：两者对数先验抵消，边界由 $g_1 = g_2$ 给出，即 $(x-0)^2 = (x-2)^2 \Rightarrow x = 1$。边界恰在两点中点。

不等先验 $P(1) = 0.8,\ P(2) = 0.2$：

过程讲解

- **起点**：计算差值

$$\begin{aligned} g_1 - g_2 &= -\frac{1}{2}x^2 + \log 0.8 - \Big[-\frac{1}{2}(x-2)^2 + \log 0.2\Big] \\ &= -\frac{1}{2}x^2 + \frac{1}{2}(x^2 - 4x + 4) + \log\frac{0.8}{0.2} \\ &= -2x + 2 + \log 4. \end{aligned}$$

  （其中 $\log 4 \approx 1.386294$。）

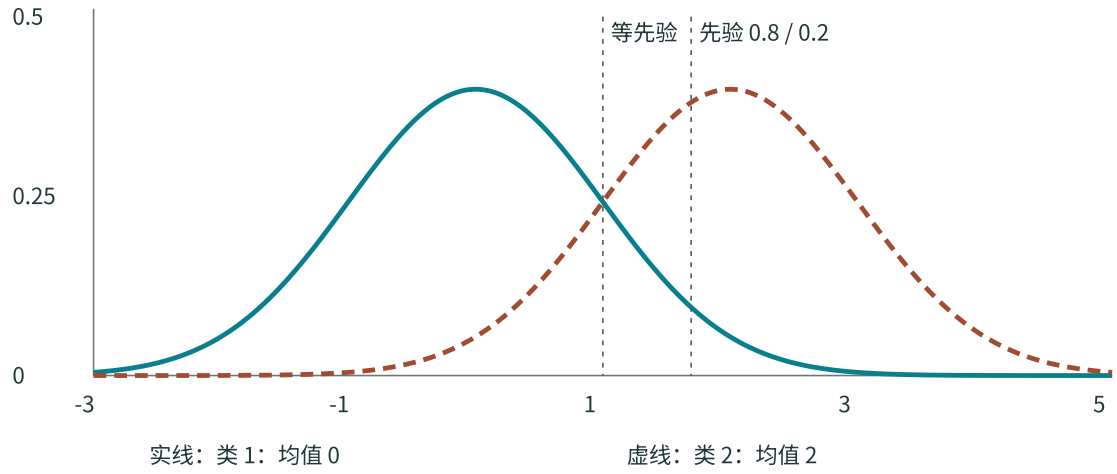
- **步骤**：令 $g_1 - g_2 = 0$：

$$-2x + 2 + \log 4 = 0 \quad \Rightarrow \quad x = \frac{2 + \log 4}{2} = 1 + \frac{\log 4}{2} \approx 1.693147.$$

- **结论**：边界从 1 移到约 1.693。先验更偏向第一类（$P(1) = 0.8$）使**第一类的决策区域扩大**——即使样本离均值 0 更远，只要超过 1.693 才判为第二类。

> **观察**：上图显示先验变化只移动边界，却**没有改变两条条件密度曲线的形状**。这再次印证：证据（密度形状）是客观的，先验只是平移了你的判定门槛。

共同方差高斯：横轴 x，纵轴为条件概率密度



2.4.7 二维抛物线边界核对（S03 30 页）

S03 30 页原例：$\boldsymbol{\mu}_1=(3,6)^T$、$\Sigma_1=\mathrm{diag}(1/2,2)$，$\boldsymbol{\mu}_2=(3,-2)^T$、$\Sigma_2=\mathrm{diag}(2,2)$，等先验。

过程讲解（核对抛物线常数）

- **起点**：类 1 协方差 $\Sigma_1=\mathrm{diag}(1/2,2)$，其逆 $\Sigma_1^{-1}=\mathrm{diag}(2,1/2)$，行列式 $|\Sigma_1|=1$，故 $-\frac{1}{2}\log|\Sigma_1|=0$；类 2 协方差 $\Sigma_2=\mathrm{diag}(2,2)$，逆 $\Sigma_2^{-1}=\mathrm{diag}(1/2,1/2)$，行列式 $|\Sigma_2|=4$，故 $-\frac{1}{2}\log|\Sigma_2|=-\log 2$。等先验使 $\log P(c)$ 抵消。
- **步骤**：写出 g_1-g_2（只保留与 $\mathbf{x}$ 有关和常数项）：

$$g_1=-\frac{1}{2}\Big[2(x_1-3)^2+\tfrac{1}{2}(x_2-6)^2\Big],$$
$$g_2=-\frac{1}{2}\Big[\tfrac{1}{2}(x_1-3)^2+\tfrac{1}{2}(x_2+2)^2\Big]-\log 2.$$

  相减（注意 g_1-g_2 中 $-g_2$ 会把 $-\log 2$ 变成 $+\log 2$）：

$$g_1-g_2=-0.75(x_1-3)^2-\tfrac{1}{4}(x_2-6)^2+\tfrac{1}{4}(x_2+2)^2+\log 2.$$

  展开 x_2 项：

$$-\tfrac{1}{4}(x_2^2-12x_2+36)+\tfrac{1}{4}(x_2^2+4x_2+4)=4x_2-8.$$

  于是

$$g_1-g_2=-0.75(x_1-3)^2+4x_2-8+\log 2.$$

- **步骤（解出边界）**：令 $g_1-g_2=0$，得

$$4x_2=0.75(x_1-3)^2+8-\log 2\quad\Rightarrow\quad x_2=0.1875(x_1-3)^2+2-\frac{\log 2}{4}.$$

  展开 $(x_1-3)^2=x_1^2-6x_1+9$：

$$x_2=0.1875x_1^2-1.125x_1+1.6875+2-\frac{\log 2}{4}\approx 3.514213-1.125x_1+0.1875x_1^2.$$

- **结论**：与课件一致，独立核对了抛物线常数 ≈ 3.514213。

> 目录中的课堂板书照片 `2f830756d2f83a2ea6c09f6878b20e33.jpg` 已单独查看：它通过协方差的对称性把两个交叉项合并，再相减消去共同二次项，得到相同法向量。这里应区分“协方差必为半正定”和“此全维高斯密度假设协方差正定”；可逆性来自后者，而不是所有协方差天然可逆。

2.5 极大似然估计

2.5.1 为什么这样想：从“模型已知”到“模型要学”

前面分类都假设概率模型已知。现实中均值、方差、硬币正面概率都要从数据里估。极大似然（MLE）的哲学很直白：**选那个让“已观测到的数据”最不意外的参数**——即最大化观测数据的似然。

2.5.2 硬币模型（二项 MLE）

符号与假设：抛硬币 N 次，第 i 次结果 $x_i \in \{0,1\}$（$1=$ 正面）。未知正面概率 $\theta \in [0,1]$。观测到 n_1 次正面、n_0 次反面，且 $N = n_1 + n_0$。样本独立同分布。

过程讲解（有序序列的似然）

- **起点**：对每个样本，$P(x_i \mid \theta) = \theta^{x_i}(1-\theta)^{1-x_i}$。独立样本联合概率为乘积：

$$L(\theta) = \prod_{i=1}^{N} \theta^{x_i}(1-\theta)^{1-x_i} = \theta^{n_1}(1-\theta)^{n_0}.$$

- **步骤（取对数，化乘为加）**：

$$\ell(\theta) = \log L(\theta) = n_1 \log\theta + n_0 \log(1-\theta).$$

- **步骤（求导并置零，假设两种结果都出现，即 $n_1 > 0, n_0 > 0$）**：

$$\frac{d\ell}{d\theta} = \frac{n_1}{\theta} - \frac{n_0}{1-\theta} = 0.$$

  两边乘 $\theta(1-\theta)$（正数，不改变零点）：

$$n_1(1-\theta) - n_0\theta = 0 \;\Rightarrow\; n_1 - n_1\theta - n_0\theta = 0 \;\Rightarrow\; n_1 = (n_1+n_0)\theta = N\theta.$$

  故

$$\hat{\theta}_{ML} = \frac{n_1}{N}.$$

- **步骤（验证是极大值）**：二阶导

$$\frac{d^2\ell}{d\theta^2} = -\frac{n_1}{\theta^2} - \frac{n_0}{(1-\theta)^2} < 0 \quad (\text{当 } n_1, n_0 > 0),$$

  故驻点为极大值。

- **结论**：MLE 就是“正面频率”。
- **边界情形（务必说明）**：若**全是正面**（$n_0 = 0$）或**全是反面**（$n_1 = 0$），上面“两边乘 $\theta(1-\theta)$”的步骤会使某一项消失，内部驻点法失效。此时 $\ell(\theta) = n_1 \log\theta$ 在 $(0,1)$ 上单调递增，最大值在**端点** $\hat{\theta}_{ML} = 1$（全正面）或 0（全反面）。**不能机械使用内部导数得到的 n_1/N 公式**——虽然这里它“恰好”给出 1 或 0，但推导逻辑在端点处不成立，必须单独说明。

> **只记录次数 vs 有序序列**：若只记录“正面次数” n_1 而不记录顺序，似然还要乘组合数 $\binom{N}{n_1}$；但该组合数是与 θ 无关的常数，求导时消失，**不改变 MLE**。S03 44 页的 $n_1=15, n_0=10$ 给出 $\hat{\theta}_{ML}=15/25=0.6$。

2.5.3 一维高斯 MLE：均值与方差

符号与假设：一维高斯样本 $x_1,\dots,x_N \overset{\text{i.i.d.}}{\sim} N(\mu,\sigma^2)$，未知 $\mu\in\mathbb{R}$、$\sigma^2>0$。样本均值记为 $\bar{x}=\frac{1}{N}\sum_i x_i$。

过程讲解（对 μ 求导）

- **起点**：对数似然

$$\ell(\mu,\sigma^2)=-\frac{N}{2}\log(2\pi\sigma^2)-\frac{1}{2\sigma^2}\sum_{i=1}^{N}(x_i-\mu)^2.$$

- **步骤**：对 μ 求偏导（视 σ^2 暂固定）：

$$\frac{\partial\ell}{\partial\mu}=\frac{1}{\sigma^2}\sum_i(x_i-\mu)=\frac{1}{\sigma^2}(N\bar{x}-N\mu)=0\ \Rightarrow\ \widehat{\mu}=\bar{x}.$$

- **结论**：均值 MLE 就是样本均值。

过程讲解（对 σ^2 求导，记 $v=\sigma^2$）

- **起点**：把 ℓ 写成 v 的函数：

$$\ell(v)=-\frac{N}{2}\log(2\pi v)-\frac{1}{2v}\sum_i(x_i-\mu)^2.$$

- **步骤**：对 v 求导（用 $\frac{d}{dv}\log v=1/v$，$\frac{d}{dv}(1/v)=-1/v^2$）：

$$\frac{d\ell}{dv}=-\frac{N}{2v}+\frac{1}{2v^2}\sum_i(x_i-\mu)^2=0.$$

  两边乘 $2v^2$：

$$-Nv+\sum_i(x_i-\mu)^2=0\ \Rightarrow\ \widehat{v}=\frac{1}{N}\sum_i(x_i-\mu)^2.$$

- **代入 $\widehat{\mu}=\bar{x}$**：

$$\widehat{\sigma}^2_{ML}=\frac{1}{N}\sum_i(x_i-\bar{x})^2.$$

2.5.4 为什么方差 MLE 的分母是 N 而不是 $N-1$（小数值例）

过程讲解（偏差来源）

- **起点**：方差 MLE 用样本均值 $\bar{x}$ 代替了真均值 μ。因为 $\bar{x}$ 本身是使平方和最小的点，用它算的平方和**偏小**：

$$\sum_i(x_i-\bar{x})^2\le\sum_i(x_i-\mu)^2\quad(\text{对任意 }\mu).$$

- **结论**：因此 $E[\widehat{\sigma}^2_{ML}]=\frac{N-1}{N}\sigma^2\neq\sigma^2$，即 MLE 方差是**有偏**的（低估），偏差为 $-\sigma^2/N$。
- **两种情形要区分**：

  1. **均值未知、由样本估计**：无偏样本方差用分母 $N-1$：

$$s^2 = \frac{1}{N-1}\sum_i (x_i - \bar{x})^2, \qquad E[s^2] = \sigma^2.$$

2. **均值已知**（用真值 μ 而非 $\bar{x}$）：则 $\frac{1}{N}\sum_i (x_i-\mu)^2$ 的期望正好是 σ^2，此时 MLE **无偏**。

> **小数值例子**：数据 $\{2,4,6\}$，$N=3$，$\bar{x}=4$，$\sum(x_i-\bar{x})^2 = (2-4)^2+(4-4)^2+(6-4)^2 = 4+0+4 = 8$。
>
> - 方差 MLE（分母 N）：$\widehat{\sigma}^2 = 8/3 \approx 2.667$;
> - 无偏估计（分母 $N-1$）：$s^2 = 8/2 = 4$。 二者不同，且 N 越小差距越显著。记住：**MLE 追求“在数据下最可能”，不保证“无偏”。**

2.6 完整后验、MAP 与后验预测

2.6.1 为什么这样想：一个点估计不够

MLE 只给一个数值（如 15/25），但少量数据时它**不能表示不确定程度**——25 次里 15 次正面，和 2500 次里 1500 次正面，频率都是 0.6，可信度却天差地别。贝叶斯方法不直接估计一个点，而是估计**参数的完整后验分布** $p(\theta \mid D)$，再用它做决策或预测。

2.6.2 Beta–二项共轭

符号与假设：硬币正面概率 $\theta \in (0,1)$ 未知，给一个 $\mathrm{Beta}(a,b)$ 先验，$a,b>0$ 是预先设定的超参数（不来自数据）。Beta 密度为

$$p(\theta) = \frac{\theta^{a-1}(1-\theta)^{b-1}}{B(a,b)}, \quad 0<\theta<1,$$

其中 $B(a,b) = \int_0^1 t^{a-1}(1-t)^{b-1}dt$ 是 Beta 函数（仅作归一化常数）。观测数据 D 给出 n_1 次正面、n_0 次反面。

过程讲解（共轭：后验仍属 Beta 族）

- **起点**：后验正比于“似然 × 先验”（分母证据与 θ 无关，写作 $\propto$）：

$$p(\theta \mid D) \propto p(D \mid \theta)\, p(\theta) = \theta^{n_1}(1-\theta)^{n_0} \cdot \frac{\theta^{a-1}(1-\theta)^{b-1}}{B(a,b)}.$$

- **步骤**：合并 θ 与 $(1-\theta)$ 的指数（常数项 $1/B(a,b)$ 吸收进 $\propto$）：

$$p(\theta \mid D) \propto \theta^{a+n_1-1}(1-\theta)^{b+n_0-1}.$$

- **结论**：这正好是一个 Beta 分布的形式，故

$$\theta \mid D \sim \mathrm{Beta}(a+n_1,\ b+n_0).$$

- **定义**：这种“先验与后验属于同一分布族”的性质叫**共轭（conjugacy）**。这里 Beta 是二项似然的**共轭先验**。直观上，先验的两个参数 (a,b) 可理解为“先验里已见到的伪正面/反面次数”。

> **记住**：后验参数增加的正是“观测到的次数” n_1, n_0，而不是比例。所以“Beta 后验参数为何增加的是次数”——因为似然 $\theta^{n_1}(1-\theta)^{n_0}$ 的指数直接加上了 n_1, n_0。

2.6.3 MAP：取后验众数

MAP（最大后验）选后验密度的**众数**（最高点）。

过程讲解

- **符号**：记 $A = a + n_1$，$B = b + n_0$（后验的两个参数，均 > 0）。
- **起点**：后验密度 $\propto \theta^{A-1}(1-\theta)^{B-1}$，对数后验（忽略与 θ 无关的常数）为

$$\log p(\theta \mid D) \propto (A-1)\log\theta + (B-1)\log(1-\theta).$$

- **步骤（对内部众数求导，假设 $A > 1$ 且 $B > 1$，使众数在开区间 $(0,1)$ 内）**：

$$\frac{d}{d\theta}\log p = \frac{A-1}{\theta} - \frac{B-1}{1-\theta} = 0.$$

两边乘 $\theta(1-\theta)$：

$$(A-1)(1-\theta) - (B-1)\theta = 0 \;\Rightarrow\; A - 1 - (A+B-2)\theta = 0.$$

故

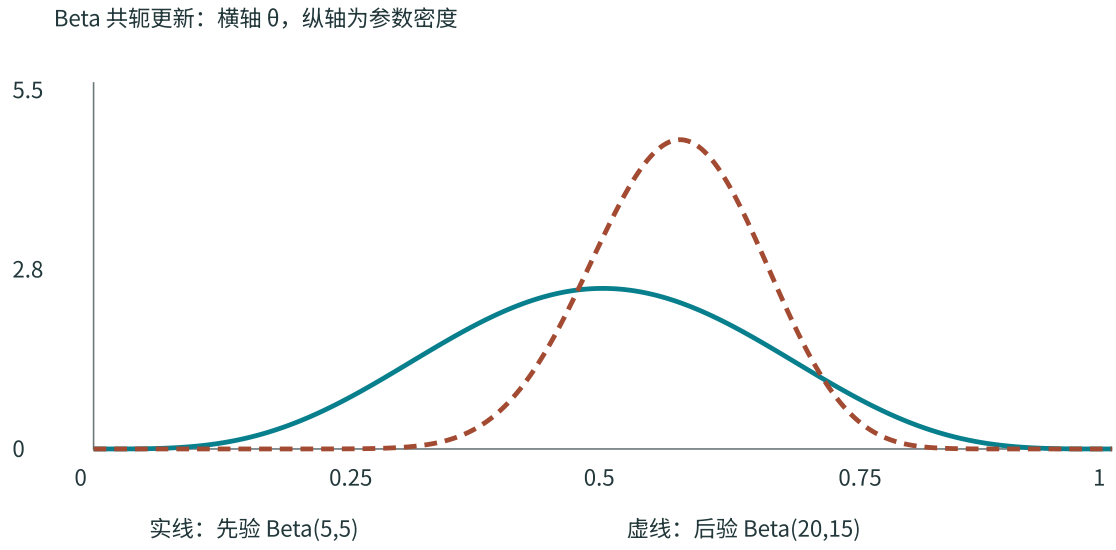
$$\hat{\theta}_{MAP} = \frac{A-1}{A+B-2}.$$

- **结论与边界情形**：当 $A > 1, B > 1$ 时众数为上式。若 $A \le 1$ 或 $B \le 1$，众数可能位于边界、双边界或不唯一（例如 $a = b = 0.5$ 的 Jeffreys 先验在两端有尖峰），**不能直接套内部众数公式**，须单独分析端点。

数值核对（S03 50 页）：取 $a = b = 5$，观测 $n_1 = 15, n_0 = 10$，则后验 $\mathrm{Beta}(A, B) = \mathrm{Beta}(20, 15)$。MAP 为

$$\hat{\theta}_{MAP} = \frac{20-1}{20+15-2} = \frac{19}{33} \approx 0.575758.$$

> 完整后验保留不确定性（一个分布），MAP 只保留一个位置（众数）。看下图：本例后验相比先验 $\mathrm{Beta}(5,5)$ 向观测成功频率移动，并且更集中（数据越多越窄）。



2.6.4 后验预测：预测下一次结果

过程讲解（对未知参数积分，而非只取一个点）

- **起点**：预测“下一次还是正面”的概率，要对未知参数 θ 积分（因为 θ 本身不确定）：

$$P(x_{\text{new}}=1 \mid D)=\int_0^1 P(x_{\text{new}}=1 \mid \theta)\, p(\theta \mid D)\, d\theta=\int_0^1 \theta\, p(\theta \mid D)\, d\theta.$$

- **步骤**：右边正是后验均值 $E[\theta \mid D]$。对 $\mathrm{Beta}(A,B)$，均值为 $A/(A+B)$：

$$P(x_{\text{new}}=1 \mid D)=\frac{A}{A+B}.$$

- **结论**：后验预测 = **后验均值**，一般**不同于** MAP（众数是最高点，均值是重心，二者只在对称时重合）。
- **数值核对**：沿用上例 $A=20, B=15$：

$$P(x_{\text{new}}=1 \mid D)=\frac{20}{20+15}=\frac{20}{35}\approx 0.571429.$$

注意 $20/35\approx 0.5714$ 与 MAP 的 $19/33\approx 0.5758$ 并不相等——这正是“用分布预测”与“用众数点估计”的区别。

2.6.5 高斯均值 MAP：精度加权平均

符号与假设：一维观测 $x_1,\dots,x_N \overset{\text{i.i.d.}}{\sim} N(\mu,\sigma^2)$，$\sigma^2>0$ **已知**。对均值 μ 给高斯先验 $\mu\sim N(\mu_0,\tau^2)$，$\tau^2>0$ 已知（先验方差）。

过程讲解（负对数后验最小化）

- **起点**：后验正比于“似然 × 先验”。取负对数并略去与 μ 无关的常数：

$$-\log p(\mu \mid D)\propto \frac{1}{2\sigma^2}\sum_{i=1}^{N}(x_i-\mu)^2+\frac{1}{2\tau^2}(\mu-\mu_0)^2.$$

- **步骤（对 μ 求导并置零）**：

$$\frac{d}{d\mu}\Big[\cdots\Big]=-\frac{1}{\sigma^2}\sum_i(x_i-\mu)+\frac{\mu-\mu_0}{\tau^2}=0.$$

注意 $\sum_i(x_i-\mu)=N\bar{x}-N\mu=N(\bar{x}-\mu)$，代入得

$$-\frac{N(\bar{x}-\mu)}{\sigma^2}+\frac{\mu-\mu_0}{\tau^2}=0\ \Rightarrow\ \frac{N}{\sigma^2}(\mu-\bar{x})+\frac{\mu-\mu_0}{\tau^2}=0.$$

整理（把含 μ 的项移到一边）：

$$\Big(\frac{N}{\sigma^2}+\frac{1}{\tau^2}\Big)\mu=\frac{N\bar{x}}{\sigma^2}+\frac{\mu_0}{\tau^2}.$$

- **结论（精度加权）**：

$$\widehat{\mu}_{MAP}=\frac{\dfrac{N}{\sigma^2}\,\bar{x}+\dfrac{1}{\tau^2}\,\mu_0}{\dfrac{N}{\sigma^2}+\dfrac{1}{\tau^2}}.$$

其中 N/σ^2 是**数据精度**（样本量除以观测方差），$1/\tau^2$ 是**先验精度**。MAP 是“观测样本均值 $\bar{x}$”与“先验均值 μ_0”按精度加权的折中：

  - 样本量增加（$N\to\infty$）：数据精度主导，$\widehat{\mu}_{MAP}\to\bar{x}$（趋近 MLE）；
  - 先验很模糊（$\tau^2\to\infty$，先验精度 $\to 0$）：先验权重消失，$\widehat{\mu}_{MAP}\to\bar{x}$（趋近 MLE）；
  - 观测极精确（$\sigma^2\to 0$）：数据精度 $\to\infty$，同样趋近 $\bar{x}$。

小数值例：设 $\bar{x}=5$，$N=10$，$\sigma^2=4$（数据精度 $10/4=2.5$）；先验 $\mu_0=0$，$\tau^2=1$（先验精度 1）。则

$$>\widehat{\mu}_{MAP}=\frac{2.5\times 5+1\times 0}{2.5+1}=\frac{12.5}{3.5}\approx 3.571.>$$

它介于先验均值 0 与样本均值 5 之间，更靠近样本均值（因为数据精度更大）。若把 N 增到 100，则 $\frac{25\times 5}{25+1}\approx 4.807$，明显更靠近 5。

2.7 本章常见混淆

类别后验 $P(c\mid \mathbf{x})$ 用于**分类**；参数后验 $p(\theta\mid D)$ 表示**未知参数的不确定性**。两者都套贝叶斯公式，但未知对象不同（一个是类别，一个是参数）。

三者层次不同，不要混为一谈：

- **朴素贝叶斯**是一种**生成式模型/条件独立假设**，用来建模 $p(\mathbf{x}\mid c)$；
- **MLE** 是一种**估计准则**（最大化似然），给出点估计；
- **MAP** 是另一种**估计准则**（最大化后验密度），也给出点估计，但引入先验。

它们不是“同一层的三个分类器”。例如你完全可以在朴素贝叶斯的框架里用 MLE 或 MAP 去估计那些一维条件密度 $p(x_j\mid c)$——模型假设和参数估计准则是两件事。

常见误区速查

1. 似然 $p(\mathbf{x}\mid c)$ 不是概率分布（对类别/参数不归一）；后验才是。
2. 删证据只因它对所有类相同；某类独有常数不能删。
3. 协方差“半正定”通用，“正定可逆”是额外假设。
4. 全正面时硬币 MLE 在端点，内部导数法失效。
5. 高斯方差 MLE 分母用 N（有偏），无偏用 $N-1$；均值已知时 N 也无偏。
6. Beta 后验增加的是“次数”不是“比例”；MAP 是众数，后验预测是均值，二者一般不同。

复习问题：为何对数判别可以删除证据？为什么共同协方差会消去二次项？Beta 后验参数为何增加的是次数？能回答这三问，再做练习。

2.8 从本章到后续章节：贝叶斯视角的延伸

本章建立的“先验—似然—后验—证据”四件套会贯穿全书，属于学习指南里的**概率主线**。几个衔接点先记下来，读到对应章节时自然呼应：

- **回归中的噪声假设**（后续线性回归章）：把“观测 = 真值 + 高斯噪声”写成似然，最大似然就推出最小二乘；这就把本章 2.5 的高斯 MLE 直接接上了。
- **概率图模型**：朴素贝叶斯的“条件独立”正是概率图里最常见的一类结构（一个类别父节点指向所有特征）。
- **模型评价**（第三章）：用似然/后验可以定义训练与测试的表现，而“证据”在模型比较（边际似然）里正是关键角色。
- **熵与信息**（第八章）：Beta/高斯后验的“集中度”可用熵来量化不确定性，与本章“后验比点估计更完整地表达不确定”的动机一致。

一句话收尾：**贝叶斯学习不是又一种分类器，而是一套“用数据更新信念”的通用语言**；本章的公式推导，是后面所有概率方法的语法基础。

第三章 线性分类：几何、统计与概率的三个入口

> **课件主线**：S05 6–41 页讲基础知识与模型评价，42–48 页讲线性分类与多分类；S06 4–27 页讲感知机（含两个课堂例题），30–43 页讲 Fisher，46–60 页讲 Logistic。正文按这一顺序保留课件概念和例题；本章统一使用列向量，b 对应课件的 w_0，补足推导与反例均标为编者解释。

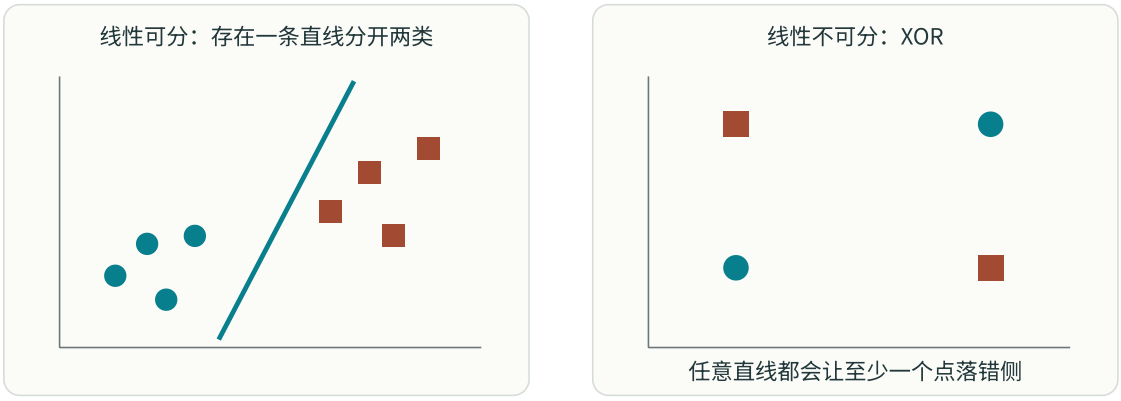
> **本章学习路线（编者提示）** 本章用三条互补的视角看同一个问题——如何把两类（或多类）样本用“平面”分开：
>
> 1. **几何视角**（3.1–3.2）：样本是空间中的点，分类面是一张超平面；我们用“有符号距离”衡量点离分界面的远近。
> 2. **统计/评价视角**（3.3）：分完后怎么算“分得好不好”。
> 3. **三个学习算法**（3.4–3.6）：感知机（错了就修正）、Fisher（投影后类间远类内紧）、Logistic（把分数变成概率）。
> 4. **横向对比与数值演练**（3.7–3.9）：把三者放在一起，再用小数据手算一遍。

符号严格遵循 `docs/guide.md`：特征 $\mathbf{x} \in \mathbb{R}^d$ 为**列向量**；设计矩阵 X 按**行**放样本（$N \times d$）；$\log$ 默认自然对数。

3.1 从特征到超平面

直觉 在二维平面上，分开两类点通常画一条直线；在三维空间里是一张平面；在 d 维空间里就是一张“超平面”。我们需要一个能同时描述“点在分界面的哪一侧”和“点离分界面多远”的数学工具。

线性可分与线性不可分的几何区别



3.1.1 线性打分函数

把第 i 个样本的特征写成列向量 $\mathbf{x}_i \in \mathbb{R}^d$。定义线性打分函数

$$g(\mathbf{x}) = \mathbf{w}^T\mathbf{x} + b.$$

- $\mathbf{w} \in \mathbb{R}^d$ 是**权重（法向量）**，也是列向量；
- $b \in \mathbb{R}$ 是**偏置**；
- 对给定的 $\mathbf{x}$，$g(\mathbf{x})$ 是一个实数（标量）。

当 $\mathbf{w} \neq \mathbf{0}$ 时，方程 $g(\mathbf{x}) = 0$（即 $\mathbf{w}^T\mathbf{x} + b = 0$）的解集就是一张超平面 $\mathcal{H}$。**分类规则**是看分数的正负：

- 若 $g(\mathbf{x}) > 0$，判为正侧；若 $g(\mathbf{x}) < 0$，判为负侧；
- 分数本身**不是概率**，只是一个“带符号的严重程度”。

3.1.2 为什么 $\mathbf{w}$ 垂直于整个平面（过程讲解）

> **假设与符号**：设 $\mathbf{u}, \mathbf{v} \in \mathcal{H}$ 是任意两个落在平面上的点，即 $g(\mathbf{u}) = 0$ 且 $g(\mathbf{v}) = 0$。 **维度**：$\mathbf{u}, \mathbf{v}, \mathbf{w} \in \mathbb{R}^d$；$\mathbf{u} - \mathbf{v} \in \mathbb{R}^d$ 表示平面内的一条方向向量。

步骤 1 | 写出两点满足的方程

$$\mathbf{w}^T\mathbf{u} + b = 0, \qquad \mathbf{w}^T\mathbf{v} + b = 0.$$

步骤 2 | 两式相减，消去偏置 b

$$\mathbf{w}^T\mathbf{u} - \mathbf{w}^T\mathbf{v} = 0 \implies \mathbf{w}^T(\mathbf{u} - \mathbf{v}) = 0.$$

步骤 3 | 解释 $\mathbf{u} - \mathbf{v}$ 是平面上任意一条方向向量（因为 $\mathbf{u}, \mathbf{v}$ 都可在平面内任取）。它与 $\mathbf{w}$ 的内积为 0，说明 $\mathbf{w}$ 与平面内**每一条**方向都正交。

结论：$\mathbf{w}$ 是超平面 $\mathcal{H}$ 的**法向量**（垂直于平面）。这与二维里直线 $ax + by + c = 0$ 的法向量是 (a, b) 完全一致。

3.1.3 有符号距离 $r = \dfrac{\mathbf{w}^T\mathbf{x} + b}{\|\mathbf{w}\|}$ 的几何推导（核心）

> **假设与符号**
>
> - $\mathbf{w} \neq \mathbf{0}$，超平面 $\mathcal{H} = \{\mathbf{x} \mid \mathbf{w}^T\mathbf{x} + b = 0\}$ 非空；
> - $\mathbf{x} \in \mathbb{R}^d$ 是任意一个（不一定在平面上的）点；
> - $\mathbf{x}_p \in \mathcal{H}$ 是 $\mathbf{x}$ 在平面上的**垂足**（正交投影点），故 $g(\mathbf{x}_p) = \mathbf{w}^T\mathbf{x}_p + b = 0$；
> - $\mathbf{w}/\|\mathbf{w}\|$ 是单位法向量；$\|\mathbf{w}\| = \sqrt{\mathbf{w}^T\mathbf{w}}$ 是 $\mathbf{w}$ 的欧几里得范数。 **关键几何事实**：从垂足 $\mathbf{x}_p$ 指向 $\mathbf{x}$ 的位移，恰好沿着单位法向，且长度就是带符号的距离 r：

$$\mathbf{x} = \mathbf{x}_p + r\,\frac{\mathbf{w}}{\|\mathbf{w}\|}.$$

这里 r 的**符号**表示 $\mathbf{x}$ 位于平面的哪一侧：$r > 0$ 在正侧（$g > 0$ 一侧），$r < 0$ 在负侧。

过程讲解（逐步代入）

步骤 1 | 把分解式代入打分函数

$$g(\mathbf{x}) = \mathbf{w}^T\mathbf{x} + b = \mathbf{w}^T\left(\mathbf{x}_p + r\,\frac{\mathbf{w}}{\|\mathbf{w}\|}\right) + b.$$

步骤 2 | 利用线性性展开

$$g(\mathbf{x}) = \mathbf{w}^T\mathbf{x}_p + b + r\,\frac{\mathbf{w}^T\mathbf{w}}{\|\mathbf{w}\|}.$$

步骤 3 | 代入垂足条件 因为 $\mathbf{x}_p \in \mathcal{H}$，有 $\mathbf{w}^T\mathbf{x}_p + b = 0$。

步骤 4 | 化简法向项 $\mathbf{w}^T\mathbf{w} = \|\mathbf{w}\|^2$，所以

$$r\,\frac{\mathbf{w}^T\mathbf{w}}{\|\mathbf{w}\|}=r\,\frac{\|\mathbf{w}\|^2}{\|\mathbf{w}\|}=r\,\|\mathbf{w}\|.$$

步骤 5 | 得到等式　合并后

$$g(\mathbf{x})=r\,\|\mathbf{w}\|.$$

结论（有符号距离公式）

$$r=\frac{\mathbf{w}^T\mathbf{x}+b}{\|\mathbf{w}\|}=\frac{g(\mathbf{x})}{\|\mathbf{w}\|}.$$

成立条件：$\mathbf{w}\neq\mathbf{0}$（否则分母为零，且“平面”退化）。r 是点 $\mathbf{x}$ 到超平面的、带符号的欧氏距离：绝对值是几何距离，符号是所在侧。

3.1.4 一维小例子（先把直觉坐实）

当 $d=1$ 时，超平面退化成一个“阈值点”。取 $w=2,\ b=-3$，则分界点满足 $2x-3=0\Rightarrow x^*=1.5$。

- 点 $x=3$：$g=2\cdot 3-3=3$，$\|w\|=2$，$r=3/2=1.5>0$。确实在 1.5 右侧 1.5 处。
- 点 $x=0$：$g=-3$，$r=-1.5<0$。在 1.5 左侧 1.5 处。

可见**符号告诉你在哪一侧，绝对值告诉你隔多远**——这正是“有符号距离”的含义。

3.1.5 缩放不变性与一个常见误区

直觉　把 $\mathbf{w},b$ 同时乘一个正数 $c>0$，分类面不会变（等式 $\mathbf{w}^T\mathbf{x}+b=0$ 两边同乘 c 不变），但原始分数 $g(\mathbf{x})$ 会被放大 c 倍。

过程讲解

$$\frac{(c\mathbf{w})^T\mathbf{x}+cb}{\|c\mathbf{w}\|}=\frac{c(\mathbf{w}^T\mathbf{x}+b)}{c\|\mathbf{w}\|}=\frac{\mathbf{w}^T\mathbf{x}+b}{\|\mathbf{w}\|}=r.$$

所以**有符号距离 r 对正缩放不变**，但分数 $g(\mathbf{x})$ 会变。

> **常见误区**：若你拿两个不同尺度的参数 $(\mathbf{w},b)$ 和 $(c\mathbf{w},cb)$ 直接比较“分数大小”，会得出错误结论——分数大只代表参数尺度大，不代表离分界面更远。**要比较几何远近，必须除以 $\|\mathbf{w}\|$。**

3.1.6 增广表示：把偏置合进向量（并澄清分母）

为了把 $\mathbf{w}^T\mathbf{x}+b$ 写成一个干净的内积，引入**增广向量**：

$$\widetilde{\mathbf{x}}=\begin{pmatrix}\mathbf{x}\\1\end{pmatrix}\in\mathbb{R}^{d+1},\qquad \widetilde{\mathbf{w}}=\begin{pmatrix}\mathbf{w}\\b\end{pmatrix}\in\mathbb{R}^{d+1}.$$

于是

$$g(\mathbf{x})=\mathbf{w}^T\mathbf{x}+b=\widetilde{\mathbf{w}}^T\widetilde{\mathbf{x}}.$$

但请特别注意（这也是初学者最容易踩的坑）：

> **记住**：在**原始 d 维特征空间**里，点 $\mathbf{x}$ 到分界面的几何距离，分母仍是 $\|\mathbf{w}\|=\sqrt{\mathbf{w}^T\mathbf{w}}$，**不是** $\|\widetilde{\mathbf{w}}\|$。增广表示只改变了“打分写成内积”的写法，并没有改变原始空间里的几何。误把间隔写成 $1/\|\widetilde{\mathbf{w}}\|$ 是错误的。

3.2 相似性与样本统计

直觉 “距离”只有在特征编码合理时才有意义。把血型任意编成 1、2、3、4 再算欧氏距离，会凭空制造出“A 型比 B 型更靠近 C 型”这种毫无依据的的顺序。单位不同的特征（如“身高 cm”和“体重 kg”）直接算距离，数值会被量纲绑架。

3.2.1 常用距离/相似度度量（定义与注意）

设 $\mathbf{x}, \mathbf{z} \in \mathbb{R}^d$ 为两个样本列向量。

度量	定义	注意事项
L_p 距离	$\left(\sum_{j=1}^{d} \lvert x_j - z_j \rvert^p\right)^{1/p}$	需 $p \geq 1$ 才是通常的范数距离
欧氏距离	$\lVert \mathbf{x} - \mathbf{z} \rVert_2 = \sqrt{\sum_j (x_j - z_j)^2}$	对单位与尺度敏感
曼哈顿距离	$\sum_{j=1}^{d} \lvert x_j - z_j \rvert$	各轴绝对差累加
切比雪夫距离	$\max_j \lvert x_j - z_j \rvert$	取最大分量差，不是求和
马氏距离	$\sqrt{(\mathbf{x}-\mathbf{z})^T \Sigma^{-1} (\mathbf{x}-\mathbf{z})}$	Σ 需正定；去掉根号是平方距离
余弦相似度	$\dfrac{\mathbf{x}^T \mathbf{z}}{\lVert \mathbf{x} \rVert \, \lVert \mathbf{z} \rVert}$	两向量均非零；值越大越相似，范围 $[-1, 1]$

过程讲解（余弦为何落在 $[-1,1]$） 由柯西–施瓦茨不等式 $\lvert \mathbf{x}^T \mathbf{z} \rvert \leq \lVert \mathbf{x} \rVert \, \lVert \mathbf{z} \rVert$，得比值绝对值 ≤ 1，故余弦相似度 $\in [-1, 1]$；取 -1 表示反向，$+1$ 表示同向，0 表示正交（不相关）。

3.2.2 用 $(3,3)$ 与 $(1,2)$ 核对全部数字（编者核算）

来源 S05 31–32 页给出两点 $\mathbf{x} = (3,3)^T$，$\mathbf{z} = (1,2)^T$（均为 $\mathbb{R}^2$ 列向量）。记差向量 $\mathbf{d} = \mathbf{x} - \mathbf{z} = (2,1)^T$。

- **欧氏距离**：$\lVert \mathbf{d} \rVert_2 = \sqrt{2^2 + 1^2} = \sqrt{5} \approx 2.23607$。
- **曼哈顿距离**：$\lvert 2 \rvert + \lvert 1 \rvert = 3$。
- **切比雪夫距离**：$\max(\lvert 2 \rvert, \lvert 1 \rvert) = 2$。
- **余弦相似度**：

$$\mathbf{x}^T \mathbf{z} = 3 \cdot 1 + 3 \cdot 2 = 9, \quad \lVert \mathbf{x} \rVert = \sqrt{3^2 + 3^2} = \sqrt{18}, \quad \lVert \mathbf{z} \rVert = \sqrt{1^2 + 2^2} = \sqrt{5},$$

$$\text{余弦相似度} = \frac{9}{\sqrt{18}\,\sqrt{5}} = \frac{9}{\sqrt{90}} \approx \frac{9}{9.48683} \approx 0.948683.$$

> **记作说明（沿用来源、避免混淆）**：S05 原课件称其为“余弦距离”，本书按公式本质称“余弦相似度”。相似度越大表示越相近，不要把它当成“距离越大越不相似”的反向量，以免在排序任务里把方向搞反。

马氏距离小例子（编者示例） 取一维情形 $d = 1$，$\Sigma = 4$（即方差为 4，标准差为 2）。两点差值 $\lvert \mathbf{x} - \mathbf{z} \rvert = 2$，则马氏距离 $= \sqrt{(2)^2 / 4} = 1$。对比欧氏距离 $= 2$：马氏距离按“标准差”重新度量，消除了量纲与离散程度的影响——这正是它在异方差数据上更合理的原因。Σ 必须正定（二维及以上时至少是满秩）才能求逆。

3.2.3 类内散度矩阵 S_W 与它的半正定性

第 k 类的样本均值（列向量，$\mathbb{R}^d$）定义为

$$\boldsymbol{\mu}_k = \frac{1}{N_k} \sum_{i:y_i=k} \mathbf{x}_i,$$

其中 N_k 是第 k 类的样本数。本书 Fisher 推导采用**不归一化**的散度（与课件一致）：

$$S_W = \sum_{k=1}^{K} \sum_{i:y_i=k} (\mathbf{x}_i - \boldsymbol{\mu}_k)(\mathbf{x}_i - \boldsymbol{\mu}_k)^T.$$

- **维度**：S_W 是 $d \times d$ 的实对称矩阵。
- **半正定性的过程讲解**：任取任意列向量 $\mathbf{a} \in \mathbb{R}^d$，

$$\mathbf{a}^T S_W \mathbf{a} = \sum_{k} \sum_{i:y_i=k} \mathbf{a}^T (\mathbf{x}_i - \boldsymbol{\mu}_k)(\mathbf{x}_i - \boldsymbol{\mu}_k)^T \mathbf{a}.$$

注意 $(\mathbf{x}_i - \boldsymbol{\mu}_k)^T \mathbf{a}$ 是一个标量，其平方等于该标量乘自身，于是

$$\mathbf{a}^T (\mathbf{x}_i - \boldsymbol{\mu}_k)(\mathbf{x}_i - \boldsymbol{\mu}_k)^T \mathbf{a} = \left((\mathbf{x}_i - \boldsymbol{\mu}_k)^T \mathbf{a}\right)^2 \geq 0.$$

对所有项求和仍为非负数，故

$$\mathbf{a}^T S_W \mathbf{a} \geq 0 \quad (\forall \mathbf{a}).$$

> **结论**：S_W 是**对称半正定（PSD）矩阵。它不必然可逆/正定**——当特征共线、或样本数少于维度、或类内波动完全落在某个子空间时，S_W 会奇异。这一点在 3.5 的 Fisher 求逆中会直接产生影响。

关于归一化的提醒　有的教材把类内散度再除以 N_k（或 $N_k - 1$）得到协方差矩阵；不同归一化会改变类间的相对权重。比较任何公式前，必须先确认 S_W 的定义是否与本文一致。

3.3 评价分类结果

直觉　分类器输出“正/负”后，我们要量化它错在哪：是把正常样本误报成异常（狼来了），还是把真正的异常放过了（更危险）。不同任务关心不同的错误。

3.3.1 混淆矩阵与 TP/FP/FN/TN

设我们关注“异常”为**正类**，则对每一次预测有四种可能：

真实 \ 预测	预测正类	预测负类
真实正类	TP（真正例，正确检出）	FN（假负例，漏报）
真实负类	FP（假正例，误报）	TN（真负例，正确排除）

- **TP**：异常被正确检出；
- **FP**：正常被误报为异常（虚惊）；
- **FN**：异常被漏报（最危险的一类错误）；
- **TN**：正常被正确排除。

3.3.2 准确率、精确率、召回率与 F_1（逐步推导）

准确率衡量全体分对的比例：

$$\text{Accuracy} = \frac{TP + TN}{N}, \qquad N = TP + FP + FN + TN.$$

精确率（Precision） = “报出来的异常里有多少是真的”：

$$\text{Precision} = \frac{TP}{TP + FP}.$$

召回率（Recall） = “真正的异常里有多少被找出来”：

$$\text{Recall} = \frac{TP}{TP + FN}.$$

F_1 是精确率与召回率的调和平均（过程讲解，验证公式等价）：

$$F_1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}.$$

代入 $P = \dfrac{TP}{TP + FP}$，$R = \dfrac{TP}{TP + FN}$：

$$\text{分子：}\quad 2PR = 2 \cdot \frac{TP}{TP + FP} \cdot \frac{TP}{TP + FN} = \frac{2TP^2}{(TP + FP)(TP + FN)}.$$

$$\text{分母：}\quad P + R = \frac{TP}{TP + FP} + \frac{TP}{TP + FN} = TP \cdot \frac{(TP + FN) + (TP + FP)}{(TP + FP)(TP + FN)} = \frac{TP\,(2TP + FN + FP)}{(TP + FP)(TP + FN)}.$$

两式相除，分母的 $(TP + FP)(TP + FN)$ 相消：

$$F_1 = \frac{2TP^2}{TP\,(2TP + FN + FP)} = \frac{2TP}{2TP + FN + FP}.$$

> **结论**：
>
> $$F_1 = \frac{2TP}{2TP + FN + FP}.$$
>
> 它比准确率更关注“正类”的表现，因为 TP 同时出现在分子与分母的每一项里。

分母为零的约定（必须显式说明）：若 $TP + FP = 0$（没有任何样本被判为正），精确率无定义，常见做法有“记为 1” “记为 0”或“报告 NA”——**任何选择都应在报告中写明**，不能默认。召回率同理（当 $TP + FN = 0$，即根本没有正类样本时）。

3.3.3 一个不平衡数据的小例子（编者示例）

假设共 100 个样本，真实异常仅 10 个。某分类器给出：TP$=8$, FP$=2$, FN$=2$, TN$=88$。

- 精确率 $= 8/(8+2) = 0.80$；召回率 $= 8/(8+2) = 0.80$；$F_1 = 2 \cdot 8/(16+2+2) = 16/20 = 0.80$。
- 准确率 $= (8+88)/100 = 0.96$。

对比“偷懒分类器”：**永远判为正常**，则 TP$=0$, FP$=0$, FN$=10$, TN$=90$。

- 准确率 $= 90/100 = 0.90$（看起来不错！），但召回率 $= 0$，一个异常都没抓住。

> **记住**：在极度不平衡数据上，高准确率可能毫无意义。**先盯召回率和精确率，再谈准确率。**

3.3.4 ROC 与 AUC

ROC 曲线通过改变判定阈值，画出一对指标：

$$TPR = \frac{TP}{TP + FN} \quad (\text{真正例率，即召回率}), \qquad FPR = \frac{FP}{FP + TN} \quad (\text{假正例率}).$$

- 横轴是 FPR，纵轴是 TPR；
- 每个阈值对应曲线上一个点；阈值从高到低扫，点从左到右下走到左上。

AUC（Area Under ROC Curve）是 ROC 曲线下的面积：

- $\mathrm{AUC} = 1$：完美排序；
- $\mathrm{AUC} = 0.5$：等价于随机乱猜；
- AUC 衡量的是**整体排序质量**，与具体部署阈值无关。

> **常见误区**：ROC/AUC 不告诉你“该把阈值设成多少”。在**正类极稀少**的场景（如异常检测），PR 曲线（横轴召回、纵轴精确率）往往比 ROC 更有解释力，因为 ROC 的 FPR 分母 $FP + TN$ 很大，微小的 FP 变化被稀释。

3.3.5 课件提及的统计检验（记录，不展开）

S05 41 页还列出假设检验、交叉验证 t 检验、McNemar、Friedman 与 Nemenyi 等方法，但**未展开**。本版将其记为“课件提及项”，不据标题推断教师考核要求。

> **编者提醒（配对数据）**：同一批测试样本上，两个模型的预测是**配对**的，不能把所有折（fold）的分数当作完全独立观测来做普通 t 检验；这正是为什么课件单独列出 McNemar / 配对检验。

3.4 感知机：错了以后朝正确方向移动

直觉 感知机是最朴素的“错了就改”算法：如果一个样本被分错（或恰好在边界上），我们就沿着“能让它变对”的方向，把分类面推过去一点。正样本分数太低，就增加和它同向的权重；负样本分数太高，就反向调整。

3.4.1 标签约定与更新规则

二分类标签取 $y_i \in \{-1, +1\}$。对样本 i：

- **正确且不在边界上**的判据是 $y_i(\mathbf{w}^T\mathbf{x}_i + b) > 0$；
- 若该值 ≤ 0（错分或在边界），执行更新

$$\mathbf{w} \leftarrow \mathbf{w} + \eta\, y_i \mathbf{x}_i, \qquad b \leftarrow b + \eta\, y_i,$$

其中 $\eta > 0$ 是步长（学习率）。

几何解释（为什么这样改）：对正样本 $y_i = +1$，若当前分数 $\mathbf{w}^T\mathbf{x}_i + b$ 太小甚至为负，加上 $\eta\mathbf{x}_i$ 到 $\mathbf{w}$、加上 η 到 b，会使该样本的新分数增大（见 3.4.2），从而更可能被判为正。负样本 $y_i = -1$ 时方向相反，把分数压低。

3.4.2 “一步使该样本分数增加 $\eta\|\widetilde{\mathbf{x}}_i\|^2$” （过程讲解）

> **假设与符号**：引入增广表示 $\widetilde{\mathbf{x}}_i=(\mathbf{x}_i^T,1)^T\in\mathbb{R}^{d+1}$，$\widetilde{\mathbf{w}}=(\mathbf{w}^T,b)^T\in\mathbb{R}^{d+1}$；样本 i 的（增广）分数为 $s_i=\widetilde{\mathbf{w}}^T\widetilde{\mathbf{x}}_i=\mathbf{w}^T\mathbf{x}_i+b$。

步骤 1 | 写出增广形式的更新　因为 $b\leftarrow b+\eta y_i$，等价于

$$\widetilde{\mathbf{w}}\leftarrow\widetilde{\mathbf{w}}+\eta\,y_i\widetilde{\mathbf{x}}_i.$$

步骤 2 | 计算更新后的分数

$$s_i'=\widetilde{\mathbf{w}}'^T\widetilde{\mathbf{x}}_i=(\widetilde{\mathbf{w}}+\eta y_i\widetilde{\mathbf{x}}_i)^T\widetilde{\mathbf{x}}_i=\widetilde{\mathbf{w}}^T\widetilde{\mathbf{x}}_i+\eta y_i\,\widetilde{\mathbf{x}}_i^T\widetilde{\mathbf{x}}_i.$$

步骤 3 | 化简　$\widetilde{\mathbf{x}}_i^T\widetilde{\mathbf{x}}_i=\|\widetilde{\mathbf{x}}_i\|^2$，故

$$s_i'=s_i+\eta\,y_i\,\|\widetilde{\mathbf{x}}_i\|^2.$$

即**原始有符号分数**增加了 $\eta y_i\|\widetilde{\mathbf{x}}_i\|^2$。

步骤 4 | 看“带标签分数”　定义带标签分数（margin）$m_i=y_is_i$。更新后

$$m_i'=y_is_i'=y_i(s_i+\eta y_i\|\widetilde{\mathbf{x}}_i\|^2)=y_is_i+\eta\,y_i^2\|\widetilde{\mathbf{x}}_i\|^2=m_i+\eta\|\widetilde{\mathbf{x}}_i\|^2,$$

因为 $y_i\in\{-1,+1\}\Rightarrow y_i^2=1$。

> **结论**：对同一个增广样本，更新后**带标签分数恰好增加** $\eta\|\widetilde{\mathbf{x}}_i\|^2>0$。这就是感知机“每一步都在把这个错分样本推离边界”的代数本质。

3.4.3 自适应步长：让该样本一步变对

我们希望更新后该样本得到**严格正**的带标签分数，即 $m_i'>0$：

$$m_i+\eta\|\widetilde{\mathbf{x}}_i\|^2>0\implies\eta>-\frac{m_i}{\|\widetilde{\mathbf{x}}_i\|^2}=-\frac{y_i\,\widetilde{\mathbf{w}}^T\widetilde{\mathbf{x}}_i}{\|\widetilde{\mathbf{x}}_i\|^2}.$$

> **结论（自适应步长下界）**：只要

$$\eta>\frac{-y_i\,\widetilde{\mathbf{w}}^T\widetilde{\mathbf{x}}_i}{\|\widetilde{\mathbf{x}}_i\|^2},$$

该样本更新后即获得严格正的带标签分数。**等号**只保证到达边界（$m_i'=0$），并不能保证其它样本不变错。

> **编者提醒（来源 S06 18–19 页）**：课件中的“误差为零”应理解为**针对当前这一个点的修正**，不能扩大成“全训练集单调改进”。感知机每步只照顾当前错分点，可能把别的点又推错。

3.4.4 课件例题一：批量感知机一步修正（S06 23–24 页）

课件给出的初始决策边界是

$$x_1+x_2-0.5=0,\qquad\widetilde{\mathbf{w}}^{(0)}=(1,1,-0.5)^T,$$

学习率为 $\eta=0.7$。当前只有两个错分样本：

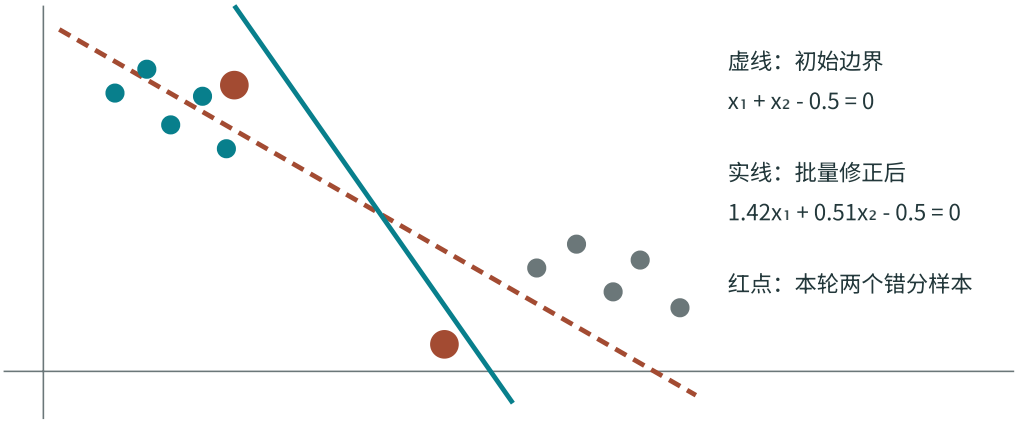
$$\widetilde{\mathbf{x}}_a=(0.4,0.05,1)^T,\quad d_a=+1;\qquad \widetilde{\mathbf{x}}_b=(-0.2,0.75,1)^T,\quad d_b=-1.$$

批量更新把本轮所有错分样本同时累加：

$$\begin{aligned}\widetilde{\mathbf{w}}^{(1)}&=\widetilde{\mathbf{w}}^{(0)}+\eta\sum_{i\in E}d_i\widetilde{\mathbf{x}}_i\\&=\begin{pmatrix}1\\1\\-0.5\end{pmatrix}+0.7\begin{pmatrix}0.4\\0.05\\1\end{pmatrix}-0.7\begin{pmatrix}-0.2\\0.75\\1\end{pmatrix}\\&=\begin{pmatrix}1.42\\0.51\\-0.5\end{pmatrix}.\end{aligned}$$

因此新边界为 $1.42x_1+0.51x_2-0.5=0$。课件图中这条实线已经把全部训练点正确分开，于是算法停止。

感知机课堂例 1：错分点推动决策边界旋转



课件例 1：η = 0.7；更新后全部训练点被正确分类。

3.4.5 课件例题二：四个点的在线感知机（S06 25–27 页）

两类原始样本为

$$C_1:\ (-1,0)^T,(0,1)^T,\quad d=+1;\qquad C_2:\ (0,-1)^T,(1,0)^T,\quad d=-1.$$

采用增广向量 $\widetilde{\mathbf{x}}=(x_1,x_2,1)^T$，初始 $\widetilde{\mathbf{w}}^{(0)}=(0,0,0)^T$，学习率 $\eta=1$。本书沿课件约定：正类要求分数 >0，负类要求分数 ≤ 0，边界上的正类样本要更新。按课件顺序扫描一轮：

步骤	样本 $\widetilde{\mathbf{x}}$	d	更新前分数	是否更新	更新后 $\widetilde{\mathbf{w}}$
1	$(-1,0,1)^T$	$+1$	0	是，正类在边界上	$(-1,0,1)^T$
2	$(0,1,1)^T$	$+1$	1	否	$(-1,0,1)^T$
3	$(0,-1,1)^T$	-1	1	是，负类被判到正侧	$(-1,1,0)^T$
4	$(1,0,1)^T$	-1	-1	否	$(-1,1,0)^T$
5–8	再检查四点	—	$1,1,-1,-1$	均正确，不再更新	$(-1,1,0)^T$

最终边界是

$$-x_1+x_2=0\quad\Longleftrightarrow\quad x_2=x_1.$$

这正好把左上方的 C_1 两点与右下方的 C_2 两点分开。这个例子也说明：**在线感知机每看一个样本就决定是否更新，样本顺序会影响中间路径和最终得到的某一个分离解。**

3.4.6 感知机与损失函数的关系（过程讲解）

感知机可视为最小化**错分样本损失和**

$$J(\mathbf{w},b)=-\sum_{i\in E} y_i\big(\mathbf{w}^T\mathbf{x}_i+b\big),$$

其中 E 是当前错分（及边界）样本集合。E 随参数变化，边界点需统一处理（本书约定边界点参与更新）。

对单样本损失 $\ell_i=-y_i(\mathbf{w}^T\mathbf{x}_i+b)$ 求梯度：

$$\frac{\partial \ell_i}{\partial \mathbf{w}}=-y_i\mathbf{x}_i,\qquad \frac{\partial \ell_i}{\partial b}=-y_i.$$

梯度下降更新 $\mathbf w\leftarrow\mathbf w-\eta\nabla_{\mathbf w}\ell_i =\mathbf w+\eta y_i\mathbf x_i$，正是感知机更新。所以**感知机的启发式规则，等价于对错分点损失做梯度下降。**

3.4.7 收敛性与反例

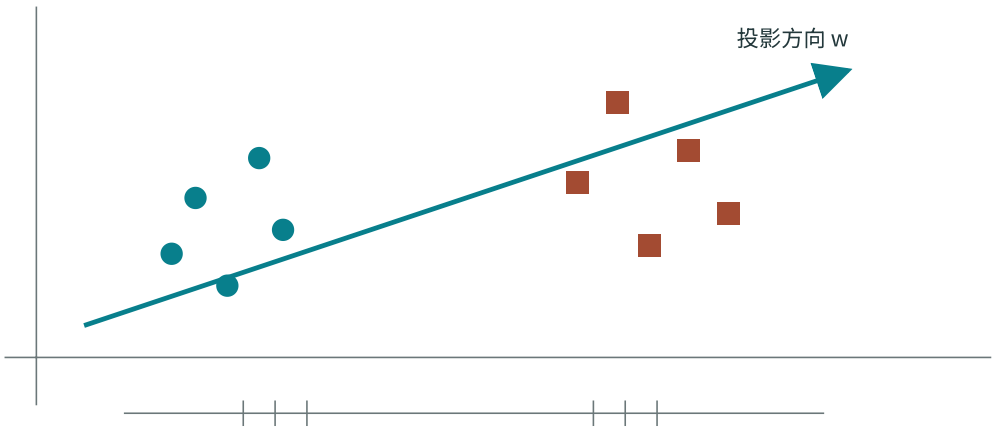
- **线性可分**且以固定正步长反复遍历数据时，标准感知机定理保证在**有限次错误更新**后找到分离超平面。
- **非线性可分**（如 XOR）时，没有收敛保证，也不保证找到“最大间隔”的分界面。
- XOR 四点 $(0,0),(1,1)$ 为正、$(0,1),(1,0)$ 为负，是最简单的线性不可分反例。

> **记住**：感知机的“收敛保证”**强依赖线性可分前提**；实际数据不可分时，它只会不停抖动，需要靠学习率衰减或转用别的模型。

3.5 Fisher 线性鉴别：投影后类间远、类内紧

直觉　只沿着两类中心连线做投影，可能把很大的类内波动也一起带进来——两类中心离得远，但各自内部散得很开，投影后仍然重叠。Fisher 的思想是：找一个投影方向，让**投影后两类均值尽量分开（类间远）**，同时**每类内部尽量集中（类内紧）**，用“比值”把这两件事平衡起来。

Fisher 线性鉴别：寻找类间远、类内紧的投影



投影后：同类紧凑、两类均值相距远

3.5.1 投影与两个散度的矩阵表达（过程讲解）

> **假设与符号**（二类情形 $K=2$）：
>
> - 投影方向 $\mathbf{w}\in\mathbb{R}^d$（列向量，长度任意，方向有意义）；
> - 投影后标量 $z_i=\mathbf{w}^T\mathbf{x}_i\in\mathbb{R}$；
> - 第 k 类投影均值 $m_k=\mathbf{w}^T\boldsymbol{\mu}_k\in\mathbb{R}$；
> - 类间均值差 $\boldsymbol{\delta}=\boldsymbol{\mu}_1-\boldsymbol{\mu}_2\in\mathbb{R}^d$；
> - 类间散度矩阵 $S_B=\boldsymbol{\delta}\boldsymbol{\delta}^T\in\mathbb{R}^{d\times d}$（秩 1，半正定）；
> - 类内散度矩阵 S_W 同 3.2.3（已证半正定）。

步骤 1 | 类间散度（投影后均值差的平方）

$$m_1-m_2=\mathbf{w}^T\boldsymbol{\mu}_1-\mathbf{w}^T\boldsymbol{\mu}_2=\mathbf{w}^T(\boldsymbol{\mu}_1-\boldsymbol{\mu}_2)=\mathbf{w}^T\boldsymbol{\delta}.$$

平方并写成二次型：

$$(m_1-m_2)^2=(\mathbf{w}^T\boldsymbol{\delta})^2=(\mathbf{w}^T\boldsymbol{\delta})(\boldsymbol{\delta}^T\mathbf{w})=\mathbf{w}^T(\boldsymbol{\delta}\boldsymbol{\delta}^T)\mathbf{w}=\mathbf{w}^TS_B\mathbf{w}.$$

步骤 2 | 类内散度（投影后各类内部方差之和）

$$\sum_{k=1}^{2}\sum_{i:y_i=k}(z_i-m_k)^2=\sum_{k}\sum_{i:y_i=k}\big(\mathbf{w}^T(\mathbf{x}_i-\boldsymbol{\mu}_k)\big)^2.$$

把平方项展开为内积：

$$\big(\mathbf{w}^T(\mathbf{x}_i-\boldsymbol{\mu}_k)\big)^2=\big(\mathbf{w}^T(\mathbf{x}_i-\boldsymbol{\mu}_k)\big)\big((\mathbf{x}_i-\boldsymbol{\mu}_k)^T\mathbf{w}\big)=\mathbf{w}^T(\mathbf{x}_i-\boldsymbol{\mu}_k)(\mathbf{x}_i-\boldsymbol{\mu}_k)^T\mathbf{w}.$$

对全部样本求和，把 $\mathbf{w}$ 提到最外：

$$\sum_{k}\sum_{i:y_i=k}\mathbf{w}^T(\mathbf{x}_i-\boldsymbol{\mu}_k)(\mathbf{x}_i-\boldsymbol{\mu}_k)^T\mathbf{w}=\mathbf{w}^T\Big(\sum_{k}\sum_{i:y_i=k}(\mathbf{x}_i-\boldsymbol{\mu}_k)(\mathbf{x}_i-\boldsymbol{\mu}_k)^T\Big)\mathbf{w}=\mathbf{w}^TS_W\mathbf{w}.$$

步骤 3 | 构造 Fisher 比值

$$J(\mathbf{w})=\frac{\mathbf{w}^TS_B\mathbf{w}}{\mathbf{w}^TS_W\mathbf{w}}.$$

结论：分子是“类间远”的度量，分母是“类内紧”的度量；J 越大越好。

3.5.2 比值为何与缩放无关

对任意非零常数 c，

$$J(c\mathbf{w})=\frac{(c\mathbf{w})^TS_B(c\mathbf{w})}{(c\mathbf{w})^TS_W(c\mathbf{w})}=\frac{c^2\,\mathbf{w}^TS_B\mathbf{w}}{c^2\,\mathbf{w}^TS_W\mathbf{w}}=J(\mathbf{w}).$$

> **结论**：$J(\mathbf{w})$ 只取决于 $\mathbf{w}$ 的**方向**，不取决于长度。因此可以固定分母为某个常数（如 1）来求极大值方向。

3.5.3 拉格朗日乘子法求极大值方向（过程讲解）

在约束 $\mathbf{w}^TS_W\mathbf{w}=1$ 下最大化 $\mathbf{w}^TS_B\mathbf{w}$。构造拉格朗日函数（$\lambda$ 为乘子）：

$$L(\mathbf{w},\lambda)=\mathbf{w}^T S_B\mathbf{w}-\lambda\big(\mathbf{w}^T S_W\mathbf{w}-1\big).$$

步骤 1 | 对 $\mathbf{w}$ 求梯度并令为零　利用对称矩阵二次型的导数公式 $\nabla_{\mathbf{w}}(\mathbf{w}^T A\mathbf{w})=2A\mathbf{w}$（$A$ 对称）：

$$\nabla_{\mathbf{w}}L=2S_B\mathbf{w}-2\lambda S_W\mathbf{w}=0\implies S_B\mathbf{w}=\lambda S_W\mathbf{w}.$$

这是一个**广义特征值问题**。左乘 $\mathbf{w}^T$ 得

$$\mathbf{w}^T S_B\mathbf{w}=\lambda\,\mathbf{w}^T S_W\mathbf{w}\implies \lambda=J(\mathbf{w})\quad(\text{因约束下 }\mathbf{w}^T S_W\mathbf{w}=1).$$

所以最大化 J 等价于取该广义特征值问题中**最大的特征根** λ。

步骤 2 | 利用 S_B 的秩 1 结构化简　因为 $S_B=\boldsymbol{\delta}\boldsymbol{\delta}^T$，

$$S_B\mathbf{w}=(\boldsymbol{\delta}\boldsymbol{\delta}^T)\mathbf{w}=\boldsymbol{\delta}\,(\boldsymbol{\delta}^T\mathbf{w})=(\boldsymbol{\delta}^T\mathbf{w})\,\boldsymbol{\delta}.$$

记标量 $\alpha=\boldsymbol{\delta}^T\mathbf{w}$，则 $S_B\mathbf{w}=\alpha\boldsymbol{\delta}$——**它总与 $\boldsymbol{\delta}$ 同向**。代入广义特征方程：

$$\alpha\boldsymbol{\delta}=\lambda S_W\mathbf{w}\implies \mathbf{w}=\frac{\alpha}{\lambda}S_W^{-1}\boldsymbol{\delta}\quad(\text{要求 }S_W\text{ 可逆且 }\lambda\neq 0).$$

由于 α/λ 只是一个标量系数，方向与尺度无关，得到 Fisher 经典解：

$$\mathbf{w}\propto S_W^{-1}\boldsymbol{\delta}.$$

结论（Fisher 解）：最优投影方向正比于 $S_W^{-1}\boldsymbol{\delta}$。

> **实践提示**：实际计算**不要显式求逆**，而是解线性方程组
>
> $$S_W\mathbf{w}=\boldsymbol{\delta}$$
>
> 得到 $\mathbf{w}$ 的方向即可（任何特解都成比例）。

3.5.4 S_W 奇异时的正则化（必须说明）

S_W 只是半正定（见 3.2.3），当特征共线或样本不足时会奇异，S_W^{-1} 不存在。此时采用**岭正则（Tikhonov）**：

$$\mathbf{w}\propto(S_W+\lambda I)^{-1}\boldsymbol{\delta},\qquad \lambda>0.$$

加 λI 后 $S_W+\lambda I$ 正定、可逆。

> **编者提醒**：这已经是**正则化版本**，不是原始 Fisher 解。引入 λ 会偏离“最大化原始 J”的目标，其大小应有依据（如由验证集选择，或给一个很小的岭系数作数值稳定用途）。**不能静默地把正则化当成原始解。**

3.5.5 方向有了，阈值怎么定?

Fisher 只给出**投影方向 $\mathbf{w}$**，还要在投影后的 1D 分数上选一个**分类阈值。**

- 在**等先验、共同协方差的高斯模型**下，最优阈值有明确的理论依据：取两类投影均值的中点 $(m_1+m_2)/2$。
- **一般情形下不能无条件认为“投影中点永远最优”**；阈值应由训练或验证流程选择。

> **常见误区**：把“Fisher 给出方向”误解为“Fisher 直接给出完整分类器”。它给的是 1D 投影，分类还需再定阈值，而阈值的选择本身就是独立的一步。

详细数值演练见 3.8 数值演练：Fisher 解的小例题。

3.6 Logistic：把线性分数变成概率

直觉 感知机只给“正负号”，Fisher 给“投影后的距离”。但我们常想知道“这个样本是正类的概率有多大”。Logistic 回归的做法是：先假设“对数优势比（log-odds）是特征的线性函数”，再由此反推出一个把任意实数分数映射到 $(0,1)$ 的概率函数——这就是 Sigmoid。

3.6.1 从优势对数推出 $\sigma(z)$（过程讲解）

> **假设与符号**：标签改为 $y_i \in \{0,1\}$；令线性分数 $z = \mathbf{w}^T\mathbf{x} + b \in \mathbb{R}$；记正类后验概率 $p = P(y=1 \mid \mathbf{x}) \in (0,1)$。

建模假设：正类的**对数优势比**是线性的：

$$\log \frac{p}{1-p} = z.$$

步骤 1 | 指数化，去掉对数

$$\frac{p}{1-p} = e^z.$$

步骤 2 | 解出 p

$$p = e^z(1-p) = e^z - e^z p \implies p + e^z p = e^z \implies p(1+e^z) = e^z.$$

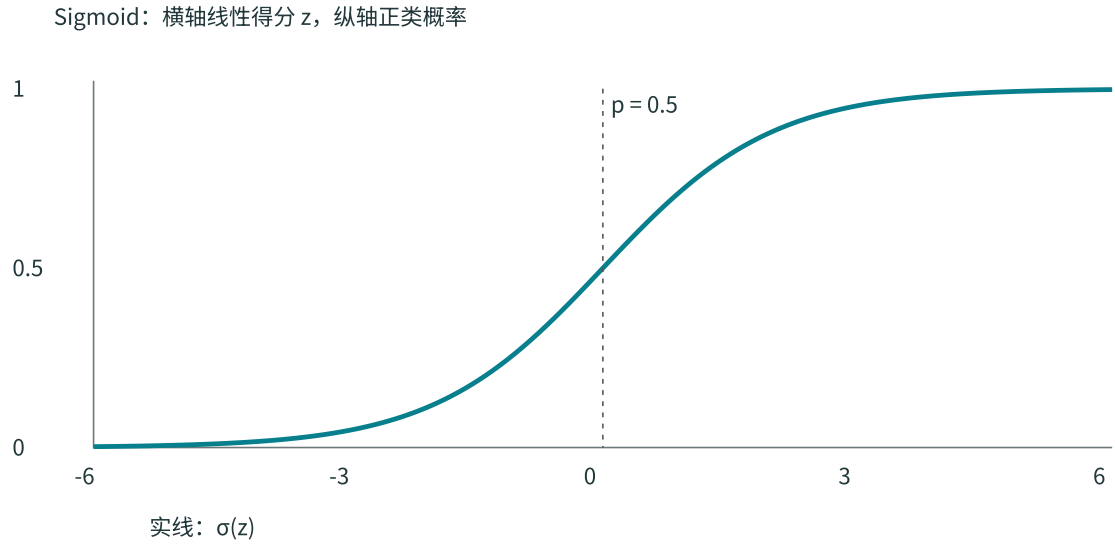
步骤 3 | 两边除以 $1+e^z$

$$p = \frac{e^z}{1+e^z}.$$

步骤 4 | 分子分母同除以 e^z，得标准形式

$$p = \frac{1}{e^{-z}+1} = \sigma(z), \qquad \sigma(z) = \frac{1}{1+e^{-z}}.$$

> **结论**：在“对数优势比为线性”的假设下，正类概率必为 Sigmoid 函数 $\sigma(z)$。σ 把 $(-\infty,\infty)$ 单调映射到 $(0,1)$，且 $\sigma(0)=0.5$、$\sigma(-z)=1-\sigma(z)$。



3.6.2 为什么仍是“线性分类器”

以 0.5 为阈值时，判正类当且仅当 $\sigma(z) \geq 0.5$，即 $z \geq 0$，即 $\mathbf{w}^T\mathbf{x} + b \geq 0$——边界仍是那张线性超平面。

若改用其它固定阈值 $t \in (0,1)$，判正类当且仅当 $p \geq t$，即

$$\sigma(z) \geq t \implies z \geq \log \frac{t}{1-t}.$$

这只把超平面沿法向平移，**边界依旧是线性的。**Logistic 与感知机的本质区别不在“边界形状”，而在“输出是校准过的概率、且由最大似然/交叉熵训练”。

3.6.3 交叉熵损失从似然来（过程讲解）

在独立同分布假设下，第 i 个样本的条件概率为

$$P(y_i \mid \mathbf{x}_i) = p_i^{y_i}(1-p_i)^{\,1-y_i},$$

因为：当 $y_i = 1$ 时为 p_i，当 $y_i = 0$ 时为 $1 - p_i$。

全体样本的似然

$$L = \prod_{i=1}^{N} p_i^{y_i}(1-p_i)^{\,1-y_i}.$$

最大化对数似然等价于最小化**负平均对数似然（交叉熵）**：

$$J(\mathbf{w}, b) = -\frac{1}{N}\sum_{i=1}^{N}\Big[y_i \log p_i + (1-y_i)\log(1-p_i)\Big].$$

> **结论**：Logistic 的训练目标就是最小化这个交叉熵；它直接对应“在模型假设下最大化数据出现的概率”。

3.6.4 交叉熵梯度 $\nabla_{\mathbf{w}} J = \frac{1}{N}\sum_i (p_i - y_i)\mathbf{x}_i$（核心推导）

> **前置结论**：Sigmoid 的导数满足

$$\sigma'(z) = \sigma(z)\big(1-\sigma(z)\big) = p(1-p).$$

过程讲解（先证 σ'）

$$\sigma(z) = \frac{1}{1+e^{-z}} = (1+e^{-z})^{-1}.$$

$$\sigma'(z) = -(1+e^{-z})^{-2}\cdot(-e^{-z}) = \frac{e^{-z}}{(1+e^{-z})^2} = \frac{1}{1+e^{-z}}\cdot\frac{e^{-z}}{1+e^{-z}} = \sigma(z)\cdot\big(1-\sigma(z)\big).$$

（其中 $1-\sigma(z) = 1-\frac{1}{1+e^{-z}} = \frac{e^{-z}}{1+e^{-z}}$，代入即得。）

单样本损失对 z 的导数：

$$\ell_i = -y_i\log p_i - (1-y_i)\log(1-p_i), \qquad p_i = \sigma(z_i).$$

$$\frac{d\ell_i}{dz_i} = -\Big[y_i\frac{1}{p_i}\frac{dp_i}{dz_i} + (1-y_i)\frac{1}{1-p_i}\cdot\Big(-\frac{dp_i}{dz_i}\Big)\Big] = -\Big[y_i\frac{p_i(1-p_i)}{p_i} - (1-y_i)\frac{p_i(1-p_i)}{1-p_i}\Big].$$

约去后：

$$\frac{d\ell_i}{dz_i} = -\big[y_i(1-p_i) - (1-y_i)p_i\big] = -\big[y_i - y_ip_i - p_i + y_ip_i\big] = -(y_i-p_i) = p_i - y_i.$$

再对 $\mathbf{w}$ 求导：因为 $z_i = \mathbf{w}^T\mathbf{x}_i + b$，有 $\dfrac{\partial z_i}{\partial \mathbf{w}} = \mathbf{x}_i$（列向量），且 $\dfrac{\partial z_i}{\partial b} = 1$。由链式法则

$$\frac{\partial \ell_i}{\partial \mathbf{w}} = \frac{d\ell_i}{dz_i}\cdot\frac{\partial z_i}{\partial \mathbf{w}} = (p_i-y_i)\mathbf{x}_i, \qquad \frac{\partial \ell_i}{\partial b} = p_i - y_i.$$

对全部 N 个样本取平均（$J = \frac{1}{N}\sum_i \ell_i$）：

$$\nabla_{\mathbf{w}} J = \frac{1}{N}\sum_{i=1}^{N}(p_i-y_i)\mathbf{x}_i, \qquad \frac{\partial J}{\partial b} = \frac{1}{N}\sum_{i=1}^{N}(p_i-y_i).$$

> **结论**：梯度方向由“预测概率与真实标签的误差 (p_i-y_i)”乘以特征 $\mathbf{x}_i$ 构成。对正样本（$y_i=1$）若 $p_i<1$，则 $p_i-y_i<0$，梯度下降会使 $\mathbf{w}$ 朝增大 z_i（从而增大 p_i）的方向更新——与直觉完全一致。

3.6.5 数值稳定实现（避免指数溢出）

直接计算 e^{-z} 在 $|z|$ 很大时会溢出。改用等价稳定形式（编者验证等价，见下）：

$$\ell_i = \max(z_i,0) - z_iy_i + \log\big(1+e^{-|z_i|}\big).$$

等价性验证（以 $y_i=1$ 为例）：原始 $\ell_i = -\log\sigma(z_i) = \log(1+e^{-z_i})$。

- 若 $z_i \ge 0$：$\max(z_i,0) - z_i + \log(1+e^{-z_i}) = 0 + \log(1+e^{-z_i})$，相等；
- 若 $z_i < 0$：$\max(z_i,0) = 0$，稳定式 $= -z_i + \log(1+e^{z_i}) = \log(e^{-z_i}) + \log(1+e^{z_i}) = \log(e^{-z_i}+1) = \log(1+e^{-z_i})$，相等。 （$y_i=0$ 情形同理可证。）该形式对任何 z_i 都不会出现 $e^{\pm z_i}$ 的极端溢出。

3.6.6 完全可分数据与正则项

在**完全线性可分且无正则**的数据上，似然可以沿“权重越来越大”的方向逼近上确界，但**未必存在有限的极大似然参数**（损失趋近于 0 却永远到不了最小值点）。这是 Logistic 回归过拟合极端可分数据的典型现象。**加入正则项**（如 ℓ_2 惩罚 $\frac{\lambda}{2}\|\mathbf{w}\|^2$）是常用且必要的处理。

3.6.7 多类 Softmax

对 K 类，令第 c 类分数 $z_c = \mathbf{w}_c^T \mathbf{x} + b_c$（$c = 1, \ldots, K$），用 Softmax 给出概率：

$$P(c \mid \mathbf{x}) = \frac{e^{z_c}}{\sum_{j=1}^{K} e^{z_j}}.$$

数值技巧：对所有 z_c 同时减去最大值 $\max_j z_j$，Softmax 输出不变（等价于分子分母同乘 $e^{-z_{\max}}$），可防止 e^{z_c} 溢出。

> **记住（参数冗余）**：对所有类别分数同时加同一个常数，Softmax 概率**不变**，因此 Softmax 的参数表示存在冗余，通常需要加约束（如固定某一类偏置为 0）才能唯一确定。

详细数值演练见 3.9 数值演练：Logistic 的一步梯度下降。

3.7 三个方法放在一起

方法	优化或学习依据	输出与边界
感知机	错分点的线性惩罚（见 3.4.5）	分类符号；线性可分时收敛
Fisher	类间散度 / 类内散度之比 J（见 3.5）	投影方向，再定阈值
Logistic	条件似然 / 交叉熵（见 3.6.3–3.6.4）	类别概率，固定阈值下为线性边界

它们**可能产生相近的超平面**，但背后的问题假设不同：感知机只关心“分不分得开”，Fisher 关心“投影后的可分性”，Logistic 关心“概率校准”。

联系第二章：在各类**协方差相同**的高斯模型下，后验概率的对数优势比也是线性的；Logistic 正是直接对“这个后验”建模，而不必为每一类去建完整的输入分布（这正是它比朴素假设全分布更省力的地方）。

3.7.1 多类推广（来源 S05 46–48 页，完整保留）

S05 46 页先用三类点说明：多类数据也可能线性可分或不可分；47 页提出“二叉树比对”；48 页再给出“最大相似性”。这里最容易把**预先训练多少模型**和**一个测试样本要比较多少次**混在一起，下面按课件的方案逐步拆开。

（a）课件的“二叉树比对”实际包含两个阶段

设有 K 个类别。课件先为每一对类别准备一个二分类器，例如 A 对 B、A 对 C。无序类别对的数量为

$$\binom{K}{2} = \frac{K(K-1)}{2}.$$

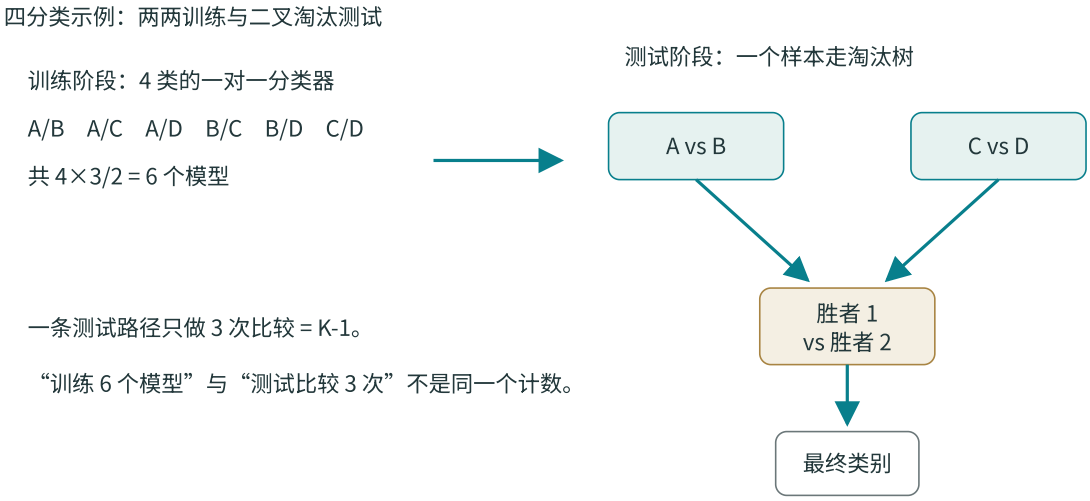
为什么？第 1 类可与其余 $K-1$ 类配对，第 2 类只需再与后面的 $K-2$ 类配对，依次得到

$$(K-1) + (K-2) + \cdots + 1 = \frac{K(K-1)}{2}.$$

训练完成后，对一个新样本做**淘汰式测试**：两类先比较，胜者再进入下一轮。每次比较淘汰一个候选类，从 K 个候选减到 1 个，必然需要

$$K - 1$$

次比较。以 $K = 4$ 为例，训练阶段共有 $4 \times 3/2 = 6$ 个两两分类器，而一次测试淘汰赛只调用其中 3 个。



> **重要限制（编者解释）**：两两分类结果可能出现循环，例如 A 胜 B、B 胜 C、C 又胜 A。因此淘汰树的最终类别可能受对阵顺序影响；它也不一定等于“让全部 $K(K-1)/2$ 个分类器投票”的结果。课件给出的是一种测试组织方式，不是多类分类唯一方案。

（b）最大相似性：直接比较 K 个类别得分

S05 48 页为每个类别 c 定义一个线性判别函数 $f_c(\mathbf{x}) = \mathbf{w}_c^T\mathbf{x}$。若像本章前文一样显式保留偏置，可写成

$$f_c(\mathbf{x}) = \mathbf{w}_c^T\mathbf{x} + b_c, \qquad c = 1, \ldots, K,$$

然后选择得分最大的类别：

$$\hat{y} = \arg\max_{c\in\{1,\ldots,K\}} f_c(\mathbf{x}).$$

这里需要训练 K 组类别参数，并在测试时计算 K 个分数。多类 Logistic / Softmax（3.6.7）就是把这些分数进一步归一化成概率。

（c）另外两种常见方案（编者补充）

- **一对其余（One-vs-Rest）**：训练 K 个“本类 vs 其他所有类”的二分类模型，再比较分数。
- **预先固定的层次分类树**：只训练 $K-1$ 个内部节点模型；每个节点通常区分的是两组类别，而不是某一对单类。这与课件“先训练全部两两分类器、再用淘汰树调用”不是同一种训练方案。

> **记住**：$K(K-1)/2$ 是**全体一对一模型池**的数量，不是所有多类方法都必须达到的最低训练数；$K-1$ 是淘汰一个测试样本时的比较次数。两者回答的是不同问题。

配套练习见 练习。

3.8 数值演练：Fisher 解的小例题

> **编者示例（自编题，确定性小数据）**：二维两类，每类 3 个点，全部来自 $\mathbb{R}^2$。
>
> - 类 1：$(1,1)^T$, $(2,2)^T$, $(1,3)^T$
> - 类 2：$(4,1)^T$, $(5,2)^T$, $(4,3)^T$

步骤 1 | 算类均值

$$\boldsymbol{\mu}_1 = \frac{1}{3}\left(\begin{pmatrix}1\\1\end{pmatrix}+\begin{pmatrix}2\\2\end{pmatrix}+\begin{pmatrix}1\\3\end{pmatrix}\right) = \begin{pmatrix}4/3\\2\end{pmatrix}, \qquad \boldsymbol{\mu}_2 = \begin{pmatrix}13/3\\2\end{pmatrix}.$$

类间差 $\boldsymbol{\delta} = \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2 = (-3,0)^T$（两类只在第 1 维有差异）。

步骤 2 | 算 S_W 类 1 各点与均值之差：$(-1/3,-1)^T$, $(2/3,0)^T$, $(-1/3,1)^T$。其外积之和

$$\sum_{i\in C_1}(\mathbf{x}_i-\boldsymbol{\mu}_1)(\mathbf{x}_i-\boldsymbol{\mu}_1)^T = \begin{pmatrix}2/3 & 0\\ 0 & 2\end{pmatrix}.$$

类 2 的偏差与类 1 完全对称，外积和相同，故

$$S_W = \begin{pmatrix}4/3 & 0\\ 0 & 4\end{pmatrix}.$$

（对角且满秩，正定，可直接求逆。可见本例特意让两类在 x_2 上都有较大离散度、在 x_1 上较集中。）

步骤 3 | 求 Fisher 方向

$$S_W^{-1} = \begin{pmatrix}3/4 & 0\\ 0 & 1/4\end{pmatrix}, \qquad S_W^{-1}\boldsymbol{\delta} = \begin{pmatrix}3/4 & 0\\ 0 & 1/4\end{pmatrix}\begin{pmatrix}-3\\0\end{pmatrix} = \begin{pmatrix}-9/4\\0\end{pmatrix} \propto \begin{pmatrix}-1\\0\end{pmatrix}.$$

所以最优投影方向 $\mathbf{w} \propto (-1,0)^T$，即沿第 1 维方向——这完全合理：两类均值差只体现在 x_1，且 x_1 的类内方差（$4/3$）远小于 x_2（4），Fisher 自然选择“类内紧、类间远”的 x_1 轴。

步骤 4 | 算比值验证 取 $\mathbf{w} = (-1,0)^T$：投影均值 $m_1 = \mathbf{w}^T\boldsymbol{\mu}_1 = -4/3$，$m_2 = -13/3$，差 $m_1 - m_2 = 3$，平方差 9；分母 $\mathbf{w}^T S_W \mathbf{w} = (-1,0)S_W(-1,0)^T = 4/3$。

$$J(\mathbf{w}) = \frac{9}{4/3} = \frac{27}{4} = 6.75.$$

> **对比（常见误区演示）**：若改取 $\mathbf{w} = (0,-1)^T$（沿 x_2 投影），则 $m_1 = m_2 = -2$，分子为 0，$J = 0$。说明“方差大、且两类均值又相同”的维度对分类毫无贡献——这正是 Fisher 比值自动规避的方向。

3.9 数值演练：Logistic 的一步梯度下降

> **编者示例（自编题，一维便于手算）**：取 $d = 1$，单样本 $x = 2$，标签 $y = 1$。初始 $\mathbf{w} = 0$, $b = 0$，学习率 $\eta = 0.1$（用梯度下降最小化 J）。

步骤 1 | 前向 $z = \mathbf{w}x + b = 0$，$\sigma(0) = 1/(1+1) = 0.5$，故预测概率 $p = 0.5$。

步骤 2 | 梯度 由 3.6.4：

$$\frac{\partial J}{\partial \mathbf{w}} = (p-y)x = (0.5-1)\cdot 2 = -1, \qquad \frac{\partial J}{\partial b} = p - y = -0.5.$$

步骤 3 | 更新（下降）

$$\mathbf{w} \leftarrow 0 - \eta(-1) = 0.1, \qquad b \leftarrow 0 - \eta(-0.5) = 0.05.$$

步骤 4 | 再前向看效果 新 $z = 0.1 \cdot 2 + 0.05 = 0.25$，

$$p_{\text{new}} = \sigma(0.25) = \frac{1}{1+e^{-0.25}} = \frac{1}{1+0.7788} \approx 0.562.$$

预测概率从 0.5 上升到 0.562，朝着真实标签 $y=1$ 移动。

> **直觉对应**：对正样本，因 $p < y$，误差 $p - y < 0$，梯度为负，下降使权重增大 $\Rightarrow$ 分数 z 增大 $\Rightarrow$ 概率 p 增大。与 3.6.4 的结论自洽。

3.10 本章要点回顾

- **几何**：$g(\mathbf{x}) = \mathbf{w}^T\mathbf{x} + b$；有符号距离 $r = g(\mathbf{x})/\|\mathbf{w}\|$ 含方向与远近；增广表示不改变原始空间里分母为 $\|\mathbf{w}\|$ 的事实。
- **距离**：选距离前先想编码是否合理；马氏距离需 Σ 正定；余弦是“相似度”不是“距离”。
- **评价**：准确率在不平衡数据上会骗人；精确率/召回率/F_1 更关注正类；ROC/AUC 衡量排序、不指定阈值。
- **感知机**：更新使该样本带标签分数增 $\eta\|\tilde{\mathbf{x}}\|^2$；仅线性可分时保证收敛；XOR 不可分。
- **Fisher**：最大化 $J = \mathbf{w}^T S_B \mathbf{w} / (\mathbf{w}^T S_W \mathbf{w})$，解 $\mathbf{w} \propto S_W^{-1}\boldsymbol{\delta}$；$S_W$ 奇异时加 λI 正则（需说明依据）；Fisher 只给方向，阈值另定。
- **Logistic**：由 $\log \frac{p}{1-p} = z$ 推出 $\sigma(z)$；交叉熵梯度 $\nabla_{\mathbf{w}} J = \frac{1}{N}\sum(p_i - y_i)\mathbf{x}_i$，依赖 $\sigma' = p(1-p)$；完全可分无正则时可能无有限解。

> 编者提示：手算以上任一小例题前，先遮住解答、自行写出假设与维度，再对照——这是把“看懂”变成“会推”的关键。

第四章 非线性分类：划分、邻域、组合与核

> 往年资料：S23 4–42 页（决策树）、44–59 页（近邻）；S24 3–26 页（集成）、28–49 页（SVM）。本年度对应课件尚未提供。2026-10-30 已视觉核对 S23 19、27–39 页与 S24 12、23–26 页，并恢复西瓜决策树和 AdaBoost 三轮原例；其余页仍属于往年资料待核对范围，不据此推定本年度考试内容。

本章线索：直线分不开两类时，至少有四种思路。一是**划分**——用一串“某个特征是否小于阈值”的简单问题，把空间切成矩形区域（决策树）；二是**邻域**——不拟合全局面，直接用最近样本的多数票决定类别（k 近邻）；三是**组合**——把多个弱模型按规则融合成强模型（集成、AdaBoost）；四是**核**——把样本映射到高维，使原本分不开的数据变得线性可分（SVM + 核技巧）。四种思路在“非线性”这个主题下汇合。

读本章前建议先掌握：熵与信息量的直觉（可先读第八章）、向量内积与超平面、梯度/求导、KL 散度方向。本仓库 log 默认自然对数；以 2 为底写作 $\log_2$，单位 bit。向量 $\mathbf{x}_i \in \mathbb{R}^d$ 为列向量，标签在树与近邻中按类别记号（如 c），在 AdaBoost 与 SVM 中为 $y_i \in \{-1, +1\}$。

4.1 决策树：一连串简单问题组成复杂边界

4.1.1 直觉：为什么“问问题”能造出曲线边界

直线无法分开的两类样本，可以通过“第一个特征是否小于某个阈值” “第二个特征是否属于哪一段”等条件**逐层划分**。每个内部节点问一个 yes/no 问题，每条边对应一个答案，叶子给出最终预测。

关键事实：一棵**轴对齐的二叉树**会在特征空间切出一块块矩形区域；把这些矩形边界拼起来，就得到了可以弯来弯去的非线性决策边界。所以决策树的重点**不是把树画出来**，而是决定“每一步该问哪一个问题”——也就是每一步该按哪个特征、哪个阈值来切分，才能让剩下的不确定性下降得最快。

4.1.2 不纯度：用一个数衡量“这一堆样本有多乱”

设当前节点拥有样本集合 D，其中第 c 类所占比例为 p_c（于是 $\sum_c p_c = 1$，$p_c \geq 0$）。我们要用一个标量 $U(D)$ 表示“这堆样本有多不纯”：纯节点（全是一类）时 $U = 0$；越杂乱 U 越大。

最常用的两个度量：

$$H(D) = -\sum_c p_c \log_2 p_c, \qquad G(D) = 1 - \sum_c p_c^2.$$

约定 $0 \log_2 0 = 0$（取极限 $\lim_{p \to 0^+} p \log_2 p = 0$）。

维度与符号说明

- D：某个节点的样本集合，大小为 $|D|$。
- K：类别数，$c = 1, \ldots, K$。
- $p_c \in [0, 1]$，$\sum_c p_c = 1$；这是**比例**，所以 H 与 G 都不依赖 $|D|$ 的绝对大小。
- 熵 $H(D)$ 的单位是 bit（因为用了 $\log_2$）；范围 $[0, \log_2 K]$。
- 基尼 $G(D)$ 的范围是 $[0, 1 - 1/K]$；它是“随机抽两个样本、类别不同”的概率。

过程讲解：为什么纯节点时两者为零、均匀时最大

1. 纯节点：某一类 $p_{c^*}=1$，其余 $p_c=0$。代入熵：

$$H(D)=-(1)\log_2(1)-\sum_{c\neq c^*}0\cdot\log_2 0=0-0=0.$$

   代入基尼：$G(D)=1-(1^2+0+\cdots)=0$。

2. 多类均匀：$p_c=1/K$ 对所有 c。熵：

$$H(D)=-\sum_{c=1}^{K}\frac{1}{K}\log_2\frac{1}{K}=-K\cdot\frac{1}{K}(-\log_2 K)=\log_2 K,$$

   达到上界（最不纯）。基尼：

$$G(D)=1-\sum_{c=1}^{K}\frac{1}{K^2}=1-\frac{K}{K^2}=1-\frac{1}{K},$$

   同样最大。

> **记住**：熵和基尼都衡量“不纯”，0 表示纯、0 之外越大越乱。两者在二分类时高度相关，基尼可看作熵的二次近似（差异不超过约 0.1 bit），但基尼**不用算对数**，所以 CART 更常用基尼做分裂标准。

小数值例子（二分类）

取节点“4 正 4 负”，则 $p_+=p_-=0.5$。

- 熵：$H=-(0.5)\log_2 0.5-(0.5)\log_2 0.5=0.5+0.5=1$ bit。
- 基尼：$G=1-(0.5^2+0.5^2)=1-0.5=0.5$。

再取子集“3 正 1 负”，则 $p_+=0.75,\ p_-=0.25$。

- 熵：$H=-(0.75)\log_2 0.75-(0.25)\log_2 0.25$。先算 $\log_2 0.75=\ln 0.75/\ln 2\approx -0.28768/0.69315\approx -0.41504$，$\log_2 0.25=-2$。于是

$$H\approx -0.75(-0.41504)-0.25(-2)=0.31128+0.5=0.81128\ \text{bit}.$$

- 基尼：$G=1-(0.75^2+0.25^2)=1-(0.5625+0.0625)=1-0.625=0.375$。

4.1.3 信息增益：切一刀能减少多少“乱”

选定属性 a 做划分，会产生若干个子集 D_v（v 枚举该属性的不同取值或区间），子集大小 $|D_v|$，占总体的比例 $|D_v|/|D|$。**划分后的平均不纯度**用子集大小加权：

$$\mathrm{Gain}(D,a)=H(D)-\sum_{v}\frac{|D_v|}{|D|}H(D_v).$$

过程讲解：这个公式从哪来

1. **起点**：我们希望切分后“剩下的不确定性”尽量小。先算未划分前的不纯度 $H(D)$。
2. **按子集加权**：划分不是只产生一个子集，而是 V 个。一个随机样本落入子集 v 的概率就是 $|D_v|/|D|$，所以划分后的期望（平均）熵是

$$\mathbb{E}_v[H(D_v)]=\sum_{v}\frac{|D_v|}{|D|}H(D_v).$$

3. **增益 = 减少量**：用“切之前的不纯度”减“切之后的平均不纯度”：

$$\mathrm{Gain}(D,a) = H(D) - \sum_v \frac{|D_v|}{|D|} H(D_v).$$

4. **结论与条件**：增益非负（因为父节点的熵 $\geq$ 子集加权熵，信息不等式）；增益越大，这一刀越值得切。决策树每一步在所有候选属性里选 $\arg\max_a \mathrm{Gain}(D,a)$。成立前提是 p_c 用经验频率估计、各子集互斥且并起来等于 D。

> **直觉**：权重按子集大小算，是因为我们关心“一个随机样本被划分后”的平均不确定性，而不是“最大的子集有多纯”。

自编例（保留并核算）

节点有 4 正 4 负，熵为 1 bit；划分为两个大小均为 4 的子集，分别 3 正 1 负与 1 正 3 负。两个子集熵都约为 0.811278 bit，于是加权平均不纯度

$$\sum_v \frac{|D_v|}{|D|} H(D_v) = \frac{4}{8} \cdot 0.811278 + \frac{4}{8} \cdot 0.811278 = 0.811278.$$

增益

$$\mathrm{Gain} = 1 - 0.811278 = 0.188722 \text{ bit}.$$

同一例的基尼视角：父节点 $G = 0.5$，两子集各 $G = 0.375$，加权平均 0.375，基尼下降量 $= 0.5 - 0.375 = 0.125$。ID3 用熵增益、CART 用基尼下降，目标一致。

4.1.3a 往年课件原例：17 个西瓜样本怎样长成决策树

> **来源性质**：S23 37–39 页，往年课件原例。这里保留教师展示的数据、信息增益和最终树；中间算式由编者补齐。它不是前面的自编 8 样本小例。

课件使用 6 个离散属性和二分类标签：

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

全体有 8 个好瓜、9 个坏瓜，因此根节点熵为

$$H(D) = -\frac{8}{17}\log_2\frac{8}{17} - \frac{9}{17}\log_2\frac{9}{17} \approx 0.998.$$

以“色泽”为例，三个子集分别为青绿 6 个（3 好 3 坏）、乌黑 6 个（4 好 2 坏）、浅白 5 个（1 好 4 坏）：

$$H(D_{\text{青绿}}) = 1, \quad H(D_{\text{乌黑}}) \approx 0.918, \quad H(D_{\text{浅白}}) \approx 0.722,$$

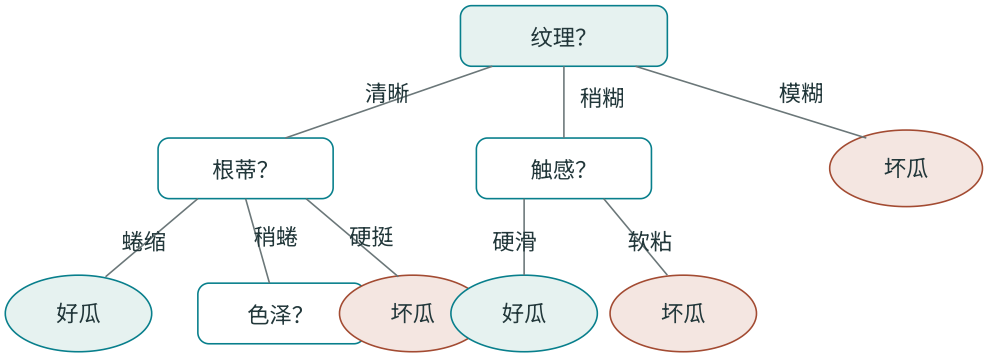
$$\text{Gain}(D, \text{色泽}) = 0.998 - \left(\frac{6}{17}\times 1 + \frac{6}{17}\times 0.918 + \frac{5}{17}\times 0.722\right) \approx 0.109.$$

同样计算其余属性，课件给出：

属性	色泽	根蒂	敲声	纹理	脐部	触感
信息增益	0.109	0.143	0.141	**0.381**	0.289	0.006

所以根节点选择“纹理”。随后在每个分支内只用该分支的样本重新计算增益，而不是继续沿用根节点的数值。

西瓜决策树：根节点按纹理划分



“稍蜷”分支继续按色泽与触感划分；图中省略三级叶的重复标签。

> **为什么必须逐层重算**：进入“纹理=清晰”后，样本集合已经从 17 个变成 9 个，类别比例和属性取值比例都变了。若仍用根节点的 $0.143, 0.141, \ldots$ 排序，就不是在优化当前节点。

4.1.4 增益率与“IV=0 不能做除法”

信息增益有个毛病：**偏好把数据切得很碎的属性。**一个取值特别多的属性，几乎能把每个样本单独切成一个子集（每个子集纯得不能再纯），增益看着很高，但显然过拟合。

C4.5 用**增益率**修正：再除以划分自身的“内在信息量”

$$IV(a) = -\sum_{v} \frac{|D_v|}{|D|} \log_2 \frac{|D_v|}{|D|}, \qquad \mathrm{GainRatio}(D,a) = \frac{\mathrm{Gain}(D,a)}{IV(a)}.$$

$IV(a)$ 衡量“这次划分本身有多碎”——子集越平均、数量越多，IV 越大，从而压低增益率。

过程讲解

1. $IV(a)$ 的式子和熵一模一样，只是把“类别比例”换成了“子集大小比例”，所以它越大表示划分越分散。
2. 增益率是“单位划分代价换来的不确定性下降”，避免只为追求高增益而过度碎片化。

IV=0 的处理（重点）

当某个划分把所有样本放进**同一个**子集时，只有一个 v 满足 $|D_v|/|D| = 1$，其余为 0。此时

$$IV(a) = -\left(1 \cdot \log_2 1\right) - \sum_{v \neq v^*} \left(0 \cdot \log_2 0\right) = 0.$$

分母为零，**增益率无定义，绝不能做除法。**同理，分母极小也会让比值爆炸、极不稳定。

> **常见误区**：以为“取增益率最大”就是 C4.5 的全部。其实 C4.5 的实用做法是**两步法**：先只在“信息增益高于平均水平”的候选属性里考虑，再从中选增益率最大者。这样天然过滤掉了 $IV = 0$（此时增益也必然为 0）和那些增益太低的属性；同时它也能缓解增益率“矫枉过正、反而偏好取值少的属性”的问题。总之：增益率不是银弹，分母接近 0 时必须特殊处理。

IV 数值例子

- 50–50 二分（如上面两个大小均为 4 的子集）：$IV = -(0.5)\log_2 0.5 - (0.5)\log_2 0.5 = 1$。
- 八等分（把 8 个样本切成 8 个单点子集）：$IV = -8 \cdot (1/8)\log_2(1/8) = \log_2 8 = 3$。

前者增益 0.188722、增益率 $0.188722/1 = 0.188722$；后者把每个样本切到纯叶子、增益可达 1，但 $IV = 3$、增益率仅 $1/3$——可见增益率确实压低了“高碎片化”属性的优势，但它也可能过度惩罚（经典的 C4.5 两步法正是为此而生）。

4.1.5 连续属性、CART 与剪枝

- **连续属性**：排序后用“相邻不同取值的中点”作候选阈值。若有 m 个不同取值，非空二分最多有 $m-1$ 个候选切点位置。课件有时按“样本值个数”描述候选问题数，那是另一种计数约定，不能直接和“有效非空划分数”混用。
- **CART 分类树**：通常选**加权基尼下降最大**的二叉划分（每个内部节点只做二分裂）。
- **过拟合与剪枝**：递归生长会把噪声也记进叶子。
  - 预剪枝：分裂前就用验证准则（如纯度增益不够就不分裂）决定是否停止。
  - 后剪枝：先长成一棵大树，再用验证集表现或“误差 + 叶子数代价”决定是否把某子树收回成叶子。

> **记住**：如果用训练集纯度去评判剪枝效果，就失去了“防训练集过拟合”的初衷——必须用独立的验证集（或复杂度代价准则）来定剪枝。

4.2 最近邻：让局部样本决定类别

4.2.1 直觉：不拟合全局面，只靠“身边人”投票

k 近邻（kNN）的做法：来一个新样本 $\mathbf{x}$，先算它到所有训练样本的距离，取最近的 k 个，再让这 k 个邻居按“多数类别”投票决定 $\mathbf{x}$ 的类别。这里**没有任何训练阶段去拟合一个全局超平面**——边界由“存下来的样本 + 距离度量”共同决定，是“基于记忆”的方法。

- $k = 1$：边界就是 Voronoi 图，对噪声极敏感（一个标错的点会直接决定一块区域）。
- k 太大：会抹平局部结构，边界变平滑甚至退化为“按全体多数”预测。
- 实操中 k 要通过验证集选择，并事先规定“距离并列”和“票数并列”的处理方式。

4.2.2 量纲：距离对尺度极度敏感

量纲特别重要。若“行走速度”取值在 0–100，而“头发比例”在 0–1，直接套欧氏距离，几乎全在比速度，头发比例被淹没。标准化（减均值除标准差）的参数**只能从训练集估计**，再应用到验证/测试集；高维时距离还可能变得“都差不多大”，不能想当然认为“加更多属性一定更好”。

4.2.3 三角不等式下界加速检索

朴素检索每次要对全部 N 个样本做约 $O(Nd)$ 的距离运算。当样本按某种结构分成若干子集（课件讨论树状子集搜索、剪辑、压缩等），可用**三角不等式**跳过显然不可能的子集。

过程讲解：下界从哪来

设某个子集被一个以 $\mathbf{m}$ 为球心、半径 r 的球覆盖，即子集内任一点 $\mathbf{z}$ 都满足 $\|\mathbf{z}-\mathbf{m}\| \le r$。对任意查询点 $\mathbf{x}$，由三角不等式（任意三点满足 $\|\mathbf{x}-\mathbf{z}\| \ge \|\mathbf{x}-\mathbf{m}\| - \|\mathbf{m}-\mathbf{z}\|$）：

$$\|\mathbf{x}-\mathbf{z}\| \;\ge\; \|\mathbf{x}-\mathbf{m}\| - \|\mathbf{m}-\mathbf{z}\| \;\ge\; \|\mathbf{x}-\mathbf{m}\| - r.$$

因为距离非负，再与 0 取大：

$$\min_{\mathbf{z}\in\text{子集}} \|\mathbf{x}-\mathbf{z}\| \;\ge\; \max\bigl(0,\; \|\mathbf{x}-\mathbf{m}\| - r\bigr) \;\equiv\; L_{\text{lb}}.$$

- **符号**：$r > 0$ 为球半径；$\mathbf{m}, \mathbf{x}, \mathbf{z} \in \mathbb{R}^d$；$\|\cdot\|$ 为欧氏范数。
- **结论与成立条件**：若当前已找到的最近距离为 d_{nn}，且 $L_{\text{lb}} > d_{\text{nn}}$，那么整个子集里没有任何点能比当前最近点更近，可安全跳过该子集。前提是该球**确实覆盖**子集（否则下界不成立）。
- **局限**：高维或非度量相似性下，这种加速未必有效（“维度灾难”会让球心与边界的差距失去区分度）。

小数值例子

球心 $\mathbf{m} = (0, 0)$，半径 $r = 1$；查询点 $\mathbf{x} = (3, 0)$。则 $\|\mathbf{x}-\mathbf{m}\| = 3$，下界

$$L_{\text{lb}} = \max(0, 3 - 1) = 2.$$

若当前最近距离 $d_{\text{nn}} = 1.5 < 2$，则整个球内都不可能有更近的点，直接跳过。

4.2.4 剪辑、压缩近邻与拒绝分类

- **剪辑近邻（Edited NN）**：删去“和邻居标签不一致”的点，倾向减少噪声。
- **压缩近邻（Condensed NN）**：保留“对当前原型集而言会被错分”的样本，逐步压缩存储规模。
- 二者目标不同，且都可能丢掉的**稀有但真实的模式**，要谨慎。
- **拒绝分类**：当邻域支持不足（如 k 个邻居里各类票数太接近、或最近距离过大）时不输出类别。必须单独报告**拒绝率**与**已接受样本的错误率**，二者不可混为一谈。

4.3 集成：组合必须保留有用差异

4.3.1 直觉：为什么“多个模型投票”可能更好

只有当多个模型**会犯不同的错误**时，组合才可能改善结果；若大家错得完全一样，组合毫无收益。所以集成的核心不是“模型多”，而是“模型之间保留有用差异”。

4.3.2 平均融合及其 KL 方向（重点推导）

设第 m 个模型给出的类后验为 $p_m(c)$，$m=1,\dots,M$，c 为类别；融合结果记为 $q(c)$，满足 $\sum_c q(c)=1,\ q(c)\geq 0$。

两种融合

- 算术平均：$q(c)=\dfrac{1}{M}\sum_{m=1}^{M} p_m(c)$。
- 归一化几何平均：$q(c)\propto \prod_{m=1}^{M} p_m(c)^{1/M}$，即 $q(c)=\dfrac{\prod_m p_m(c)^{1/M}}{\sum_{c'}\prod_m p_m(c')^{1/M}}$。

> **常见误区**：几何平均对某个模型给出的**零概率**极其敏感——一旦有模型在某类上给 0，几何平均也会给 0，即使其他模型很有把握。算术平均则不会。

过程讲解（一）：为什么算术平均来自 $\sum_m D_{KL}(p_m\|q)$

KL 散度方向不能省略。先证“前向”平均得到算术平均。目标：在约束 $\sum_c q(c)=1$ 下最小化

$$J_{\text{fwd}}(q)=\sum_{m=1}^{M} D_{KL}(p_m\|q)=\sum_m\sum_c p_m(c)\log\frac{p_m(c)}{q(c)}.$$

1. **展开**：把对数拆开，

$$J_{\text{fwd}}=\underbrace{\sum_m\sum_c p_m(c)\log p_m(c)}_{\text{与 } q \text{ 无关}}-\sum_m\sum_c p_m(c)\log q(c).$$

   优化只看第二项（带负号）。

2. **带约束写拉格朗日**：引入乘子 λ 处理 $\sum_c q(c)=1$，

$$\mathcal{L}=-\sum_m\sum_c p_m(c)\log q(c)+\lambda\left(\sum_c q(c)-1\right).$$

3. **对 $q(c)$ 求导并置零**：

$$\frac{\partial\mathcal{L}}{\partial q(c)}=-\frac{\sum_m p_m(c)}{q(c)}+\lambda=0\ \Longrightarrow\ q(c)=\frac{\sum_m p_m(c)}{\lambda}.$$

4. **用归一化定 λ**：

$$1=\sum_c q(c)=\frac{\sum_m\sum_c p_m(c)}{\lambda}=\frac{M}{\lambda}\ \Longrightarrow\ \lambda=M.$$

5. **结论**：

$$q(c)=\frac{1}{M}\sum_{m=1}^{M} p_m(c),$$

正是**算术平均**。成立条件：$\sum_c q(c)=1$，且对所有 c 有 $\lambda>0$（这里 $\lambda=M>0$ 满足）。

过程讲解（二）：为什么归一化几何平均来自 $\sum_m D_{KL}(q\|p_m)$

再把方向反过来——让 q 去逼近各 p_m（“反向”平均），目标：

$$J_{\text{rev}}(q)=\sum_{m=1}^{M} D_{KL}(q\|p_m)=\sum_m\sum_c q(c)\log\frac{q(c)}{p_m(c)}.$$

1. **展开并提取公因式**：

$$J_{\text{rev}}=\sum_c q(c)\sum_m\log\frac{q(c)}{p_m(c)}=\sum_c q(c)\Big(M\log q(c)-\sum_m\log p_m(c)\Big).$$

2. **拉格朗日**（约束 $\sum_c q(c)=1$，乘子 λ）：

$$\mathcal{L}=\sum_c q(c)\Big(M\log q(c)-\sum_m\log p_m(c)\Big)+\lambda\left(\sum_c q(c)-1\right).$$

3. **对 $q(c)$ 求导**：注意 $\frac{d}{dq}(q\log q)=\log q+1$，

$$\frac{\partial\mathcal{L}}{\partial q(c)}=M(\log q(c)+1)-\sum_m\log p_m(c)+\lambda=0.$$

4. **解出 $q(c)$**：

$$M\log q(c)=\sum_m\log p_m(c)-M-\lambda\implies\log q(c)=\frac{1}{M}\sum_m\log p_m(c)-(1+\lambda/M).$$

指数化：

$$q(c)=\exp\left(\frac{1}{M}\sum_m\log p_m(c)\right)\cdot e^{-(1+\lambda/M)}=\left(\prod_{m=1}^{M}p_m(c)\right)^{1/M}\cdot\text{常数}.$$

5. **归一化定常数**：

$$q(c)=\frac{\prod_{m=1}^{M}p_m(c)^{1/M}}{\sum_{c'}\prod_{m=1}^{M}p_m(c')^{1/M}}.$$

这正是**归一化几何平均**。

> **记住**：方向是关键——
>
> - $\min\sum_m D_{KL}(p_m\|q)$ → 算术平均（让 q 被各 p_m “拉向自己”的平均）；
> - $\min\sum_m D_{KL}(q\|p_m)$ → 归一化几何平均（让 q 去“覆盖”各 p_m）。 丢掉方向，两套融合就分不清了。

4.3.3 多数投票与独立性的收益

假设有**奇数** M 个二分类器，相互独立、各自正确概率同为 p。要“多数正确”，即正确数 $\geq(M+1)/2$。令 j 为正确分类器个数（服从二项分布 $\text{Bin}(M,p)$），多数投票正确率为

$$\sum_{j=(M+1)/2}^{M}\binom{M}{j}p^j(1-p)^{M-j}.$$

过程讲解

1. **假设**：M 为奇数（避免平票）；各分类器独立同分布，正确概率 $p \in (0,1)$。
2. **单点概率**：恰有 j 个正确的概率是 $\binom{M}{j}p^j(1-p)^{M-j}$（选哪 j 个对、各自以 p 对、其余以 $1-p$ 错）。
3. **求和**：把所有“正确的个数达到多数”的情形加起来，下界为 $(M+1)/2$。

保留数值例（核算）：$M=3,\ p=0.7$。

$$\begin{aligned} P(\text{正确}) &= \binom{3}{2}0.7^2\cdot 0.3 + \binom{3}{3}0.7^3 \\ &= 3\cdot 0.49\cdot 0.3 + 0.343 \\ &= 0.441 + 0.343 = 0.784. \end{aligned}$$

单个分类器只有 0.7 正确率，三个独立投票后升到 0.784。

再多看一眼（补充小例）：取 $M=5,\ p=0.6$。

$$\begin{aligned} P &= \binom{5}{5}0.6^5 + \binom{5}{4}0.6^4\cdot 0.4 + \binom{5}{3}0.6^3\cdot 0.4^2 \\ &= 0.07776 + 5\cdot 0.1296\cdot 0.4 + 10\cdot 0.216\cdot 0.16 \\ &= 0.07776 + 0.2592 + 0.3456 = 0.68256. \end{aligned}$$

单个 0.6 的弱分类器，五个独立投票后约 0.683——集成确实把“弱”变“强”。

> **常见误区**：独立性是理想假设。若 M 个分类器完全一样（相关系数 1），投票等于只用其中一个，收益为 0。这也是为什么随机森林要“每棵树随机选属性”、Bagging 要“用不同自助样本”来制造差异。

4.3.4 Bagging 与随机森林

- **Bagging**：用多个**自助样本**（有放回抽样）各训一个模型，再平均/投票。自助抽样天然让不同模型看到不同数据，制造差异。
- **随机森林**：在 Bagging 基础上，每个树节点再从全部属性里**随机选一部分**作为候选分裂属性，进一步降低树间相关性。
- **记住**：随机性本身不保证每个模型都强，也不保证组合一定优于任意单棵树；要由验证集比较，而不是想当然。

4.4 AdaBoost：逐轮关注难样本

4.4.1 直觉：把注意力放在老犯错的地方

AdaBoost 也是加法集成，但更聪明：每一轮训练一个弱分类器后，会**提高被它错分样本的权重**、降低被正确分类样本的权重，于是下一轮弱分类器被迫去“啃”之前难分的点。最终把所有弱分类器按“它有多靠谱”加权组合。

记号：标签 $y_i \in \{-1,+1\}$，基分类器 $h_t(\mathbf{x}) \in \{-1,+1\}$。加法模型在第 t 轮为

$$F_t(\mathbf{x}) = F_{t-1}(\mathbf{x}) + \alpha_t h_t(\mathbf{x}),$$

目标是最小化指数损失 $\sum_i e^{-y_i F_t(\mathbf{x}_i)}$。

4.4.2 指数损失对 α_t 的求导（核心推导）

符号与假设

- $D_t(i) \ge 0$ 为第 t 轮归一化样本权重，$\sum_{i=1}^N D_t(i) = 1$。它正比于前一轮的指数损失项：$D_t(i) \propto e^{-y_i F_{t-1}(\mathbf{x}_i)}$。

- 固定本轮弱分类器 h_t 后，其**加权错误率**

$$\epsilon_t = \sum_{i:\, h_t(\mathbf{x}_i)\neq y_i} D_t(i), \qquad \text{于是正确部分权重之和} = 1-\epsilon_t.$$

- 我们只在 α 上优化（分类器已定）。

过程讲解：把目标函数写成只关于 α 的式子

1. **起点**：这轮要最小化的指数损失（把归一化常数吸收掉，不影响 α 的最优点）为

$$Z_t(\alpha) = \sum_{i=1}^{N} D_t(i)\, e^{-\alpha\, y_i h_t(\mathbf{x}_i)}.$$

2. **按对错分两类**：
   - 正确样本：$y_i h_t(\mathbf{x}_i) = +1$，指数项 $= e^{-\alpha}$，其权重和 $= 1-\epsilon_t$。
   - 错误样本：$y_i h_t(\mathbf{x}_i) = -1$，指数项 $= e^{+\alpha}$，其权重和 $= \epsilon_t$。

3. **化简**（这就是教材里的 $Z(\alpha)$）：

$$Z_t(\alpha) = (1-\epsilon_t)e^{-\alpha} + \epsilon_t e^{\alpha}.$$

4. **一阶导并置零**：

$$\frac{dZ_t}{d\alpha} = -(1-\epsilon_t)e^{-\alpha} + \epsilon_t e^{\alpha} \overset{!}{=} 0.$$

   移项：

$$\epsilon_t e^{\alpha} = (1-\epsilon_t)e^{-\alpha}.$$

5. **解出 α**：两边同乘 e^{α}，

$$\epsilon_t e^{2\alpha} = 1-\epsilon_t \implies e^{2\alpha} = \frac{1-\epsilon_t}{\epsilon_t} \implies 2\alpha = \log\frac{1-\epsilon_t}{\epsilon_t}.$$

   故

$$\boxed{\alpha_t = \frac{1}{2}\log\frac{1-\epsilon_t}{\epsilon_t}}.$$

6. **二阶导验证是最小值**：

$$\frac{d^2 Z_t}{d\alpha^2} = (1-\epsilon_t)e^{-\alpha} + \epsilon_t e^{\alpha} > 0,$$

   所以驻点是**全局最小**。

7. **补充结论（最小值）**：把 α_t 代回，可得最小损失

$$Z_t^{\min} = 2\sqrt{\epsilon_t(1-\epsilon_t)}.$$

   验证：α_t 处 $e^{-\alpha_t} = \sqrt{\epsilon_t/(1-\epsilon_t)}$，$e^{\alpha_t} = \sqrt{(1-\epsilon_t)/\epsilon_t}$，两项相加得 $2\sqrt{\epsilon_t(1-\epsilon_t)}$。

保留数值例（核算）：取 $\epsilon_t = 0.3$。

$$\alpha_t = \frac{1}{2}\log\frac{1-0.3}{0.3} = \frac{1}{2}\log\frac{0.7}{0.3} = \frac{1}{2}\log\frac{7}{3}.$$

$\log(7/3) = \log(2.3333\cdots) \approx 0.847297$，所以

$$\alpha_t \approx 0.5 \times 0.847297 = 0.423649.$$

最小损失 $Z^{\min} = 2\sqrt{0.3 \times 0.7} = 2\sqrt{0.21} \approx 2 \times 0.458258 = 0.916516$。

> **记住**：$\alpha_t > 0$ 要求 $\epsilon_t < 0.5$（弱分类器必须比乱猜好）。$\epsilon_t = 0.5$ 时 $\alpha_t = 0$，该分类器不被采用；$\epsilon_t > 0.5$ 时 $\alpha_t < 0$，等于“反向”使用——通常应直接丢弃并终止。

4.4.3 权重更新与“错分点被放大多少倍”

下一轮权重在前一轮基础上乘上per-sample的指数因子，再整体归一化：

$$D_{t+1}(i) = \frac{D_t(i)\, e^{-\alpha_t\, y_i h_t(\mathbf{x}_i)}}{Z_t}.$$

过程讲解：为什么错分点的权重被放大 $e^{2\alpha_t}$ 倍

1. **正确样本**：$y_i h_t(\mathbf{x}_i) = +1$，分子中因子 $= e^{-\alpha_t}$。
2. **错误样本**：$y_i h_t(\mathbf{x}_i) = -1$，分子中因子 $= e^{+\alpha_t}$。
3. **比值**：错误/正确的权重倍率

$$\frac{e^{+\alpha_t}}{e^{-\alpha_t}} = e^{2\alpha_t}.$$

4. **代入 α_t 的闭式**：

$$e^{2\alpha_t} = e^{\log \frac{1-\epsilon_t}{\epsilon_t}} = \frac{1-\epsilon_t}{\epsilon_t}.$$

保留数值例（核算）：$\epsilon_t = 0.3$ 时

$$e^{2\alpha_t} = \frac{1-0.3}{0.3} = \frac{0.7}{0.3} = \frac{7}{3} \approx 2.3333.$$

即**错分点相对正确点被放大 $7/3$ 倍**——这正是 AdaBoost“逐轮关注难样本”的量化表达。

4.4.3a 往年课件原例：三轮 AdaBoost 的数字怎样串起来

> **来源性质**：S24 23–26 页，往年课件原例。课件用 10 个二维样本和三个轴对齐弱分类器演示三轮更新。图中“0.1、0.233、0.3664”是同一比例尺度下的未归一化权重；计算每轮错误率时再除以权重总和。

初始每个样本权重为 0.1。第一轮弱分类器错 3 个样本：

$$p_1 = 3 \times 0.1 = 0.3, \qquad \alpha_1 = \frac{1}{2}\ln\frac{1-p_1}{p_1} = \frac{1}{2}\ln\frac{0.7}{0.3} \approx 0.4236.$$

按课件采用的等价更新写法，正确样本保持 0.1，错分样本乘 $(1-p_1)/p_1 = 7/3$，所以错分样本变成 0.2333。第二个弱分类器错的是 3 个仍为 0.1 的样本，故归一化后的错误率是

$$p_2 = 3\frac{0.1}{7 \times 0.1 + 3 \times 0.2333} \approx 0.2144, \qquad \alpha_2 = \frac{1}{2}\ln\frac{1-p_2}{p_2} \approx 0.6493.$$

第二轮错分样本的新未归一化权重为

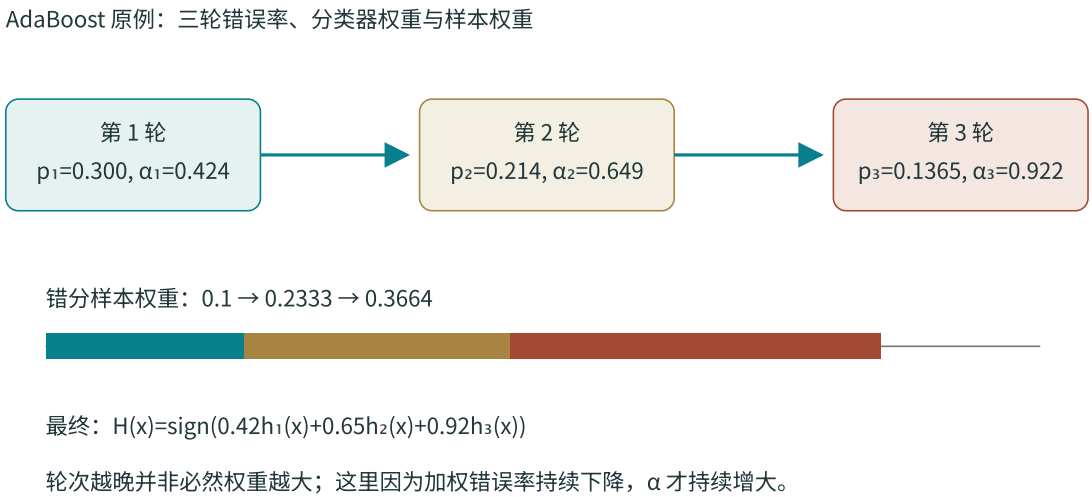
$$0.1\frac{1-0.2144}{0.2144} \approx 0.3664.$$

第三个弱分类器又错 3 个原权重为 0.1 的样本，而当前总权重由 4 个 0.1、3 个 0.2333、3 个 0.3664 组成：

$$p_3 = 3\frac{0.1}{4\times 0.1 + 3\times 0.2333 + 3\times 0.3664} \approx 0.1365, \qquad \alpha_3 \approx \frac{1}{2}\ln\frac{0.8635}{0.1365} \approx 0.9223.$$

最后组合为

$$H(\mathbf{x}) = \operatorname{sign}\big(0.42h_1(\mathbf{x}) + 0.65h_2(\mathbf{x}) + 0.92h_3(\mathbf{x})\big).$$



> **易混点**：p_t 是按当前样本权重计算的加权错误率，不是“错了几个点除以 10”。第二、三轮虽然仍各错 3 个点，p_2, p_3 却不断下降，因为它们错到的是当前权重较小的点。

4.4.4 终止与数值保护

- $\epsilon_t = 0$（完全可分）：理论上 $\alpha_t \to \infty$，应**终止训练**或对该轮设数值保护（如限制 α_t 上限）。
- $\epsilon_t \geq 0.5$：不能继续当作“正权重弱分类器”处理，通常停止。
- 注意：持续把注意力压在“始终学不会的噪声点”上，也可能伤害泛化——权重更新不是越极端越好。

4.5 SVM：选择几何间隔最大的面

4.5.1 直觉：分离面有很多，挑“最宽”的那条

线性可分的数据通常有无数个能把两类分开的超平面。SVM 的准则是：在所有能分开两类的面里，选**离最近样本最远**的那个——也就是几何间隔最大的面。这样做直觉上最“稳”，对新样本最不容易跨错边界。

4.5.2 函数间隔与几何间隔

对超平面 $g(\mathbf{x}) = \mathbf{w}^T\mathbf{x} + b = 0$（$\mathbf{w} \in \mathbb{R}^d$, $b \in \mathbb{R}$），样本 $\mathbf{x}_i$ 的**带符号距离**（函数间隔）为

$$y_i(\mathbf{w}^T\mathbf{x}_i + b).$$

它既包含“在正确一侧”（符号），也包含“离面多远”（绝对值）。

几何间隔（真正的欧氏距离）是把它除以 $\|\mathbf{w}\|$：

$$\text{几何间隔} = \frac{y_i(\mathbf{w}^T\mathbf{x}_i + b)}{\|\mathbf{w}\|}.$$

过程讲解：为什么除以 $\|\mathbf{w}\|$

1. 平面上一点到超平面的欧氏距离公式就是 $|g(\mathbf{x}_i)|/\|\mathbf{w}\|$；乘上 y_i（标签 ±1）既保留符号又给出带符号距离。
2. $\mathbf{w}$ 的尺度可任意缩放：把 $(\mathbf{w}, b)$ 换成 $(c\mathbf{w}, cb)$，函数间隔放大 c 倍，但几何间隔不变。
3. **利用这个自由度固定最小函数间隔为 1**：把所有 $(\mathbf{w}, b)$ 同比例缩放，使“最危险的点”满足 $y_i(\mathbf{w}^T\mathbf{x}_i + b) = 1$。

> **记住**：此时分类面到任意一侧支撑面的距离为 $1/\|\mathbf{w}\|$；两侧支撑面（$g = +1$ 与 $g = -1$）之间的**总宽度**为 $2/\|\mathbf{w}\|$。这两个量不要混用。

为什么宽度是 $2/\|\mathbf{w}\|$：两平行超平面 $\mathbf{w}^T\mathbf{x} + b = 1$ 与 $\mathbf{w}^T\mathbf{x} + b = -1$ 间距公式为 $|1 - (-1)|/\|\mathbf{w}\| = 2/\|\mathbf{w}\|$。最大化间隔 ⇔ 最小化 $\|\mathbf{w}\|$（或等价于最小化 $\frac{1}{2}\|\mathbf{w}\|^2$，便于求导）。

4.5.3 硬间隔原问题

$$\min_{\mathbf{w},b} \ \frac{1}{2}\|\mathbf{w}\|^2, \qquad \text{s.t.} \quad y_i(\mathbf{w}^T\mathbf{x}_i + b) \geq 1, \ \ i = 1, \ldots, N.$$

符号：$\mathbf{w} \in \mathbb{R}^d$，$b \in \mathbb{R}$，$\|\mathbf{w}\|^2 = \mathbf{w}^T\mathbf{w}$。约束要求每个样本的函数间隔至少为 1（即都在支撑面之外、被正确分类）。

4.5.4 拉格朗日对偶推导（核心推导）

过程讲解：从原问题到对偶，一步步来

1. **写拉格朗日函数**（对每个约束引入乘子 $\alpha_i \geq 0$）：

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2}\mathbf{w}^T\mathbf{w} + \sum_{i=1}^{N} \alpha_i \Big(1 - y_i(\mathbf{w}^T\mathbf{x}_i + b)\Big).$$

2. **对 $\mathbf{w}$ 求偏导并置零**（$\mathbf{w}, \mathbf{x}_i \in \mathbb{R}^d$，注意 $\nabla_{\mathbf{w}}(\mathbf{w}^T\mathbf{x}_i) = \mathbf{x}_i$）：

$$\nabla_{\mathbf{w}} L = \mathbf{w} - \sum_{i=1}^{N} \alpha_i y_i \mathbf{x}_i = 0 \implies \boxed{\mathbf{w} = \sum_{i=1}^{N} \alpha_i y_i \mathbf{x}_i}.$$

   这把权重显式写成样本的线性组合——**支撑向量机“稀疏性”的源头**：只有 $\alpha_i > 0$ 的样本（支撑向量）才出现在最终模型里。

3. **对 b 求偏导并置零**：

$$\frac{\partial L}{\partial b} = -\sum_{i=1}^{N} \alpha_i y_i = 0 \implies \boxed{\sum_{i=1}^{N} \alpha_i y_i = 0}.$$

4. **把 $\mathbf{w}$ 代回 L，消去原变量**：先展开

$$L = \frac{1}{2}\mathbf{w}^T\mathbf{w} + \sum_i \alpha_i - \sum_i \alpha_i y_i(\mathbf{w}^T\mathbf{x}_i) - b\sum_i \alpha_i y_i.$$

   最后一项因步骤 3 为 0。现在处理前两项：由步骤 2，$\mathbf{w} = \sum_j \alpha_j y_j \mathbf{x}_j$，故

$$\mathbf{w}^T\mathbf{w} = \mathbf{w}^T\Big(\sum_j \alpha_j y_j \mathbf{x}_j\Big) = \sum_j \alpha_j y_j(\mathbf{w}^T\mathbf{x}_j).$$

于是

$$\frac{1}{2}\mathbf{w}^T\mathbf{w} - \sum_i \alpha_i y_i(\mathbf{w}^T\mathbf{x}_i) = \frac{1}{2}\sum_j \alpha_j y_j(\mathbf{w}^T\mathbf{x}_j) - \sum_i \alpha_i y_i(\mathbf{w}^T\mathbf{x}_i) = -\frac{1}{2}\sum_i \alpha_i y_i(\mathbf{w}^T\mathbf{x}_i).$$

再把 $\mathbf{w}^T\mathbf{x}_i = \sum_j \alpha_j y_j(\mathbf{x}_j^T\mathbf{x}_i)$ 代入：

$$\sum_i \alpha_i y_i(\mathbf{w}^T\mathbf{x}_i) = \sum_{i,j} \alpha_i\alpha_j y_i y_j(\mathbf{x}_i^T\mathbf{x}_j).$$

所以最终

$$L = \sum_{i=1}^{N}\alpha_i - \frac{1}{2}\sum_{i=1}^{N}\sum_{j=1}^{N}\alpha_i\alpha_j y_i y_j(\mathbf{x}_i^T\mathbf{x}_j).$$

5. **得到对偶（最大化该式，约束见步骤 3 与 $\alpha_i \geq 0$）**：

$$\boxed{\max_{\boldsymbol{\alpha}} \sum_{i=1}^{N}\alpha_i - \frac{1}{2}\sum_{i,j}\alpha_i\alpha_j\, y_i y_j\, \mathbf{x}_i^T\mathbf{x}_j \quad \text{s.t.} \quad \alpha_i \geq 0,\ \sum_i \alpha_i y_i = 0.}$$

结论与成立条件：强对偶在凸二次规划 + 线性可分（Slater 条件）下成立，所以解原问题与解对偶等价。最优 $\mathbf{w}$ 由步骤 2 给出；$\alpha_i = 0$ 的样本对 $\mathbf{w}$ 无贡献，只有支撑向量（$\alpha_i > 0$）决定分界面。

4.5.5 互补松弛与支撑向量

KKT 互补松弛条件给出

$$\alpha_i\big[y_i(\mathbf{w}^T\mathbf{x}_i + b) - 1\big] = 0.$$

过程讲解：对每个样本，要么 $\alpha_i = 0$（普通点，远离边界，对模型无贡献），要么方括号为 0 即 $y_i(\mathbf{w}^T\mathbf{x}_i + b) = 1$（正好落在支撑面上，是支撑向量）。所以**只有支撑向量对应的乘子才可能非零**，这也解释了 SVM 的稀疏性。

4.5.6 一个二维小数值例（把对偶算一遍）

取两个样本：$\mathbf{x}_1 = (1,0),\ y_1 = +1$；$\mathbf{x}_2 = (-1,0),\ y_2 = -1$。显然线性可分（中间竖线即可分开）。

1. **KKT 约束**：$\alpha_1 y_1 + \alpha_2 y_2 = \alpha_1 - \alpha_2 = 0 \Rightarrow \alpha_1 = \alpha_2$（记为 α）。
2. **内积**：$x_1^T x_1 = 1,\ x_2^T x_2 = 1,\ x_1^T x_2 = -1$；$y_1 y_2 = -1$。
3. **对偶目标**：

$$\begin{aligned} J(\alpha) &= \alpha_1 + \alpha_2 - \frac{1}{2}\big[\alpha_1^2 y_1^2 x_1^T x_1 + 2\alpha_1\alpha_2 y_1 y_2 x_1^T x_2 + \alpha_2^2 y_2^2 x_2^T x_2\big] \\ &= 2\alpha - \frac{1}{2}\big[\alpha^2\cdot 1 + 2\alpha^2(-1)(-1) + \alpha^2\cdot 1\big] = 2\alpha - \frac{1}{2}(4\alpha^2) = 2\alpha - 2\alpha^2. \end{aligned}$$

4. **最大化**：$dJ/d\alpha = 2 - 4\alpha = 0 \Rightarrow \alpha = 1/2$。故 $\alpha_1 = \alpha_2 = 1/2$。
5. **反推 $\mathbf{w}, b$**：$\mathbf{w} = \alpha_1 y_1 x_1 + \alpha_2 y_2 x_2 = \frac{1}{2}(1,0) + \frac{1}{2}(1,0) = (1,0)$，$\|\mathbf{w}\| = 1$，间隔 $= 1/\|\mathbf{w}\| = 1$。由 $y_1(\mathbf{w}^T x_1 + b) = 1$ 得 $1 + b = 1 \Rightarrow b = 0$。检验 x_2：$y_2(\mathbf{w}^T x_2 + b) = (-1)(-1 + 0) = 1$，满足约束。
6. **强对偶核对**：对偶最大值 $J(1/2) = 2(1/2) - 2(1/4) = 0.5$；原问题 $\frac{1}{2}\|\mathbf{w}\|^2 = 0.5$，二者相等 ✓。两侧支撑面间距 $= 2/\|\mathbf{w}\| = 2$，正是 x_1, x_2 在 x 轴上距原点的距离之和。

4.5.7 软间隔：容忍噪声

含噪声/不可分时，引入松弛变量 $\xi_i \geq 0$，允许个别样本“越界”：

$$\min_{\mathbf{w},b,\boldsymbol{\xi}} \frac{1}{2}\|\mathbf{w}\|^2 + C\sum_{i=1}^{N}\xi_i, \qquad \text{s.t.} \quad y_i(\mathbf{w}^T\mathbf{x}_i + b) \geq 1 - \xi_i,\ \xi_i \geq 0.$$

过程讲解：$C > 0$ 是**正则强度**（见统一符号表）——C 越大越不容忍错误（越接近硬间隔），C 越小越允许误分以换更宽的间隔。对偶形式与硬间隔几乎相同，只是乘子上界变为

$$0 \leq \alpha_i \leq C.$$

（边界上的支撑向量分“在支撑面上” $\alpha_i < C$ 与“被误分/越界” $\alpha_i = C$ 两类。）

4.6 核技巧

4.6.1 直觉：升到高维，线性可分

很多数据在低维里是弯弯曲曲分不开的，但映射到一个更高（甚至无穷）维的特征空间 $\phi(\mathbf{x})$ 后，就可能变得线性可分。问题来了：高维空间里算内积 $\phi(\mathbf{x}_i)^T\phi(\mathbf{x}_j)$ 代价极高。核技巧的妙处在于——**对偶里只出现内积**，我们不必显式构造 ϕ，只要直接定义一个“内积函数” $k(\mathbf{x}_i, \mathbf{x}_j)$ 即可。

4.6.2 对偶只含内积 → 核替换

回看 4.5.4 的对偶目标，所有 $\mathbf{x}$ 都以“内积 $\mathbf{x}_i^T\mathbf{x}_j$”形式出现。定义核函数

$$k(\mathbf{x}, \mathbf{z}) = \langle \phi(\mathbf{x}), \phi(\mathbf{z}) \rangle = \phi(\mathbf{x})^T\phi(\mathbf{z}),$$

把对偶里的 $\mathbf{x}_i^T\mathbf{x}_j$ 全部替换为 $k(\mathbf{x}_i, \mathbf{x}_j)$，得到核化对偶（形式不变，只是内积换成核）。

4.6.3 预测式：核形式

训练后得到最优乘子 α_i 与偏置 b。新样本 $\mathbf{x}$ 的决策函数为

$$g(\mathbf{x}) = \sum_{i=1}^{N} \alpha_i y_i\, k(\mathbf{x}_i, \mathbf{x}) + b,$$

判定 $\hat{y} = \operatorname{sign}(g(\mathbf{x}))$。

过程讲解：这式从哪来

1. 4.5.4 给出 $\mathbf{w} = \sum_i \alpha_i y_i \mathbf{x}_i$；在特征空间应是 $\mathbf{w} = \sum_i \alpha_i y_i \phi(\mathbf{x}_i)$。
2. 于是 $g(\mathbf{x}) = \mathbf{w}^T\phi(\mathbf{x}) + b = \sum_i \alpha_i y_i\, \phi(\mathbf{x}_i)^T\phi(\mathbf{x}) + b$。
3. 用核定义 $\phi(\mathbf{x}_i)^T\phi(\mathbf{x}) = k(\mathbf{x}_i, \mathbf{x})$，即得上式。全程**不需要写出** ϕ。

小数值例子（线性核）：线性核 $k(\mathbf{u}, \mathbf{v}) = \mathbf{u}^T\mathbf{v}$，则上式退化回 $g(\mathbf{x}) = \sum_i \alpha_i y_i \mathbf{x}_i^T\mathbf{x} + b = \mathbf{w}^T\mathbf{x} + b$，与 4.5 一致（此时 ϕ 就是恒等映射）。这验证了核形式是原 SVM 的自然推广。

4.6.4 什么函数才“合法”：Gram 矩阵半正定

并非任意“相似度函数”都是合法核。判定准则（Mercer）：对任意**有限**样本集合 $\{\mathbf{x}_1, \ldots, \mathbf{x}_N\}$，由其构成的 **Gram 矩阵** $K \in \mathbb{R}^{N\times N}$，

$$K_{ij} = k(\mathbf{x}_i, \mathbf{x}_j),$$

必须是**对称半正定（PSD）**的，即对任意实向量 $\mathbf{c} \in \mathbb{R}^N$ 满足

$$\mathbf{c}^T K \mathbf{c} = \sum_{i,j} c_i c_j \, k(\mathbf{x}_i, \mathbf{x}_j) \geq 0.$$

过程讲解

1. **为什么必须对称**：$k(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j) = \phi(\mathbf{x}_j)^T \phi(\mathbf{x}_i) = k(\mathbf{x}_j, \mathbf{x}_i)$，故 K 对称。
2. **为什么必须半正定**：对任意 $\mathbf{c}$，

   $$\mathbf{c}^T K \mathbf{c} = \sum_{i,j} c_i c_j \, \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j) = \Big\| \sum_i c_i \phi(\mathbf{x}_i) \Big\|^2 \geq 0,$$

   这是特征空间里一个向量的平方范数，必然非负。
3. **结论**：若某个相似函数对任意有限样本都让 Gram 矩阵对称半正定，它就是合法核，可以当作某个（可能无穷维）ϕ 的内积来用。反之，不满足此条件的“相似度”不能直接套进核 SVM。

4.6.5 RBF 核与调参

最常用的非线性核——径向基（高斯）核：

$$k(\mathbf{x}, \mathbf{z}) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{z}\|^2}{2s^2} \right), \qquad s > 0.$$

过程讲解

- 它对应一个**无穷维**特征映射 ϕ（可借泰勒展开 $\exp(\cdot) = \sum_{m \geq 0} (\cdot)^m / m!$ 理解），且已被证明对任意 $s > 0$ 都满足 Gram 矩阵 PSD，是合法核。
- 参数 s（或写作 $\gamma = 1/(2s^2)$）控制“局部性”：s 小→核只在很近的点有响应（容易过拟合）；s 大→更平滑（可能欠拟合）。
- **调参**：核参数 s（或 γ）与软间隔的 C 一起决定拟合松紧，都必须通过**训练集内部的验证**（如交叉验证）来确定，绝不能拿测试集去挑参数。

> **延伸练习**：相关动手题见 练习。

第五章 回归：从最小二乘到正则化

> 往年资料：S10 4–16 页（问题）、18–31 页（LS/ML）、33–37 页（MAP）、39–48 页（基函数与误差）。2026-10-30 已视觉核对 S10 4、25–31 页，并把课件的 13 个房价训练点及 90 m² 问题恢复为本章主例；其余推导补充和小例均明确标为编者内容。本年度对应课件尚未提供。

> **编者注（与课件区别的阅读提示）：** 本章在保留上述往年资料来源框架的基础上，对每条主线公式都补写了“过程讲解”与一维 / 二维小数值例子；凡属编者额外补充的推导或提示，均标以「编者注」。来源页段只作定位，未逐页核对视觉格式，请勿据此推定考试范围。

5.1 回归预测的是数值

直觉： 分类题的答案可以随意改名（猫 = 0、狗 = 1 或猫 = 5、狗 = 100 都不影响决策）；回归题的答案是一个具体数值，数值之间的“距离”本身就是信息。房价 200 万与 300 万相差 100 万，这个差距会被损失函数如实计入。

5.1.1 符号与数据组织（先定维度，再写公式）

本书采用**行样本**约定（与 `docs/guide.md` 统一符号一致）：

- N：样本个数，$N \geq 1$；
- p：设计矩阵的列数。若原始特征维度为 d，加入一列全 1 当作截距后，$p = d + 1$。统一符号表里的 $X \in \mathbb{R}^{N \times d}$ 指“未增广”的设计矩阵，本章的 p 是其增广后的列数；
- 设计矩阵 $X \in \mathbb{R}^{N \times p}$，**每一行是一个样本的特征向量**，第 i 行记为 $\mathbf{x}_i^\top$（把该行视为列向量时记作 $\mathbf{x}_i \in \mathbb{R}^p$）；
- 待估参数 $\boldsymbol{\beta} \in \mathbb{R}^p$，包含各特征权重与截距；
- 观测响应 $\mathbf{y} \in \mathbb{R}^N$，第 i 个分量 $y_i \in \mathbb{R}$；
- 预测 $\hat{\mathbf{y}} = X\boldsymbol{\beta} \in \mathbb{R}^N$，第 i 个分量 $\hat{y}_i = \mathbf{x}_i^\top \boldsymbol{\beta}$。

> **记住：** 先写清“谁在第几行、谁在第几列、向量的维度是多少”，再代入公式。行样本约定下，$\hat{y}_i = \mathbf{x}_i^\top \boldsymbol{\beta}$（行向量转置成列向量再点乘），而不是 $\boldsymbol{\beta}^\top \mathbf{x}_i$ 之外的其他形式——两者数值相等，但维度顺序必须心里有数。

5.1.2 评价准则：MSE、RMSE、MAE

平方误差（squared error）是最常用的回归损失：

$$\mathrm{MSE} = \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2 = \frac{1}{N}\|\mathbf{y} - \hat{\mathbf{y}}\|^2, \qquad \hat{\mathbf{y}} = X\boldsymbol{\beta}.$$

- $\mathrm{RMSE} = \sqrt{\mathrm{MSE}}$，单位与 y 一致（如“万元”）；
- $\mathrm{MAE} = \frac{1}{N}\sum_{i=1}^{N}|y_i - \hat{y}_i|$，对个别大残差惩罚更温和。

小数值例子（体会 MSE 对误差的“平方放大”）： 设有两个模型在同一测试点上的误差序列：

- 模型 A 残差：$(1, 1, 1)$，则 $\mathrm{MSE}_A = (1+1+1)/3 = 1$；
- 模型 B 残差：$(0, 0, 3)$，则 $\mathrm{MSE}_B = (0+0+9)/3 = 3$。

两者平均绝对误差都是 1，但 MSE 相差 3 倍——因为 MSE 对第 3 个点的残差 3 平方成了 9。这说明 **MSE 会严厉惩罚少数“离谱”的预测**，这是它和 MAE 的关键区别。

> **常见误区：** 不同量纲任务的 MSE 不能直接比大小。用“万元”计的房价 MSE 天然比用“厘米”计的人体身高 MSE 大得多，这不是模型好坏，是单位不同。比较前应先标准化或统一量纲。

5.2 正规方程为什么成立

直觉： 我们要找一条直线（更一般地说，一个超平面）$X\boldsymbol{\beta}$，让它“尽量靠近”观测到的 $\mathbf{y}$。在欧氏距离意义下，“最近的那个列空间里的向量”恰是 $\mathbf{y}$ 到列空间的正交投影。正规方程就是把“残差垂直于列空间”这条几何事实翻译成代数。

5.2.1 从目标函数出发：设定与展开

假设与维度

- $X \in \mathbb{R}^{N\times p}$（行样本），$\boldsymbol{\beta} \in \mathbb{R}^{p}$，$\mathbf{y} \in \mathbb{R}^{N}$；
- 目标：最小化残差平方和 $J(\boldsymbol{\beta}) = \|\mathbf{y} - X\boldsymbol{\beta}\|^2$。

起始式（写成内积）

$$J(\boldsymbol{\beta}) = \|\mathbf{y} - X\boldsymbol{\beta}\|^2 = (\mathbf{y} - X\boldsymbol{\beta})^\top(\mathbf{y} - X\boldsymbol{\beta}).$$

逐步展开

第 1 步：用分配律把括号拆开。

$$(\mathbf{y} - X\boldsymbol{\beta})^\top(\mathbf{y} - X\boldsymbol{\beta}) = (\mathbf{y}^\top - \boldsymbol{\beta}^\top X^\top)(\mathbf{y} - X\boldsymbol{\beta}).$$

第 2 步：逐项相乘（四个项）。

$$= \mathbf{y}^\top\mathbf{y} - \mathbf{y}^\top X\boldsymbol{\beta} - \boldsymbol{\beta}^\top X^\top\mathbf{y} + \boldsymbol{\beta}^\top X^\top X\boldsymbol{\beta}.$$

第 3 步：合并两个标量交叉项。注意 $\mathbf{y}^\top X\boldsymbol{\beta}$ 是一个标量，标量等于自己的转置，故

$$\mathbf{y}^\top X\boldsymbol{\beta} = (\mathbf{y}^\top X\boldsymbol{\beta})^\top = \boldsymbol{\beta}^\top X^\top\mathbf{y}.$$

两项相加为 $-2\boldsymbol{\beta}^\top X^\top\mathbf{y}$。于是

$$J(\boldsymbol{\beta}) = \mathbf{y}^\top\mathbf{y} - 2\boldsymbol{\beta}^\top X^\top\mathbf{y} + \boldsymbol{\beta}^\top X^\top X\boldsymbol{\beta}.$$

求导（对向量 $\boldsymbol{\beta}$ 的梯度）

用两条向量微分规则（对列向量 $\boldsymbol{\beta}$）：

- $\nabla_{\boldsymbol{\beta}}(\mathbf{a}^\top\boldsymbol{\beta}) = \mathbf{a}$；
- $\nabla_{\boldsymbol{\beta}}(\boldsymbol{\beta}^\top M\boldsymbol{\beta}) = 2M\boldsymbol{\beta}$，当 M 对称（这里 $M = X^\top X$ 显然对称）。

$$\nabla_{\boldsymbol{\beta}} J = -2X^\top\mathbf{y} + 2X^\top X\boldsymbol{\beta}.$$

令梯度为零，得到正规方程

$$-2X^\top\mathbf{y} + 2X^\top X\boldsymbol{\beta} = 0 \quad\Longrightarrow\quad X^\top X\boldsymbol{\beta} = X^\top\mathbf{y}. \tag{5.1}$$

这就是**正规方程（normal equation）**。

> **编者注（为什么是“最小”而不是“驻点”就行）：** $J(\boldsymbol{\beta})$ 是 $\boldsymbol{\beta}$ 的二次型且二次型矩阵 $X^\top X$ 半正定，因此它是凸函数；梯度为零的驻点就是全局最小点。无需再检验二阶充分条件。

5.2.2 解的唯一性、满列秩与正定性

假设： X **满列秩**，即 $\operatorname{rank}(X) = p$（要求 $N \geq p$）。

证明 $X^\top X$ **正定：** 任取非零向量 $\mathbf{v} \in \mathbb{R}^p$，

$$\mathbf{v}^\top (X^\top X)\mathbf{v} = (X\mathbf{v})^\top (X\mathbf{v}) = \|X\mathbf{v}\|^2.$$

因为 X 满列秩，$X\mathbf{v} \neq \mathbf{0}$（否则 $\mathbf{v}$ 落在零空间），故 $\|X\mathbf{v}\|^2 > 0$。所以 $X^\top X$ 正定，从而可逆。

唯一解

$$\widehat{\boldsymbol{\beta}} = (X^\top X)^{-1} X^\top \mathbf{y}. \tag{5.2}$$

结论与成立条件： 在“行样本、满列秩、欧氏平方损失”三条件下，最小二乘解唯一，且由式 (5.2) 给出。

5.2.3 几何解释：正交投影（最直观的“为什么成立”）

把正规方程 (5.1) 移项：

$$X^\top (\mathbf{y} - X\widehat{\boldsymbol{\beta}}) = 0 \quad \Longrightarrow \quad X^\top \mathbf{r} = 0,\ \mathbf{r} = \mathbf{y} - X\widehat{\boldsymbol{\beta}}.$$

$X^\top \mathbf{r}$ 的第 j 个分量正是“设计矩阵第 j 列”与残差 $\mathbf{r}$ 的内积，因此 $X^\top \mathbf{r} = 0$ 表示：**残差 $\mathbf{r}$ 与设计矩阵的每一列都正交**，即 $\mathbf{r} \perp \mathcal{C}(X)$（$\mathcal{C}(X)$ 为 X 的列空间）。

于是 $X\widehat{\boldsymbol{\beta}}$ 是 $\mathbf{y}$ 在 $\mathcal{C}(X)$ 上的**正交投影**，投影矩阵为

$$P = X(X^\top X)^{-1} X^\top, \qquad \widehat{\mathbf{y}} = P\mathbf{y}.$$

容易验证 P 是幂等且对称的（$P^2 = P,\ P^\top = P$），这是投影算子的标准性质。

二维小数值例子（让投影“看得见”）： 取 5.2.5 的例，$X = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}$，$\mathbf{y} = (1, 2, 2)^\top$，由后面算得 $\widehat{\boldsymbol{\beta}} = (7/6,\ 1/2)^\top$，

于是投影

$$\widehat{\mathbf{y}} = X\widehat{\boldsymbol{\beta}} = \left(\tfrac{7}{6},\ \tfrac{5}{3},\ \tfrac{13}{6}\right)^\top, \quad \mathbf{r} = \mathbf{y} - \widehat{\mathbf{y}} = \left(-\tfrac{1}{6},\ \tfrac{1}{3},\ -\tfrac{1}{6}\right)^\top.$$

取 X 的两列 $\mathbf{c}_1 = (1,1,1)^\top,\ \mathbf{c}_2 = (0,1,2)^\top$，检查正交性：

$$\mathbf{r}^\top \mathbf{c}_1 = -\tfrac{1}{6} + \tfrac{1}{3} - \tfrac{1}{6} = 0, \qquad \mathbf{r}^\top \mathbf{c}_2 = 0 \cdot (-\tfrac{1}{6}) + 1 \cdot \tfrac{1}{3} + 2 \cdot (-\tfrac{1}{6}) = \tfrac{1}{3} - \tfrac{1}{3} = 0.$$

残差同时垂直于两列，几何上正是“投影残差垂直于投影平面”，与代数结论一致。

5.2.4 列不满秩时：参数不唯一、伪逆取最小范数解

假设放宽： X 列相关，即 $\operatorname{rank}(X) = r < p$。

此时存在非零 $\mathbf{v}$ 使 $X\mathbf{v} = \mathbf{0}$，于是

$$\mathbf{v}^\top X^\top X \mathbf{v} = \|X\mathbf{v}\|^2 = 0,$$

故 $X^\top X$ **半正定但不正定**，不可逆，正规方程 (5.1) 有无穷多解。

关键事实： 虽然 $\boldsymbol{\beta}$ 不唯一，但“投影” $X\widehat{\boldsymbol{\beta}}$ 唯一。因为任意两个解相差一个零空间向量 $\mathbf{v}$（即 $\widehat{\boldsymbol{\beta}}_2 = \widehat{\boldsymbol{\beta}}_1 + \mathbf{v}$ 仍满足方程），而

$$X\widehat{\boldsymbol{\beta}}_2 = X\widehat{\boldsymbol{\beta}}_1 + X\mathbf{v} = X\widehat{\boldsymbol{\beta}}_1,$$

投影不变。

最小范数解（Moore–Penrose 伪逆）：

$$\widehat{\boldsymbol{\beta}}^{+} = X^{+}\mathbf{y}, \qquad X^{+} = (X^{\top}X)^{+}X^{\top},$$

其中 $(\cdot)^{+}$ 表示伪逆。在“所有令 $X\boldsymbol{\beta}$ 等于同一投影的解”中，$\boldsymbol{\beta}^{+}$ 是欧氏范数 $\|\boldsymbol{\beta}\|$ 最小的那一个。

> **记住：** 列相关 ≠ 模型不能预测。预测（投影）仍然唯一；不唯一的是“参数本身”。伪逆在 $X^{\top}X$ 奇异时给出稳定、最小范数的 $\boldsymbol{\beta}$。

数值计算建议： 不要直接算 $(X^{\top}X)^{-1}$（先平方条件数、再求逆会放大误差）。优先用 QR 分解、SVD，或直接求解线性方程组 $X^{\top}X\boldsymbol{\beta} = X^{\top}\mathbf{y}$。

5.2.5 往年课件原例：13 个房价点与 90 m² 预测

> **来源性质**：S10 4、25–31 页，往年课件原例。S10 第 4 页给出数据与问题，25–31 页用同类一元回归图解释损失曲面和参数搜索；课件没有在该页打印 90 m² 的最终教师答案。以下最小二乘数字是编者复算。

面积 x（m²）	35	40	45	65	74	80	120	140	230	300	400	500	600
房价 y（万元）	150	170	190	200	224	245	320	400	640	780	900	1100	1300

令模型为 $\hat{y} = ax + b$。一元最小二乘可把正规方程化成

$$a = \frac{N\sum_i x_i y_i - (\sum_i x_i)(\sum_i y_i)}{N\sum_i x_i^2 - (\sum_i x_i)^2}, \qquad b = \frac{\sum_i y_i - a\sum_i x_i}{N}.$$

本题统计量为

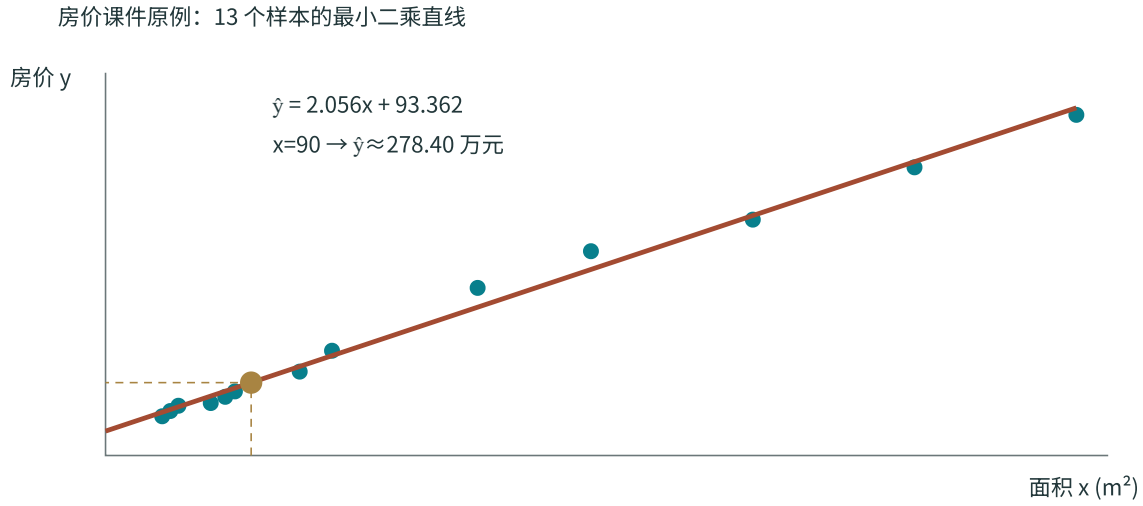
$$N = 13, \quad \sum x_i = 2629, \quad \sum y_i = 6619, \quad \sum x_i^2 = 967851, \quad \sum x_i y_i = 2235376.$$

代入得到

$$a = \frac{13 \times 2235376 - 2629 \times 6619}{13 \times 967851 - 2629^2} \approx 2.056026, \qquad b \approx 93.362058.$$

因此

$$\boxed{\hat{y}(90) = 2.056026 \times 90 + 93.362058 \approx 278.40 \text{ 万元}}.$$



怎样读课件 25–31 页的动态图：固定一组 (a,b) 就得到一条直线和一个损失值 $J(a,b)$；移动参数时，直线在数据图中变化，同时参数点在碗形等高线上移动。红色路径走向等高线中心，表示损失下降。它不是“在图上凭眼睛画一条线”，而是在参数空间里最小化同一个平方损失。

5.2.6 自编例题（核对数字，并用正规方程复算）

数据 $(x,y)=(0,1),(1,2),(2,2)$，模型 $y=ax+b$。

矩阵写法（行样本）： 取每行 $(1,\ x_i)$，则

$$X=\begin{bmatrix}1&0\\1&1\\1&2\end{bmatrix},\quad \boldsymbol{\beta}=\begin{bmatrix}b\\a\end{bmatrix},\quad \mathbf{y}=\begin{bmatrix}1\\2\\2\end{bmatrix}.$$

算 $X^\top X$ 与 $X^\top\mathbf{y}$：

$$X^\top X=\begin{bmatrix}1&1&1\\0&1&2\end{bmatrix}\begin{bmatrix}1&0\\1&1\\1&2\end{bmatrix}=\begin{bmatrix}3&3\\3&5\end{bmatrix},\qquad X^\top\mathbf{y}=\begin{bmatrix}1&1&1\\0&1&2\end{bmatrix}\begin{bmatrix}1\\2\\2\end{bmatrix}=\begin{bmatrix}5\\6\end{bmatrix}.$$

正规方程：

$$\begin{bmatrix}3&3\\3&5\end{bmatrix}\begin{bmatrix}b\\a\end{bmatrix}=\begin{bmatrix}5\\6\end{bmatrix}.$$

由第一行 $3b+3a=5$ 得 $b+a=5/3$；代入第二行 $3b+5a=6$ 消去 b：

$$3(\tfrac{5}{3}-a)+5a=6\ \Rightarrow\ 5-3a+5a=6\ \Rightarrow\ 2a=1\ \Rightarrow\ a=\tfrac{1}{2}.$$

于是 $b=\frac{5}{3}-\frac{1}{2}=\frac{10-3}{6}=\frac{7}{6}$。**与课件公式结果一致**：$a=1/2,\ b=7/6$。

残差与 MSE（逐一核算）：

- $x=0$：$\hat{y}=7/6$，残差 $1-7/6=-1/6$；
- $x=1$：$\hat{y}=1/2+7/6=5/3$，残差 $2-5/3=1/3$；
- $x=2$：$\hat{y}=1+7/6=13/6$，残差 $2-13/6=-1/6$。

残差平方和：

$$(-\tfrac{1}{6})^2+(\tfrac{1}{3})^2+(-\tfrac{1}{6})^2=\tfrac{1}{36}+\tfrac{4}{36}+\tfrac{1}{36}=\tfrac{6}{36}=\tfrac{1}{6}.$$

$$\mathrm{MSE} = \frac{1}{N} \cdot \tfrac{1}{6} = \tfrac{1}{18}.$$

> **编者注（与一元公式对照）：** 课件用中心化公式 $a = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$、$b = \bar{y} - a\bar{x}$，其中 $\bar{x} = 1$，$\bar{y} = 5/3$。分子 $= (-1)(-2/3) + 0(1/3) + (1)(1/3) = 1$，分母 $= 2$，得 $a = 1/2$，$b = 5/3 - 1/2 = 7/6$，与正规方程结果完全相同——因为一元公式本身就是正规方程在 $p = 2$ 时的特例。

5.3 高斯误差连接最小二乘与 ML

直觉： 最小二乘“不问误差来源”，只看距离最小；极大似然“问误差分布”。当误差恰好是高斯（正态）时，两者殊途同归：让“出现这组数据的概率最大”等价于“让残差平方和最小”。

5.3.1 设定：高斯噪声模型

假设

- $\mathbf{y} = X\boldsymbol{\beta} + \boldsymbol{\epsilon}$，其中 $\boldsymbol{\epsilon} = (\epsilon_1, \ldots, \epsilon_N)^\top$；
- 各误差独立同分布，$\epsilon_i \sim N(0, \sigma^2)$，$\sigma^2 > 0$ 已知或待估；
- 给定 X 与 $\boldsymbol{\beta}$，则 $y_i \mid \mathbf{x}_i \sim N(\mathbf{x}_i^\top \boldsymbol{\beta},\, \sigma^2)$，整体 $\mathbf{y} \mid X \sim N(X\boldsymbol{\beta},\, \sigma^2 I_N)$。

5.3.2 似然、对数似然与负对数似然（逐步推导）

写出似然（联合密度）

$$p(\mathbf{y} \mid X, \boldsymbol{\beta}, \sigma^2) = \prod_{i=1}^{N} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2}{2\sigma^2} \right) = (2\pi\sigma^2)^{-N/2} \exp\left(-\frac{\|\mathbf{y} - X\boldsymbol{\beta}\|^2}{2\sigma^2} \right).$$

取对数似然

$$\ell(\boldsymbol{\beta}) = \log p(\mathbf{y} \mid X, \boldsymbol{\beta}, \sigma^2) = -\frac{N}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \|\mathbf{y} - X\boldsymbol{\beta}\|^2.$$

负对数似然（要最小化的目标）

$$-\ell(\boldsymbol{\beta}) = \frac{N}{2} \log(2\pi\sigma^2) + \frac{1}{2\sigma^2} \|\mathbf{y} - X\boldsymbol{\beta}\|^2. \tag{5.3}$$

5.3.3 为什么 MLE = 最小二乘

对 $\boldsymbol{\beta}$ 最小化 (5.3)：

- 第一项 $\frac{N}{2}\log(2\pi\sigma^2)$ 与 $\boldsymbol{\beta}$ 无关，可丢弃；
- 第二项系数 $\frac{1}{2\sigma^2} > 0$ 是常数，不影响最优点位置。

因此“最小化负对数似然”等价于“最小化 $\|\mathbf{y} - X\boldsymbol{\beta}\|^2$”，即最小二乘。最优参数相同：

$$\widehat{\boldsymbol{\beta}}_{\mathrm{ML}} = \widehat{\boldsymbol{\beta}}_{\mathrm{LS}} = (X^\top X)^{-1} X^\top \mathbf{y} \quad (\text{满列秩时}).$$

结论与成立条件： 在“误差独立同分布、零均值、同方差、服从高斯”前提下，MLE 与 LS 给出相同估计。**“等价”指目标函数等价，并不表示现实误差都该服从高斯**；若误差非高斯，LS 与 ML 一般会分道扬镳。

5.3.4 梯度下降视角：批量梯度与 SGD

把 LS 目标写成**平均损失**（便于跨数据量比较）：

$$L(\boldsymbol{\beta}) = \frac{1}{2N}\|X\boldsymbol{\beta} - \mathbf{y}\|^2.$$

全样本（批量）梯度： 对 (5.3) 的 $\|X\boldsymbol{\beta} - \mathbf{y}\|^2/(2N)$ 求梯度，

$$\nabla_{\boldsymbol{\beta}} L = \frac{1}{N} X^\top (X\boldsymbol{\beta} - \mathbf{y}). \tag{5.4}$$

批量梯度下降更新：$\boldsymbol{\beta} \leftarrow \boldsymbol{\beta} - \eta \nabla_{\boldsymbol{\beta}} L$。

随机梯度下降（SGD）： 每次取一个样本 i，用其梯度近似整体梯度。第 i 个样本对平均损失 L 的贡献为 $\frac{1}{2N}(\mathbf{x}_i^\top \boldsymbol{\beta} - y_i)^2$，其梯度为

$$\nabla_{\boldsymbol{\beta}}^{(i)} L = \frac{1}{N}(\mathbf{x}_i^\top \boldsymbol{\beta} - y_i)\mathbf{x}_i. \tag{5.5}$$

若不除以 N（即优化未平均的总损失 $\frac{1}{2}(\mathbf{x}_i^\top \boldsymbol{\beta} - y_i)^2$），则梯度为 $(\mathbf{x}_i^\top \boldsymbol{\beta} - y_i)\mathbf{x}_i$——这正是课件所写形式。**两种写法只差常数倍 $1/N$，本质相同，但比较学习率时要先分清用的是哪种目标。**

> **常见误区：** 学习率 η 过大时，参数在最优解两侧来回跳跃甚至发散。直觉上，若 $X^\top X$ 的最大特征值很大，一步跨得太远就会越过谷底。对特征做标准化/缩放可改善条件数，使梯度下降更平稳。

5.4 MAP 与岭回归

直觉： 最小二乘“惜墨如金”地拟合数据，数据少或特征相关时容易过拟合、系数乱跳。岭回归给参数加一个“偏好：系数别太大”的先验（高斯先验），于是把 LS 目标加上 $\lambda\|\boldsymbol{\beta}\|^2$ 的惩罚——这等价于贝叶斯里的 MAP（最大后验）。LASSO 换成 L_1 惩罚，能把不重要系数压成精确的 0。

5.4.1 MAP 设定：参数的高斯先验

假设

- 似然同 5.3：$\mathbf{y} \mid X, \boldsymbol{\beta} \sim N(X\boldsymbol{\beta}, \sigma^2 I)$；
- 参数先验 $\boldsymbol{\beta} \sim N(\mathbf{0}, \tau^2 I_p)$，$\tau^2 > 0$，即各分量独立、零均值、方差 τ^2。

后验（贝叶斯公式）：

$$p(\boldsymbol{\beta} \mid \mathbf{y}, X) \propto p(\mathbf{y} \mid X, \boldsymbol{\beta})\, p(\boldsymbol{\beta}).$$

MAP 即最大化后验，等价于最小化**负对数后验。**

5.4.2 负对数后验的逐步推导

由 5.3 已知负对数似然：

$$-\log p(\mathbf{y} \mid X, \boldsymbol{\beta}) = \frac{N}{2}\log(2\pi\sigma^2) + \frac{1}{2\sigma^2}\|\mathbf{y} - X\boldsymbol{\beta}\|^2.$$

写负对数先验：

$$-\log p(\boldsymbol{\beta}) = \frac{p}{2}\log(2\pi\tau^2) + \frac{1}{2\tau^2}\|\boldsymbol{\beta}\|^2.$$

负对数后验 = 二者相加（再加与 $\boldsymbol{\beta}$ 无关的常数）：

$$-\log p(\boldsymbol{\beta} \mid \mathbf{y}, X) = \frac{N}{2}\log(2\pi\sigma^2) + \frac{1}{2\sigma^2}\|\mathbf{y} - X\boldsymbol{\beta}\|^2 + \frac{p}{2}\log(2\pi\tau^2) + \frac{1}{2\tau^2}\|\boldsymbol{\beta}\|^2 + \text{const}.$$

只保留含 β 的项并同乘 $2\sigma^2$：

$$\|\mathbf{y}-X\boldsymbol{\beta}\|^2+\frac{\sigma^2}{\tau^2}\|\boldsymbol{\beta}\|^2.$$

记

$$\lambda=\frac{\sigma^2}{\tau^2}>0, \tag{5.6}$$

得到**岭回归目标**：

$$J_{\text{ridge}}(\boldsymbol{\beta})=\|\mathbf{y}-X\boldsymbol{\beta}\|^2+\lambda\|\boldsymbol{\beta}\|^2. \tag{5.7}$$

5.4.3 岭回归的正规方程

对 (5.7) 求梯度（沿用 5.2 的微分规则，并加 $\nabla(\lambda\|\boldsymbol{\beta}\|^2)=2\lambda\boldsymbol{\beta}$）：

$$\nabla_{\boldsymbol{\beta}}J_{\text{ridge}}=-2X^\top(\mathbf{y}-X\boldsymbol{\beta})+2\lambda\boldsymbol{\beta}.$$

令为零：

$$-2X^\top\mathbf{y}+2X^\top X\boldsymbol{\beta}+2\lambda\boldsymbol{\beta}=0\ \Rightarrow\ (X^\top X+\lambda I)\boldsymbol{\beta}=X^\top\mathbf{y}. \tag{5.8}$$

解（注意 $\lambda>0$ 保证可逆）：

$$\widehat{\boldsymbol{\beta}}_{\text{ridge}}=(X^\top X+\lambda I)^{-1}X^\top\mathbf{y}. \tag{5.9}$$

正定性论证（为何岭回归不怕列相关）： 任取 $\mathbf{v}\neq\mathbf{0}$，

$$\mathbf{v}^\top(X^\top X+\lambda I)\mathbf{v}=\|X\mathbf{v}\|^2+\lambda\|\mathbf{v}\|^2>0,$$

因为 $\|X\mathbf{v}\|^2\geq 0$ 且 $\lambda\|\mathbf{v}\|^2>0$。所以 $X^\top X+\lambda I$ 必正定、必可逆——**即使 $X^\top X$ 奇异，岭回归仍有唯一解。**

收缩效应（沿特征向量方向看）： 设 $X^\top X$ 的单位特征向量为 $\mathbf{u}$、特征值 $\gamma\geq 0$。在 $\mathbf{u}$ 方向上，岭系数相对 LS 系数被乘了因子 $\frac{\gamma}{\gamma+\lambda}$。$\gamma$ 越小（该方向越不稳定）收缩越强；$\lambda\to 0$ 回到 LS，$\lambda\to\infty$ 系数趋零。

5.4.4 截距不惩罚 与 λ 的 N 换算（两处易错点）

截距（偏置）通常不应被惩罚。 若把截距也压向 0，模型会被迫用截距去“抵消”惩罚，扭曲斜率。标准做法是只对权重加惩罚：把 (5.8) 中的 I 换成“截距位为 0、其余为 1”的对角矩阵 D，即

$$(X^\top X+\lambda D)\boldsymbol{\beta}=X^\top\mathbf{y},\quad D=\operatorname{diag}(0,1,\dots,1).$$

这对应“先验只加在权重上、截距用无信息先验”。

> **常见误区：** 不同教材对岭目标用“总损失” $\|.\|^2+\lambda\|\boldsymbol{\beta}\|^2$ 还是“平均损失” $\frac{1}{N}\|.\|^2+\lambda\|\boldsymbol{\beta}\|^2$ 定义不同。若用平均损失，式 (5.6) 变为 $\lambda=\sigma^2/(N\tau^2)$，多一个 N。**跨资料比较 λ 数值前，必须先确认对方用的是哪种损失定义。**

5.4.5 岭回归小数值例子（看“收缩”与“训练误差交换”）

仍用 5.2.5 的数据 $(0,1),(1,2),(2,2)$，模型 $y=ax+b$，**只惩罚斜率** a（截距不罚），即目标 $\|.\|^2+\lambda a^2$。

先中心化：令 $\tilde{x}_i=x_i-\bar{x}$，$\tilde{y}_i=y_i-\bar{y}$，$\bar{x}=1$，$\bar{y}=5/3$。则截距最优为 $b=\bar{y}-a\bar{x}=5/3-a$（截距不罚时其估计公式不变）。残差平方和只在中心化量上依赖 a：

$$S(a)=\sum_i\left(\tilde y_i-a\tilde x_i\right)^2=\underbrace{\sum\tilde y_i^2}_{2/3}-2a\underbrace{\sum\tilde x_i\tilde y_i}_{1}+a^2\underbrace{\sum\tilde x_i^2}_{2}.$$

加惩罚：

$$J(a)=\tfrac{2}{3}-2a+2a^2+\lambda a^2=\tfrac{2}{3}-2a+(2+\lambda)a^2.$$

$$\frac{dJ}{da}=-2+2(2+\lambda)a=0\ \Rightarrow\ a=\frac{1}{2+\lambda}.$$

- $\lambda=0$：$a=1/2$（回到 LS）；
- $\lambda=1$：$a=1/3$，斜率被“收缩”向 0；
- $\lambda\to\infty$：$a\to 0$，模型退化为常数。

取 $\lambda=1$ 算训练 MSE（验证“用训练误差换稳定性”）：$b=5/3-1/3=4/3$，预测 $(4/3,\,5/3,\,2)$，残差 $(-1/3,\,1/3,\,0)$，平方和 $2/9$，$\mathrm{MSE}=2/27\approx 0.074$，比 LS 的 $1/18\approx 0.056$ 略大。**这正是预期**：在这 3 个点上岭回归牺牲了一点训练拟合，换取更小的系数与更稳的外推——偏差—方差视角（5.5）会解释它为何可能降低总体预测误差。

5.4.6 LASSO 与 L_1 惩罚：精确零系数

LASSO 把岭回归的 L_2 惩罚换成 L_1：

$$J_{\text{lasso}}(\boldsymbol\beta)=\|\mathbf y-X\boldsymbol\beta\|^2+\lambda\sum_{j=1}^{p}|\beta_j|. \tag{5.10}$$

为什么能给出精确零？ L_2 球是光滑椭圆，最优解一般不会恰好落在坐标轴上；而 L_1 球是带尖角（角落在坐标轴上）的菱形。最小化凸目标时，解容易“卡”在尖角上，对应某些 $\beta_j=0$——从而实现**自动特征选择**。岭回归通常只收缩、不产生精确零，不能默认当作离散特征选择工具。

> **记住：** L_1→稀疏（精确零、可做选择）；L_2→收缩（趋零但不为零、稳方向）。这是两者最实用的区别。

5.5 非线性输入与偏差—方差

直觉： 数据可能不是直线，但我们不必放弃“对参数线性”这一强大工具——把 x 换成一组基函数 $\phi(x)$（比如多项式、正弦），模型对输入非线性、对参数仍线性，最小二乘照用。代价是：基函数越复杂越容易过拟合。偏差—方差分解则告诉我们“过拟合”到底损失在哪：预测误差 = 偏差² + 方差 + 噪声。

5.5.1 基函数：对输入非线性，对参数仍线性

令

$$\boldsymbol\phi(x)=\big(\phi_1(x),\dots,\phi_p(x)\big)^\top,$$

例如多项式基 $\boldsymbol\phi(x)=(1,\,x,\,x^2,\dots,x^m)^\top$。模型为

$$f(x)=\boldsymbol\beta^\top\boldsymbol\phi(x)=\sum_{j=1}^{p}\beta_j\phi_j(x).$$

关键点： 虽然 f 对 x 是多项式（非线性），但对 $\boldsymbol\beta$ 是线性的——只要把“特征”从 x 换成 $\boldsymbol\phi(x)$，5.2 的全部最小二乘结论直接适用，只是把设计矩阵的每行换成 $\boldsymbol\phi(\mathbf x_i)^\top$。

> **常见误区：** “训练误差更小”不保证外推更可靠。高阶多项式可能在 $[0,2]$ 内拟合得极好，却在 $x=10$ 处剧烈震荡（龙格现象式行为）。基函数带来表达力，也带来过拟合风险，需要靠正则化或交叉验证来驾驭。

5.5.2 偏差—方差分解的设定

假设（逐条写清）

- 真实关系：$Y = f_*(x) + \epsilon$，其中 $f_*(x)$ 是未知真函数；
- 噪声零均值、条件方差有限：$\mathbb{E}[\epsilon \mid x] = 0$，$\mathrm{Var}(\epsilon \mid x) = \sigma^2(x)$；
- 训练集 D 是随机抽取的（含 N 个样本），其随机性记为下标 D；
- 用 D 训练得到模型 $\hat{f}_D(x)$（$\hat{f}$ 依赖 D，故下标 D）；
- 在**固定输入** x 处考察预测误差，对训练集随机性与噪声同时取期望：

$$\mathrm{Err}(x) = \mathbb{E}_{D,\epsilon}\big[(Y - \hat{f}_D(x))^2\big].$$

5.5.3 逐步推导：加减 $\bar{f}$ 并利用零均值消去交叉项

第 1 步：定义平均预测

$$\bar{f}(x) = \mathbb{E}_D[\hat{f}_D(x)]$$

（把不同训练集训出的模型在 x 处的预测取平均）。

第 2 步：在误差里加、减 $\bar{f}(x)$

$$Y - \hat{f}_D(x) = \big(Y - f_*(x)\big) + \big(f_*(x) - \bar{f}(x)\big) + \big(\bar{f}(x) - \hat{f}_D(x)\big).$$

记三段分别为 A, B, C：

$$A = Y - f_*(x), \quad B = f_*(x) - \bar{f}(x), \quad C = \bar{f}(x) - \hat{f}_D(x).$$

注意：A 含噪声 ϵ；B 只依赖 x、与训练集 D 及噪声 ϵ 都无关（因 f_*、$\bar{f}$ 不含随机性）；C 依赖训练集 D 但不含 ϵ。

第 3 步：展开平方

$$\mathbb{E}[(A+B+C)^2] = \mathbb{E}[A^2] + \mathbb{E}[B^2] + \mathbb{E}[C^2] + 2\mathbb{E}[AB] + 2\mathbb{E}[AC] + 2\mathbb{E}[BC].$$

第 4 步：逐项处理，重点证明三个交叉项为零

- $\mathbb{E}[A^2]$：

$$\mathbb{E}_\epsilon[A^2] = \mathbb{E}_\epsilon[(Y - f_*(x))^2] = \mathbb{E}[\epsilon^2] = \sigma^2(x) \quad (\text{因 } \mathbb{E}[\epsilon] = 0).$$

- $\mathbb{E}[B^2]$：B 与随机性无关，故 $\mathbb{E}[B^2] = B^2 = \big(f_*(x) - \bar{f}(x)\big)^2$。这正是**偏差平方**。
- $\mathbb{E}[C^2]$：$C = \bar{f}(x) - \hat{f}_D(x)$，于是

$$\mathbb{E}_D[C^2] = \mathbb{E}_D\big[(\hat{f}_D(x) - \bar{f}(x))^2\big] = \mathrm{Var}_D[\hat{f}_D(x)].$$

  这正是**方差**。

- $\mathbb{E}[AB] = 0$：先对 ϵ 取条件期望，B 视作常数，

$$\mathbb{E}[AB] = \mathbb{E}_D\big[B \cdot \mathbb{E}_\epsilon[A \mid D]\big] = \mathbb{E}_D\big[B \cdot \mathbb{E}_\epsilon[Y - f_*(x) \mid D]\big] = \mathbb{E}_D[B \cdot 0] = 0.$$

- $\mathbb{E}[AC] = 0$：给定 D 时 C 是常数（不含 ϵ），

$$\mathbb{E}[AC] = \mathbb{E}_D\big[C \cdot \mathbb{E}_\epsilon[A \mid D]\big] = \mathbb{E}_D[C \cdot 0] = 0.$$

- $\mathbb{E}[BC] = 0$：这里 $\bar{f}(x) = \mathbb{E}_D[\hat{f}_D(x)]$。展开

$$\mathbb{E}_D[(f_* - \bar{f})(\bar{f} - \hat{f})] = \mathbb{E}_D\big[f_*\bar{f} - f_*\hat{f} - \bar{f}^2 + \bar{f}\hat{f}\big] = f_*\bar{f} - f_*\bar{f} - \bar{f}^2 + \bar{f}^2 = 0.$$

（用到了 $\mathbb{E}_D[\hat{f}] = \bar{f}$。）

第 5 步：合并得三项分解

$$\boxed{\mathbb{E}_{D,Y}\big[(Y - \hat{f}_D(x))^2\big] = \big[\bar{f}(x) - f_*(x)\big]^2 + \mathrm{Var}_D[\hat{f}_D(x)] + \sigma^2(x)} \tag{5.11}$$

即

$$\text{期望预测误差} = \text{偏差}^2 + \text{方差} + \text{不可约噪声}.$$

结论与成立条件： 分解只需要“噪声零均值、方差有限、训练集随机抽取”这几条；它不要求模型是高斯、也不要求线性。偏差衡量“平均预测偏离真函数多远”，方差衡量“不同训练集训出的模型波动多大”，$\sigma^2(x)$ 是再好的模型也去不掉的噪声下限。

5.5.4 用偏差—方差理解岭回归与最小二乘

- **最小二乘的无偏性有前提：** 说“LS 是无偏的”需要两层假设——(1) 模型形式正确（真函数确实在所拟合的基函数空间内，即 $f_* \in \mathrm{span}\{\phi_j\}$）；(2) 噪声零均值 $\mathbb{E}[\epsilon \mid X] = 0$。若真函数不在该空间（模型误设），平均预测 $\bar{f}$ 仍偏离 f_*，偏差不为零。无偏不是无需前提的普遍结论。
- **岭回归主动引入偏差以降低方差：** 把系数向零收缩，使 $\mathrm{Var}_D[\hat{f}]$ 下降；当方差降得比偏差升得多时，总误差 (5.11) 下降。所以“岭回归通常更好”是**期望意义下**的权衡，并不保证对每一条具体数据都改善。

> **记住：** 复杂度↑→偏差↓、方差↑；复杂度↓→偏差↑、方差↓。最优模型在两者间取得平衡，而非“训练误差最低”的模型。

5.6 本章小结与练习

本章主线回顾

1. 回归预测实数，用 MSE/RMSE/MAE 评价；MSE 对大残差平方放大，且跨量纲不可直接比较。
2. 正规方程 $X^\top X\boldsymbol{\beta} = X^\top \mathbf{y}$ 由最小化 $\|\mathbf{y} - X\boldsymbol{\beta}\|^2$ 求导得到；满列秩时解唯一 $\boldsymbol{\beta} = (X^\top X)^{-1}X^\top \mathbf{y}$；几何上是 $\mathbf{y}$ 到列空间的正交投影。
3. 高斯噪声下，负对数似然与 LS 目标只差常数，故 MLE = LS。
4. 高斯先验 $\boldsymbol{\beta} \sim N(0, \tau^2 I)$ 下 MAP 给出岭回归 $(X^\top X + \lambda I)\boldsymbol{\beta} = X^\top \mathbf{y}$，$\lambda = \sigma^2/\tau^2$；LASSO 用 L_1 可得精确零系数。
5. 基函数让模型对输入非线性、对参数仍线性；偏差—方差分解 $\mathbb{E}[(Y - \hat{f})^2] = \text{偏差}^2 + \text{方差} + \text{噪声}$ 解释了过拟合与正则化的本质。

练习： 本章对应习题见 练习。建议先遮住解答，独立写出 5.2 的正规方程推导与 5.5 的偏差—方差三项展开，再对照检查假设、维度与交叉项消去步骤。

第六章 聚类：相似结构由什么决定

> 往年资料：S25 4–17 页（定义与评价）、19–30 页（序贯）、32–47 页（层次）、49–75 页（K 均值与调整）。2026-10-30 已视觉核对 S25 32、36–37、45–46、49–63、72–75 页，并恢复五点层次聚类与 30 个西瓜样本 K-means 原例。本年度对应课件尚未提供；其余阈值例和手算数据仍标为自编。

> **读前提示（编者补充）**。聚类是无监督学习的代表：我们**没有**样本的类别标签，只根据"相似性"把数据分成若干组。本章先说清"一类"的严格定义，再讲两类构建方法（序贯/层次、K 均值），最后说清如何评价结果。凡是编者补充的推导与自编数值例，文中会标"编者推导"或"自编例"，以便与课件内容区分；来源块已给出 S25 的页码范围，本章未逐页核对，也未新增任何具体页码事实。

6.1 没有标签时，"一类"是什么

6.1.1 聚类的任务与动机

分类（有监督）是"给定标签，学一个映射"；聚类（无监督）是"没有标签，只按数据自身结构分组"。我们想回答的是：**在不借助外部答案的情况下，数据里是否天然分成几团？每一团内部为何相似、团与团之间为何不同？**

现实里"相似"由三件事共同决定：

1. **特征怎么选**（用颜色还是用形状？用原始像素还是用纹理？）；
2. **距离怎么量**（欧氏距离、曼哈顿距离、余弦相似度……）；
3. **聚合规则怎么定**（最近点对、最远点对、类心距离……）。

这三件事不同，得到的"一类"就不同。因此**不存在脱离任务的唯一"真实划分"**——按颜色聚类与按形状聚类可能都合理。

> **记住**：聚类结果的好坏，最终要回到业务/实验目标来判断，不能只因为"算法跑出来了"就认为它正确。

6.1.2 硬划分的严格定义（编者推导）

本书采用的"一类"是**硬划分（hard partition）**：把全部 N 个样本分成 K 个簇 $C_1, \dots, C_K$，满足三条：

$$C_k \neq \varnothing, \quad \forall k = 1, \dots, K \tag{非空}$$

$$C_k \cap C_{k'} = \varnothing, \quad k \neq k' \tag{两两不交}$$

$$\bigcup_{k=1}^{K} C_k = \{\mathbf{x}_1, \dots, \mathbf{x}_N\} \tag{覆盖全部}$$

- **假设与符号**：$\mathbf{x}_i \in \mathbb{R}^d$ 是第 i 个样本列向量（$i = 1, \dots, N$）；C_k 是第 k 个簇的样本集合；K 为簇数（正整数，$1 \leq K \leq N$）。
- **逐条含义**：
  - "非空"表示每个簇至少要有一个点——空簇在硬划分里不被允许（这一点在第 6.3、6.4 节会反复用到）。
  - "两两不交"表示每个样本**只能属于一个簇**（这就是"硬"的含义；软划分允许一个样本以概率属于多个簇，本书不展开）。

- "覆盖全部"表示不能丢样本，所有点都必须被分到某个簇。

- **等价写法**：用指示变量 $r_i \in \{1,\dots,K\}$ 表示样本 i 所属簇；或用 0–1 指示矩阵 $z_{ik} \in \{0,1\}$，满足 $\sum_{k=1}^{K} z_{ik} = 1$（每个样本恰好分给一个簇）。后文 K 均值用 r_i，层次聚类用集合 C_k。

6.1.3 簇编号没有语义（置换不变性）

簇的编号 $1,2,\dots,K$ 只是占位符。把"簇 1 与簇 2 改名"不应改变任何评价结论——这只是对编号做了一 shuffled 置换。

过程讲解（形式化）

- *假设*：设 $\pi : \{1,\dots,K\} \to \{1,\dots,K\}$ 是任意置换（双射）。
- *起始式*：原划分 $\{C_1,\dots,C_K\}$，改名后划分 $\{C_{\pi(1)},\dots,C_{\pi(K)}\}$。
- *结论*：任何合理的聚类评价指标（Rand、轮廓系数、目标函数 J 等）在满足 $\sum_k z_{ik} = 1$ 的约束下，只依赖于"哪些样本同簇"，而**不**依赖于这些簇被标成几号。因此**评价必须对该置换不变**，否则指标本身就有缺陷。

> **常见误区**：把簇编号当成"类别含义"（例如以为簇 1 一定是"猫"）。硬划分里的编号与语义无关，跨次运行得到不同编号是正常现象。

6.1.4 类间距离（链接）的四种定义

"两簇有多近"有不止一种说法，它们表达不同的"接近"概念（层次聚类会用到，见 6.2）：

$$d_{\mathrm{SL}}(A,B) = \min_{\mathbf{x}\in A,\,\mathbf{y}\in B} \|\mathbf{x}-\mathbf{y}\| \qquad \text{(单链接/最近)}$$

$$d_{\mathrm{CL}}(A,B) = \max_{\mathbf{x}\in A,\,\mathbf{y}\in B} \|\mathbf{x}-\mathbf{y}\| \qquad \text{(全链接/最远)}$$

$$d_{\mathrm{AL}}(A,B) = \frac{1}{|A||B|}\sum_{\mathbf{x}\in A}\sum_{\mathbf{y}\in B} \|\mathbf{x}-\mathbf{y}\| \qquad \text{(平均链接)}$$

$$d_{\mathrm{CEN}}(A,B) = \|\boldsymbol{\mu}_A - \boldsymbol{\mu}_B\|, \quad \boldsymbol{\mu}_A = \frac{1}{|A|}\sum_{\mathbf{x}\in A}\mathbf{x} \qquad \text{(类心链接)}$$

- **符号/维度**：A, B 为两簇；$\mathbf{x},\mathbf{y} \in \mathbb{R}^d$；$\boldsymbol{\mu}_A, \boldsymbol{\mu}_B \in \mathbb{R}^d$。
- **直觉**：单链接看"最近一对"、全链接看"最远一对"、平均链接看"所有点对的平均"、类心链接看"两个中心的距离"。
- 这四种定义将在 6.2 节的层次聚类中决定"每次合并哪两簇"，结果可能**完全不同**。

6.2 序贯方法与层次聚类

6.2.1 序贯法（逐点扫描）

序贯法**逐个**处理样本：当前样本若与某个已有簇"足够接近"就加入该簇，否则以它为中心新建一簇。

- **直觉**：像排队分组——你走到队尾时，只会和已经存在的组比较，决定插队还是另起一组。
- **对顺序与阈值敏感**：先到的样本"定下"了簇的形状，后到的只能将就。换一个输入顺序可能得到不同结果。
- **双阈值法**：用较小阈值 τ_{in} 决定"接受"（加入现有簇），用较大阈值 τ_{out} 决定"新建"（自成新簇），中间区域 $\tau_{\text{in}} <$ 距离 $< \tau_{\text{out}}$ 延后处理。这样能减少"边界点"的仓促决定。
- **补救**：允许簇间合并与样本重新分配，可缓解早期决策难以撤回的问题，但必须事先规定明确的更新规则。

> **常见误区**：认为序贯法"跑一遍就够"。由于顺序敏感，实践中常多次以不同顺序或不同随机种子重跑，再比较。

6.2.2 凝聚与分裂层次聚类

- **凝聚（自底向上）**：一开始让每个样本各自成簇（共 N 个簇），每次合并"距离最近"的两簇，直到剩下一个簇或满足停止条件。得到的是**嵌套划分**，可在树状图不同高度"切开"得到 K 个簇。
- **分裂（自顶向下）**：从整体一簇出发，逐步拆分成两个最不相似的子簇。

两者都输出一棵能切出任意 K 的树，区别只在构建方向。

6.2.3 链接准则的详细对比（编者推导）

每次合并选使类间距离最小的两簇。用 6.1.4 的四种定义，得到不同算法：

准则	类间距离	倾向的簇形状	典型问题
单链接	最近点对	细长"链"、易桥接远处点	chaining（一条链串起所有点）
全链接	最远点对	紧凑、近似球形	对离群点敏感
平均链接	点对平均	折中，较稳健	计算量略大
类心链接	类心距离	受簇大小影响	可能出现逆转移（inversion）

过程讲解（为何单链接易成链）

- *假设*：存在三团 A, B, C，其中 A 与 B 各自紧密，但 A 中某点离 B 中某点极近，而 B 与 C 也仅由一对近点相连。
- *起始式*：单链接距离只取 $\min$，故 $d_{\mathrm{SL}}(A,B)$ 可能很小、$d_{\mathrm{SL}}(B,C)$ 也可能很小。
- *结论*：单链接会优先合并这两对"近点"，从而把 A, B, C 串成一条贯穿的链，即使 A 与 C 整体相距很远。这就是 chaining 现象。全链接用 $\max$ 则会拒绝这种"靠一对近点牵强合并"，倾向紧凑簇。

6.2.4 合并后的距离更新（Lance–Williams 公式，编者推导）

凝聚法每次只合并两簇，之后**不必重算所有点对距离**——只需更新"新簇与其余各簇"的距离。这由 Lance–Williams 递推统一表达：

$$d(C_i \cup C_j,\ C_k) = \alpha_i\, d(C_i, C_k) + \alpha_j\, d(C_j, C_k) + \beta\, d(C_i, C_j) + \gamma\, |d(C_i, C_k) - d(C_j, C_k)| \qquad (\mathrm{LW})$$

- **符号**：C_i, C_j 为刚合并的两簇，C_k 为其余某簇；$d(\cdot,\cdot)$ 是所用链接准则下的类间距离。
- **逐步说明**：合并后新簇 $C_i \cup C_j$ 与 C_k 的距离，可由合并前的三个距离 $d(C_i, C_k), d(C_j, C_k), d(C_i, C_j)$ 线性（加一项绝对值）组合得到。于是每次合并只更新 $O(K)$ 个值，整体比"每次重算全部"快得多。
- **三种链接的参数表**：

准则	α_i	α_j	β	γ
单链接	$1/2$	$1/2$	0	$-1/2$
全链接	$1/2$	$1/2$	0	$+1/2$
平均链接(UPGMA)	$n_i/(n_i+n_j)$	$n_j/(n_i+n_j)$	0	0

其中 $n_i = |C_i|$, $n_j = |C_j|$。注意平均链接用到簇大小（未加权的 UPGMA），而单/全链接与大小无关。该公式是聚类算法的标准结论，作为编者补充给出，便于理解"距离为何能复用"。

6.2.5 一维手算例：点 0、1、4、5（自编例，已核算）

取一维点 $\{0, 1, 4, 5\}$，欧氏距离即绝对值差。初始两两距离：

$$d(0,1) = 1,\ d(0,4) = 4,\ d(0,5) = 5,\ d(1,4) = 3,\ d(1,5) = 4,\ d(4,5) = 1.$$

单链接过程：

1. 最小距离是 1，先合并 $\{0,1\}$（也可先合并 $\{4,5\}$，平局次序可互换）；此时簇为 $\{0,1\}, \{4\}, \{5\}$。
2. 更新单链接距离：$d(\{0,1\}, \{4\}) = \min(4, 3) = 3$，$d(\{0,1\}, \{5\}) = \min(5, 4) = 4$，$d(\{4\}, \{5\}) = 1$。
3. 再合并 $\{4,5\}$（距离 1）；簇为 $\{0,1\}, \{4,5\}$。
4. 最后 $d(\{0,1\}, \{4,5\}) = \min(4, 5, 3, 4) = 3$，在高度 3 合并。

→ **单链接最终合并高度为 3**（即跨簇最短距离为 3）。

全链接过程：前两步同上合并出 $\{0,1\}, \{4,5\}$；但全链接取最远点对：

$$d_{\mathrm{CL}}(\{0,1\}, \{4,5\}) = \max(4, 5, 3, 4) = 5.$$

→ **全链接最终合并高度为 5。**

> **记住**：相同数据、不同链接，树状图的"高度"含义不同——单链接高度是"最近一对"，全链接高度是"最远一对"。比较聚类结果时务必先确认用了哪种链接。

6.2.6 往年课件原例：五个对象的嵌套划分

> **来源性质**：S25 36 页，往年课件原例。该页重点不是算具体距离，而是看懂“层次聚类的每一层都是上一层的合并结果”。

课件给出的凝聚序列可写成

$$\begin{aligned}
R_0 &= \{\{x_1\}, \{x_2\}, \{x_3\}, \{x_4\}, \{x_5\}\},\\
R_1 &= \{\{x_1, x_2\}, \{x_3\}, \{x_4\}, \{x_5\}\},\\
R_2 &= \{\{x_1, x_2\}, \{x_3\}, \{x_4, x_5\}\},\\
R_3 &= \{\{x_1, x_2, x_3\}, \{x_4, x_5\}\},\\
R_4 &= \{\{x_1, x_2, x_3, x_4, x_5\}\}.
\end{aligned}$$

每一步只把两个当前簇合并，所以 $R_0 \subset R_1 \subset R_2 \subset R_3 \subset R_4$。树状图的横向叶子是对象，纵向高度是合并距离；若在某一高度水平切一刀，穿过几条竖枝就得到几个簇。课件 37 页进一步展示了带边权的图，提醒“下一对合并对象”取决于单链接、全链接或均值链接的定义，不能只看肉眼最近的两个点。

6.3 K-means 的两步为何都不会增加目标

6.3.1 问题与平方欧氏目标

K 均值要在给定簇数 K 下，找到使"样本到所属中心距离平方和"最小的硬划分。

设定（符号/维度）

- 样本 $\mathbf{x}_i \in \mathbb{R}^d$，$i = 1, \dots, N$；
- 簇中心 $\boldsymbol{\mu}_k \in \mathbb{R}^d$，$k = 1, \dots, K$；
- 每个样本所属簇 $r_i \in \{1, \dots, K\}$（即 6.1 的硬划分指示）。

目标函数（平方欧氏准则）：

$$J = \sum_{i=1}^{N} \|\mathbf{x}_i - \boldsymbol{\mu}_{r_i}\|^2. \tag{6.1}$$

- **直觉（一维小例）**：假设一维点 $\{0, 2, 8, 10\}$，两个中心。若把 $0, 2$ 归到中心 $\mu_1 = 1$，$8, 10$ 归到 $\mu_2 = 9$，则误差是 $(0-1)^2 + (2-1)^2 + (8-9)^2 + (10-9)^2 = 1 + 1 + 1 + 1 = 4$。$J$ 衡量"整体有多散"。K 均值就是不断调 r_i 和 μ_k 把 J 压小。

6.3.2 步一：固定中心，贪心分配最近（编者推导）

- *假设*：中心 $\boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_K$ 暂时固定不变。
- *起始式*：第 i 项误差为 $J_i = \|\mathbf{x}_i - \boldsymbol{\mu}_{r_i}\|^2$，总目标 $J = \sum_i J_i$。
- *逐步推导*：由于中心已定，对样本 i 而言，选择不同的 r_i **只影响它自己的那一项** J_i，与其它样本无关。因此可对每个 i 独立地取最优：

$$r_i \;\leftarrow\; \arg\min_{k \in \{1,\dots,K\}} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2. \tag{6.2}$$

- *结论与条件*：这样重新分配后，每一项 J_i 都取到它在"固定中心"下的最小值，故新 $J \le$ 旧 J。该步**单调不增**，对任意维度、任意距离（只要取最近即可）都成立。

6.3.3 步二：固定分配，求最优中心（编者推导，含导数）

- *假设*：分配 r_i（即哪些样本属于 C_k）固定不变，仅优化中心 $\boldsymbol{\mu}_k$。
- *观察*：不同簇的中心彼此独立——改 $\boldsymbol{\mu}_k$ 只影响 C_k 内样本的项。故可对每个 k 单独最小化

$$J_k = \sum_{i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2. \tag{6.3}$$

- *起始式（展开范数）*：把 $\|\cdot\|^2$ 写成内积，

$$J_k = \sum_{i \in C_k} (\mathbf{x}_i - \boldsymbol{\mu}_k)^\top (\mathbf{x}_i - \boldsymbol{\mu}_k) = \sum_{i \in C_k} \left(\mathbf{x}_i^\top \mathbf{x}_i - 2\mathbf{x}_i^\top \boldsymbol{\mu}_k + \boldsymbol{\mu}_k^\top \boldsymbol{\mu}_k \right).$$

- *逐步求导*：对向量 $\boldsymbol{\mu}_k$ 求梯度（用 $\nabla_{\boldsymbol{\mu}_k} (\boldsymbol{\mu}_k^\top \boldsymbol{\mu}_k) = 2\boldsymbol{\mu}_k$，$\nabla_{\boldsymbol{\mu}_k} (\mathbf{x}_i^\top \boldsymbol{\mu}_k) = \mathbf{x}_i$）：

$$\nabla_{\boldsymbol{\mu}_k} J_k = \sum_{i \in C_k} \big(-2\mathbf{x}_i + 2\boldsymbol{\mu}_k \big) = 2 \sum_{i \in C_k} (\boldsymbol{\mu}_k - \mathbf{x}_i). \tag{6.4}$$

- *令梯度为零*：

$$2 \sum_{i \in C_k} (\boldsymbol{\mu}_k - \mathbf{x}_i) = 0 \;\Longrightarrow\; |C_k|\, \boldsymbol{\mu}_k = \sum_{i \in C_k} \mathbf{x}_i \;\Longrightarrow\; \boldsymbol{\mu}_k = \frac{1}{|C_k|} \sum_{i \in C_k} \mathbf{x}_i. \tag{6.5}$$

- *二阶验证（确认是最小而非最大）*：再求 Hessian，$\nabla^2_{\boldsymbol{\mu}_k} J_k = 2|C_k|\, I$（$I$ 为 $d \times d$ 单位阵），正定，故 (6.5) 给出的是**最小值**。
- *结论与条件*：在分配固定时，把中心取为簇内样本算术平均，可使该簇误差最小，因而总 J 单调不增。前提是 $C_k \neq \varnothing$（即 $|C_k| \ge 1$）；若 $C_k = \varnothing$ 则 (6.5) 分母为 0，均值无定义——这就是"空簇"问题（见 6.3.6）。

6.3.4 两步行交替 ⇒ 单调不增（编者推导）

一次完整迭代 = 先做步一（重分配）再做步二（更新中心）。由 6.3.2 与 6.3.3：

$$J^{(t)} \xrightarrow{\text{步一}} J^{(t+1/2)} \le J^{(t)} \xrightarrow{\text{步二}} J^{(t+1)} \le J^{(t+1/2)}.$$

因此 $J^{(t+1)} \le J^{(t)}$，即**每次迭代目标不增。**

- **收敛性**：因 $J \ge 0$ 有下界，且单调不增，序列 $\{J^{(t)}\}$ 必收敛到某极限。停在"两步都不再改善"的**局部稳定点。**
- **非凸与局部最优**：目标 (6.1) 关于 $(\boldsymbol{\mu}, r)$ 整体**非凸**（例如一维两个点选哪个中心是组合问题）。单调不增**只保证到局部最优，不保证全局最优。**不同初始化可能得到不同 J^*。

6.3.5 一维手算例：点 0、2、8、10（自编例，已核算）

初始中心 $\mu_1 = 0,\ \mu_2 = 8$。

第一轮分配（步一，取最近中心）

- 点 0：$\|0-0\|^2 = 0 < \|0-8\|^2 = 64$ → 归簇 1。
- 点 2：$\|2-0\|^2 = 4 < \|2-8\|^2 = 36$ → 归簇 1。
- 点 8：$\|8-8\|^2 = 0 < \|8-0\|^2 = 64$ → 归簇 2。
- 点 10：$\|10-8\|^2 = 4 < \|10-0\|^2 = 100$ → 归簇 2。

分配得 $C_1 = \{0, 2\},\ C_2 = \{8, 10\}$。目标：

$$J = 0^2 + 2^2 + 0^2 + 2^2 = 0 + 4 + 0 + 4 = 8. \qquad (\text{首轮 J=8})$$

第一轮更新（步二，取均值）

$$\mu_1 = \frac{0+2}{2} = 1, \qquad \mu_2 = \frac{8+10}{2} = 9.$$

第二轮分配+更新

- 点 0：$\|0-1\|^2 = 1 < \|0-9\|^2 = 81$ → 簇 1。
- 点 2：$\|2-1\|^2 = 1 < \|2-9\|^2 = 49$ → 簇 1。
- 点 8：$\|8-9\|^2 = 1 < \|8-1\|^2 = 49$ → 簇 2。
- 点 10：$\|10-9\|^2 = 1 < \|10-1\|^2 = 81$ → 簇 2。

分配不变，故中心不变。目标：

$$J = 1^2 + 1^2 + 1^2 + 1^2 = 4. \qquad (\text{次轮 J=4})$$

→ 目标从 **8 降到 4**，且下一轮不再变化，算法停滞在局部稳定点。该例印证 6.3.2–6.3.4 的"单调不增"。

一维 K-means：中心向各簇均值移动



分配不变时，均值更新让平方误差从 8 降到 4。

6.3.5a 往年课件原例：30 个西瓜样本的一轮 K-means

> **来源性质**：S25 72–75 页，往年课件原例，数据来自课件注明的《机器学习》表 9.1。这里逐项保留初始化、第一轮划分和均值更新。

课件数据按“编号、密度、含糖率”排成三组：

编号	密度	含糖率	编号	密度	含糖率	编号	密度	含糖率
1	0.697	0.460	11	0.245	0.057	21	0.748	0.232
2	0.774	0.376	12	0.343	0.099	22	0.714	0.346
3	0.634	0.264	13	0.639	0.161	23	0.483	0.312
4	0.608	0.318	14	0.657	0.198	24	0.478	0.437
5	0.556	0.215	15	0.360	0.370	25	0.525	0.369
6	0.403	0.237	16	0.593	0.042	26	0.751	0.489
7	0.481	0.149	17	0.719	0.103	27	0.532	0.472
8	0.437	0.211	18	0.359	0.188	28	0.473	0.376
9	0.666	0.091	19	0.339	0.241	29	0.725	0.445
10	0.243	0.267	20	0.282	0.257	30	0.446	0.459

取 $k=3$，课件选择 x_6, x_{12}, x_{27} 作为初始中心：

$$\boldsymbol{\mu}_1 = (0.403, 0.237), \quad \boldsymbol{\mu}_2 = (0.343, 0.099), \quad \boldsymbol{\mu}_3 = (0.532, 0.472).$$

按欧氏距离分配后的第一轮簇为

$$\begin{aligned} C_1 &= \{x_5, x_6, x_7, x_8, x_9, x_{10}, x_{13}, x_{14}, x_{15}, x_{17}, x_{18}, x_{19}, x_{20}, x_{23}\}, \\ C_2 &= \{x_{11}, x_{12}, x_{16}\}, \\ C_3 &= \{x_1, x_2, x_3, x_4, x_{21}, x_{22}, x_{24}, x_{25}, x_{26}, x_{27}, x_{28}, x_{29}, x_{30}\}. \end{aligned}$$

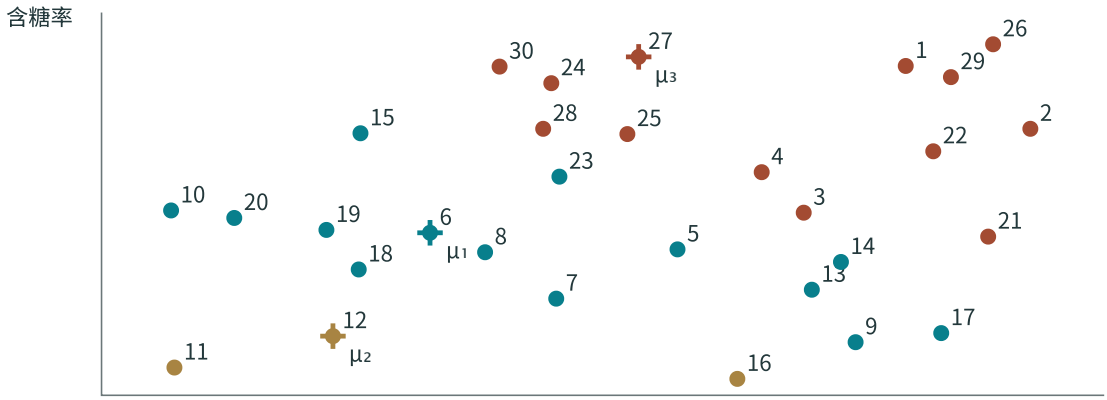
分别对簇内坐标取算术平均，课件给出

$$\boldsymbol{\mu}_1' = (0.473, 0.214), \qquad \boldsymbol{\mu}_2' = (0.394, 0.066), \qquad \boldsymbol{\mu}_3' = (0.623, 0.388).$$

以 C_2 为例直接复算：

$$\boldsymbol{\mu}_2' = \frac{(0.245, 0.057) + (0.343, 0.099) + (0.593, 0.042)}{3} = (0.3937, 0.0660) \approx (0.394, 0.066).$$

西瓜数据 K-means：第一轮分配与初始中心



颜色表示第一轮分配；十字为课件指定的三个初始中心。

之后重复“按最近中心分配”和“按簇内均值更新”，直到划分不再变化。这里的三个中心来自指定初始化；换一组初始样本，最终划分可能不同。

6.3.6 空簇、距离度量与"均值"的匹配（编者补充）

空簇：若某次分配使 $C_k = \varnothing$，则 (6.5) 分母 $|C_k| = 0$，均值无定义，目标里也没有该项。处理方式需**事先规定**，例如：把该中心重新播种到"当前误差最大的样本"上，或把它并入最近的非空簇，或丢弃该簇（此时实际簇数减少）。硬划分要求每簇非空，因此空簇必须被显式处理。

距离换了，中心也要换（编者推导）

- 步二的导数证明依赖 $\|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2$，即**平方欧氏距离**。
- 若改用 L_1 距离 $\sum_j |x_{ij} - \mu_{kj}|$，则对每个坐标独立地，使绝对偏差和最小的是该坐标的**中位数**，而非算术均值。
- *结论*：任意把距离换成 L_1 却仍用算术均值更新中心，会**失去** 6.3.3 的"该步最小化目标"证明，算法不再保证单调不增。匹配关系为：平方欧氏 ↔ 均值；L_1 ↔ 中位数；L_∞ ↔ 各坐标中点（按范围）。

> **常见误区**：以为"K 均值 = 随便定个距离 + 取平均"。距离是平方欧氏时算术均值才最优；换距离必须换中心更新规则。

6.4 单点转移的精确变化

6.4.1 为什么需要它：两种准则并不相同

步一（6.2）的"贪心最近"只看**当前**中心：把点分给离它最近的旧中心。但移动一个点会**改变两个簇的中心**，移动后新的误差未必由"旧中心谁更近"决定。S25 后部讨论的正是这种"更新两个中心后再比较"的单点转移准则。

设从含 $n_a > 1$ 个点的簇 a 移出点 $\mathbf{x}$，放入含 $n_b \geq 1$ 个点的簇 b。下面的公式给出目标变化的**精确值** ΔJ，而不是近似。

6.4.2 新均值与误差恒等式（编者推导）

- *假设*：a 原有 n_a 个点、均值 $\boldsymbol{\mu}_a$；b 原有 n_b 个点、均值 $\boldsymbol{\mu}_b$。移出 $\mathbf{x}$ 后，a 变 a'（大小 $n_a - 1$），b 变 b'（大小 $n_b + 1$）。
- *起始式（新均值）*：由均值定义 $\sum_{i \in a} \mathbf{x}_i = n_a \boldsymbol{\mu}_a$，移除 $\mathbf{x}$ 后

$$\boldsymbol{\mu}_{a'} = \frac{n_a \boldsymbol{\mu}_a - \mathbf{x}}{n_a - 1}, \qquad \boldsymbol{\mu}_{b'} = \frac{n_b \boldsymbol{\mu}_b + \mathbf{x}}{n_b + 1}. \tag{6.6}$$

- *误差平方和恒等式*：对任意簇 C（大小 n，均值 $\boldsymbol{\mu}_C$），有

$$\sum_{i \in C} \|\mathbf{x}_i - \boldsymbol{\mu}_C\|^2 = \sum_{i \in C} \|\mathbf{x}_i\|^2 - n \, \|\boldsymbol{\mu}_C\|^2. \tag{6.7}$$

  推导：展开 $\|\mathbf{x}_i - \boldsymbol{\mu}_C\|^2 = \|\mathbf{x}_i\|^2 - 2\mathbf{x}_i^\top \boldsymbol{\mu}_C + \|\boldsymbol{\mu}_C\|^2$，对 $i \in C$ 求和，注意 $\sum_{i \in C} \mathbf{x}_i = n \boldsymbol{\mu}_C$，则中间项 $-2(n\boldsymbol{\mu}_C)^\top \boldsymbol{\mu}_C = -2n\|\boldsymbol{\mu}_C\|^2$，与末项 $n\|\boldsymbol{\mu}_C\|^2$ 合并得 $-n\|\boldsymbol{\mu}_C\|^2$。得证。

6.4.3 "加入簇 b"那一项的推导（编者推导）

记 $S_b = \sum_{i \in b} \|\mathbf{x}_i\|^2$。簇 b 移动**前后**的误差分别为

$$E_b^{\text{old}} = S_b - n_b \|\boldsymbol{\mu}_b\|^2, \qquad E_b^{\text{new}} = S_b + \|\mathbf{x}\|^2 - (n_b + 1)\|\boldsymbol{\mu}_{b'}\|^2.$$

加入导致的变化：

$$\Delta J_b = E_b^{\text{new}} - E_b^{\text{old}} = \|\mathbf{x}\|^2 - (n_b + 1)\|\boldsymbol{\mu}_{b'}\|^2 + n_b \|\boldsymbol{\mu}_b\|^2. \tag{6.8}$$

代入 (6.6) 的 $\boldsymbol{\mu}_{b'}$：

$$(n_b + 1)\|\boldsymbol{\mu}_{b'}\|^2 = \frac{1}{n_b + 1}\|n_b \boldsymbol{\mu}_b + \mathbf{x}\|^2 = \frac{1}{n_b + 1}\left(n_b^2 \|\boldsymbol{\mu}_b\|^2 + 2 n_b \boldsymbol{\mu}_b^\top \mathbf{x} + \|\mathbf{x}\|^2\right).$$

代回 (6.8) 并按 $\|\mathbf{x}\|^2$，$\boldsymbol{\mu}_b^\top \mathbf{x}$，$\|\boldsymbol{\mu}_b\|^2$ 分组：

$$\Delta J_b = \|\mathbf{x}\|^2 - \frac{\|\mathbf{x}\|^2 + 2 n_b \boldsymbol{\mu}_b^\top \mathbf{x} + n_b^2 \|\boldsymbol{\mu}_b\|^2}{n_b + 1} + n_b \|\boldsymbol{\mu}_b\|^2.$$

提取系数：

- $\|\mathbf{x}\|^2$ 项：$1 - \frac{1}{n_b+1} = \frac{n_b}{n_b+1}$；
- $\boldsymbol{\mu}_b^\top \mathbf{x}$ 项：$-\frac{2n_b}{n_b+1} + 0 = -\frac{2n_b}{n_b+1}$，即 $-\frac{2n_b}{n_b+1}\boldsymbol{\mu}_b^\top \mathbf{x}$；
- $\|\boldsymbol{\mu}_b\|^2$ 项：$-\frac{n_b^2}{n_b+1} + n_b = \frac{-n_b^2 + n_b(n_b+1)}{n_b+1} = \frac{n_b}{n_b+1}$。

于是

$$\Delta J_b = \frac{n_b}{n_b + 1}\left(\|\mathbf{x}\|^2 - 2\boldsymbol{\mu}_b^\top \mathbf{x} + \|\boldsymbol{\mu}_b\|^2\right) = \frac{n_b}{n_b + 1}\|\mathbf{x} - \boldsymbol{\mu}_b\|^2. \tag{6.9}$$

6.4.4 "移出簇 a"那一项的推导（编者推导）

完全对称地，用 (6.7) 计算簇 a 移出前后的误差差：

$$\Delta J_a = E_a^{\text{new}} - E_a^{\text{old}} = -\|\mathbf{x}\|^2 - (n_a - 1)\|\boldsymbol{\mu}_{a'}\|^2 + n_a \|\boldsymbol{\mu}_a\|^2. \tag{6.10}$$

代入 $\boldsymbol{\mu}_{a'} = \frac{n_a \boldsymbol{\mu}_a - \mathbf{x}}{n_a - 1}$，同理分组可得

--

$$\Delta J_a = -\frac{n_a}{n_a - 1}\|\mathbf{x} - \boldsymbol{\mu}_a\|^2. \tag{6.11}$$

(验证要点：把 $\|\mathbf{x} - \boldsymbol{\mu}_a\|^2 = \|\mathbf{x}\|^2 - 2\boldsymbol{\mu}_a^\top \mathbf{x} + \|\boldsymbol{\mu}_a\|^2$ 乘上 $-\frac{n_a}{n_a-1}$ 后，各项系数恰好与 (6.10) 展开一致。)

6.4.5 合并得到 ΔJ（结论）

总变化 = 加入 b 的增量 + 移出 a 的减量：

$$\boxed{\Delta J = \frac{n_b}{n_b + 1}\|\mathbf{x} - \boldsymbol{\mu}_b\|^2 - \frac{n_a}{n_a - 1}\|\mathbf{x} - \boldsymbol{\mu}_a\|^2} \tag{6.12}$$

- **结论**：只有当 $\Delta J < 0$ 时，这次单点转移才**改善**目标。
- **成立条件**：$n_a > 1$（保证移出后 a 仍非空、且 (6.11) 分母非零），$n_b \geq 1$。
- $n_a = 1$ **不可用**：此时 a 只有一个点，移出后变成空簇，违反硬划分"非空"；公式 (6.11) 中 $\frac{n_a}{n_a-1} = \frac{1}{0}$ 无定义。因此 S25 强调该式只适用于 $n_a > 1$。
- **两种准则差异的解释**：$\Delta J < 0$ 与"$\mathbf{x}$ 离 $\boldsymbol{\mu}_b$ 比离 $\boldsymbol{\mu}_a$ 近"不是一回事——前者还受两簇大小 n_a, n_b 加权（项前系数 $\frac{n_a}{n_a-1}$ 与 $\frac{n_b}{n_b+1}$），且用的是**更新后的中心**。这正是为什么"最近中心分配"不等于"更新中心后最优转移"。

6.4.6 一维验证例（自编例，已核算）

例 A（有害转移）：簇 $a = \{2, 4\}$，$\mu_a = 3$，$n_a = 2$；簇 $b = \{10\}$，$\mu_b = 10$，$n_b = 1$。考虑把 $x = 4$ 从 a 移到 b。

- 用 (6.12)：

$$\Delta J = \frac{1}{2}\|4 - 10\|^2 - \frac{2}{1}\|4 - 3\|^2 = \frac{1}{2} \cdot 36 - 2 \cdot 1 = 18 - 2 = 16.$$

- 直接核算：移动前 $E_a = (2-3)^2 + (4-3)^2 = 2$，$E_b = 0$，合计 2；移动后 $a' = \{2\}$ 误差 0，$b' = \{10, 4\}$ 均值 7，误差 $(10-7)^2 + (4-7)^2 = 9 + 9 = 18$，合计 18。$\Delta J = 18 - 2 = 16$，与公式一致且为正 → 不转移。

例 B（有益转移）：簇 $a = \{2, 4\}$，$\mu_a = 3$，$n_a = 2$；簇 $b = \{3.5\}$，$\mu_b = 3.5$，$n_b = 1$。把 $x = 4$ 从 a 移到 b。

- 用 (6.12)：

$$\Delta J = \frac{1}{2}\|4 - 3.5\|^2 - \frac{2}{1}\|4 - 3\|^2 = \frac{1}{2} \cdot 0.25 - 2 \cdot 1 = 0.125 - 2 = -1.875 < 0.$$

- 直接核算：移动前合计 2；移动后 $a' = \{2\}$ 误差 0，$b' = \{3.5, 4\}$ 均值 3.75，误差 $(3.5 - 3.75)^2 + (4 - 3.75)^2 = 0.125$，合计 0.125。$\Delta J = 0.125 - 2 = -1.875$，一致且为负 → 应转移。

> **记住**：ΔJ 的符号才决定转不转移；光看"哪个旧中心更近"会漏掉簇大小与中心更新带来的效应。

6.5 如何评价结果

6.5.1 有外部标签：比较样本对（外部指标）

若有参考标签，最直观的想法是看"两样本是否同簇"在两种划分下是否一致。

Rand 指数（编者推导）

- 全部样本对共 $\binom{N}{2} = \frac{N(N-1)}{2}$ 对。
- 记：

- a：在参考划分与聚类结果中**都同簇**的对数；
- d：在两者中**都异簇**的对数；
- b：参考同簇、聚类异簇；c：参考异簇、聚类同簇。

- *起始式*：一致的对数 $= a + d$，故

$$\mathrm{Rand} = \frac{a+d}{\binom{N}{2}} = \frac{a+d}{a+b+c+d}. \tag{6.13}$$

- *结论与性质*：Rand $\in [0,1]$，越大越一致；$\mathrm{Rand} = 1$ 表示两划分完全相同（允许簇编号置换）。它**对簇编号置换不变**（见 6.1.3），因为只统计"同/异簇"是否一致，不关心编号。
- 课件还列出 Jaccard 指数 $\frac{a}{a+b+c}$、Fowlkes–Mallows 指数 $\frac{a}{\sqrt{(a+b)(a+c)}}$ 等外部指标，思路都是用列联表统计四类对数。

一维验证例（自编例，已核算）：4 个样本，参考标签 $\{1,2\}$ 属类 A、$\{3,4\}$ 属类 B；聚类结果簇 $C_1 = \{1,2,3\}$、$C_2 = \{4\}$。列联表：

参考 \ 聚类	C_1	C_2	合计
A	2	0	2
B	1	1	2
合计	3	1	4

逐对判断（共 $\binom{4}{2} = 6$ 对）：

- (1,2)：参考同、聚类同 → a；
- (3,4)：参考异、聚类异 → d；
- (1,3)、(2,3)：参考异、聚类同 → b（共 2）；
- (1,4)、(2,4)：参考异、聚类异 → d（共 2）。

于是 $a=1,\ d=3,\ b=2,\ c=0$，$\mathrm{Rand} = \frac{1+3}{6} = \frac{2}{3}$。该例说明 Rand 能区分"部分一致"的聚类。

6.5.2 无参考标签：轮廓系数（内部指标，编者推导）

内部指标只用量到的几何结构，不依赖外部标签。轮廓系数对每个点 i 评估"它待在当前簇有多合适"。

定义（符号/维度）：设 i 属于簇 C_{r_i}，其它簇记为 $k \neq r_i$，$\mathbf{x}_j \in \mathbb{R}^d$。

- 簇内不相识距离：

$$a_i = \frac{1}{|C_{r_i}| - 1} \sum_{j \in C_{r_i},\, j \neq i} \|\mathbf{x}_i - \mathbf{x}_j\|. \tag{6.14}$$

- 到其它各簇的平均距离（取最小）：

$$b_i = \min_{k \neq r_i} \left(\frac{1}{|C_k|} \sum_{j \in C_k} \|\mathbf{x}_i - \mathbf{x}_j\| \right). \tag{6.15}$$

- 轮廓系数：

$$s_i = \frac{b_i - a_i}{\max(a_i, b_i)}. \tag{6.16}$$

过程讲解

- *假设*：a_i 衡量"我与同簇伙伴有多近"，b_i 衡量"我与最近的别的簇有多近"。
- *逐项含义*：若 $s_i \approx 1$，说明 $b_i \gg a_i$，点远离其它簇、紧贴本簇，分得好；若 $s_i \approx 0$，说明 $a_i \approx b_i$，点在边界；若 $s_i < 0$，说明 $b_i < a_i$，点其实离别的簇更近，可能分错。
- *范围*：由构造知 $-1 \le s_i \le 1$。
- *结论与条件*：整体轮廓系数取所有 s_i 的平均，用以比较不同 K 或不同算法的紧凑—分离折中。**单点簇**时 $|C_{r_i}| - 1 = 0$，(6.14) 无定义，需另定约定（如令该点 $s_i = 0$ 或单独处理）。
- *局限*：内部指标只衡量"某种几何偏好"，**不能证明语义正确**——分得的簇在几何上紧凑，未必对应真实的类别含义。

一维验证例（自编例，已核算）：簇 $A = \{1, 2, 3\}$，簇 $B = \{10, 11\}$。取点 $i = 2 \in A$。

- $a_i = \frac{|2-1|+|2-3|}{2} = \frac{1+1}{2} = 1$。
- 到簇 B 的平均距离 $= \frac{|2-10|+|2-11|}{2} = \frac{8+9}{2} = 8.5$，故 $b_i = 8.5$。
- $s_i = \frac{8.5-1}{\max(1, 8.5)} = \frac{7.5}{8.5} \approx 0.882$。接近 1，说明该点分得很好。（同理点 $10 \in B$：$a_i = 1$，$b_i = \frac{9+8+7}{3} = 8$，$s_i = \frac{8-1}{8} = 0.875$。）

6.5.3 如何选 K

K 不是算法自动决定的。常用做法：

- **肘部法**：画 J 随 K 的曲线，J 随 K 增大单调下降，"拐点"处近似最优 K（但拐点常不明显）。
- **稳定性**：多次不同初始化，看哪些簇稳定出现。
- **领域含义与验证目标**：结合业务可解释性与下游任务判断。
- 内部指标（轮廓系数等）可在无标签时辅助比较不同 K，但如前所述，不能替代语义正确性判断。

6.6 收敛、初始化与常见陷阱

6.6.1 收敛到什么、不保证什么（编者补充）

- K 均值每轮 J 单调不增且 $J \ge 0$，故 $\{J^{(t)}\}$ 收敛（6.3.4）。但收敛点是**局部稳定点**：在"重分配"和"更新中心"两步上都不再改善，未必是全局最小。
- 目标 (6.1) 关于"谁归哪簇"是组合问题、整体非凸，所以**不同初始化可能得到不同 J^* 与不同划分**。

6.6.2 初始化与多起点（编者补充）

- **随机种子**：结果依赖初始中心；本项目手算实验用确定性小数据，不依赖单次随机运行来下结论（见学习指南）。
- **多起点重启**：跑若干次不同随机初始化，保留最小 J 的结果，是实践中减小局部最优影响的常用办法。
- **K-means++ 直觉（编者补充）**：首中心随机取；之后每个新中心都以"与已选中心距离越大、被选概率越高"的方式采样。这样让初始中心彼此分散，通常比纯随机更快接近好解。其严格概率保证超出本章范围。

6.6.3 空簇的处理约定（编者补充）

硬划分要求每簇非空。若分配后出现空簇（见 6.3.6），须事先规定处理，例如：把该中心重新播种到当前误差最大的样本、或并入最近的非空簇、或丢弃该簇（实际簇数减少）。**不能**让分母为 0 的均值公式悄悄运行。

6.6.4 常见误区汇总（编者补充）

1. **距离换了还用算术均值**：只有平方欧氏对应均值；L_1 应换中位数（6.3.6）。
2. **把簇编号当语义**：编号可任意置换，不与类别挂钩（6.1.3）。

3. **用内部指标当真相**：轮廓系数等只衡量几何偏好，不证明语义正确（6.5.2）。
4. **认为 K 均值给全局最优**：它只到局部稳定点，依赖初始化（6.3.4、6.6.1）。
5. **忽视特征缩放**：欧氏距离对量纲敏感，先标准化常能显著改变结果（与学习指南"单位、缩放会影响算法"一致）。
6. **单点转移直接用 $n_a = 1$ 的公式**：此时会产生空簇且分母为 0，公式 (6.12) 不适用（6.4.5）。

> **本章小结**：聚类先定义"硬划分"（非空、不交、覆盖），再用距离与聚合规则构建簇。序贯/层次法靠链接准则合并，K 均值靠"重分配 + 更新均值"两步把平方误差单调压低；单点转移的 ΔJ 公式说明"更新中心后最优"与"最近中心"并不同。评价时，有标签用 Rand 等外部指标，无标签用轮廓系数等内部指标，但内部指标不能替代语义判断。

第七章 特征选择与降维：保留什么，舍弃什么

> 往年资料：S11 5–48 页（选择）；S12 4–43 页（线性降维与 PCA）、44–54 页（KPCA、LLE、NMF）。2026-10-30 已视觉核对 S11 5–8、15、40–45 页和 S12 36–38 页，并恢复三维 Filter 子集评价原例；本年度对应课件尚未提供。课件中的行列约定不统一，本章统一样本按行；其余概率距离与原表数值仍待逐项核验。

> **本章怎么读**：先建立直觉（“为什么高维会有问题、要保留/丢掉什么”），再读正式推导。本章所有非平凡公式都配有“过程讲解”：先讲假设、符号、维度，再写起始式，逐步展示代数中间步骤，最后说明结论与成立条件。统一符号见学习指南；本书 X 按**行**放样本，与部分按列放样本的课件差一个转置。

7.1 选择原特征还是构造新特征

7.1.1 为什么高维会带来麻烦（直觉）

高维数据常常包含三类“没用”的特征：

- **无关特征**：与目标完全无关，只会引入噪声；
- **冗余特征**：与已有特征高度相关，信息重复；
- **噪声特征**：本身是随机扰动。

但有一个**常见误区**必须澄清：

> **记住**：某个特征“取值经常为零”或“方差很小”，**并不能证明它无用。**稀有事件往往最有辨识力——例如欺诈检测中，欺诈样本极少，其指示特征在绝大多数时刻为 0，但恰恰是最关键的特征。判断是否保留，要看它与标签/任务的关系，而不是单纯看它“动得勤不勤”。

维度过高还会带来两个实际困难：

1. **计算与存储**：模型复杂度、训练时间随维度上升；
2. **统计可靠性下降**：样本数固定时，维度越高，单位体积内样本越稀疏（“维度灾难”），估计出的模型越不可靠。

所以我们要回答一个核心问题：**保留什么，舍弃什么?**

7.1.2 两条路线：特征选择 vs 特征提取

路线	做法	输出含义	典型例子
特征选择	从原始 d 个坐标里挑出 q 个保留	仍是原始坐标，可解释	去掉“身高”换成只用“体重”
特征提取（构造）	用变换把原始特征组合成新的 q 个坐标	新坐标，通常是原特征的线性/非线性组合	把多个像素组合成一个投影分量（PCA 分量）

两者**都能降维**，但输出的含义不同：

- 选择：保留的是“看得懂”的原始变量，便于向业务方解释（“我们用了年龄、收入两个特征”）。
- 提取：得到的是“合成变量”，解释性通常较差（“第一主成分”是各列的加权混合）。

监督性差异：特征选择可以利用标签（选“对分类最有帮助”的特征）；而 PCA 这类经典提取方法通常**只利用输入分布**（只看 X 的形状，不看 y）。需要利用标签的提取方法见 7.4 的 LDA、7.5 的 KPCA 等。

7.1.3 一个小例子：噪声轴该不该留

设二维数据共有 4 个点（已中心化）：

$$(2, 0.0),\ (1, -0.1),\ (-1, 0.1),\ (-2, 0.1)$$

横向（第 1 维）跨度约 $[-2, 2]$，纵向（第 2 维）只在 $[-0.1, 0.1]$ 抖动，几乎是常数。

- 若用**特征选择**：第 2 维方差极小，很可能被直接丢弃；保留第 1 维。
- 若用**PCA 提取**（见 7.3）：会自动找到沿横向的长轴作为第一主方向，把“横向信息”压缩到一维。

两种路线都“降到了一维”，但选择得到的是原始横坐标，提取得到的是长轴投影——含义不同，后续可解释性也不同。

7.2 子集生成与评价必须区分

7.2.1 子集选择有多少种可能（复杂度 $C(d, q)$）

过程讲解：数一数子集个数

- **假设与符号**：d 个原始特征，要选出恰好 q 个（$0 < q < d$）。
- **起始式**：从 d 个里挑 q 个的组合数记为

$$C(d, q) = \binom{d}{q} = \frac{d!}{q!\,(d-q)!}.$$

- **逐步含义**：
  1. 第一个位置有 d 种选法，第二个有 $d-1$ 种……共 $d(d-1)\cdots(d-q+1) = \frac{d!}{(d-q)!}$ 种有序排列；
  2. 但选出的 q 个特征**没有顺序**（集合），同一集合被重复排了 $q!$ 次；
  3. 除以 $q!$ 得到无序子集数 $\binom{d}{q}$。
- **结论与增长**：子集总数（任意大小）为 $2^d - 1$。当 $d = 20, q = 2$ 时 $\binom{20}{2} = 190$ 还可穷举；当 $d = 100, q = 10$ 时 $\binom{100}{10} \approx 1.73 \times 10^{13}$，**穷举完全不可行。**
- **成立条件**：这里指“恰好选 q 个”的固定规模搜索；若允许任意大小，还要对所有 q 求和，仍是 $2^d - 1$ 量级。

常见误区：很多人以为“特征才几十个，穷举一下没关系”。事实上 $2^{20} \approx 10^6$ 尚可，$2^{30} \approx 10^9$ 已很吃力，2^{50} 远超现实。所以大数据维下必须靠**启发式搜索。**

7.2.2 贪心搜索：SFS / SBS / 广义版本（逐步）

既然不能穷举，就用贪心：**每次只做局部最优**，但**不保证全局最优。**

(a) 前向序贯 SFS（Sequential Forward Selection）

- 从空集 $F = \varnothing$ 开始。
- 每一步：对**尚未入选**的每个候选特征 f，计算“把 f 加入 F 后”的评价得分，选让得分提升最多的那个加入。
- 重复 q 次，得到 q 个特征。

> **过程讲解（SFS 第 t 步）**：设当前已选集合 F_{t-1}（大小 $t-1$），候选集 $\overline{F}$。要解
>
> $$\hat{f} = \arg\max_{f \in \overline{F}} \ \mathrm{Score}(F_{t-1} \cup \{f\}).$$
>
> 这一步只需评估 $|\overline{F}| = d - (t-1)$ 个特征，总共约 $\sum_{t=1}^{q}(d-t+1) \approx dq$ 次评价，远小于 $\binom{d}{q}$。

（b）后向序贯 SBS（Sequential Backward Selection）：从全集 $F = \{1, \ldots, d\}$ 开始，每一步删掉“删掉后得分下降最少”的特征，直到剩 q 个。SBS 适合“特征间有强冗余”的情形（先拥有全部信息再逐步裁剪）。

（c）广义/可逆版本（Plus-L-Minus-R，L-R）：SFS 一旦选了某特征就**永远不能反悔**，早期错选会一直拖累结果。L-R 方法允许“增加 L 个后，再删除 R 个”，或反过来（删除后再加回），从而缓解“早期选择无法撤销”的问题。

记住：贪心搜索**没有全局最优保证。**它可能陷入次优子集——这与梯度下降可能停在非凸函数的局部极小是类似的思想。

7.2.3 Filter / Wrapper / Embedded 三种评价框架

框架	子集如何评分	适用考虑
Filter（过滤式）	用数据本身的统计量：类间散度、概率可分性、互信息等	通常较快、与后续模型无关，但所选指标**未必等于**目标模型的最终效果
Wrapper（包裹式）	用指定模型在内部验证集上的表现（如交叉验证准确率）	最贴近最终目标，但每评估一个子集就要**重训一次模型**，成本高
Embedded（嵌入式）	在模型训练过程中联合完成选择，如 LASSO 的 L_1 正则、决策树的特征分裂	依赖具体模型与正则准则，兼顾效率与目标

Filter 不是“每个特征独立排名”：Filter 也可以对**整个子集**计算统计量（例如用子集的协方差矩阵算类间散度）。但最常见的“单变量排序滤子”有个经典陷阱：

> **常见误区（XOR 交互）**：两个**均匀二元**特征 A, B 各自都与标签独立，但标签 $y = A \oplus B$（异或）却完全由二者**共同**决定。单变量 Filter 会同时丢掉 A 和 B，漏掉关键交互。这说明：Filter 排名好 ≠ 子集最终效果好，必要时用 Wrapper 或能捕捉交互的模型兜底。

7.2.3a 往年课件原例：三维数据的 Filter 子集评分

> **来源性质**：S11 40–43 页，往年课件原例。课件用两类、每类 3 个三维样本，比较单特征、双特征和全部三特征的 Fisher 型评分。

两类数据为

$$W_1 = \begin{bmatrix} 1 & 2 & 4 \\ 3 & 3 & 5 \\ 4 & 4 & 7 \end{bmatrix}, \qquad W_2 = \begin{bmatrix} 2 & 7 & 6 \\ 5 & 8 & 8 \\ 6 & 9 & 9 \end{bmatrix},$$

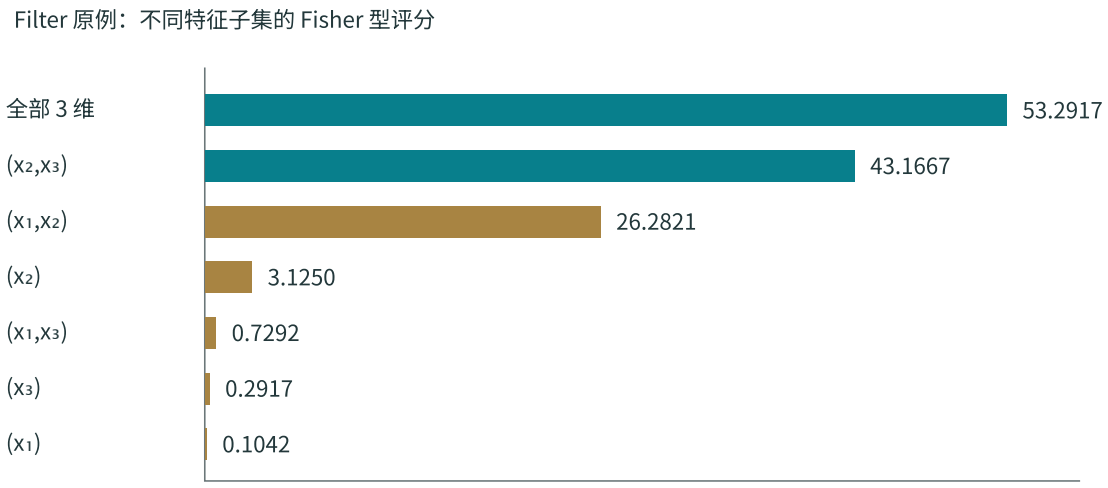
每行一个样本，三列分别是 x_1, x_2, x_3。课件采用

$$J_2 = \mathrm{tr}(S_W^{-1} S_B)$$

评价子集，其中 S_W 是子集坐标下的类内散度矩阵，S_B 是类间散度矩阵。若子集只有一维，式子退化为“类均值差平方 / 两类方差之和”。

课件列出的评分为：

子集	J_2
(x_1, x_2, x_3)	**53.2917**
(x_2, x_3)	**43.1667**
(x_1, x_2)	26.2821
(x_2)	3.1250
(x_1, x_3)	0.7292
(x_3)	0.2917
(x_1)	0.1042



逐步读结论：

1. 单特征排名是 $J_2(x_2) > J_2(x_3) > J_2(x_1)$，所以若只能留一维，应选 x_2。
2. 若保留两维，不能只凭单变量排名猜结果，必须直接评价候选子集。本题 (x_2, x_3) 的 43.1667 明显大于 (x_1, x_2) 的 26.2821。
3. 三维全部保留时分数最高，但这不自动意味着泛化最好；维数增加也提高了模型复杂度，Wrapper 还要用验证误差检查。

> **数值约定**：散度矩阵是否除以样本数会改变 J_2 的整体尺度，但在同一约定下比较子集的排序不变。复算时必须让所有候选子集采用同一归一化方式。

7.2.4 Bhattacharyya 距离：概率可分性的一种度量

S11 列出了 Bhattacharyya、Chernoff 等多种概率距离。它们的**名称、尺度、最优方向各不相同，不能都当成欧氏距离。**下面只细讲 Bhattacharyya，因为它是教材里最常被引用的一种。

过程讲解：定义与基本性质

- **假设与符号**：两类的概率密度（或质量）函数 $p(x), q(x)$，定义在同一样本空间上。
- **起始式**：Bhattacharyya 系数（Bhattacharyya coefficient）

$$BC(p,q) = \int \sqrt{p(x)\,q(x)}\,dx \qquad （离散情形把积分换成求和）.$$

- **逐步含义**：
  1. 被积函数 $\sqrt{p(x)q(x)}$ 同时被两类“同时有大概率”的区域拉高；两类越重叠，BC 越接近 1。
  2. 由柯西-施瓦茨不等式可证 $0 \le BC(p,q) \le 1$（离散时同理，因 $\sum\sqrt{pq} \le \sqrt{\sum p \sum q} = 1$）。
  3. 取负对数得到 Bhattacharyya 距离

$$D_B(p,q) = -\log BC(p,q) = -\log \int \sqrt{p(x)q(x)}\,dx.$$

- **结论与范围**：$D_B \in [0, +\infty)$。
  - 两类**完全重合**（$p = q$）时 $BC = 1$，$D_B = 0$；
  - 支撑**完全不交**时 $BC = 0$，$D_B \to +\infty$。
- **成立条件**：积分/求和在整个样本空间上进行；$\log$ 默认自然对数（见统一符号表）。

一维离散数值小例（自编例，未与 S11 原表核对）：设两类在 $\{0,1\}$ 上的分布为

$$p = (0.5,\ 0.5), \qquad q = (0.9,\ 0.1).$$

则

$$BC = \sqrt{0.5 \times 0.9} + \sqrt{0.5 \times 0.1} = \sqrt{0.45} + \sqrt{0.05} \approx 0.6708 + 0.2236 = 0.8944,$$

$$D_B = -\ln(0.8944) \approx 0.1116.$$

可以看到两类有重叠（q 在 0 处概率更高），所以 D_B 是一个较小但为正的数。

> **补充（标准结果，自编补充，未与 S11 原表逐项核对）**：当 p, q 均为高斯分布 $p = \mathcal{N}(\boldsymbol{\mu}_1, \Sigma_1)$，$q = \mathcal{N}(\boldsymbol{\mu}_2, \Sigma_2)$ 时，Bhattacharyya 距离有闭式

$$D_B = \frac{1}{8}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^T \Sigma^{-1} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) + \frac{1}{2}\ln\frac{\det\Sigma}{\sqrt{\det\Sigma_1 \det\Sigma_2}}, \qquad \Sigma = \frac{\Sigma_1 + \Sigma_2}{2}.$$

> 该式是教科书标准结果；本章不声称已与 S11 具体页码数值逐项核验（见顶部来源说明）。

Chernoff 距离（一并提及）：更一般的形式为

$$D_C(\lambda) = -\log \int p(x)^{\lambda} q(x)^{1-\lambda} dx, \qquad \lambda \in (0,1).$$

当 $\lambda = \frac{1}{2}$ 时即为 Bhattacharyya 距离，所以 Bhattacharyya 是 Chernoff 在 $\lambda = 1/2$ 处的特例。

7.2.5 Relief：用“近邻”给特征打分的直观方法

Relief 的思路很贴近直觉：对抽到的每个样本，找**同类最近邻（hit）和异类最近邻（miss）**。一个“好特征”应当满足：

- 在**同类**样本间变化小（hit 在该特征上接近）；
- 在**异类**样本间变化大（miss 在该特征上远离）。

于是该特征的评分应增加。对连续特征 m，一次更新大致是

$$W_m \leftarrow W_m - \frac{\mathrm{diff}(x_{i,m}, x_{\mathrm{hit},m})}{R_m} + \frac{\mathrm{diff}(x_{i,m}, x_{\mathrm{miss},m})}{R_m},$$

其中 R_m 是第 m 个特征的取值跨度（用于归一化），diff 取绝对差。**注意**：具体差异函数必须与连续/离散特征类型匹配；抽样方式、归一化、多类扩展都需要明确设定，Relief 本身只是一种启发式，不是最优准则。

Relief 迷你例（自编例）：两个特征、三个样本

样本	特征 x	特征 y	标签
A	0	0	+
B	1	0	−
C	0	5	+

考察样本 A（标签 +）：

- 同类最近邻是 C：特征 x 差为 $|0-0|=0$，特征 y 差为 $|0-5|=5$；
- 异类最近邻是 B：特征 x 差为 $|0-1|=1$，特征 y 差为 $|0-0|=0$。

按上面的更新方向：

- 特征 x 的增量 $\propto -0+1=+1$（有判别力，得分上升）；
- 特征 y 的增量 $\propto -5+0=-5$（同类反而差很多，得分下降）。

Relief 会**更看重 x 而非 y**——这与“y 在同类间剧烈变化、在异类间相同”的事实一致。

7.3 PCA 从最大投影方差推出

PCA（主成分分析）的目标：**找一组互相垂直的方向，让数据投影到这些方向后的方差最大。**方差大意味着“沿这个方向数据铺得开、信息多”。

7.3.1 第一主方向的完整推导

过程讲解（最大化投影方差）

- **假设与符号**
  - $X \in \mathbb{R}^{N\times d}$：行放样本，共 N 个、维度 d。
  - 已按训练均值**中心化**：每列均值为 0，即 $\frac{1}{N}\mathbf{1}^T X = \mathbf{0}$（$\mathbf{1}$ 为全 1 向量）。
  - $S = \dfrac{1}{N}X^T X \in \mathbb{R}^{d\times d}$：按 N 归一化的样本协方差矩阵，对称半正定。
  - 方向向量 $\mathbf{w} \in \mathbb{R}^d$，要求单位长度 $\mathbf{w}^T\mathbf{w}=1$。
- **步骤 1（写投影坐标）**：第 i 个样本投影为 $(X\mathbf{w})_i = \mathbf{x}_i^T\mathbf{w}$；全体投影是列向量 $X\mathbf{w} \in \mathbb{R}^N$。
- **步骤 2（写投影方差）**：因已中心化，投影后均值也为 0，故方差等于均值平方：

$$\frac{1}{N}\|X\mathbf{w}\|^2 = \frac{1}{N}(X\mathbf{w})^T(X\mathbf{w}) = \frac{1}{N}\mathbf{w}^T X^T X\mathbf{w} = \mathbf{w}^T\left(\frac{X^T X}{N}\right)\mathbf{w} = \mathbf{w}^T S\mathbf{w}.$$

- **步骤 3（为什么必须加约束）**：若不限制长度，把 $\mathbf{w}$ 放大 c 倍，方差就变成 $c^2\mathbf{w}^T S\mathbf{w}$，可任意增大——但这**不是方向变了，只是长度变了。**因此固定 $\|\mathbf{w}\| = 1$。
- **步骤 4（构造拉格朗日函数）**：最大化 $f(\mathbf{w}) = \mathbf{w}^T S\mathbf{w}$，约束 $g(\mathbf{w}) = \mathbf{w}^T\mathbf{w} - 1 = 0$：

$$\mathcal{L}(\mathbf{w}, \lambda) = \mathbf{w}^T S\mathbf{w} - \lambda(\mathbf{w}^T\mathbf{w} - 1).$$

- **步骤 5（对 $\mathbf{w}$ 求梯度并令为 0）**：先展开 $\mathbf{w}^T S\mathbf{w} = \sum_{a,b} w_a S_{ab} w_b$。对第 c 个分量求偏导（利用 S 对称，$S_{ac} = S_{ca}$）：

$$\frac{\partial}{\partial w_c}(\mathbf{w}^T S\mathbf{w}) = \sum_b S_{cb} w_b + \sum_a w_a S_{ac} = (S\mathbf{w})_c + (S\mathbf{w})_c = 2(S\mathbf{w})_c.$$

故 $\nabla_{\mathbf{w}}(\mathbf{w}^T S\mathbf{w}) = 2S\mathbf{w}$；同理 $\nabla_{\mathbf{w}}(\mathbf{w}^T\mathbf{w}) = 2\mathbf{w}$。令梯度为 0：

$$2S\mathbf{w} - 2\lambda\mathbf{w} = \mathbf{0} \quad \Longrightarrow \quad S\mathbf{w} = \lambda\mathbf{w}.$$

- **步骤 6（解释结论）**：驻点处 $\mathbf{w}$ 是 S 的**单位特征向量**，λ 是其特征值。代回目标：

$$\mathbf{w}^T S\mathbf{w} = \mathbf{w}^T(\lambda\mathbf{w}) = \lambda\,\mathbf{w}^T\mathbf{w} = \lambda.$$

所以**最大方差方向 = 最大特征值对应的单位特征向量**，该方向携带的方差正是 λ_1。

- **步骤 7（多方向）**：第二主方向在与第一方向正交的子空间里重复上述最大化，得到第二大特征值对应的特征向量；依次得到全部（秩数以内）主方向。
- **步骤 8（取前 q 个并投影/重构）**：令 $W \in \mathbb{R}^{d\times q}$ 的列为前 q 个**单位、互相正交**的特征向量，则

$$Z = XW \in \mathbb{R}^{N\times q}, \qquad \widehat{X} = ZW^T = XWW^T.$$

> 若原始数据**未**中心化，重构时还要把样本均值加回去：$\widehat{\mathbf{x}}_i = \widehat{\mathbf{x}}_i^{(\text{中心化})} + \boldsymbol{\mu}$。

- **成立条件**：X 已中心化。若改用 $\frac{1}{N-1}X^T X$（无偏样本协方差），**主方向完全相同**，特征值仅差 $N/(N-1)$ 的比例因子，不影响方向排序与解释方差比例。

7.3.2 解释方差比例

第 j 个主成分对应的方差是特征值 λ_j。前 q 个主成分解释的方差比例为

$$\text{ExplainedRatio}(q) = \frac{\sum_{j=1}^{q}\lambda_j}{\sum_{j=1}^{d}\lambda_j}.$$

- 分母 $\sum_{j=1}^{d}\lambda_j = \text{tr}(S)$ 等于**所有原始特征方差之和**（因 S 已中心化，对角线就是各特征方差）。
- **常见误区**：分母为零（所有样本完全相同，无任何变异）时该比值**无定义**；实际中若某特征恒为常数，要先剔除或单独处理。
- 实践上常选最小的 q 使比例达到例如 90%–95%，以此在“保信息”和“降维”间折中。

7.3.3 已有例题（保留并核验）

自编例：已中心化点 $(-2,0),(-1,0),(1,0),(2,0)$。

核验 S：设计矩阵（行放样本）

$$X = \begin{bmatrix} -2 & 0 \\ -1 & 0 \\ 1 & 0 \\ 2 & 0 \end{bmatrix}, \quad X^T X = \begin{bmatrix} 10 & 0 \\ 0 & 0 \end{bmatrix}, \quad N = 4,$$

故

$$S = \frac{1}{N} X^T X = \mathrm{diag}(2.5,\ 0).$$

- 特征值 $\lambda_1 = 2.5,\ \lambda_2 = 0$。第一主方向是对应 λ_1 的单位特征向量 $(1,0)^T$，即沿横轴。
- 取第一主成分 $Z = X(1,0)^T = (-2,-1,1,2)^T$，重构 $\widehat{X} = ZW^T$ 恰好还原原数据，**一维投影无重构损失。**
- **但注意结论的局限**：该数据集在纵轴（第 2 维）方差为 0，完全不含信息。然而“最大方差方向”并不保证“对分类最有用”——**若标签只由某个小方差方向决定**（例如标签实际取决于纵坐标，而这里纵坐标恒为 0，是退化情形），最大方差方向未必是最佳判别方向。这正是 PCA 与 7.4 的 LDA 的根本区别之一。

7.3.4 第二个数值小例：非退化情形

为展示 PCA 如何挑出“长轴”，看四个已中心化点：

$$(2, 0.1),\ (1, -0.1),\ (-1, 0.1),\ (-2, -0.1).$$

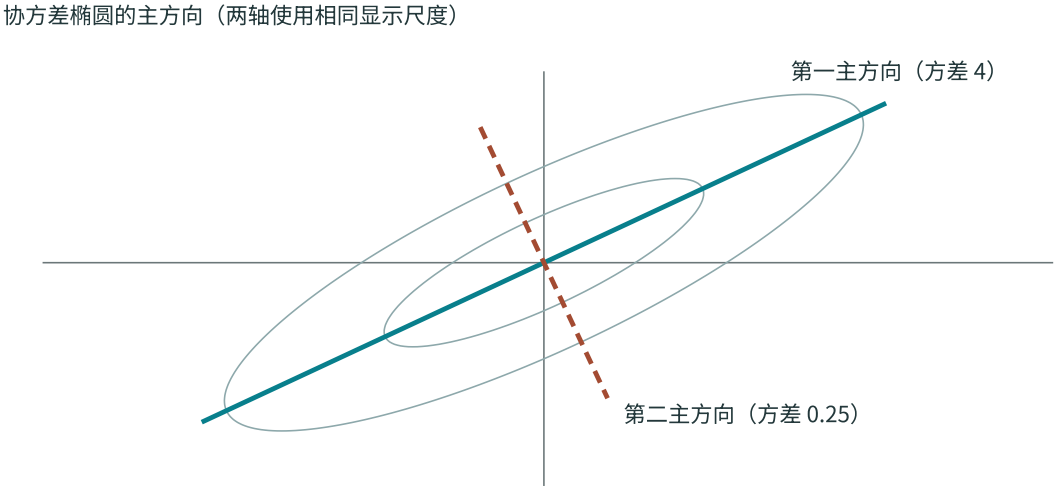
设计矩阵

$$X = \begin{bmatrix} 2 & 0.1 \\ 1 & -0.1 \\ -1 & 0.1 \\ -2 & -0.1 \end{bmatrix}, \quad X^T X = \begin{bmatrix} 10 & 0.2 \\ 0.2 & 0.04 \end{bmatrix},$$

$$S = \frac{1}{N} X^T X = \begin{bmatrix} 2.5 & 0.05 \\ 0.05 & 0.01 \end{bmatrix} \quad (N = 4).$$

- 迹 $\mathrm{tr}(S) = 2.51$，行列式 $\det(S) = 2.5 \times 0.01 - 0.05^2 = 0.0225$。
- 特征值：$\lambda_{1,2} = \frac{2.51 \pm \sqrt{2.51^2 - 4 \times 0.0225}}{2} = \frac{2.51 \pm \sqrt{6.2101}}{2} \approx \frac{2.51 \pm 2.492}{2}$，即 $\lambda_1 \approx 2.501,\ \lambda_2 \approx 0.009$。
- 第一主成分解释方差比例 $\approx 2.501 / 2.51 \approx 99.6\%$——几乎全部信息都在横向长轴上，纵向只是微小抖动。这正是 PCA “沿最大铺开方向投影” 的直观体现。

观察下图：PCA 选取的是方差较大的方向（斜向/长轴），而不是某条预先规定的坐标轴。



示意模型：协方差特征值为 4 与 0.25；椭圆轴比为标准差比 4:1。

7.4 中心化、标准化、SVD 与 LDA

7.4.1 中心化 ≠ 标准化（务必区分）

- **中心化（centering）**：每列减去该列均值，使均值变为 0。只改变位置，不改变尺度。
- **标准化（standardization / z-score）**：先中心化，再除以该列标准差，使每列均值 0、方差 1。

> **常见误区**：部分课件把“减均值”也叫“标准化”。本书**明确区分**二者——标准化一定包含减均值，但减均值不等于标准化。

何时用哪种?

- 单位不同又希望平等比较（如“身高(米)”与“体重(千克)”）时，可先标准化，避免量纲大的特征在距离/方差中占主导。
- 若幅值本身就有意义（如“像素亮度 0–255”的某种物理含义），就不一定该缩放。
- **PCA 对缩放敏感**：标准化与否，主方向可能完全不同。务必在训练流程内、用训练集统计量来做，见 7.6。

7.4.2 SVD 与 PCA 的联系（逐步推导）

过程讲解：从 SVD 得到主方向

- **假设与符号**：$X \in \mathbb{R}^{N\times d}$ 已中心化，其**截断**奇异值分解为

$$X = U\Sigma V^T,$$

其中 $U \in \mathbb{R}^{N\times r}$, $\Sigma \in \mathbb{R}^{r\times r}$（对角，奇异值 $\sigma_1 \geq \sigma_2 \geq \cdots > 0$），$V \in \mathbb{R}^{d\times r}$，且 $U^TU = I$, $V^TV = I$，$r = \operatorname{rank}(X)$。

- **步骤 1（写出 X^TX）**：

$$X^TX = (U\Sigma V^T)^T(U\Sigma V^T) = V\Sigma^TU^TU\Sigma V^T.$$

- **步骤 2（用正交性化简）**：因为 $U^TU = I$，所以

$$X^TX = V\Sigma^T\Sigma V^T.$$

- **步骤 3（认出特征分解）**：$\Sigma^T\Sigma$ 是 $r \times r$ 对角矩阵，对角元为 σ_j^2。于是

$$X^TX = V\,\operatorname{diag}(\sigma_1^2, \ldots, \sigma_r^2)V^T.$$

- **步骤 4（与 S 对照）**：$S = \frac{1}{N}X^TX$，故

$$S = V\,\operatorname{diag}\left(\frac{\sigma_1^2}{N}, \ldots, \frac{\sigma_r^2}{N}\right)V^T.$$

- **结论**：
  1. **主方向 = V 的列**（单位特征向量）；
  2. **协方差特征值** $\lambda_j = \sigma_j^2/N$；
  3. 前 q 个主成分方向就是 V 的前 q 列，与 7.3 用 S 直接做特征分解完全一致。

> **记住（SVD 奇异值 ≠ 方差）**：奇异值 σ_j 的**平方除以 N** 才是方差 λ_j。直接用 σ_j 当“方差”是常见错误。以 7.3.3 的例子验证：$X^TX = \operatorname{diag}(10, 0)$，故奇异值 $\sigma_1 = \sqrt{10} \approx 3.162$，而方差为 $\lambda_1 = 10/4 = 2.5$——“奇异值 3.162”和“方差 2.5”显然不是一回事。

7.4.3 LDA：利用标签的降维，与 PCA 的区别

线性判别分析（LDA）通过解广义特征值问题寻找判别方向：

$$S_B\mathbf{w} = \lambda S_W\mathbf{w},$$

其中 S_W（类内散度）度量“同类样本有多紧凑”，S_B（类间散度）度量“不同类的均值离得多远”。详细二分类推导见第三章。

关键事实：判别方向数 $\leq \min(d, K-1)$

过程讲解（为什么最多 $K-1$ 个方向）

- **假设与符号**：K 个类别，第 k 类均值 $\boldsymbol{\mu}_k$，总体均值 $\boldsymbol{\mu}$，$S_B = \sum_{k=1}^{K} n_k(\boldsymbol{\mu}_k - \boldsymbol{\mu})(\boldsymbol{\mu}_k - \boldsymbol{\mu})^T$。
- **步骤 1**：S_B 是 K 个**秩至多 1** 的外积矩阵之和，故 $\operatorname{rank}(S_B) \leq K$。
- **步骤 2**：但这些外积都落在“各类均值相对总体均值的差向量”张成的空间里，而 $\sum_k n_k(\boldsymbol{\mu}_k - \boldsymbol{\mu}) = \mathbf{0}$，所以这些差向量**至多只有 $K-1$ 个线性无关。**
- **步骤 3**：因此 $\operatorname{rank}(S_B) \leq K-1$，广义特征值问题 $S_B\mathbf{w} = \lambda S_W\mathbf{w}$ **最多只有 $K-1$ 个非零特征值**，即最多 $K-1$ 个非零判别方向。
- **结论**：LDA 可用方向数上界为 $\min(d,\ K-1)$。这**不是** PCA 的维数上限——PCA 在 S 满秩时最多可有 d 个主方向。

PCA vs LDA 的核心区别（先睹，详见 7.6 对照表）：

	PCA	LDA
是否用标签	否（无监督）	是（监督）
优化目标	最大投影方差	类间/类内散度比最大
方向数上限	$\leq \operatorname{rank}(S) \leq d$	$\leq \min(d, K-1)$
适合场景	去相关、压缩、可视化	分类前的判别降维

7.5 KPCA、LLE 和非负矩阵分解

7.5.1 核 PCA（KPCA）：在隐式特征空间做 PCA

KPCA 的思想：把样本通过非线性映射 $\Phi(\cdot)$ 送到高维（甚至无限维）特征空间，再在那个空间里做普通 PCA。我们**不需要显式写出 Φ**，只需核函数 $k(\mathbf{x}_i, \mathbf{x}_j) = \langle \Phi(\mathbf{x}_i), \Phi(\mathbf{x}_j) \rangle$。

过程讲解（核矩阵中心化 $K_c = HKH$）

- **假设与符号**：核矩阵 $K \in \mathbb{R}^{N\times N}$，$K_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$；$\mathbf{1} \in \mathbb{R}^N$ 为全 1 向量，$\mathbf{1}\mathbf{1}^T$ 是 $N \times N$ 全 1 矩阵；

$$H = I_N - \frac{1}{N}\mathbf{1}\mathbf{1}^T.$$

- **步骤 1（为什么中心化在特征空间也要做）**：PCA 要求数据中心化。在特征空间，中心化后的映射为 $\Phi_c(\mathbf{x}_i) = \Phi(\mathbf{x}_i) - \frac{1}{N}\sum_{j=1}^{N}\Phi(\mathbf{x}_j)$。
- **步骤 2（写出中心化核矩阵）**：中心化后的 Gram 矩阵为

$$K_c = (H\Phi)(H\Phi)^T = H\,\Phi\Phi^T\,H.$$

而 $\Phi\Phi^T$ 的 (i,j) 元正是 $\langle \Phi(\mathbf{x}_i), \Phi(\mathbf{x}_j) \rangle = K_{ij}$，故

$$K_c = HKH.$$

- **步骤 3（验证 H 的性质，说明中心化可一步完成）**：
  - 对称性：$H^T = (I - \frac{1}{N}\mathbf{1}\mathbf{1}^T)^T = I - \frac{1}{N}\mathbf{1}\mathbf{1}^T = H$。
  - 幂等性：令 $M = \frac{1}{N}\mathbf{1}\mathbf{1}^T$，则 $M^2 = \frac{1}{N^2}\mathbf{1}(\mathbf{1}^T\mathbf{1})\mathbf{1}^T = \frac{1}{N^2}\mathbf{1}\,(N)\,\mathbf{1}^T = M$，于是

    $$H^2 = (I - M)^2 = I - 2M + M^2 = I - 2M + M = I - M = H.$$

  所以 HKH 只做一次居中操作，结果仍是“已中心化”的核矩阵。

- **步骤 4（实用展开式）**：把 $K_c = HKH = (I - M)K(I - M) = K - MK - KM + MKM$ 写成分量：

$$K_c(i,j) = K(i,j) - \frac{1}{N}\sum_{l=1}^{N} K(l,j) - \frac{1}{N}\sum_{l=1}^{N} K(i,l) + \frac{1}{N^2}\sum_{l,m=1}^{N} K(l,m).$$

即“原核 − 行平均 − 列平均 + 总平均”。这一式只用原始 K 就能算，不必碰 Φ。

- **步骤 5（求主分量与训练投影）**：对中心化核矩阵做特征分解

$$K_c\mathbf{v} = \lambda\mathbf{v}, \qquad \lambda > 0,\ \|\mathbf{v}\| = 1.$$

（这里的 λ 是 K_c 的特征值，与 7.3 中 S 的特征值 λ 含义不同，注意区分。）训练数据在该主分量上的坐标为

$$\mathbf{z} = \sqrt{\lambda}\,\mathbf{v} \in \mathbb{R}^N.$$

- **步骤 6（新样本也必须中心化）**：对测试点 $\mathbf{x}$，其与训练样本的核向量为 $\mathbf{k}(\mathbf{x}) = [k(\mathbf{x}_1,\mathbf{x}),\ldots,k(\mathbf{x}_N,\mathbf{x})]^T$。**不能直接拿未中心化的 $\mathbf{k}$ 投影**，而要先按训练集统计做同样的中心化：

$$k_c(\mathbf{x}_i) = k(\mathbf{x}_i,\mathbf{x}) - \frac{1}{N}\sum_{l=1}^{N} k(\mathbf{x}_l,\mathbf{x}) - \frac{1}{N}\sum_{l=1}^{N} K(i,l) + \frac{1}{N^2}\sum_{l,m=1}^{N} K(l,m).$$

得到中心化核向量 $\mathbf{k}_c(\mathbf{x}) \in \mathbb{R}^N$ 后，投影坐标为

$$z(\mathbf{x}) = \frac{1}{\sqrt{\lambda}}\,\mathbf{v}^T\mathbf{k}_c(\mathbf{x}).$$

> **常见误区**：省略“新点中心化”是 KPCA 最常见的实现错误——训练时减的是训练集均值，测试点必须用**同一套**训练统计来中心化，否则投影不再在同一坐标系。

7.5.2 局部线性嵌入（LLE）：保持局部重构关系

LLE 假设：每个点都可由它的近邻**线性重构**；降维后要**保持同一组权重**，从而保持局部几何。

过程讲解（第一步：求重构权重）

- **假设与符号**：对每个 $\mathbf{x}_i$，取近邻集合 $N(i)$；权重 w_{ij} 在非近邻处固定为 0，且每行满足 $\sum_j w_{ij} = 1$。
- **步骤 1（写重构误差）**：

$$\varepsilon(W) = \sum_{i=1}^{N} \left\| \mathbf{x}_i - \sum_{j\in N(i)} w_{ij}\mathbf{x}_j \right\|^2.$$

- **步骤 2（化简）**：令 $\mathbf{z}_j = \mathbf{x}_j - \mathbf{x}_i$，则

$$\mathbf{x}_i - \sum_j w_{ij}\mathbf{x}_j = \mathbf{x}_i - \Big(\sum_j w_{ij}\Big)\mathbf{x}_i - \sum_j w_{ij}\mathbf{z}_j = -\sum_j w_{ij}\mathbf{z}_j$$

（用到 $\sum_j w_{ij} = 1$）。于是误差化为

$$\varepsilon_i = \left\| \sum_{j \in N(i)} w_{ij}\mathbf{z}_j \right\|^2 = \mathbf{w}_i^T G_i \mathbf{w}_i,$$

其中 $(G_i)_{jl} = (\mathbf{x}_j - \mathbf{x}_i)^T(\mathbf{x}_l - \mathbf{x}_i)$ 是局部 $k \times k$ Gram 矩阵。

- **步骤 3（带约束最小化）**：对 $\mathbf{w}_i$ 最小化 $\mathbf{w}_i^T G_i \mathbf{w}_i$，约束 $\mathbf{1}^T\mathbf{w}_i = 1$。拉格朗日函数

$$\mathcal{L} = \mathbf{w}_i^T G_i \mathbf{w}_i - \mu(\mathbf{1}^T\mathbf{w}_i - 1).$$

求梯度：$2G_i\mathbf{w}_i - \mu\mathbf{1} = \mathbf{0} \Rightarrow G_i\mathbf{w}_i = \frac{\mu}{2}\mathbf{1}$。记 $\alpha = \mu/2$，得 $\mathbf{w}_i = \alpha G_i^{-1}\mathbf{1}$。代入约束：

$$\mathbf{1}^T\mathbf{w}_i = \alpha\, \mathbf{1}^T G_i^{-1}\mathbf{1} = 1 \quad \Longrightarrow \quad \alpha = \frac{1}{\mathbf{1}^T G_i^{-1}\mathbf{1}}.$$

- **结论（闭式解）**：

$$\mathbf{w}_i = \frac{G_i^{-1}\mathbf{1}}{\mathbf{1}^T G_i^{-1}\mathbf{1}}.$$

（若 G_i 奇异，通常用正则化 $G_i + \varepsilon I$ 处理。）

过程讲解（第二步：在低维保持权重）

- **步骤 4（写低维保持目标）**：设低维坐标 $Y \in \mathbb{R}^{N\times q}$（行放点），希望

$$\min_Y \sum_{i=1}^N \left\| \mathbf{y}_i - \sum_j w_{ij}\mathbf{y}_j \right\|^2 = \operatorname{tr}\big(Y^T(I-W)^T(I-W)Y\big).$$

记 $M = (I-W)^T(I-W) \in \mathbb{R}^{d\times d}$（注意此处 W 是 $N\times N$ 的权重矩阵，非 7.3 的投影矩阵）。

- **步骤 5（为什么需要额外约束）**：若不加约束，令所有 $\mathbf{y}_i$ 等于同一常数 $\mathbf{c}$，则 $\mathbf{y}_i - \sum_j w_{ij}\mathbf{y}_j = \mathbf{c} - \mathbf{c}\sum_j w_{ij} = \mathbf{0}$，损失为 0——所有点**塌缩成一个点**，毫无意义。因此必须加“零均值、单位协方差”类约束（常写作 $Y^TY = NI$ 或对坐标做正交归一）。
- **步骤 6（取特征向量）**：在约束下，最小化 $\operatorname{tr}(Y^TMY)$ 的解 Y 由 M 的**最小特征值**对应的特征向量给出。但要**排除平凡常数方向**：因为全 1 向量是 M 的零特征值特征向量（对应塌缩解）。所以最终取 M 的**最小 q 个非零特征值**对应的特征向量（即第 2 到第 $q+1$ 小特征值方向）作为低维嵌入。

> **记住**：LLE 是**无监督、流形式**的降维，擅长保持“局部邻域结构”；它对近邻数 k 敏感，且对噪声、数据采样密度不均较脆弱。

7.5.3 非负矩阵分解（NMF）：加性部件表示

对非负数据 $X \geq 0$（$X \in \mathbb{R}_+^{N\times d}$），寻找

$$X \approx AB, \qquad A \in \mathbb{R}_+^{N\times q},\ B \in \mathbb{R}_+^{q\times d},$$

其中“非负”指所有元素 ≥ 0。

- **目标函数（两种常见选择）**：
  - **Frobenius 误差**：$\min_{A,B\geq 0} \|X - AB\|_F^2$；

- **广义 KL 散度**：$\min_{A,B\geq 0} D_{KL}(X\|AB)$。
- **记住**：二者**更新公式不同**，不能混用；教材/代码务必确认用的是哪一种。

- **为什么“非负”有用（直觉）**：非负约束下，原数据被表示成若干**非负基的加权和**（如一张脸 = “鼻子部件” + “眼睛部件” +... 的正向叠加），这比 PCA 的“可正可负”组合更接近“部件相加”的人类直觉，因此常产生**加性部件表示**，便于解释。
- **常见误区**：NMF 的优化是**非凸**的，初始值不同常得到不同解；解通常**不唯一**（缩放/置换等价）。它不是 PCA 的“非负版等价物”，而是另一条建模路线。

7.5.4 任何降维都必须在训练折内拟合（数据泄漏警告）

> **记住**：标准化、PCA、特征选择、KPCA 等的参数（均值、标准差、W、K_c 的中心化统计、被选特征子集.....）都**只能从训练数据学习**。若先对**全数据**做 PCA 再划分训练/验证去交叉验证，验证集的分布信息会“漏”进训练，评估结果过于乐观。正确流程：在每一个训练折内独立拟合变换，再应用到验证/测试折。

7.6 方法对照与选择指南

7.6.1 一张速查表

方法	监督?	核心思想	输出	方向/部件数上限	典型用途
特征选择（Filter/Wrapper/Embedded）	可监督	挑原始坐标子集	原始特征子集	q（人为设定）	可解释性优先、预处理
PCA	否	最大投影方差	正交主成分	$\leq \operatorname{rank}(S) \leq d$	去相关、压缩、可视化
LDA	是	类间/类内散度比最大	判别方向	$\leq \min(d, K-1)$	分类前降维
KPCA	可监督（核可含标签信息）	特征空间 PCA	非线性主成分	同 PCA（核空间）	线性 PCA 不够时的非线性结构
LLE	否	保持局部线性重构权重	流形坐标	q（人为设定）	流形/非线性结构可视化
NMF	否	非负加性组合	非负基与系数	q（人为设定）	*parts-based* 可解释表示（如图像）

7.6.2 怎么选（决策要点）

1. **要可解释、保留原始变量含义** → 用特征选择（Filter 快、Wrapper 准、Embedded 兼顾）。
2. **无标签、想压缩/去相关/先看数据主轴** → PCA（必要时先标准化）。
3. **有标签、目标是分类降维** → LDA；注意方向数受 $\min(d, K-1)$ 限制。
4. **线性方法抓不住结构（如环形、瑞士卷）** → 试 KPCA（选核）或 LLE（选近邻数 k）。
5. **数据天然非负、想要“部件相加”式解释** → NMF。
6. **维度灾难来自无关/冗余特征且模型对维度敏感** → 先做选择或 PCA 再训练。

7.6.3 流程顺序红线（再强调）

- 中心化/标准化、PCA/KPCA 拟合、特征选择——**全部只在训练折内完成**；
- 新样本（测试/部署）用**训练阶段学到的同一套参数**做同样变换；
- 随机性实验固定种子；手算示例用确定性小数据，不靠一次随机运行下结论。

> 相关练习与自测见练习；回到来源页段时，请分清“课件已讲内容”与“编者补充推导”。

第八章 信息论模型：不确定性、差异与约束

> 往年资料：S13 8–18 页（熵与最大熵）、20–26 页（互信息与 KL）、28–39 页（条件最大熵）。本章采用明确的对数底，补足支持集与可逆性条件。

> **本章定位（编者补充，非考试范围推定）**：信息论给机器学习提供了统一的“不确定性语言”。熵衡量分布的不确定性，互信息衡量“看到 Y 能少猜多少 X”，KL 散度衡量两个分布的差异。它们分别服务于第四章决策树的**信息增益**、第三章 logistic / softmax 的**最大熵推导**、以及分类任务的**交叉熵损失**。第八章的熵可在第四章决策树之前预读（见学习指南）。

> **符号约定（来自统一符号表）**：本书 $\log$ 默认自然对数（单位 nat）；以 2 为底写作 $\log_2$，单位 bit。离散用求和 $\sum$，连续用积分 $\int$。向量按行放样本（设计矩阵 X 为 $N \times d$），与部分课件按列放样本存在转置差异时应检查维度。

8.1 熵是平均意外程度

8.1.1 自信息与离散熵的定义

直觉先行：一个事件带来的“信息量”，本质是我们的**意外程度**。几乎必然发生的事（比如“太阳从东边升起”）发生时，我们毫不意外，得到的信息极少；罕见的事（“陨石砸中自家屋顶”）一旦发生，意外极大，信息极多。所以信息量应当是概率的**递减函数**：概率越小，自信息越大。数学上取 $I(x) = -\log_2 p(x)$ 正好满足这一点（对数让极端概率拉开差距，负号把“小概率→大信息”翻正）。

过程讲解（离散熵的由来）：

- **假设与符号**：设 X 是离散随机变量，取值于有限或可数集合 $\mathcal{X}$。其概率质量函数为 $p(x) = P(X = x)$，满足 $p(x) \geq 0$ 且 $\sum_x p(x) = 1$。
- **维度/单位**：这是对**离散结果求和**；对数底取 2，单位 **bit**（若改用自然对数 $\log$，单位 nat）。
- **起始式**：把每个结果 x 的自信息 $I(x) = -\log_2 p(x)$ 按它发生的概率 $p(x)$ 做加权平均（即求期望），得到**平均自信息**，即熵：

$$H(X) = \mathbb{E}[I(X)] = \sum_x p(x)\, I(x) = \sum_x p(x)\big(-\log_2 p(x)\big).$$

整理即得标准形式：

$$H(X) = -\sum_x p(x) \log_2 p(x).$$

- $0 \log 0 = 0$ **约定（务必记住）**：当某个结果 x 的概率为 0 时，直接写 $0 \cdot \log_2 0$ 是“0×∞”不定式。统一约定

$$\lim_{t \to 0^+} t \log_2 t = 0,$$

故规定凡是 $p(x) = 0$ 的项其贡献为 0，不计入求和。这与“不会发生的事不带来信息”的直觉一致。

> **记住**：熵衡量的是**分布的不确定性**（平均而言还要猜多久），不是某个具体样本“包含多少知识”。一次抽样得到哪个值，和熵大小没有一一对应。

8.1.2 数值例子：公平硬币与 0.9 偏置硬币

例 1（公平硬币）：正面 H、反面 T，各 $p = 0.5$。

$$H = -\big[0.5\log_2 0.5 + 0.5\log_2 0.5\big] = -\log_2 0.5 = 1 \text{ bit}.$$

一个公平硬币的“不确定性”正好是 1 bit——用 1 个二进制问题（“是正面吗？”）就能消除全部不确定性。

例 2（偏置硬币，教师原题/教师答案核对）：正面概率 $p = 0.9$，反面 0.1。

过程讲解：

- 起始式：$H = -[0.9\log_2 0.9 + 0.1\log_2 0.1]$。
- 用换底 $\log_2 a = \ln a / \ln 2$（$\ln 2 \approx 0.6931472$）：

$$\log_2 0.9 = \frac{\ln 0.9}{\ln 2} \approx \frac{-0.1053605}{0.6931472} \approx -0.1520031,$$
$$\log_2 0.1 = \frac{\ln 0.1}{\ln 2} \approx \frac{-2.3025851}{0.6931472} \approx -3.3219281.$$

- 代入：

$$0.9\cdot(-0.1520031) = -0.1368028, \qquad 0.1\cdot(-3.3219281) = -0.3321928,$$

两项之和 ≈ -0.4689956，取负得

$$H \approx 0.468996 \text{ bit}.$$

> **结论**：正面概率 0.9 的硬币熵约为 **0.468996 bit**（与往年资料答案一致）。它远比公平硬币的 1 bit 小——因为结果高度可预测（多半是正面），平均只需不到半 bit 就能确定结果。

8.1.3 熵的上下界：$0 \le H(X) \le \log_2 K$

设 $K = |\mathcal{X}|$ 为可能结果个数（或支撑集大小）。

下界 $H \ge 0$：因 $p(x) \in [0,1]$，有 $-\log_2 p(x) \ge 0$；又 $p(x) \ge 0$，故每项 $p(x)(-\log_2 p(x)) \ge 0$，求和仍 ≥ 0。取等号当且仅当除一个结果外全为 0（即分布退化到一点，毫无不确定性）。

上界 $H \le \log_2 K$：下面用一条初等不等式严格证明（不依赖后文的 KL）。

过程讲解：

- **准备不等式**：对任意 $z > 0$，有 $\ln z \ge 1 - \frac{1}{z}$。证明：令 $g(z) = z - 1 - \ln z$，则 $g'(z) = 1 - \frac{1}{z}$，在 $z = 1$ 处取极小且 $g(1) = 0$，故 $g(z) \ge 0$，即 $\ln z \ge 1 - 1/z$。
- **目标**：证 $\sum_x p(x)\log_2(1/p(x)) \le \log_2 K$。
- **推导**：先写差值

$$\log_2 K - H = \sum_x p(x)\log_2 K + \sum_x p(x)\log_2 p(x) = \sum_x p(x)\log_2\big(K\,p(x)\big).$$

把 $\log_2$ 写成 $\ln / \ln 2$，并对每个 $z = K\,p(x) > 0$ 套用 $\ln z \ge 1 - 1/z$：

$$\log_2 K - H = \frac{1}{\ln 2}\sum_x p(x)\ln\big(K\,p(x)\big) \ge \frac{1}{\ln 2}\sum_x p(x)\left(1-\frac{1}{K\,p(x)}\right).$$

- 右边化简：$\sum_x p(x)\cdot 1 = 1$；$\sum_x p(x)\cdot\frac{1}{K\,p(x)} = \sum_x \frac{1}{K} = \frac{K}{K} = 1$。所以

$$\log_2 K - H \ge \frac{1}{\ln 2}(1-1) = 0 \quad\Longrightarrow\quad H \le \log_2 K.$$

- **成立条件与等号**：等号当且仅当对每个 $p(x)>0$ 有 $K\,p(x)=1$，即 $p(x)=1/K$ 对所有 x 成立——**均匀分布熵最大。**
- **直觉**：结果越多越不确定（上界随 K 增大）；分布越集中越确定（下界在一点分布取到）。

> **常见误区**：上界 $\log_2 K$ 的 K 是“支撑集大小”（概率非零的结果数）。若某结果概率为 0，它不贡献信息，此时上界应以实际支撑集计，而非名义总数。

8.1.4 微分熵与尺度变换 $h(aX) = h(X) + \log|a|$

连续随机变量的“熵”不再是对数概率求和，而是对数密度积分：

$$h(X) = -\int p(x)\log p(x)\,dx,$$

其中 log 取自然对数（单位 nat）。注意这里用密度 $p(x)$ 而非概率，因为单点概率为 0。

尺度变换公式：设 $a\neq 0$，$Y = aX$，则其密度为

$$p_Y(y) = \frac{1}{|a|}\,p_X\!\left(\frac{y}{a}\right).$$

过程讲解（推导 $h(aX) = h(X) + \log|a|$）：

- 起始式：$h(Y) = -\int p_Y(y)\log p_Y(y)\,dy$。
- 代入 $p_Y(y) = \frac{1}{|a|}p_X(y/a)$，并利用 $\log(c\cdot d) = \log c + \log d$：

$$\log p_Y(y) = \log\!\left(\frac{1}{|a|}\right) + \log p_X\!\left(\frac{y}{a}\right) = -\log|a| + \log p_X\!\left(\frac{y}{a}\right).$$

- 于是

$$h(Y) = -\int \frac{1}{|a|}p_X\!\left(\frac{y}{a}\right)\left[-\log|a| + \log p_X\!\left(\frac{y}{a}\right)\right]dy.$$

- 做变量代换 $u = y/a$，则 $dy = |a|\,du$（一维），第一项积分为

$$-\int \frac{1}{|a|}p_X(u)\big(-\log|a|\big)\,|a|\,du = \log|a|\int p_X(u)\,du = \log|a|\cdot 1 = \log|a|.$$

- 第二项积分为

$$-\int p_X(u)\log p_X(u)\,du = h(X).$$

- **结论**：

$$h(aX) = h(X) + \log|a|, \qquad a\neq 0.$$

> **记住**：微分熵会因尺度而整体平移 $\log|a|$。把变量单位从“米”换成“厘米”（$a=100$）会让微分熵凭空增加 $\log 100 \approx 4.6$ nat——所以它**不能无条件当作离散熵那种“绝对信息量”**。这也是为什么连续情形更常用的差异度量是 KL 散度（见 8.2.3）。

8.1.5 微分熵可为负：均匀分布的例子

对区间 $[a,b]$ 上的均匀分布 $U(a,b)$，密度恒为 $1/(b-a)$，于是

$$h(U) = -\int_a^b \frac{1}{b-a}\log\left(\frac{1}{b-a}\right)dx = -\log\left(\frac{1}{b-a}\right) = \log(b-a)$$

（自然对数）。

数值例子：若 $X \sim U(0, 0.5)$，则 $h(X) = \ln 0.5 \approx -0.693$ nat < 0。

> **结论**：微分熵**可以为负**，而离散熵恒非负。这进一步说明二者语义不同：离散熵有“最少需要几位编码”的信息论解释；微分熵只是某种“相对”的不确定性度量，比较时多用差值（即 KL）才有意义。

8.2 条件熵、互信息与 KL

8.2.1 条件熵与链式法则 $H(X,Y) = H(Y) + H(X \mid Y)$

已知 Y 之后，X 还剩下的不确定性叫**条件熵**：

$$H(X \mid Y) = \sum_y p(y)\, H(X \mid Y=y) = \sum_y p(y)\Big[-\sum_x p(x \mid y)\log_2 p(x \mid y)\Big].$$

交换求和顺序可写成

$$H(X \mid Y) = -\sum_{x,y} p(x,y)\log_2 p(x \mid y).$$

链式法则推导：

过程讲解：

- **准备**：联合概率分解 $p(x,y) = p(y)\,p(x \mid y)$，两边取对数（底 2）：

$$\log_2 p(x,y) = \log_2 p(y) + \log_2 p(x \mid y).$$

- **起始式**：联合熵

$$H(X,Y) = -\sum_{x,y} p(x,y)\log_2 p(x,y).$$

- 代入分解式并拆开：

$$H(X,Y) = -\sum_{x,y} p(x,y)\big[\log_2 p(y) + \log_2 p(x \mid y)\big] = -\sum_{x,y} p(x,y)\log_2 p(y) \;-\; \sum_{x,y} p(x,y)\log_2 p(x \mid y).$$

- **第一项**：对 x 求和时 $p(y)$ 不变，且 $\sum_x p(x,y) = p(y)$，故

$$-\sum_{x,y} p(x,y)\log_2 p(y) = -\sum_{y} p(y)\log_2 p(y) = H(Y).$$

- **第二项**：正是条件熵定义 $H(X\mid Y)$（见上）。
- **结论（链式法则）**：

$$H(X,Y) = H(Y) + H(X\mid Y).$$

由对称性亦得 $H(X,Y) = H(X) + H(Y\mid X)$。两式相减得

$$H(X\mid Y) = H(X) - I(X;Y), \qquad H(Y\mid X) = H(Y) - I(X;Y).$$

数值验证（2×2 联合分布）：设

$$p(0,0)=0.4,\ p(0,1)=0.1,\ p(1,0)=0.1,\ p(1,1)=0.4.$$

边缘：$P(X=0)=P(X=1)=0.5$，故 $H(X)=H(Y)=1$ bit。联合熵：

$$H(X,Y) = -\big[0.8\log_2 0.4 + 0.2\log_2 0.1\big] = -\big[0.8(-1.321928) + 0.2(-3.321928)\big] \approx 1.721928 \text{ bit}.$$

用链式法则检验：$H(X\mid Y) = H(X,Y) - H(Y) = 1.721928 - 1 = 0.721928$ bit。也可直接算条件分布（如给定 $Y=0$ 时 $P(X=0\mid Y=0)=0.8$），得 $H(X\mid Y=0) = -\big[0.8\log_2 0.8 + 0.2\log_2 0.2\big] \approx 0.721928$，与链式法则一致 ✓。

8.2.2 互信息 $I(X;Y)$：定义、对称性与非负性

互信息衡量“观察到 Y 后，对 X 的平均不确定性减少了多少”：

$$I(X;Y) = H(X) - H(X\mid Y).$$

过程讲解（三种等价形式与对称性）：

- 由 8.2.1 的 $H(X\mid Y) = H(X) - I(X;Y)$ 立刻得第一种：$I(X;Y) = H(X) - H(X\mid Y)$。
- 对称地，$H(Y\mid X) = H(Y) - I(X;Y)$，故 $I(X;Y) = H(Y) - H(Y\mid X)$。
- 把两个熵展开：

$$I(X;Y) = \big[H(X) + H(Y) - H(X,Y)\big].$$

- 写成联合/边缘比的形式（用 $p(x,y) = p(x)p(y\mid x)$ 等）：

$$I(X;Y) = \sum_{x,y} p(x,y)\log_2 \frac{p(x,y)}{p(x)p(y)}.$$

对称性：上式分母 $p(x)p(y)$ 对称，分子 $p(x,y)$ 也对称，故 $I(X;Y) = I(Y;X)$。

非负性：注意到

$$I(X;Y) = D_{KL}\big(p(x,y)\,\|\,p(x)p(y)\big),$$

即把“联合分布”与“两变量独立时的乘积分布”作 KL 散度。由 8.2.4 的 KL 非负性立刻得 $I(X;Y)\geq 0$。

为零的充要条件：当且仅当 $p(x,y) = p(x)p(y)$（两变量独立）时，比值恒为 1、对数为 0，互信息为 0。

> **常见误区**：单次条件事件**可能**增大不确定性（比如“看到乌云”反而让你更不确定是否下雨的概率分布变宽），但**平均**条件熵 $H(X\mid Y)\leq H(X)$ 恒成立（因 $I\geq 0$）。这两句话并不矛盾：前者是单点特例，后者是全概率平均。

> **跨章联系**：第四章决策树的“信息增益”正是 $H(Y)-H(Y\mid X_{\text{特征}})=I(X_{\text{特征}};Y)$——用互信息挑选最能降低标签不确定性的特征。

8.2.3 KL 散度：定义、性质与支撑集处理

KL 散度（Kullback–Leibler 散度）用来比较分布 p（“真实/参考”）与 q（“近似/模型”）：

$$D_{KL}(p\|q)=\sum_x p(x)\log\frac{p(x)}{q(x)}\quad(\text{离散}),\qquad D_{KL}(p\|q)=\int p(x)\log\frac{p(x)}{q(x)}dx\quad(\text{连续}).$$

性质清单（务必记住）：

1. **非负**：$D_{KL}(p\|q)\geq 0$（证明见 8.2.4）。
2. **不对称**：一般 $D_{KL}(p\|q)\neq D_{KL}(q\|p)$。它衡量“用 q 编码来自 p 的样本所多花的代价”，方向很重要。
3. **不是距离**：不满足三角不等式，且不对称，因此**不是度量（metric）**，只是“散度”。
4. **支撑集不匹配**：p 的支撑集记为 $S_p=\{x:p(x)>0\}$，q 的支撑集 $S_q=\{x:q(x)>0\}$。
   - 若某点 $p(x)>0$ 但 $q(x)=0$，则该项 $p(x)\log(p(x)/0)=+\infty$，整体 $D_{KL}=+\infty$。
   - 若 $p(x)=0$，则该项按 $0\log 0=0$ **约定**计为 0，**即便此时 $q(x)=0$ 也记为 0**（即定义 $0\cdot\log(0/0):=0$）。
   - **结论**：要使 $D_{KL}(p\|q)$ 有限，必须 $S_p\subseteq S_q$。

> **记住**：比较连续分布时，KL 要求 q 的支撑涵盖 p 的支撑，否则直接发散到无穷。

8.2.4 KL 非负性证明（$-\log u\geq 1-u$ 加权）

这是全章最该亲手推一遍的结论。

过程讲解：

- **准备不等式**：对任意 $u>0$，有 $-\log u\geq 1-u$。证明：令 $f(u)=u-1-\log u$，则 $f'(u)=1-1/u$，在 $u=1$ 取极小且 $f(1)=0$，故 $f(u)\geq 0$，即 $-\log u\geq 1-u$，等号当且仅当 $u=1$。

  （若用自然对数 $\ln$，同样有 $-\ln u\geq 1-u$；用 $\log_2$ 时右端需除以 $\ln 2$，但非负性不受影响。）
- **设元**：令 $u(x)=\dfrac{q(x)}{p(x)}$（在 $p(x)>0$ 处定义）。则 $-\log u(x)\geq 1-u(x)=1-\dfrac{q(x)}{p(x)}$。
- **加权**：两边同乘非负的 $p(x)$，得

$$p(x)\big(-\log u(x)\big)\geq p(x)-q(x).$$

- **对全部 x 求和（离散情形）**：

$$D_{KL}(p\|q)=\sum_x p(x)\log\frac{p(x)}{q(x)}=\sum_x p(x)\big(-\log u(x)\big)\geq\sum_x\big[p(x)-q(x)\big].$$

- 由于二者均为概率分布（或密度积分均为 1），$\sum_x p(x)=1$、$\sum_x q(x)=1$，故右端 $=1-1=0$。
- **结论**：

$$D_{KL}(p\|q)\geq 0.$$

- **等号条件**：当且仅当对每个 $p(x)>0$ 都有 $u(x)=1$，即 $q(x)=p(x)$ 在支撑集 S_p 上处处成立（要求支撑匹配，见 8.2.3）。

- **连续情形**：把求和换成积分、同样用 $-\log u \geq 1-u$ 加权 $\int p(x)dx$ 即可，论证完全一致。

> **互信息非负性的另一种来源**：因为 $I(X;Y)=D_{KL}(p(x,y)\|p(x)p(y))\geq 0$，所以“看到 Y 总能不增加（平均）对 X 的不确定性”。

8.2.5 交叉熵 = 熵 + KL，以及分类损失的含义

交叉熵定义（用 q 去编码来自 p 的样本的平均“惊喜度”）：

$$H(p,q)=-\sum_x p(x)\log q(x).$$

过程讲解（分解）：

- 起始式：$H(p,q)=-\sum_x p(x)\log q(x)$。
- 加一项减一项 $\log p(x)$：

$$H(p,q)=-\sum_x p(x)\big[\log p(x)+\log(q(x)/p(x))\big]=-\sum_x p(x)\log p(x)\ -\ \sum_x p(x)\log\frac{q(x)}{p(x)}.$$

- 第一项是 $H(p)$；第二项等于 $-D_{KL}(p\|q)$（注意 KL 定义里是 $\log(p/q)$，这里是 $\log(q/p)$ 且带负号）。整理：

$$H(p,q)=H(p)+D_{KL}(p\|q).$$

- **结论**：固定真实分布 p 时，最小化交叉熵 $\iff$ 最小化 KL 散度（因为 $H(p)$ 是常数）。

> **与分类训练的联系**：多类分类中，真实标签常用“独热（one-hot）”分布 p（某类为 1，其余 0），模型输出为 softmax 分布 q_θ。训练目标“最小化交叉熵损失”等价于“让模型分布 q_θ 逼近真实分布 p”，也就是最小化 $D_{KL}(p\|q_\theta)$。这正是 8.4 节最大熵模型落到分类任务时的优化目标。

8.3 最大熵是有约束的保守推断

8.3.1 最大熵原则与约束设定

直觉：当我们只知道有限个统计量（如均值、某些特征期望）时，最“保守”、最不额外臆造结构的做法是——**在满足已知约束的分布中，选熵最大的那一个。**熵最大 = 假设最少、最均匀。

约束通常包含三类：

1. **支撑集**：变量能取哪些值（离散：某些状态允许；连续：区间或全空间）。
2. **归一化**：$\sum_x p(x)=1$（离散）或 $\int p(x)dx=1$（连续）。
3. **矩/特征期望**：$\sum_x p(x)f_j(x)=a_j$，$j=1,\dots,m$（例如 $f_1(x)=x$ 对应均值约束）。

> **重要边界（编者补充）**：在整条实轴上**不做任何矩约束**地最大化微分熵，一般**没有有限解**——你可以把质量铺得极宽使微分熵任意大，或挤得极窄使其任意小。必须有“支撑 + 归一化 + 期望约束”三者共同限定，最大熵问题才有唯一、良态的解。

8.3.2 离散最大熵的指数族形式（拉格朗日求导）

目标：在约束 $\sum_x p(x)=1$ 与 $\sum_x p(x)f_j(x)=a_j$ $(j=1,\dots,m)$ 下，最大化

$$H(p)=-\sum_x p(x)\log p(x)$$

（推导中用自然对数，仅整体缩放，不影响最优点；约束里的底数任选一致即可）。

过程讲解（拉格朗日法）：

- **构造拉格朗日函数**（λ_0 对应归一化，λ_j 对应第 j 个特征约束）：

$$\mathcal{L}=-\sum_x p(x)\ln p(x)-\lambda_0\Big(\sum_x p(x)-1\Big)-\sum_{j=1}^{m}\lambda_j\Big(\sum_x p(x)f_j(x)-a_j\Big).$$

- **对每个 $p(x)$ 求偏导**（把每个 x 处的概率当作独立变量；注意 $\frac{\partial}{\partial p(x)}[p(x)\ln p(x)]=\ln p(x)+1$）：

$$\frac{\partial\mathcal{L}}{\partial p(x)}=-\big(\ln p(x)+1\big)-\lambda_0-\sum_{j=1}^{m}\lambda_j f_j(x)\overset{!}{=}0.$$

- **解出** $\ln p(x)$：

$$\ln p(x)=-1-\lambda_0-\sum_{j=1}^{m}\lambda_j f_j(x).$$

- **指数化**：

$$p(x)=\exp\left(-1-\lambda_0-\sum_{j=1}^{m}\lambda_j f_j(x)\right)=\exp(-1-\lambda_0)\cdot\exp\left(\sum_{j=1}^{m}\lambda_j f_j(x)\right).$$

- **归一化定常数**：令

$$Z(\boldsymbol{\lambda})=\sum_x\exp\left(\sum_{j=1}^{m}\lambda_j f_j(x)\right),$$

则归一化要求 $p(x)$ 在 x 上求和为 1，于是 $\exp(-1-\lambda_0)=1/Z(\boldsymbol{\lambda})$，得到**指数族形式**：

$$\boxed{p(x)=\frac{\exp\left(\sum_{j=1}^{m}\lambda_j f_j(x)\right)}{Z(\boldsymbol{\lambda})}},\qquad Z(\boldsymbol{\lambda})=\sum_x\exp\left(\sum_{j=1}^{m}\lambda_j f_j(x)\right).$$

- **结论与符号提醒**：最大熵解必为“各特征 f_j 的线性组合放进指数、再除以配分函数 Z”。**拉格朗日乘子的正负取决于约束如何书写**（例如把约束写成 $\sum pf_j=a_j$ 还是 $a_j-\sum pf_j=0$，乘子差一个负号），统一改名后模型形式完全相同。**不能只凭一个中间乘子的符号判断最终结果。**

8.3.3 五状态例题：$P(A)=P(B)=0.15$，其余为 $7/30$

例（S13 35–39 页原例，教师原题/教师答案核对）：5 个状态 A,B,C,D,E。仅归一化，再加一个约束 $P(A)+P(B)=0.3$。求最大熵分布。

过程讲解（两种方法核对同一答案）：

- **方法一（对称性）**：约束只区分“$\{A,B\}$ 组”和“$\{C,D,E\}$ 组”，组内无任何区别。最大熵在组内必取相等概率。设 $P(A)=P(B)=a$，$P(C)=P(D)=P(E)=b$。由约束 $2a=0.3\Rightarrow a=0.15$；由归一化 $2a+3b=1\Rightarrow 3b=0.7\Rightarrow b=7/30\approx 0.2333$。结果：

$$P(A)=P(B)=0.15,\qquad P(C)=P(D)=P(E)=\frac{7}{30}.$$

- **方法二（指数族显式验证，自编题补充）**：取特征 $f(x)=\mathbf{1}_{\{x\in\{A,B\}\}}$、约束 $\mathbb{E}[f]=0.3$。则最大熵形式 $p(x)\propto\exp(\lambda f(x))$。对 A,B 权重为 e^{λ}，对 C,D,E 权重为 1。配分函数 $Z=2e^{\lambda}+3$。约束要求

$$\frac{2e^{\lambda}}{2e^{\lambda}+3}=0.3\implies 2e^{\lambda}=0.3(2e^{\lambda}+3)=0.6e^{\lambda}+0.9\implies 1.4e^{\lambda}=0.9\implies e^{\lambda}=\frac{9}{14}.$$

于是 $P(A)=P(B)=\dfrac{e^{\lambda}}{Z}=\dfrac{9/14}{2\cdot 9/14+3}=\dfrac{9/14}{30/7}=\dfrac{9}{14}\cdot\dfrac{7}{30}=\dfrac{3}{20}=0.15$，$P(C)=\dfrac{1}{Z}=\dfrac{1}{30/7}=\dfrac{7}{30}$。两种算法一致 ✓。

> **常见误区**：最大熵**不是**“把每个状态都设为 $1/5$”。$1/5$ 只在“无任何额外约束”时成立；一旦加入 $P(A)+P(B)=0.3$，组内平均、组间按约束拉开才是正确解。

8.3.4 高斯最大微分熵：$D_{KL}(p\|q)=h(q)-h(p)\geq 0$

结论：在所有满足 $\mathbb{E}[X]=\mu$、$\mathrm{Var}(X)=\sigma^2>0$ 的连续分布中，**高斯分布** $N(\mu,\sigma^2)$ **使微分熵最大**，且最大值为

$$h_{\max}=\frac{1}{2}\log(2\pi e\sigma^2).$$

过程讲解（用 KL 非负性给出全局最优，而非仅变分驻点）：

- **设参考 q 为同均值同方差的高斯**：

$$q(x)=\frac{1}{\sqrt{2\pi\sigma^2}}\exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

- 对任意满足相同均值、方差约束的 p，写出 KL：

$$D_{KL}(p\|q)=\int p(x)\log\frac{p(x)}{q(x)}dx=-\int p(x)\log q(x)\,dx-\left(-\int p(x)\log p(x)\,dx\right)=-h(p)-\int p(x)\log q(x)\,dx.$$

- **关键一步**：因为 $\log q(x)=-\frac{(x-\mu)^2}{2\sigma^2}-\frac{1}{2}\log(2\pi\sigma^2)$，其对 x 的依赖**只通过** $(x-\mu)^2$。于是

$$\int p(x)\log q(x)\,dx=-\frac{1}{2\sigma^2}\mathbb{E}_p[(X-\mu)^2]-\frac{1}{2}\log(2\pi\sigma^2).$$

而 $\mathbb{E}_p[(X-\mu)^2]=\mathrm{Var}_p(X)=\sigma^2$（约束），与 q 的二阶矩相同。所以

$$\int p(x)\log q(x)\,dx=-\frac{1}{2\sigma^2}\sigma^2-\frac{1}{2}\log(2\pi\sigma^2)=-\frac{1}{2}-\frac{1}{2}\log(2\pi\sigma^2)=-\frac{1}{2}\log(2\pi e\sigma^2)=-h(q).$$

- 代回 KL：$D_{KL}(p\|q)=-h(p)+h(q)=h(q)-h(p)$。
- 由 8.2.4 的 KL 非负性 $D_{KL}(p\|q)\geq 0$，得

$$h(p)\leq h(q)=\frac{1}{2}\log(2\pi e\sigma^2).$$

- **结论与等号**：对任意合规 p 都成立，故这是**全局**最大（不仅是驻点）；等号当且仅当 $p=q$，即高斯分布。

> **为什么这里出现 e**：来自 $\frac{1}{2}+\frac{1}{2}\log(2\pi\sigma^2)=\frac{1}{2}\log(2\pi e\sigma^2)$ 中的 $\frac{1}{2}=\frac{1}{2}\log e$。这是方差与微分熵单位换算的自然结果，不是笔误。

8.3.5 在整条实轴上无约束会怎样

> **边界说明（编者补充，呼应 8.3.1）**：若对连续变量**只要求归一化**、不限制均值/方差/支撑，则“最大微分熵”问题无有限解——让分布越来越宽，微分熵可任意增大；让其支撑收缩到一点附近，微分熵可任意减小（见 8.1.5 均匀分布的 $\log(b-a)$）。因此上节的“高斯最大熵”**必须**带着“固定均值和方差”这两个矩约束才成立。这与离散情形不同：离散情形只要支撑集有限，无额外矩约束时最大熵就是均匀分布。

8.4 条件最大熵与 logistic 的联系

8.4.1 条件最大熵 → softmax 的逐步推导

分类任务需要的是**条件分布** $p(y \mid \mathbf{x})$。做法：固定输入的经验分布 $\tilde{p}(\mathbf{x})$，要求模型的特征期望与经验特征期望一致，再最大化**条件熵**

$$H(Y \mid X) = -\sum_{x} \tilde{p}(x) \sum_{y} p(y \mid x) \log p(y \mid x).$$

约束：$\sum_{x,y} \tilde{p}(x) p(y \mid x) f_j(x,y) = \sum_{x,y} \tilde{p}(x,y) f_j(x,y)$（即模型与经验在第 j 个特征上期望相同）。

过程讲解（对每个 $\mathbf{x}$ 分别最大化）：

- 因为约束对给定的 $\mathbf{x}$ 只涉及该 $\mathbf{x}$ 下的 $p(y \mid x)$，且归一化 $\sum_y p(y \mid x) = 1$ 也是逐 $\mathbf{x}$ 成立，所以**最大化可对每个 $\mathbf{x}$ 独立进行**——这正是 8.3.2 的离散最大熵，只是把“状态 x”换成“标签 y”、“特征 $f_j(x)$”换成“特征 $f_j(\mathbf{x}, y)$”。
- 直接套用 8.3.2 的结论（对每个 $\mathbf{x}$）：

$$p_{\mathbf{w}}(y \mid \mathbf{x}) = \frac{\exp\left(\sum_j w_j f_j(\mathbf{x}, y)\right)}{Z_{\mathbf{w}}(\mathbf{x})}, \qquad Z_{\mathbf{w}}(\mathbf{x}) = \sum_{y'} \exp\left(\sum_j w_j f_j(\mathbf{x}, y')\right).$$

- **分母 $Z_{\mathbf{w}}(\mathbf{x})$ 只对候选标签 y' 求和**，职责是“给定输入 $\mathbf{x}$ 下”归一化，使 $\sum_y p(y \mid \mathbf{x}) = 1$。它**不含对 $\mathbf{x}$ 的求和。**

落到多类 logistic / softmax：若特征按类别组织为线性形式 $f_j(\mathbf{x}, y) = \mathbf{x}_j \cdot \mathbf{1}_{\{y=k\}}$（含偏置项），则对每个类 k 有分数 $w_k^\top \mathbf{x}$，得到

$$p(y = k \mid \mathbf{x}) = \frac{\exp(w_k^\top \mathbf{x})}{\sum_{k'} \exp(w_{k'}^\top \mathbf{x})}.$$

这就是**softmax** 分类器。

8.4.2 二分类与 logistic：与第三章的联系

当类别数 $K = 2$（记 $y \in \{0, 1\}$）时，softmax 退化为 logistic。

过程讲解：

- 二分类只需一个分数 $w^\top \mathbf{x}$（另一类分数为 0 作基准）。由归一化：

$$p(y = 1 \mid \mathbf{x}) = \frac{\exp(w^\top \mathbf{x})}{\exp(w^\top \mathbf{x}) + 1} = \frac{1}{1 + \exp(-w^\top \mathbf{x})} = \sigma(w^\top \mathbf{x}),$$

其中 $\sigma(z) = 1/(1 + e^{-z})$ 是 **sigmoid 函数。**

- 这正是**第三章 logistic 回归**的预测式。可见：logistic 不是凭空假设的“S 形”；它是“在给定特征期望约束下最大化条件熵”这一最大熵原则在两分类上的必然形式。

> **跨章联系**：第三章给出 logistic 的似然与梯度推导；本章说明它**为何是最大熵模型的自然特例**。两处结论一致——最大熵模型的训练对数似然梯度正是“经验特征期望 − 模型特征期望”，最优点使二者匹配（见下）。

8.4.3 训练目标与梯度（编者补充）

最大化条件对数似然（对经验分布 $\tilde{p}$ 取期望）：

$$\mathcal{L}(\mathbf{w}) = \sum_{x,y} \tilde{p}(x,y) \log p_{\mathbf{w}}(y \mid x).$$

代入 $p_{\mathbf{w}}$ 的指数形式：

$$\log p_{\mathbf{w}}(y \mid x) = \sum_{j} w_j f_j(\mathbf{x}, y) - \log Z_{\mathbf{w}}(\mathbf{x}).$$

过程讲解（梯度）：

- 第一项对 $\mathbf{w}$ 贡献经验特征期望 $\sum_{x,y} \tilde{p}(x,y) f_j(\mathbf{x}, y)$。
- 第二项 $\log Z_{\mathbf{w}}(\mathbf{x}) = \log \sum_{y'} \exp(\sum_j w_j f_j(\mathbf{x}, y'))$，其对 w_j 的导数是模型在输入 $\mathbf{x}$ 下的特征期望 $\sum_y p_{\mathbf{w}}(y \mid x) f_j(\mathbf{x}, y)$。
- 故对 w_j 的梯度 = **经验特征期望 − 模型特征期望**。
- **最优条件**：梯度为 0 $\iff$ 二者在所有特征上相等，即约束被精确满足。这与拉格朗日约束的“松弛变量归零”完全吻合。

8.4.4 课件提及的 ICA 与互信息（编者补充）

课件还提到最大 / 最小互信息与 ICA（独立成分分析）。

> **编者补充边界**：ICA 试图从观测中分解出**统计独立**的源信号，其“独立性”强于“不相关性”（互不相关只要求协方差为 0，独立要求联合密度等于边缘密度乘积）。ICA 还需额外的**非高斯性**、混合模型等条件才能识别源；**不能把 PCA 白化直接当作独立源恢复**（PCA 只去相关，不保证独立）。相关算法并未在本课件中详细推导，本版不把它列为已覆盖的完整算法。

> **可逆变换保留信息（编者补充）**：若 $Y = g(X)$ 可逆，则 $H(X,Y) = H(X) + H(Y \mid X) = H(X)$（已知 Y 可反推 X），信息不增不减；**不可逆**的压缩（降维、量化）通常会损失信息，不能把“可逆变换保留信息”的结论套用到任意降维上。

8.5 数值例题、常见误区与跨章链接

8.5.1 一页速查：核心公式清单

概念	公式	单位/底	关键性质
自信息	$I(x) = -\log_2 p(x)$	bit	小概率→大信息

概念	公式	单位/底	关键性质
离散熵	$H(X)=-\sum_x p(x)\log_2 p(x)$	bit	$0\le H\le \log_2 K$，$0\log 0:=0$
微分熵	$h(X)=-\int p(x)\log p(x)dx$	nat	可为负；$h(aX)=h(X)+\log\lvert a\rvert$
条件熵	$H(X\mid Y)=-\sum_{x,y}p(x,y)\log_2 p(x\mid y)$	bit	$H(X,Y)=H(Y)+H(X\mid Y)$
互信息	$I(X;Y)=H(X)-H(X\mid Y)=D_{KL}(p(x,y)\Vert p(x)p(y))$	bit	非负、对称、独立时为 0
KL 散度	$D_{KL}(p\Vert q)=\sum_x p(x)\log\frac{p(x)}{q(x)}$	—	非负、不对称、非距离；需 $S_p\subseteq S_q$
交叉熵	$H(p,q)=H(p)+D_{KL}(p\Vert q)$	bit	固定 p 时最小化等价于最小化 KL
最大熵（离散）	$p(x)=\exp(\sum_j\lambda_j f_j(x))/Z(\boldsymbol{\lambda})$	—	拉格朗日对 $p(x)$ 求导得到
高斯最大微分熵	$h_{\max}=\frac{1}{2}\log(2\pi e\sigma^2)$	nat	固定均值方差时全局最大
条件最大熵	$p(y\mid\mathbf{x})=\exp(\sum_j w_j f_j(\mathbf{x},y))/Z_{\mathbf{w}}(\mathbf{x})$	—	多类→softmax，二类→logistic

8.5.2 常见误区汇总

1. $\log$ **的底数**：本书 $\log$ 默认自然对数（nat）；熵要 bit 时务必写 $\log_2$。混用只差一个常数 $\ln 2$，但单位会错。
2. $0\log 0=0$：不是“0 乘任何数得 0”，而是极限约定，用于跳过概率为 0 的结果。
3. **微分熵不是“绝对信息量”**：它可为负、随尺度平移 $\log\lvert a\rvert$；比较连续分布应看 KL 差值。
4. **KL 不是距离**：不对称、不三角，写作 $D_{KL}(p\Vert q)$ 时 p 是“真实/参考”、q 是“模型”。
5. **支撑集**：只要 $p>0$ 处 $q=0$，KL 即 $+\infty$；这是模型崩溃的强信号。
6. **最大熵≠均匀**：有额外约束时，组内均匀、组间按约束拉开（见 8.3.3 五状态例）。
7. **互信息非负但单点条件熵可增**：平均与单点不矛盾（见 8.2.2）。

8.5.3 跨章与跨文件链接

- **第三章 logistic 回归**：二分类最大熵模型即 logistic（见 8.4.2）；其梯度推导见第三章。
- **第四章决策树**：信息增益 = $H(Y)-H(Y\mid X_{\text{特征}})=I(X_{\text{特征}};Y)$，直接复用本章互信息（见 8.2.2）。
- **第二章贝叶斯**：熵最大化的指数族与“指数族先验/似然”在形式上相通，可对照阅读。
- **练习与基线**：配套习题见 练习；数值例的数字核对请以教师原题/教师答案为准，自编题已单独标注。

> **边界说明（呼应 AGENTS.md）**：本章为往年资料整理与编者补充，明确标记“编者补充”的内容不推定考试范围；原始课件未逐页做视觉验收，相关页码（S13）仅作来源索引，未声称已逐页核对。

第九章 概率图模型：把联合分布拆成局部关系

> 往年资料：S14（69 页）与 S15（80 页）。主题包括有向 / 无向图、学习、推断、HMM、CRF。2026-10-30 已视觉核对 S14 8–13、22–25、33 页与 S15 16–26、69–70 页，并恢复草坪贝叶斯网络和信封 HMM 原例；本年度对应课件尚未提供。其余结构学习图例和采样过程仍待视觉复核。

> **本章读法**：先建立直觉，再亲手写一次推导。建议先读 §9.1 的分解动机、§9.2 的三种局部结构与碰撞例，然后依次攻克 §9.4 的 EM 下界、§9.5 的 HMM 前向递推与 Viterbi。涉及第二章的贝叶斯公式与第八章的熵，遇到记不清的符号先回看对应章节。

9.1 图首先是一组分解与独立性假设

9.1.1 为什么要引入图：参数爆炸与局部关系

直觉。假设我们有 d 个**二元**随机变量（每个只能取 0 或 1）。它们最一般的联合分布 $p(x_1, \dots, x_d)$ 需要列出所有 2^d 种取值组合的概率，并且这些概率之和必须为 1，因此自由参数是

$$2^d - 1.$$

当 $d = 3$ 时需要 $2^3 - 1 = 7$ 个参数；$d = 10$ 时需要 1023 个；$d = 20$ 时超过一百万。直接估计这样庞大的表既不可行，也没有泛化能力。

图模型的核心想法是用一张图表达"谁直接依赖谁"，从而把联合分布拆成许多**只涉及少数变量**的局部因子。参数总量从指数级降到与图大小相关的量级，同时"图里的边"与"独立性假设"一一对应，推断也能按图结构组织。

> **记住**：节点 = 随机变量；有向边表达"允许的直接依赖方向"；无向边表达"允许的直接耦合"。**仅从箭头不能自动推出现实因果**——图是建模者的假设，不是自然法则。

9.1.2 贝叶斯网络分解：从链式法则到局部条件

符号与假设。

- 图是**有向无环图（DAG）**：有方向、无环路。
- 变量已按某个**拓扑顺序**排好：若 x_i 指向 x_j（存在路径），则 $i < j$。即父节点一定排在子节点前面。
- $\mathrm{pa}(x_i)$ 表示节点 x_i 的**父节点取值集合**（parents）。
- 模型假设：每个变量在给定其父节点后，与所有"更早出现但不是父节点"的变量**条件独立**。

起始式（无条件分解的链式法则）。对任意顺序的变量，概率永远可以写

$$p(x_1, \dots, x_d) = p(x_1)\, p(x_2 \mid x_1)\, p(x_3 \mid x_1, x_2) \cdots p(x_d \mid x_1, \dots, x_{d-1}).$$

这是链式法则（第二章贝叶斯公式的多次应用），不依赖任何假设。

逐步代入独立性假设。因为拓扑序保证 x_i 只依赖其前面的变量，而模型进一步假设它**只依赖父节点** $\mathrm{pa}(x_i)$、不依赖其余更早变量，于是有

$$p(x_i \mid x_1, \ldots, x_{i-1}) = p(x_i \mid \mathrm{pa}(x_i)).$$

把它逐个代入上面的链式法则，得到贝叶斯网络的标准分解：

$$p(x_1, \ldots, x_d) = \prod_{i=1}^{d} p(x_i \mid \mathrm{pa}(x_i)). \tag{1}$$

结论与成立条件。式 (1) 成立需要：① 图有向无环；② 拓扑序存在；③ 每个变量在给定父节点后与其非后代的所有更早变量条件独立（这正是"局部马尔可夫性"）。连续变量时把概率质量换成密度即可，形式不变。

9.1.3 一个小数值例子：参数从 7 降到 5

设三个二元变量 A, B, C，构成链 $A \to B \to C$。若用完全表需要 $2^3 - 1 = 7$ 个参数。用分解

$$p(a, b, c) = p(a)\, p(b \mid a)\, p(c \mid b).$$

参数计数（离散、二元、每行条件概率归一化减 1）：

- $p(a)$：2 个取值，和为 1，故 $2 - 1 = 1$ 个自由参数；
- $p(b \mid a)$：父节点 a 有 2 种取值，每种对应一个 2 维条件分布，共 $2 \times (2 - 1) = 2$ 个参数；
- $p(c \mid b)$：同理 2 个参数。

总计 $1 + 2 + 2 = 5 < 7$。图结构每去掉/增加一条边，都会改变可表达的分布族与参数数量——这正是"用结构换取参数效率"。

9.1.4 朴素贝叶斯：贝叶斯网络的一个特例

类别节点 c 指向每个特征 x_j，特征之间在给定类别后相互独立：

$$p(c, \mathbf{x}) = p(c) \prod_{j=1}^{d} p(x_j \mid c).$$

这正是第二章朴素贝叶斯的图表示：$\mathrm{pa}(x_j) = \{c\}$。它用"特征在类内独立"这一（通常过强但实用）假设，把原本需要 $K(2^d - 1)$ 量级参数的表压成了线性规模。

> **常见误区**：朴素贝叶斯的"朴素"不是说特征相互独立，而是说"给定类别后特征相互独立"。在预测时，后验仍会把所有特征组合起来，所以预测并不"简单"。

9.1.5 往年课件原例：草坪贝叶斯网络的四个问题

> **来源性质**：S14 8–13 页，往年课件原例。设 R 表示下雨，S 表示洒水器开启，G 表示草坪湿，取值 1 表示“是”。图结构为 $R \to S$、$R \to G$、$S \to G$。

课件给出的概率表是

$$P(R = 1) = 0.2, \qquad P(R = 0) = 0.8,$$

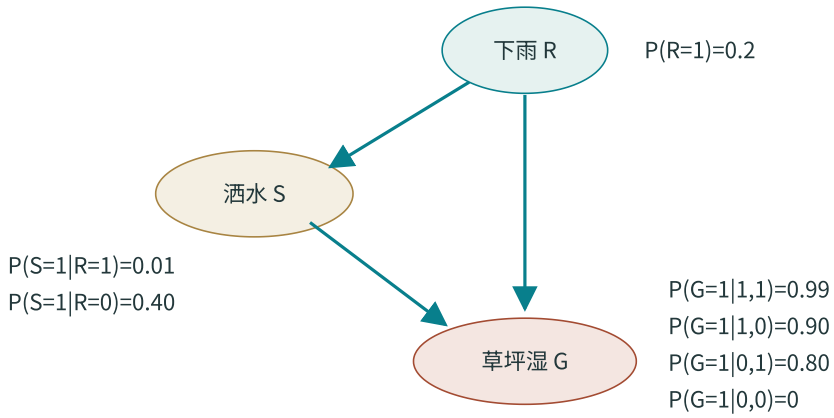
R	$P(S = 1 \mid R)$	$P(S = 0 \mid R)$
1	0.01	0.99
0	0.40	0.60

S	R	$P(G=1 \mid S,R)$	$P(G=0 \mid S,R)$
1	1	0.99	0.01
1	0	0.90	0.10
0	1	0.80	0.20
0	0	0.00	1.00

联合分布按图分解为

$$P(G,S,R) = P(G \mid S,R)P(S \mid R)P(R).$$

草坪贝叶斯网络：下雨、洒水与草坪湿



问题 1：同时下雨、洒水、草坪湿的概率

$$P(G=1,S=1,R=1) = 0.99 \times 0.01 \times 0.2 = 0.00198.$$

问题 2：已知不下雨，草坪湿的概率。必须把未知的 S 边际化：

$$P(G=1 \mid R=0) = \sum_{s\in\{0,1\}} P(G=1 \mid S=s,R=0)P(S=s \mid R=0)$$
$$= 0.90 \times 0.40 + 0 \times 0.60 = 0.36.$$

问题 3：看到草坪湿后，下过雨的概率。先计算 $G=1$ 的四个联合分量：

(S,R)	$P(G=1,S,R)$
$(1,1)$	$0.99 \times 0.01 \times 0.2 = 0.00198$
$(1,0)$	$0.90 \times 0.40 \times 0.8 = 0.288$
$(0,1)$	$0.80 \times 0.99 \times 0.2 = 0.1584$
$(0,0)$	$0 \times 0.60 \times 0.8 = 0$

因此 $P(G=1) = 0.44838$，

$$P(R=1 \mid G=1) = \frac{0.00198 + 0.1584}{0.44838} \approx 0.3577.$$

问题 4：看到草坪湿后，洒过水的概率

$$P(S=1 \mid G=1)=\frac{0.00198+0.288}{0.44838}\approx 0.6467.$$

> **关键区别**：问题 2 已知 $R=0$，只需在该条件下对 S 求和；问题 3、4 是后验推断，分母必须把所有能产生“草坪湿”的隐藏情况相加。直接拿某一行条件概率当答案会漏掉其他路径。

9.2 三种局部结构与 d 分离

直觉：我们说"图表达了独立性"，但具体怎么从图上读出"哪些变量在给定某些证据后独立"？答案叫 **d 分离（d-separation，d 表示 directional/dependency）**。判断规则只需看图里的**局部结构**并沿所有路径传播。

9.2.1 三种基本结构

设路径上三个相邻节点，只可能有三种局部形状：

结构	图示	给定中间节点时的效果
链 (chain)	$A \to B \to C$	给定 B，阻断 A 与 C 之间的联系
分叉 (fork / common cause)	$A \leftarrow B \to C$	给定 B（共同原因），阻断 A 与 C
碰撞 (collider / common effect)	$A \to B \leftarrow C$	未观测 B 及其后代时阻断；**给定 B 或其后代会打开**路径

为什么链和分叉"条件化中间节点就阻断"？因为 B 是 A 影响 C 的唯一"管道"，一旦把 B 固定（条件化），管道被堵住。碰撞结构则反过来：A 与 C 原本互不相干，但一旦你**知道共同结果** B，关于一个原因的信息就会改变对另一个原因的推断——这就是"知道共同结果以后，两个原因可能相关"。

$$\begin{aligned}
&\text{链 } A \to B \to C: && A \perp\!\!\!\perp C \mid B \\
&\text{分叉 } A \leftarrow B \to C: && A \perp\!\!\!\perp C \mid B \\
&\text{碰撞 } A \to B \leftarrow C: && A \perp\!\!\!\perp C \quad (\text{未观测 } B \text{ 时}); \quad A \not\perp\!\!\!\perp C \mid B
\end{aligned}$$

9.2.2 碰撞例：一步步算清三个数字

> **自编碰撞例。**取两个独立公平二元变量 $A, C \sim \text{Bernoulli}(1/2)$，定义共同结果 $B = A \vee C$（逻辑或，即"至少有一个为 1 则 $B=1$"）。

先把四个等概率组合列成表（每种概率都是 $1/4$）：

A	C	$B = A \vee C$	概率
0	0	0	$1/4$
1	0	1	$1/4$
0	1	1	$1/4$
1	1	1	$1/4$

步骤 1：先验。$P(A=1)=1/2$（第一行与第二行之和 $=1/4+1/4=1/2$）。此时 A 与 C 独立。

步骤 2：已知 $B=1$。在表中筛出 $B=1$ 的三行（1,0）、(0,1)、(1,1)，它们总概率 $3/4$，且由于原来等概率，条件化后三者**等概率**各为 $(1/4)/(3/4)=1/3$。其中 $A=1$ 的是 (1,0) 与 (1,1) 两行：

$$P(A=1\mid B=1)=\frac{P(A=1,B=1)}{P(B=1)}=\frac{1/4+1/4}{3/4}=\frac{2/4}{3/4}=\frac{2}{3}.$$

注意：原本 $P(A=1)=1/2$，现在升到 $2/3$。说明"看到共同结果 $B=1$"后，我们对原因 A 的判断变了——这正是碰撞结构"未观测时独立、观测后相关"的体现。

步骤 3：再知 $C=1$。在已经 $B=1$ 的前提下，进一步筛选 $C=1$ 的行，剩 (0,1) 与 (1,1) 两行，各占 $1/3$（在条件 $B=1$ 下）。其中 $A=1$ 的只有 (1,1)：

$$P(A=1\mid B=1,C=1)=\frac{P(A=1,B=1,C=1)}{P(B=1,C=1)}=\frac{1/4}{1/4+1/4}=\frac{1/2}{1}=\frac{1}{2}.$$

数字从 $2/3$ 又**回到** $1/2$。直觉：当 $C=1$ 已经解释了"为什么 $B=1$"时，A 是否为 1 就又变得无关紧要了——第二个原因把第一个原因对结果的"解释责任"抢走了一半。

> **记住**：碰撞结构 $A\to B\leftarrow C$ 的诡异之处在于——"不观测 B 时 A,C 独立，观测 B 后反而相关"。这是很多悖论（如"必然混淆"）的根源，务必亲手算一遍上例。

9.2.3 从局部到整张图：d 分离的完整判据

对一般图，要沿连接 X 与 Y 的**每一条**路径检查：

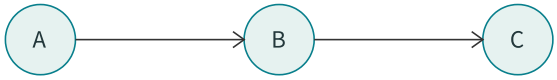
- 路径上每个**非碰撞**节点若被条件化（出现在证据集合里），则该路径被**阻断**；
- 路径上每个**碰撞**节点及其**后代**若都**未被**条件化，则该路径被阻断；
- 一旦某条路径上出现"未被阻断"的节点序列，该路径就**畅通**。

定义：若在所有连接 X 与 Y 的路径都被证据 Z 阻断时，称 X 与 Y 被 Z **d 分离**，记为 $X \perp\!\!\!\perp Y \mid Z$，并据此推出 $p(X,Y\mid Z)=p(X\mid Z)\,p(Y\mid Z)$。

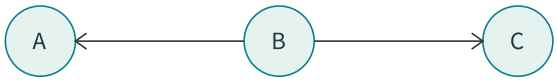
> **常见误区**：只检查一条路径、或只检查局部三个节点就下结论，是错的。必须遍历**所有**路径；一条畅通的路径就足以破坏独立性。d 分离是"图上能推出的所有条件独立"，但现实里某些分布可能比图允许的独立性更多（图是上界）。

三种局部结构：箭头相遇方式决定阻断规则

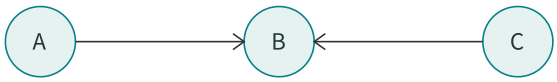
链：A → B → C



分叉：A ← B → C



碰撞：A → B ← C



前两种：给定 B 阻断路径；碰撞：给定 B 或其后代会打开路径。

9.3 马尔可夫随机场

直觉：贝叶斯网络用**有向**箭头和"条件概率"建模，父子关系天然不对称。但很多场景（图像相邻像素、蛋白质相互作用网络）关系本身是对称的"耦合"，没有天然的因果方向。这时用**无向图**更自然：把联合分布写成"团（clique，完全子图）上的非负势函数"的乘积，再整体归一化。

9.3.1 团势分解与归一化常数 Z

符号与假设。

- $\mathbf{x} = (x_1, \ldots, x_d)$ 是全体变量；无向边表示局部耦合。
- **团** C 是一组两两相连的节点；$\mathbf{x}_C$ 是这些节点的取值。
- **势函数（potential）** $\psi_C(\mathbf{x}_C)$ 是定义在团上的任意**非负**函数，衡量该团取某组值的"兼容性/能量"高低。
- Z 是归一化常数（配分函数，partition function）。

起始式（未归一化的乘积）。先把所有团的势乘起来，得到一个非负但不一定和为 1 的量：

$$\tilde{p}(\mathbf{x}) = \prod_{C} \psi_C(\mathbf{x}_C).$$

归一化（求 Z）。要让它成为合法概率，必须把所有可能取值的概率加起来等于 1。因此

$$Z = \sum_{\mathbf{x}} \tilde{p}(\mathbf{x}) = \sum_{\mathbf{x}} \prod_{C} \psi_C(\mathbf{x}_C),$$

于是最终分布为

$$p(\mathbf{x}) = \frac{1}{Z} \prod_{C} \psi_C(\mathbf{x}_C), \qquad Z = \sum_{\mathbf{x}} \prod_{C} \psi_C(\mathbf{x}_C). \tag{2}$$

（连续变量时把求和 $\sum_{\mathbf{x}}$ 改成积分 $\int d\mathbf{x}$。）

结论与成立条件。式 (2) 对**任意**非负势函数都给出合法概率分布，无需势函数各自归一化。代价是 Z 通常需要对全部 2^d 种（离散）或整个空间（连续）求和/积分，可能非常昂贵——这叫"配分函数难算"。

> **常见误区**：势函数 ψ_C **不是概率**，不必 ≤ 1，也不必各自归一化。只有乘上 $1/Z$ 之后的 $p(\mathbf{x})$ 才是概率。势常常写成 $\psi_C = \exp(-E_C)$（能量越低势越高），但本章先用一般势函数，避免与第八、十章的能量概念混淆。

9.3.2 一个小数值例子：两个变量的 MRF

设 $x_1, x_2 \in \{0, 1\}$，只有一个团 $C = \{1, 2\}$。给势函数赋值：

(x_1, x_2)	$\psi(x_1, x_2)$
(0,0)	1
(0,1)	2
(1,0)	2
(1,1)	1

步骤：先算 $Z = 1 + 2 + 2 + 1 = 6$。再逐格除以 Z 得到概率：

$$p(0,0) = \frac{1}{6}, \quad p(0,1) = \frac{2}{6}, \quad p(1,0) = \frac{2}{6}, \quad p(1,1) = \frac{1}{6}.$$

可见 ψ 越大概率越大，但 ψ 本身（如 2）可以大于 1，而最终每个概率都 ≤ 1 且和为 1。势函数表达了"相邻变量取值组合的偏好"，不要求局部归一。

9.3.3 无向图里的条件独立与有向/无向对比

给定一组节点把图分成不相连的两部分，则这两部分在给定这组节点后**条件独立**（全局马尔可夫性）。

有向 vs 无向的关键区别：

- 贝叶斯网络的每个局部条件表 $p(x_i \mid \mathrm{pa}(x_i))$ **各自归一化**（每行和为 1），归一化是局部的、便宜的；
- MRF 的归一化是**全局**的，集中在 Z 上，往往昂贵；
- 二者能表达的**独立性结构并不完全相同。**例如链 $A \to B \to C$ 与无向三角 $A - B - C$ 表达的独立集合不同；有向碰撞 $A \to B \leftarrow C$ 对应的无向图需要把 A, B, C 全连成一个团（因为观测 B 会引入相关性），而朴素地把有向边换成无向边会丢失碰撞特性——这正是"道德图（moral graph）"要补边的原因（属结构学习，待视觉复核）。

> **严格性提示**：式 (2) 的团分解与图的马尔可夫性之间的标准等价关系，要求分布**严格正**（所有取值概率 > 0）。若图上存在零概率配置，等价性需要更细致的前提，不能直接套用。

9.4 学习、精确推断与采样

直觉：拿到图模型后有两件不同的事常被混淆：

- **学习（learning）**：模型结构或参数未知，由数据去确定；
- **推断（inference）**：模型（结构+参数）已定，求边缘分布、条件分布，或最可能的隐变量配置。

> **记住**：永远先分清"这一步是在求参数，还是给定观测求隐变量"。二者数学不同、算法不同，混为一谈是初学者最常见的错误。

9.4.1 变量消去：重排求和避免全枚举

问题。给定分解 $p(a,b,c) = p(a)\,p(b \mid a)\,p(c \mid b)$，求边缘 $p(c)$。

朴素做法需对所有 a, b 枚举（指数级）。**变量消去**利用求和与乘积可重排，把求和"贴着"相关因子做掉：

起始式。

$$p(c) = \sum_{a,b} p(a,b,c) = \sum_{a,b} p(a)\,p(b \mid a)\,p(c \mid b).$$

步骤 1：先消去 a。把只含 a 的因子聚成关于 b 的中间量：

$$m(b) = \sum_{a} p(a)\,p(b \mid a). \tag{3}$$

这里对 a 求和，结果 $m(b)$ 只依赖 b，维度从 (a,b) 降到 b。

步骤 2：再消去 b。

$$p(c) = \sum_{b} m(b)\,p(c \mid b). \tag{4}$$

结论。通过先算式 (3) 再代入式 (4)，我们**从未同时枚举 a 和 b**，而是分两步各自求和。更大图的思路相同：选择合适的**消去顺序**，每步只把"当前因子里能消去的变量"求和掉，生成中间因子（message）。

> **记住**：复杂度取决于**消去顺序与图结构**，不只取决于节点数。糟糕的顺序会产生巨大的中间因子（"中间因子爆炸"）；好的顺序是精确推断的核心难题之一（属图消去顺序，待视觉复核）。

9.4.2 和积/信念传播与采样（概述）

- **树上的和积（sum-product）/信念传播**：把变量消去组织成节点间传递的"消息"，在树上可精确算得所有边缘，复杂度仅线性于边数。
- **带环图**：消息在环上反复迭代（loopy belief propagation）通常**只是近似**，既不保证精确也不保证收敛。
- **前向采样**：按拓扑顺序逐节点从条件分布采样生成样本；若先观测到罕见证据再用"拒绝采样"丢弃不匹配样本，效率可能极低。
- **Gibbs 采样**：每次从一个变量在其余变量给定下的条件分布 $p(x_i \mid \mathbf{x}_{-i})$ 采样。需讨论马尔可夫链的可达性、收敛（混合时间）以及样本间的自相关（有效样本量下降）。

9.4.3 EM 算法：从恒等式推出下界

这是本章最重要的推导之一。情形：**数据含隐变量** z，观测为 x，参数 θ 待估。目标是最大化对数似然 $\log p_\theta(x)$。

（a）先写恒等式

对任一取正值的分布 $q(z)$（只要满足 $q(z) > 0$ 处 $p_\theta(z \mid x) > 0$），利用 $p_\theta(x) = \dfrac{p_\theta(x,z)}{p_\theta(z \mid x)}$（对任意具体 z 成立，因为 $p_\theta(x,z) = p_\theta(x)\,p_\theta(z \mid x)$），有

$$\log p_\theta(x) = \log \frac{p_\theta(x,z)}{p_\theta(z \mid x)}.$$

把分母换写成 $q(z)$ 的"拆项"形式（加一项减一项同一个 $q(z)$）：

$$\log p_\theta(x) = \log \frac{p_\theta(x,z)}{q(z)} - \log \frac{p_\theta(z \mid x)}{q(z)}. \tag{5}$$

（b）两边对 $q(z)$ 取期望

左边与 z 无关，期望仍是自己。右边第一项的期望记为 $\mathcal{L}(q,\theta)$，第二项正好是 KL 散度：

$$\begin{aligned}\log p_\theta(x) &= \mathbb{E}_{q(z)}\left[\log \frac{p_\theta(x,z)}{q(z)}\right] - \mathbb{E}_{q(z)}\left[\log \frac{p_\theta(z\mid x)}{q(z)}\right] \\ &= \underbrace{\mathbb{E}_{q(z)}[\log p_\theta(x,z)] + \mathbb{H}[q]}_{\mathcal{L}(q,\theta)} \;+\; \underbrace{D_{\mathrm{KL}}\big(q(z)\,\|\,p_\theta(z\mid x)\big)}_{\geq 0}.\end{aligned} \tag{6}$$

其中 $\mathbb{H}[q] = -\mathbb{E}_q[\log q(z)]$ 是 q 的熵（与 θ 无关），KL 散度定义 $D_{\mathrm{KL}}(q\|p) = \mathbb{E}_q[\log(q/p)] \geq 0$，等号当且仅当 $q(z) = p_\theta(z\mid x)$。

关键结论：因为 KL 项非负，

$$\log p_\theta(x) \;\geq\; \mathcal{L}(q,\theta). \tag{7}$$

即 $\mathcal{L}$ 是 $\log p_\theta(x)$ 的一个**下界（ELBO，证据下界）**。这就是"EM 下界"的来历——它不靠 Jensen 不等式的"凑凸性"，而是靠上面这段**恒等式 + 期望 + KL 非负**的等价拆分。

> **常见误区**：不要把 ELBO 记成 $\mathbb{E}_q[\log p_\theta(x\mid z)]$ 漏掉 $\log p_\theta(z)$。完整是 $\mathbb{E}_q[\log p_\theta(x,z)] = \mathbb{E}_q[\log p_\theta(x\mid z)] + \mathbb{E}_q[\log p_\theta(z)]$。在贝叶斯混合/高斯混合里 z 的先验项不可省。

（c）E 步：把下界"贴紧"

选定当前参数 θ^{old}，令

$$q(z) = p_{\theta^{\mathrm{old}}}(z\mid x).$$

代入式 (6)：此时 $D_{\mathrm{KL}}(p_{\theta^{\mathrm{old}}}(z\mid x)\,\|\,p_{\theta^{\mathrm{old}}}(z\mid x)) = 0$，于是

$$\mathcal{L}\big(p_{\theta^{\mathrm{old}}}(\cdot\mid x),\theta^{\mathrm{old}}\big) = \log p_{\theta^{\mathrm{old}}}(x).$$

下界**贴紧**到真实对数似然（缝隙为零）。所以 E 步本质是"用当前参数算出隐变量的后验"，并把它固定为 q。

（d）M 步：抬高下界（从而抬高似然）

M 步在 q 固定（=E 步得到的后验）下，最大化 $\mathcal{L}(q,\theta)$ 关于 θ：

$$\theta^{\mathrm{new}} = \arg\max_\theta \mathcal{L}(q,\theta).$$

为什么这能让真实似然不降？因为在 E 步后 $\log p_\theta(x) = \mathcal{L} + D_{\mathrm{KL}}$ 且 KL=0；M 步抬高了 $\mathcal{L}$，而新的 KL 仍 ≥ 0，所以

$$\log p_{\theta^{\mathrm{new}}}(x) = \mathcal{L}^{\mathrm{new}} + D_{\mathrm{KL}}^{\mathrm{new}} \geq \mathcal{L}^{\mathrm{new}} \geq \mathcal{L}^{\mathrm{old}} = \log p_{\theta^{\mathrm{old}}}(x).$$

即**每轮 EM 观测似然单调不降。**

结论与边界：该保证依赖"E 步得到**精确**后验、M 步**精确**最大化"。若用近似推断（变分、采样）或近似优化，则单调保证不再自动成立。EM 仍可能停在**局部最优**或鞍点——下界抬高不等于到达全局最大。

> **记住（EM 一句话）**：E 步把下界贴到当前似然（算后验），M 步沿下界抬高参数；反复迭代，似然单调上升但未必到顶。

9.5 HMM：用动态规划求序列概率

直觉：隐马尔可夫模型（HMM）是一个有向图模型，状态随时间推进，但状态本身不可见，只能看到它"发射"出的观测。因为序列有顺序结构，可以用**动态规划**把指数级的"枚举所有状态路径"压成线性时间的递推。

9.5.1 模型设定与联合分布

符号与维度。

- 隐藏状态 $z_t \in \{1, \dots, K\}$，离散、K 个取值；$t = 1, \dots, T$。
- 观测 x_t，可为离散或连续。
- 初始概率 $\pi_j = P(z_1 = j)$，$\sum_j \pi_j = 1$，维度 K。
- 转移概率 $a_{ij} = P(z_t = j \mid z_{t-1} = i)$，维度 $K \times K$，每行和为 1。
- 发射概率 $b_j(x) = p(x_t = x \mid z_t = j)$，每个状态一个分布。

两个建模假设：① 一阶马尔可夫性 $p(z_t \mid z_{t-1}, \dots, z_1) = p(z_t \mid z_{t-1})$；② 给定当前状态后观测独立于历史 $p(x_t \mid z_t, \text{history}) = p(x_t \mid z_t)$。

起始式（链式法则展开联合）。

$$p(\mathbf{x}, \mathbf{z}) = p(z_1)\, p(x_1 \mid z_1) \prod_{t=2}^{T} p(z_t \mid z_{t-1})\, p(x_t \mid z_t).$$

代入符号 π, a, b 即得 HMM 联合：

$$p(\mathbf{x}, \mathbf{z}) = \pi_{z_1}\, b_{z_1}(x_1) \prod_{t=2}^{T} a_{z_{t-1}, z_t}\, b_{z_t}(x_t). \tag{8}$$

结论。式 (8) 把"全序列联合"写成"初始×发射×转移×发射…"的连乘，每项只依赖相邻状态——这正是 §9.1 有向分解的具体实例。

9.5.2 前向算法 α：一步步推出递推

定义。

$$\alpha_t(j) = p(x_{1:t},\, z_t = j),$$

即"前 t 个观测为 $x_1, \dots, x_t$，且第 t 时刻状态恰为 j"的概率。它把**所有以状态 j 在时刻 t 结束的状态路径**的概率都加了起来。

初始步（$t = 1$）。

$$\alpha_1(j) = p(x_1, z_1 = j) = p(z_1 = j)\, p(x_1 \mid z_1 = j) = \pi_j\, b_j(x_1). \tag{9}$$

递推步（$t > 1$）——核心推导。从定义出发，对上一时刻状态 i 求和：

$$\begin{aligned}
\alpha_t(j) &= p(x_{1:t},\, z_t = j) \\
&= \sum_i p(x_{1:t},\, z_{t-1} = i,\, z_t = j) && \text{（对 } i \text{ 边际化）} \\
&= \sum_i p(x_{1:t-1},\, z_{t-1} = i)\; p(z_t = j \mid x_{1:t-1},\, z_{t-1} = i)\; p(x_t \mid x_{1:t-1},\, z_{t-1} = i,\, z_t = j) && \text{（链式法则）} \\
&= \sum_i \alpha_{t-1}(i)\; a_{ij}\; b_j(x_t). && \text{（马尔可夫假设化简）}
\end{aligned}$$

化简的两处关键：

- $p(z_t = j \mid x_{1:t-1}, z_{t-1} = i) = p(z_t = j \mid z_{t-1} = i) = a_{ij}$（未来状态只依赖上一状态）；

- $p(x_t \mid \cdots, z_t = j) = p(x_t \mid z_t = j) = b_j(x_t)$（发射只依赖当前状态）。

提取与 i 无关的公因子 $b_j(x_t)$，得到标准前向递推：

$$\alpha_1(j) = \pi_j\, b_j(x_1), \qquad \alpha_t(j) = b_j(x_t) \sum_{i=1}^{K} \alpha_{t-1}(i)\, a_{ij}. \tag{10}$$

终止步。全序列观测概率把所有终态加起来：

$$p(\mathbf{x}) = \sum_{j=1}^{K} \alpha_T(j). \tag{11}$$

前向数值小例（K=2，T=2）

设状态 $z \in \{1, 2\}$，观测 $x \in \{0, 1\}$。

- $\pi = (0.6,\, 0.4)$；
- 转移 $A = \begin{pmatrix} 0.7 & 0.3 \\ 0.4 & 0.6 \end{pmatrix}$，即 $a_{11} = 0.7$, $a_{12} = 0.3$, $a_{21} = 0.4$, $a_{22} = 0.6$；
- 发射：状态 1 偏好 0，$b_1(0) = 0.9$, $b_1(1) = 0.1$；状态 2 偏好 1，$b_2(0) = 0.2$, $b_2(1) = 0.8$。

观测序列 $x_1 = 0$, $x_2 = 1$。

$t = 1$（式 9）：

$$\alpha_1(1) = 0.6 \times 0.9 = 0.54, \qquad \alpha_1(2) = 0.4 \times 0.2 = 0.08.$$

$t = 2$（式 10）：

$$\alpha_2(1) = b_1(1)\big[\alpha_1(1)a_{11} + \alpha_1(2)a_{21}\big] = 0.1\,[0.54 \times 0.7 + 0.08 \times 0.4] = 0.1\,[0.378 + 0.032] = 0.1 \times 0.41 = 0.041,$$
$$\alpha_2(2) = b_2(1)\big[\alpha_1(1)a_{12} + \alpha_1(2)a_{22}\big] = 0.8\,[0.54 \times 0.3 + 0.08 \times 0.6] = 0.8\,[0.162 + 0.048] = 0.8 \times 0.21 = 0.168.$$

终止（式 11）：

$$p(\mathbf{x}) = \alpha_2(1) + \alpha_2(2) = 0.041 + 0.168 = 0.209.$$

每一步都只做了 $O(K)$ 的求和，而非枚举 $K^T = 4$ 条（这里恰巧相等，但 T 大时差距巨大）路径。

> **常见误区**：长序列下 α 会指数级下溢到 0。实际实现要每步做**缩放**（除以当前总和）或用 **log-sum-exp**（$\log \sum_j e^{\log \alpha_j}$）避免数值溢出/下溢。

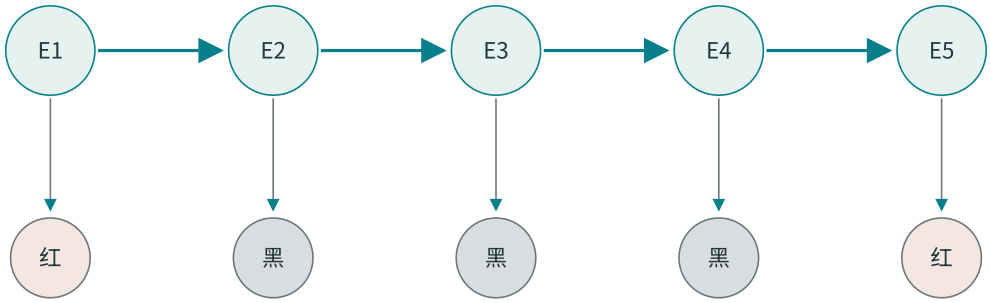
往年课件原例：信封 HMM 的五步前向计算

> **来源性质**：S15 69–70 页，往年课件原例。开始等概率选择两个信封之一；若上次选信封 0，下次必选信封 1；若上次选信封 1，下次等概率选择。信封 0 只有黑球，信封 1 的红黑球各占一半。观测序列为“红、黑、黑、黑、红”。

令状态 $E_t \in \{0, 1\}$，观测编码为红 r、黑 b。参数为

$$\boldsymbol{\pi} = (0.5, 0.5), \qquad A = \begin{bmatrix} 0 & 1 \\ 0.5 & 0.5 \end{bmatrix}, \qquad B = \begin{bmatrix} P(r \mid 0) & P(b \mid 0) \\ P(r \mid 1) & P(b \mid 1) \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ 0.5 & 0.5 \end{bmatrix}.$$

信封 HMM：隐藏信封序列与红黑观测



π=(0.5,0.5)，A=[[0,1],[0.5,0.5]]，B=[[0,1],[0.5,0.5]]
红球排除状态 0；黑球在状态 0 必然出现，在状态 1 概率为 0.5。

按式 (10) 逐步递推：

t	观测	$\alpha_t(0)$	$\alpha_t(1)$	说明
1	红	$0.5 \times 0 = 0$	$0.5 \times 0.5 = 0.25$	看到红球排除信封 0
2	黑	$0.25 \times 0.5 \times 1 = 0.125$	$0.25 \times 0.5 \times 0.5 = 0.0625$	从状态 1 分到两条转移
3	黑	$0.0625 \times 0.5 = 0.03125$	$(0.125 \times 1 + 0.0625 \times 0.5) \times 0.5 = 0.078125$	到状态 1 的路径求和
4	黑	$0.078125 \times 0.5 = 0.0390625$	$(0.03125 + 0.078125 \times 0.5) \times 0.5 = 0.03515625$	同一递推
5	红	0	$(0.0390625 + 0.03515625 \times 0.5) \times 0.5 = 0.0283203125$	红球再次排除状态 0

所以该观测序列的概率为

$$P(r, b, b, b, r) = \alpha_5(0) + \alpha_5(1) = 0.0283203125.$$

若改做 Viterbi，把每一步对前驱的“求和”换成“最大值”，得到最可能状态路径

$$\boxed{(E_1, E_2, E_3, E_4, E_5) = (1, 0, 1, 0, 1)},$$

其联合概率为 0.015625。它小于整个观测序列概率 0.0283203125，因为后者把所有合法状态路径的概率都加了起来。

> **这里最容易混淆**：前向算法回答“看到这串颜色的总概率”，Viterbi 回答“产生这串颜色的单条最可能信封路径”。一个用 $\sum$，一个用 $\max$，结果不应相等。

9.5.3 后向算法 β 与状态后验 $\propto \alpha\beta$

定义。

$$\beta_t(i) = p(x_{t+1:T} \mid z_t = i),$$

即"已知第 t 时刻状态为 i，之后观测为 $x_{t+1}, \dots, x_T$"的概率（只含未来）。

边界。 $t = T$ 时没有未来观测，空事件概率为 1：

$$\beta_T(i) = 1. \tag{12}$$

递推步——推导。

$$\begin{aligned}\beta_t(i) &= p(x_{t+1:T} \mid z_t = i) \\ &= \sum_j p(x_{t+1:T},\, z_{t+1} = j \mid z_t = i) && \text{（对下一状态 } j \text{ 边际化）} \\ &= \sum_j p(x_{t+1},\, z_{t+1} = j \mid z_t = i)\, p(x_{t+2:T} \mid z_t = i,\, z_{t+1} = j,\, x_{t+1}) \\ &= \sum_j a_{ij}\, b_j(x_{t+1})\, \beta_{t+1}(j). && \text{（马尔可夫假设）}\end{aligned}$$

最后一步：$p(x_{t+1}, z_{t+1} = j \mid z_t = i) = p(z_{t+1} = j \mid z_t = i)\, p(x_{t+1} \mid z_{t+1} = j) = a_{ij} b_j(x_{t+1})$；而给定 $z_{t+1} = j$ 后未来与过去无关，故 $p(x_{t+2:T} \mid \cdots) = \beta_{t+1}(j)$。

$$\beta_t(i) = \sum_{j=1}^{K} a_{ij}\, b_j(x_{t+1})\, \beta_{t+1}(j), \qquad \beta_T(i) = 1. \tag{13}$$

状态后验为什么 $\propto \alpha\beta$。

$$\begin{aligned}p(x_{1:t},\, z_t = j,\, x_{t+1:T}) &= p(x_{1:t},\, z_t = j)\, p(x_{t+1:T} \mid z_t = j) && \text{（给定 } z_t = j\text{，未来独立于过去）} \\ &= \alpha_t(j)\, \beta_t(j).\end{aligned}$$

再除以 $p(\mathbf{x}) = \sum_j \alpha_T(j)$ 得后验：

$$p(z_t = j \mid \mathbf{x}) = \frac{\alpha_t(j)\, \beta_t(j)}{\sum_k \alpha_T(k)}. \tag{14}$$

所以**状态后验正比于** $\alpha_t(j)\beta_t(j)$，比例常数只与 t 无关地与全序列概率有关。α 携带过去、β 携带未来，二者相乘即得该时刻的完整信息。

9.5.4 Viterbi：把"求和"换成"取最大值"并回溯

问题：不是求概率，而是求**整条最可能的状态路径** $\hat{\mathbf{z}} = \arg\max_{\mathbf{z}} p(\mathbf{z}, \mathbf{x})$。

直觉：前向递推把"所有路径概率求和"，若把求和 $\sum$ 改成最大值 $\max$，就得到"到时刻 t 以状态 j 结尾的**最优子路径**概率"，再在终点取最大并沿保存的指针回溯，即得全局最优路径。

定义与递推。

$$\delta_t(j) = \max_{z_{1:t-1}} p(z_t = j,\, z_{1:t-1},\, x_{1:t}),$$

$$\delta_1(j) = \pi_j\, b_j(x_1), \qquad \delta_t(j) = \max_{1 \le i \le K} \left[\delta_{t-1}(i)\, a_{ij}\right] b_j(x_t). \tag{15}$$

同时保存**回溯指针**：

$$\psi_t(j) = \arg\max_{1 \le i \le K} \left[\delta_{t-1}(i)\, a_{ij}\right]. \tag{16}$$

终止与回溯。

$$\hat{z}_T = \arg\max_j \delta_T(j), \qquad \hat{z}_{t-1} = \psi_t(\hat{z}_t),\ t = T, T-1, \ldots, 2. \tag{17}$$

> **常见误区**：**逐时刻选边缘后验最大的状态**（即分别取 $\arg\max_j p(z_t = j \mid \mathbf{x})$）**不保证**构成最可能的整体路径！因为各时刻最优状态之间可能违反转移约束 a_{ij}。Viterbi 之所以正确，是因为它最大化的是**整条路径的联合概率**，并用指针保证相邻状态合法衔接。

9.5.5 用 EM 学习 HMM 参数

E 步（§9.4.3）在本模型下产出两个统计量：

- 单点后验 $\gamma_t(i) = P(z_t = i \mid \mathbf{x})$，由式 (14) 直接得到；
- 两点后验 $\xi_t(i,j) = P(z_t = i,\, z_{t+1} = j \mid \mathbf{x})$，同样可由 α, β 与 a, b 组合而成。

M 步用这些期望计数更新参数（归一化即得最大似然估计）：

$$\pi_i = \gamma_1(i), \qquad a_{ij} = \frac{\sum_{t<T} \xi_t(i,j)}{\sum_{t<T} \gamma_t(i)}. \tag{18}$$

离散发射概率则按状态相关的期望计数归一化得到；连续发射可改用高斯并做相应均值/方差更新。

> **边界提示**：分母为 0（某状态从未被分配到正概率）、多条序列（对序列求和）、连续发射（高斯/混合）都需各自单独处理，不能套用上式而不检查。

9.6 CRF：直接建模条件序列分布

直觉：HMM 先建模**联合** $p(\mathbf{x}, \mathbf{y})$，再用贝叶斯公式得 $p(\mathbf{y} \mid \mathbf{x})$。但我们要的往往只是"给定观测 $\mathbf{x}$ 的标签分布"。CRF（条件随机场）直接建模**条件分布** $p(\mathbf{y} \mid \mathbf{x})$，绕开了对复杂观测 $p(\mathbf{x})$ 的建模，也避免了 HMM 中"每个状态发射必须独立"的强假设。

9.6.1 线性链 CRF 的形式

符号。 $\mathbf{y} = (y_1, \ldots, y_T)$ 是标签序列，y_t 取某标签集合中的值；$\mathbf{x}$ 是整段观测（如一句话的词向量）。特征函数 $f_j(y_{t-1}, y_t, \mathbf{x}, t)$ 衡量"在位置 t、上一标签 y_{t-1}、当前标签 y_t 下，这条特征是否成立/多强烈"，权重 w_j 待学。

起始式（未归一化条件得分）。把所有位置、所有特征加权求和作为"对数得分"：

$$\Phi(\mathbf{y}, \mathbf{x}) = \sum_{t=1}^{T} \sum_{j} w_j \, f_j(y_{t-1}, y_t, \mathbf{x}, t).$$

把它指数化并整体归一化，得到条件分布：

$$p(\mathbf{y} \mid \mathbf{x}) = \frac{1}{Z(\mathbf{x})} \exp\left[\sum_{t} \sum_{j} w_j \, f_j(y_{t-1}, y_t, \mathbf{x}, t) \right]. \tag{19}$$

其中归一化常数只针对**标签序列**求和（观测 $\mathbf{x}$ 固定，故只写 $Z(\mathbf{x})$）：

$$Z(\mathbf{x}) = \sum_{\mathbf{y}} \exp\left[\sum_{t} \sum_{j} w_j \, f_j(y_{t-1}, y_t, \mathbf{x}, t) \right]. \tag{20}$$

结论与要点。

- 式 (19) 是"给定 $\mathbf{x}$ 的条件概率"，因此**不需要**对观测 $\mathbf{x}$ 建模，也不需要 HMM 的局部发射独立性假设。
- 特征 f_j 可以**依赖整个观测序列** $\mathbf{x}$（如"当前词是'苹果'且标签为水果"），而标签之间仍按链式 $y_{t-1} \to y_t$ 组织。
- $Z(\mathbf{x})$ 要对**所有**标签序列求和，看似 K^T 爆炸，但因链式结构可用类似前向的**动态规划**在 $O(TK^2)$ 内算得。

9.6.2 $Z(\mathbf{x})$ 的动态规划（与前向同构）

把式 (20) 中指数里的求和按时间拆开，定义"到时刻 t、以标签 i 结尾的部分序列得分"的前向量 $F_t(i)$，递推：

$$F_1(i)=\exp\Big(\sum_j w_j f_j(\text{start},i,\mathbf{x},1)\Big),\qquad F_t(i)=\sum_k F_{t-1}(k)\,\exp\Big(\sum_j w_j f_j(k,i,\mathbf{x},t)\Big).$$

则 $Z(\mathbf{x})=\sum_i F_T(i)$。可见 CRF 的归一化与前向算法**结构同构**——区别只在 HMM 的转移/发射是概率（已归一），而 CRF 这里是未归一的特征指数。

9.6.3 训练梯度与解码

对参数 w_j 求对数条件似然 $\log p(\mathbf{y}\mid\mathbf{x})=\Phi(\mathbf{y},\mathbf{x})-\log Z(\mathbf{x})$ 的梯度：

$$\frac{\partial \log p(\mathbf{y}\mid\mathbf{x})}{\partial w_j}=\underbrace{\sum_t f_j(y_{t-1},y_t,\mathbf{x},t)}_{\text{经验特征计数（数据）}}-\underbrace{\sum_{\mathbf{y}} p(\mathbf{y}\mid\mathbf{x})\sum_t f_j(y_{t-1},y_t,\mathbf{x},t)}_{\text{模型期望特征计数}}. \tag{21}$$

即"**经验计数减模型期望计数**"，与最大熵/逻辑回归的梯度形式一致，可用前向-后向（上面的 F_t）高效计算模型期望。

解码：求 $\arg\max_{\mathbf{y}} p(\mathbf{y}\mid\mathbf{x})$ 等价于在指数（未归一）得分上取最大，因 $Z(\mathbf{x})$ 与 $\mathbf{y}$ 无关。这正是一个 **Viterbi 型**算法（把概率乘积换成指数得分求和、把乘号换成加号），回溯方式同 §9.5.4。

> **常见误区**：不能由 HMM 的"局部发射"假设推断"CRF 里每个标签只和本词有关"。CRF 的特征本就可看全句；而且即便在 HMM 中，**整条序列的联合后验**仍受其他位置的观测与转移约束共同影响——"局部发射"是生成模型里的方便假设，不是解码时的局部性。

9.7 本章速查与常见误区

公式速查。

- 贝叶斯网络：$p=\prod_i p(x_i\mid \mathrm{pa}(x_i))$（有向、局部归一）。
- MRF：$p=(1/Z)\prod_C \psi_C$（无向、全局归一，Z 难算）。
- d 分离：链/分叉条件化中间节点→阻断；碰撞条件化→打开。
- EM 下界：$\log p_\theta(x)=\mathcal{L}(q,\theta)+D_{\mathrm{KL}}(q\|p_\theta(z\mid x))\ge\mathcal{L}$。
- HMM 前向：$\alpha_t(j)=b_j(x_t)\sum_i \alpha_{t-1}(i)a_{ij}$；后向：$\beta_t(i)=\sum_j a_{ij}b_j(x_{t+1})\beta_{t+1}(j)$；后验 $\propto\alpha_t\beta_t$。
- Viterbi：把 $\sum$ 换 $\max$，存回溯指针；逐点最大后验 $\neq$ 全局最优路径。
- CRF：$p(\mathbf{y}\mid\mathbf{x})=(1/Z(\mathbf{x}))\exp(\sum_t\sum_j w_j f_j)$，梯度=经验计数−模型期望计数，解码用 Viterbi 型。

最常错的五点。

1. 把"箭头"当"因果"；把"求参数"和"给定观测求隐变量"混为一谈。
2. 认为碰撞结构给定结果后仍独立（实际是打开路径，见 §9.2.2 的 $2/3$ 例）。
3. 误以为势函数 ψ_C 是概率（它不必 ≤ 1、不必归一）。
4. 以为逐时刻选最大后验状态就是 Viterbi 最优路径（错，见 §9.5.4）。
5. 以为 CRF 因"条件"二字就只看本词（特征可依赖整句，见 §9.6.3）。

> **学习建议**：本章推导多、易混。请按"先写直觉→列符号维度→写起始式→逐步行变换→给结论与条件"的模板，把 §9.1 分解、§9.4 EM 下界、§9.5 前向递推各自**亲手推一遍**，再对照这里的数值小例核验。相关练习见 `../exercises.md`；第二章贝叶斯公式与第八章熵是前置，遇到符号不清先回看。

第十章 神经网络与深度学习：可学习表示的组合

> 往年资料：S16（概述），S17 4–47 页（多层感知机与 BP）、49–71 页（CNN），S18 3–27 页（RNN），S19 3–73 页（深度学习与前沿概览）。原始章节编号出现“第十一章 / 14.x”残留，本书按课程大纲统一为第十章。历史产品列表与性能数据未当作最新事实。

> **本章定位（编者说明）**：本章属于“往年资料”，公式与机制说明依据 S16–S19 的课件整理；标注“编者推导”“编者解释”的内容用于补足教材未写出的逐步代数过程。2026-10-30 已视觉核对 S17 50–71 页与 S18 21 页，补回卷积滑窗、尺寸/参数量例和截断 BPTT 作业的可解释部分；其余原页图仍待完整视觉转录，不推定本年度考试范围。

10.1 为什么多层网络需要非线性

直观直觉：一个最简单的反例——XOR

第三章的线性分类器（感知机、Fisher、logistic）学习的是“一条直线（或超平面）把空间一分为二”。但有一类问题，**任何一条直线都分不开**，最经典的例子就是异或（XOR）：

输入 (x_1, x_2)	标签 y
$(0, 0)$	0
$(0, 1)$	1
$(1, 0)$	1
$(1, 1)$	0

如果你在坐标纸上点出这四点，会发现“标签为 1 的点”被“标签为 0 的点”夹在中间，没有任何一条直线能把红蓝分开。单层线性模型必然失败。

那么“多叠几层线性层”行不行？**不行，因为层与层串起来仍然是线性变换。**下面用代数把这个结论讲死。

过程讲解：两层线性串联仍然线性

假设与符号（与全书统一符号一致；列向量记法）

- 第 l 层的宽度为 d_l（即该层神经元个数，也是该层激活向量的维度）。
- 输入记作 $\mathbf{a}^{(0)} = \mathbf{x} \in \mathbb{R}^{d_0=\mathbf{d}}$。
- 第 l 层先做仿射变换，再做逐元素非线性激活：

$$\mathbf{z}^{(l)} = W^{(l)}\mathbf{a}^{(l-1)} + \mathbf{b}^{(l)}, \qquad \mathbf{a}^{(l)} = \phi_l\left(\mathbf{z}^{(l)}\right).$$

维度约定（务必先确认）

$$W^{(l)} \in \mathbb{R}^{d_l \times d_{l-1}}, \qquad \mathbf{b}^{(l)}, \mathbf{z}^{(l)}, \mathbf{a}^{(l)} \in \mathbb{R}^{d_l}.$$

也就是说 $W^{(l)}$ 的每一行对应一个输出神经元，每一列对应一个输入神经元；偏置 $\mathbf{b}^{(l)}$ 与输出同维，对每个输出神经元各加一个标量。

起始式：考虑连续两层“中间没有非线性”的仿射变换（即把第一层的输出 $\mathbf{a}^{(1)}$ 直接当作第二层的输入，跳过激活）：

$$\mathbf{z}^{(2)} = W^{(2)}\big(W^{(1)}\mathbf{a}^{(0)} + \mathbf{b}^{(1)}\big) + \mathbf{b}^{(2)}.$$

逐步推导

1. 先把 $W^{(2)}$ 分配进括号（矩阵对向量加法的分配律）：

$$\mathbf{z}^{(2)} = W^{(2)}W^{(1)}\mathbf{a}^{(0)} + W^{(2)}\mathbf{b}^{(1)} + \mathbf{b}^{(2)}.$$

2. 令组合权重 $\widetilde{W} = W^{(2)}W^{(1)}$，组合偏置 $\widetilde{\mathbf{b}} = W^{(2)}\mathbf{b}^{(1)} + \mathbf{b}^{(2)}$，则

$$\mathbf{z}^{(2)} = \widetilde{W}\,\mathbf{a}^{(0)} + \widetilde{\mathbf{b}}.$$

结论：两层线性（仿射）变换的复合，仍然是一个仿射变换 $\widetilde{W} \in \mathbb{R}^{d_2 \times d_0}$、$\widetilde{\mathbf{b}} \in \mathbb{R}^{d_2}$。推而广之，无论叠多少层纯线性层，整体等价于**单个**线性层。

成立条件 / 边界：该结论依赖“两层之间不插入非线性”。一旦在每层之后插入非线性激活 ϕ_l，上面的合并就不再成立——这正是我们引入非线性的原因。

> **记住**：多层“表示能力”的提升，来源不是“多”，而是“非线性”。没有非线性，深和浅等价。

常见激活函数（编者解释）

名称	公式	特点与注意
Sigmoid	$\sigma(z) = \dfrac{1}{1+e^{-z}}$	输出 $(0,1)$，两端饱和导数趋于 0，易引发梯度衰减
Tanh	$\tanh(z) = \dfrac{e^{z}-e^{-z}}{e^{z}+e^{-z}}$	输出 $(-1,1)$，零中心化，同样存在饱和
ReLU	$\phi(z) = \max(0, z)$	正区间导数恒为 1，缓解梯度衰减；但负区间恒为 0，可能产生“长期不激活的死单元”

最后一层按任务选择：回归用实值输出、二分类用 sigmoid（配二元交叉熵）、多分类用 softmax（配交叉熵）。

过程讲解：用手工权重构造 XOR（保留例题并核对数字）

编者自编 XOR 构造（仅证明“表示能力存在”，不证明梯度训练一定找到它）：

$$h_1 = \max(0, x_1 + x_2), \qquad h_2 = \max(0, x_1 + x_2 - 1), \qquad \hat{y} = h_1 - 2h_2.$$

逐点核对（把四个二元输入代进去，确认得到 0,1,1,0）

- $(x_1, x_2) = (0,0)$：$x_1 + x_2 = 0 \Rightarrow h_1 = 0$；$x_1 + x_2 - 1 = -1 \Rightarrow h_2 = 0$；$\hat{y} = 0 - 0 = 0$。✓
- $(0,1)$：$x_1 + x_2 = 1 \Rightarrow h_1 = 1$；$x_1 + x_2 - 1 = 0 \Rightarrow h_2 = 0$；$\hat{y} = 1 - 0 = 1$。✓
- $(1,0)$：对称地 $x_1 + x_2 = 1 \Rightarrow h_1 = 1, h_2 = 0$；$\hat{y} = 1$。✓
- $(1,1)$：$x_1 + x_2 = 2 \Rightarrow h_1 = 2$；$x_1 + x_2 - 1 = 1 \Rightarrow h_2 = 1$；$\hat{y} = 2 - 2 \times 1 = 0$。✓

得到序列 $0, 1, 1, 0$，与 XOR 标签一致。这里第一隐藏单元 h_1 在“至少一位为 1”时开启，第二隐藏单元 h_2 只在“两位都为 1”时开启，二者之差恰好区分了“恰好一个 1”和“两个都是 1 / 两个都是 0”。

> **常见误区**：手工能构造出一组权重，只说明网络“容量上”能表达 XOR，不等于训练算法一定能收敛到这组权重。表示能力 ≠ 可训练性。

10.2 BP 是高效组织链式法则

直观直觉：为什么需要“反向传播”

网络有上百万参数，我们最终要算的是损失 J 对每个参数的偏导数 $\partial J/\partial W^{(l)}$、$\partial J/\partial \mathbf{b}^{(l)}$。直接对每个参数单独求导不现实。反向传播（Backpropagation, BP）的本质就是：**用一张计算图，按链式法则从输出往输入方向，把梯度“高效、复用”地算一遍。**

- 前向：一层层算 $\mathbf{z}^{(l)}, \mathbf{a}^{(l)}$ 并**保存中间结果**（反向要用）。
- 反向：从输出层往回，利用“每个节点的局部梯度”乘上“已算好的上游梯度”，一路复用，避免重复计算。

本章的反向传播只为参数**提供梯度**；真正用梯度更新参数的是梯度下降，其思想在第三章的感知机与梯度更新中已经出现——第三章的“错了朝正确方向移动”本质就是沿梯度（或次梯度）下降。

记号与误差信号定义

- 单样本标量损失记为 J（批量时再对样本求和或平均，须与损失定义一致）。
- 定义第 l 层的**局部误差信号**（对“预激活” $\mathbf{z}^{(l)}$ 的梯度）：

$$\boldsymbol{\delta}^{(l)} = \frac{\partial J}{\partial \mathbf{z}^{(l)}} \in \mathbb{R}^{d_l}.$$

$\boldsymbol{\delta}^{(l)}$ 的物理意义：第 l 层每个神经元“预激活”变动一点点，会对总损失造成多大影响。它是连接“上游梯度”和“本层参数梯度”的桥梁。

过程讲解（核心）：隐藏层误差信号递推 $\boldsymbol{\delta}^{(l)}$

目标：用下一层误差 $\boldsymbol{\delta}^{(l+1)}$ 表达本层误差 $\boldsymbol{\delta}^{(l)}$，得到反向递推式。

依赖关系（先看计算图）：本层预激活 $\mathbf{z}^{(l)}$ 经激活得到 $\mathbf{a}^{(l)} = \phi_l(\mathbf{z}^{(l)})$；再进入下一层 $\mathbf{z}^{(l+1)} = W^{(l+1)}\mathbf{a}^{(l)} + \mathbf{b}^{(l+1)}$。所以 J 通过 $\mathbf{a}^{(l)}$ 间接依赖 $\mathbf{z}^{(l)}$。

起始式（对第 i 个分量写链式法则）：

$$\delta_i^{(l)} = \frac{\partial J}{\partial z_i^{(l)}} = \sum_j \underbrace{\frac{\partial J}{\partial z_j^{(l+1)}}}_{\delta_j^{(l+1)}} \frac{\partial z_j^{(l+1)}}{\partial z_i^{(l)}}.$$

关键一步：算 $\partial z_j^{(l+1)}/\partial z_i^{(l)}$。展开下一层预激活的第 j 个分量：

$$z_j^{(l+1)} = \sum_k W_{jk}^{(l+1)}\, a_k^{(l)} + b_j^{(l+1)} = \sum_k W_{jk}^{(l+1)}\, \phi_l\left(z_k^{(l)}\right) + b_j^{(l+1)}.$$

对 $z_i^{(l)}$ 求偏导时，只有 $k = i$ 那一项含有 $z_i^{(l)}$，其余项导数为 0：

$$\frac{\partial z_j^{(l+1)}}{\partial z_i^{(l)}} = W_{ji}^{(l+1)}\, \phi_l'\left(z_i^{(l)}\right).$$

代回起始式并整理：

$$\delta_i^{(l)} \;=\; \sum_j \delta_j^{(l+1)}\, W_{ji}^{(l+1)}\, \phi_l'\!\left(z_i^{(l)}\right) \;=\; \left[\left(W^{(l+1)}\right)^T \boldsymbol{\delta}^{(l+1)}\right]_i \, \phi_l'\!\left(z_i^{(l)}\right).$$

写成向量形式（逐元素乘法用 $\odot$）：

$$\boxed{\boldsymbol{\delta}^{(l)} = \left[\left(W^{(l+1)}\right)^T \boldsymbol{\delta}^{(l+1)}\right] \odot \phi_l'\!\left(\mathbf{z}^{(l)}\right)}$$

维度检查：

- $W^{(l+1)} \in \mathbb{R}^{d_{l+1}\times d_l} \Rightarrow \left(W^{(l+1)}\right)^T \in \mathbb{R}^{d_l \times d_{l+1}}$；
- $\boldsymbol{\delta}^{(l+1)} \in \mathbb{R}^{d_{l+1}}$；
- 二者相乘 $\mathbb{R}^{d_l\times d_{l+1}} \times \mathbb{R}^{d_{l+1}} \to \mathbb{R}^{d_l}$；
- $\phi_l'(\mathbf{z}^{(l)}) \in \mathbb{R}^{d_l}$，逐元素乘后仍 $\mathbb{R}^{d_l}$，与 $\boldsymbol{\delta}^{(l)}$ 维度一致。✓

> **记住**：矩阵转置 $(W^{(l+1)})^T$ 干的事情是“把下一层每个单元对本层第 i 个神经元的贡献汇总起来”；$\odot$ 完成的是激活函数的链式法则因子。

过程讲解：参数梯度 $\partial J/\partial W^{(l)}$ 与维度检查

目标：把 $\boldsymbol{\delta}^{(l)}$ 变成可直接用于更新的权重梯度。

起始式：看 $W^{(l)}$ 第 j 行第 k 列元素如何影响损失。由前向式

$$z_j^{(l)} = \sum_k W_{jk}^{(l)}\, a_k^{(l-1)} + b_j^{(l)},$$

所以 $\partial z_j^{(l)}/\partial W_{jk}^{(l)} = a_k^{(l-1)}$，与 j 行其它列无关。

链式法则：

$$\frac{\partial J}{\partial W_{jk}^{(l)}} \;=\; \sum_i \frac{\partial J}{\partial z_i^{(l)}}\,\frac{\partial z_i^{(l)}}{\partial W_{jk}^{(l)}} \;=\; \delta_j^{(l)}\, a_k^{(l-1)}.$$

（只有 $i=j$ 的项非零，因为 $W_{jk}^{(l)}$ 只影响 $z_j^{(l)}$。）

写成矩阵：把所有 (j,k) 拼成矩阵，正好是“列向量 $\boldsymbol{\delta}^{(l)}$ 乘行向量 $(\mathbf{a}^{(l-1)})^T$”：

$$\boxed{\frac{\partial J}{\partial W^{(l)}} = \boldsymbol{\delta}^{(l)}\left(\mathbf{a}^{(l-1)}\right)^T, \qquad \frac{\partial J}{\partial \mathbf{b}^{(l)}} = \boldsymbol{\delta}^{(l)}}$$

维度检查（题目明确要求核对）：

- $\boldsymbol{\delta}^{(l)} \in \mathbb{R}^{d_l\times 1}$；
- $(\mathbf{a}^{(l-1)})^T \in \mathbb{R}^{1\times d_{l-1}}$；
- 外积结果 $\mathbb{R}^{d_l\times 1} \times \mathbb{R}^{1\times d_{l-1}} \to \mathbb{R}^{d_l\times d_{l-1}}$，恰好等于 $W^{(l)}$ 的形状。✓

> **常见误区**：有人写成 $\boldsymbol{\delta}^{(l)}(\mathbf{a}^{(l-1)})^T$ 却搞反内外积，得到 $d_{l-1}\times d_l$ 的错误形状。请始终用“行数=输出维、列数=输入维”回扣 $W^{(l)}$ 的维度。

过程讲解：输出层 softmax + 交叉熵的简化误差 $\boldsymbol{\delta}^{(L)} = \mathbf{p} - \mathbf{y}$

这是 BP 在分类任务里**最省事也最容易算错**的一步。设输出层（第 L 层）有 K 类：

- 预激活（logits）$\mathbf{z}^{(L)} \in \mathbb{R}^K$；
- softmax 概率 $p_i = \dfrac{e^{z_i^{(L)}}}{\sum_{j=1}^{K} e^{z_j^{(L)}}}$；
- one-hot 标签 $\mathbf{y} \in \mathbb{R}^K$，$\sum_i y_i = 1$；
- 交叉熵损失 $J = -\sum_{i=1}^{K} y_i \log p_i$。

目标：求 $\delta_i^{(L)} = \partial J / \partial z_i^{(L)}$。

第一步：展开 $\partial J / \partial z_i^{(L)}$

$$\frac{\partial J}{\partial z_i^{(L)}} \;=\; -\sum_{k=1}^{K} y_k \, \frac{\partial \log p_k}{\partial z_i^{(L)}}.$$

第二步：算 $\partial \log p_k / \partial z_i^{(L)}$。先写出 $\log p_k = z_k^{(L)} - \log\big(\sum_j e^{z_j^{(L)}}\big)$，再求导：

$$\frac{\partial \log p_k}{\partial z_i^{(L)}} \;=\; \frac{\partial z_k^{(L)}}{\partial z_i^{(L)}} - \frac{e^{z_i^{(L)}}}{\sum_j e^{z_j^{(L)}}} \;=\; \delta_{ki} - p_i,$$

其中 δ_{ki} 是克罗内克符号（$k = i$ 时为 1，否则为 0）。

第三步：代回并化简

$$\frac{\partial J}{\partial z_i^{(L)}} \;=\; -\sum_{k=1}^{K} y_k(\delta_{ki} - p_i) \;=\; -y_i + p_i \underbrace{\sum_{k=1}^{K} y_k}_{=p_i \cdot 1} \;=\; p_i - y_i.$$

于是

$$\boxed{\boldsymbol{\delta}^{(L)} = \mathbf{p} - \mathbf{y}}$$

结论与边界：该简化**仅在“softmax 输出 + 交叉熵损失 + one-hot 标签”三者同时成立**时才有效；若输出层用别的激活（如 sigmoid 配二元交叉熵、或 MSE），$\boldsymbol{\delta}^{(L)}$ 会是不同形式。它的维度 $\mathbb{R}^K$，与类别数一致。

> **小数值检查**：假设三分类，$p = (0.2, 0.5, 0.3)$，真实类是第 2 类 $y = (0, 1, 0)$，则 $\delta^{(L)} = (0.2, -0.5, 0.3)$。注意正确类别处为负（降低其 logit 会让损失上升，所以梯度要“推高”它，负号即对应上升方向），符合直觉。

批量、实现与训练注意事项

- **批量训练**：对 N 个样本的损失 $J = \frac{1}{N}\sum_{n=1}^{N} J^{(n)}$（或求和），梯度同样对样本取平均（或求和），须与损失定义保持一致。
- **前向要存、反向要逆序**：必须保存各层 $\mathbf{a}^{(l)}, \mathbf{z}^{(l)}$ 供反向使用；反向按依赖逆序计算。
- **统一更新**：应在**全部梯度算好后再统一更新**参数，避免同一轮反向传播混用“已更新”和“未更新”的权重——否则 BP 的链式法则假设（图结构固定）被破坏。
- **BP 与梯度下降是两件事**：BP 负责“算梯度”，梯度下降（或 Adam 等）负责“用梯度更新”。不要把二者混为一谈。

梯度消失 / 爆炸（保留并深化）

深层网络里梯度是许多因子连乘：$\boldsymbol{\delta}^{(l)}$ 含 $(W^T)^{L-l}$ 与一堆 ϕ'。若这些因子绝对值普遍小于 1（如饱和 sigmoid，$\phi' \in (0, 0.25]$），乘积指数级趋零——**梯度消失**；若普遍大于 1，则**梯度爆炸**。ReLU 在正区间导数恒为 1，能缓解部分消失，但负区间导数 0 会产生“长期不激活的死单元”。因此初始化、归一化（Batch/Layer Norm）、残差连接与优化器设置都会影响训练，**并非“换个激活就一定能解决”**。

10.3 CNN：局部连接和权重共享

直观直觉：为什么卷积“省参数又有效”

自然图像里，“边缘、角点”这类局部模式可能在图像任何位置出现。若每个位置都学一套独立检测器，参数会爆炸且泛化差。卷积层让**同一组核参数在不同空间位置复用**（权重共享），一个输出通道对应一种局部模式；输入的不同通道（RGB）在求和时共享同一组核权重，因此参数不随图像空间尺寸增长。

过程讲解：输出尺寸公式 $L_{out} = \left\lfloor \frac{L_{in}+2P-F}{S} \right\rfloor + 1$

假设与符号（一维，便于看清；二维对高、宽分别计算）

- L_{in}：输入长度（如宽度方向的像素数）；
- F：卷积核大小（filter size）；
- P：单侧填充（padding），左右各加 P，故填充后长度为 $L_{in} + 2P$；
- $S > 0$：步长（stride），每次核滑动 S 个像素；
- 要求核在填充后的输入上**至少能完整放置一次**，否则该层定义不成立。

起始式（数“合法起始位置”）：核第一次放在位置 0，覆盖 $[0, F-1]$。设核左端起始位置为 s，则需满足

$$s + F - 1 \le (L_{in} + 2P) - 1 \quad \Longrightarrow \quad s \le L_{in} + 2P - F.$$

合法的 s 为 $0, S, 2S, \ldots$，不超过上界，其个数为

$$\text{个数} = \left\lfloor \frac{L_{in} + 2P - F}{S} \right\rfloor + 1.$$

结论（这也是二维尺寸的逐轴公式）：

$$\boxed{L_{out} = \left\lfloor \frac{L_{in} + 2P - F}{S} \right\rfloor + 1}$$

二维：对高 H、宽 W 分别套用上式，得到 (H_{out}, W_{out})，通道数变为 C_{out}。

小数值检查（无填充）：原例题 $L_{in} = 32, F = 5, P = 0, S = 1$：

$$L_{out} = \left\lfloor \frac{32 + 0 - 5}{1} \right\rfloor + 1 = 27 + 1 = 28. \quad \checkmark$$

补充数值例子（同尺寸卷积）：若 $L_{in} = 7, F = 3, P = 1, S = 1$，则 $L_{out} = \lfloor (7 + 2 - 3)/1 \rfloor + 1 = 6 + 1 = 7$，输出与输入等长——这正是对图像做“same padding”的常见情形。

过程讲解：参数量公式（保留例题并核对 456）

假设与符号

- 输入通道 C_{in}，输出通道 C_{out}；
- 每个输出通道对应一个大小为 $F_h \times F_w$ 的空域核，且该核要**跨全部 C_{in} 个输入通道求和**；
- 每个输出通道另有一个标量偏置。

起始式（数一个输出通道的参数）：一个输出通道的核权重数为

$$F_h \times F_w \times C_{in},$$

再加 1 个偏置，共 $F_h F_w C_{in} + 1$。

对 C_{out} 个通道求和：

$$\boxed{\text{参数量} = C_{out}\left(F_h F_w\, C_{in} + 1\right)}$$

关键点：该式**不含 L_{in} 或图像空间尺寸**——因为权重在空域共享，图像变大参数不变（这是 CNN 相对全连接的核心优势）。

核对原例题：$32 \times 32 \times 3$ 输入，$C_{in} = 3$，6 个 5×5 核即 $C_{out} = 6, F_h = F_w = 5$，步长 1、不填充：

$$\text{参数量} = 6\left(5 \times 5 \times 3 + 1\right) = 6(75 + 1) = 6 \times 76 = 456. \quad \checkmark$$

输出为 $28 \times 28 \times 6$（由上方尺寸公式得 28×28，通道 $C_{out} = 6$）。

往年课件原例：7×7 输入上的 3×3 卷积

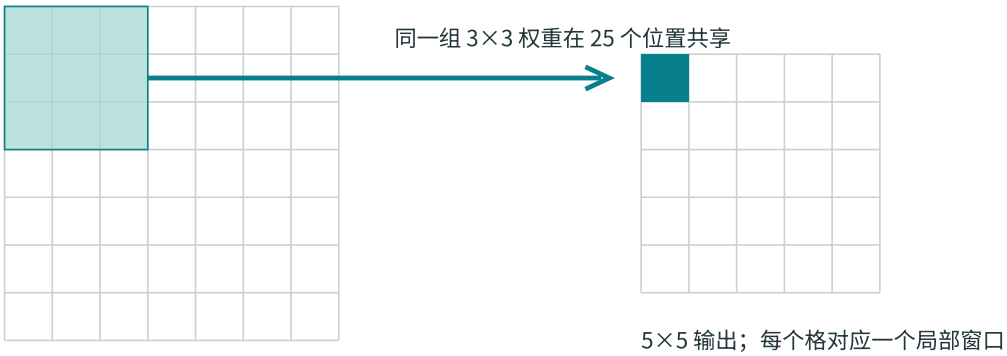
> **来源性质**：S17 56–61 页，往年课件原例。课件用连续动画展示一个 3×3 核在 7×7 输入上逐格滑动。

取 $H_{in} = W_{in} = 7$、$F_h = F_w = 3$、$P = 0$、$S = 1$。核左上角的横纵起点都只能取 $0, 1, 2, 3, 4$，因此

$$H_{out} = W_{out} = \frac{7 - 3}{1} + 1 = 5,$$

总共计算 $5 \times 5 = 25$ 个输出位置。每个位置都读取一个局部 3×3 窗口，与同一组 9 个核权重逐元素相乘后求和，再加同一个偏置。

七乘七输入上的三乘三卷积：局部连接与权重共享



若输入只有 1 个通道、输出也只有 1 个通道，参数量是 $3 \times 3 + 1 = 10$；虽然同一核在 25 个位置执行 25 次，参数仍只有 10 个。**执行次数增加不等于参数量增加**，这正是权重共享。

课件 62 页还比较了填充：若 $P=1$，同样的 7×7 输入与 3×3 核会得到 7×7 输出；边界外补零会影响边缘处的卷积值，但不会新增可学习参数。

池化、平移等变性与边界说明

- **最大/平均池化**通常**没有可学习参数**，作用是降采样；但它会丢失精确位置信息（只保留“某区域内最大值”）。
- **局部共享带来平移等变性**：输入平移，输出按同样方式平移（equivariance），即“卷积 + 平移 = 平移 + 卷积”；但 CNN **不自动保证任意平移下分类结果完全不变**（invariance）——真正的不变量通常要靠池化/全局池化与训练数据共同塑造。不要把“等变”误说成“不变”。

10.4 RNN：共享参数的时间展开

直观直觉：序列依赖过去

很多任务（语言、时序）中，当前预测依赖历史。若用前馈网络硬接固定长度历史，窗口长度受限。循环神经网络（RNN）让**同一组参数在不同时间步复用**，从而用有限参数处理任意长度序列。代价是：训练时要沿时间“展开”成一张很深的图，梯度沿时间回传。

过程讲解：时间展开与误差信号 $\boldsymbol{\delta}_t$

假设与符号

- 隐状态 $\mathbf{h}_t\in\mathbb{R}^{d_h}$，输入 $\mathbf{x}_t\in\mathbb{R}^{d_x}$，输出 $\mathbf{o}_t\in\mathbb{R}^{d_o}$；
- 预激活（隐藏层“激活前”的值）记为 $\mathbf{u}_t=W_h\mathbf{h}_{t-1}+W_x\mathbf{x}_t+\mathbf{b}$，则 $\mathbf{h}_t=\phi(\mathbf{u}_t)$；
- 各时刻**共享**同一组 $W_h,W_x,W_o,\mathbf{b},\mathbf{c}$；
- 总损失 $J=\sum_{t=1}^{T}\ell_t$，设 $\boldsymbol{\delta}_t=\partial J/\partial\mathbf{u}_t\in\mathbb{R}^{d_h}$，输出梯度 $\mathbf{e}_t=\partial\ell_t/\partial\mathbf{o}_t\in\mathbb{R}^{d_o}$。

展开视角：把 $\mathbf{h}_1\to\mathbf{h}_2\to\cdots\to\mathbf{h}_T$ 在纸上横向铺开，每个时间步是图中的一个“层”，共享参数跨层复用——所以 RNN 的训练图在“时间维”上非常深。

起始式（对 $t<T$ 写 $\boldsymbol{\delta}_t$）：$\mathbf{u}_t$ 影响损失有两条路——(1) 经 $\mathbf{h}_t$ 直接到 $\mathbf{o}_t$（输出损失 ℓ_t）；(2) 经 $\mathbf{h}_t$ 到下一步预激活 $\mathbf{u}_{t+1}$（从而影响 $\ell_{t+1},\ldots$）。因此

$$\boldsymbol{\delta}_t=\frac{\partial J}{\partial\mathbf{u}_t}=\underbrace{\frac{\partial J}{\partial\mathbf{h}_t}}_{\text{来自两条路}}\odot\phi'(\mathbf{u}_t).$$

而 $\partial J/\partial\mathbf{h}_t$ 由两部分组成：

$$\frac{\partial J}{\partial\mathbf{h}_t}=\big(W_o\big)^T\mathbf{e}_t\;+\;\big(W_h\big)^T\boldsymbol{\delta}_{t+1}.$$

理由：$\mathbf{h}_t$ 进入输出 $\mathbf{o}_t=W_o\mathbf{h}_t+\mathbf{c}$（带来 $W_o^T\mathbf{e}_t$），也进入下一步 $\mathbf{u}_{t+1}=W_h\mathbf{h}_t+\cdots$（带来 $W_h^T\boldsymbol{\delta}_{t+1}$）。

合并得到递推式（末态之后无未来，$t=T$ 时只有输出项，$\boldsymbol{\delta}_{T+1}=0$）：

$$\boxed{\boldsymbol{\delta}_t=\big(W_o^T\mathbf{e}_t+W_h^T\boldsymbol{\delta}_{t+1}\big)\odot\phi'(\mathbf{u}_t),\qquad\boldsymbol{\delta}_{T+1}=0}$$

维度检查：

- $W_o^T\in\mathbb{R}^{d_h\times d_o}$，$\mathbf{e}_t\in\mathbb{R}^{d_o}\Rightarrow$ 乘积 $\mathbb{R}^{d_h}$；
- $W_h^T\in\mathbb{R}^{d_h\times d_h}$，$\boldsymbol{\delta}_{t+1}\in\mathbb{R}^{d_h}\Rightarrow$ 乘积 $\mathbb{R}^{d_h}$；

- $\phi'(\mathbf{u}_t) \in \mathbb{R}^{d_h}$，逐元素乘后仍为 $\mathbb{R}^{d_h} = \boldsymbol{\delta}_t$ 的维度。✓

过程讲解：共享参数的梯度必须“按时间求和”

目标：因为 W_h 在每个时间步都出现，它对总损失的梯度是**各时间步贡献之和**，不能只取最后一步。

起始式：对每个时间步 t，W_h 通过 $\mathbf{u}_t = W_h\mathbf{h}_{t-1} + \cdots$ 影响损失。类似 10.2 的权重梯度推导：

$$\frac{\partial \ell_{\le T}}{\partial W_h} \supset \frac{\partial J}{\partial \mathbf{u}_t}\frac{\partial \mathbf{u}_t}{\partial W_h} = \boldsymbol{\delta}_t\,\mathbf{h}_{t-1}^T, \qquad \frac{\partial \mathbf{u}_t}{\partial W_h} = \mathbf{h}_{t-1}^T.$$

对所有时间步求和（共享参数把各步梯度累加）：

$$\boxed{\frac{\partial J}{\partial W_h} = \sum_{t=1}^{T} \boldsymbol{\delta}_t\,\mathbf{h}_{t-1}^T}$$

维度检查：$\boldsymbol{\delta}_t \in \mathbb{R}^{d_h}$，$\mathbf{h}_{t-1} \in \mathbb{R}^{d_h} \Rightarrow \boldsymbol{\delta}_t\mathbf{h}_{t-1}^T \in \mathbb{R}^{d_h\times d_h}$，与 W_h 形状一致，求和后仍为 $\mathbb{R}^{d_h\times d_h}$。✓

同类结果（一并给出，便于实现）：

$$\frac{\partial J}{\partial W_x} = \sum_t \boldsymbol{\delta}_t\,\mathbf{x}_t^T, \qquad \frac{\partial J}{\partial W_o} = \sum_t \mathbf{e}_t\,\mathbf{h}_t^T, \qquad \frac{\partial J}{\partial \mathbf{b}} = \sum_t \boldsymbol{\delta}_t, \qquad \frac{\partial J}{\partial \mathbf{c}} = \sum_t \mathbf{e}_t.$$

截断 BPTT（必须说明的边界）

截断 BPTT（Truncated BPTT）只把梯度回传有限时间窗，以换取计算与内存可控。课件 S18 21 页把“截断深度为 h 的学习”列为课堂作业，但该页只给作业标题，没有给数值、教师答案或指定网络，因此这里不能伪造一套“原题数值解”。可把作业要求明确写成以下通用推导：

对时刻 t 的损失 ℓ_t，完整 BPTT 会沿链式法则一直回到任意早的 $t-k$：

$$\frac{\partial \ell_t}{\partial \mathbf{h}_{t-k}} = \frac{\partial \ell_t}{\partial \mathbf{h}_t}\prod_{j=t-k+1}^{t}\frac{\partial \mathbf{h}_j}{\partial \mathbf{h}_{j-1}}.$$

截断深度为 h 时，只保留 $k \le h$ 的这些项；所有从 $t-h-1$ 及更早状态传来的梯度都停止传播。若把序列分成窗口 $[1,h],[h+1,2h],\ldots$，实现中通常在窗口边界把隐藏状态的计算图断开，但**隐藏状态数值仍传到下一窗口**。

例如 $T=6, h=2$，计算 ℓ_6 的梯度时最多回到 $\mathbf{h}_4$，不会再通过 $\mathbf{h}_3,\mathbf{h}_2,\mathbf{h}_1$；计算 ℓ_5 时最多回到 $\mathbf{h}_3$。因此截断后的梯度少了长程依赖项：

$$\nabla J_{\text{trunc}} \neq \nabla J_{\text{full}}.$$

> **结论与限制**：截断 BPTT 是有偏近似。h 越大，越接近完整 BPTT，但显存和计算成本越高；h 太小会学不到超过窗口长度的依赖。它解决的是计算图长度，不会自动消除梯度消失或爆炸。

10.5 注意力、Transformer 与预训练

直观直觉：固定长度状态装不下长序列

RNN 把历史压缩进一个定长隐状态 $\mathbf{h}_t$，长输入时“远处信息”容易被冲掉。注意力机制换一种思路：当前位置（查询）直接去“翻看”序列里所有位置（键—值），按**相关性**加权取用，需要多少就看多少。

过程讲解：缩放点积注意力逐步写清

假设与符号

- 查询 $Q \in \mathbb{R}^{n_q \times d_k}$，键 $K \in \mathbb{R}^{n_k \times d_k}$，值 $V \in \mathbb{R}^{n_k \times d_v}$；
- 掩码 $M \in \mathbb{R}^{n_q \times n_k}$，允许位置为 0、禁止位置为 $-\infty$；
- softmax 沿**每个查询行、对键维度** n_k 归一化。

标准公式：

$$\mathrm{Attention}(Q, K, V) = \mathrm{softmax}\left(\frac{QK^T}{\sqrt{d_k}} + M\right)V.$$

下面把这一步拆成 5 个小步，每一步都标注维度与含义：

1. **算相关性分数** $S = QK^T$。
   - 维度：$\mathbb{R}^{n_q \times d_k} \times \mathbb{R}^{d_k \times n_k} \to \mathbb{R}^{n_q \times n_k}$；
   - 含义：$S_{ij} = Q_{i:} \cdot K_{j:}$，即“查询 i 与键 j 的点积相似度”。
2. **缩放除以** $\sqrt{d_k}$。
   - 含义：点积的方差随维度 d_k 增大而增大，数值过大使 softmax 进入“饱和区”、梯度趋零；除以 $\sqrt{d_k}$ 把分数方差稳定在量级 1 附近，训练更稳。
3. **加掩码** $+M$。
   - 禁止位置加 $-\infty$，使该位置在后续 softmax 中权重趋近于 0；允许位置加 0，不变。
4. **按行 softmax。**
   - 对每行 i：$A_{ij} = \dfrac{\exp\left(S_{ij}/\sqrt{d_k} + M_{ij}\right)}{\sum_{j'=1}^{n_k} \exp\left(S_{ij'}/\sqrt{d_k} + M_{ij'}\right)}$；
   - 每行之和为 1，得到“权重分布” $A \in \mathbb{R}^{n_q \times n_k}$。
5. **用权重对值加权求和** $O = AV$。
   - 维度：$\mathbb{R}^{n_q \times n_k} \times \mathbb{R}^{n_k \times d_v} \to \mathbb{R}^{n_q \times d_v}$；
   - 含义：$O_{i:} = \sum_j A_{ij} V_{j:}$，即“查询 i 的输出是各值向量的相关加权组合”。

> **小数值检查（无掩码、单查询）**：设 $d_k = 2$，$Q = [1, 0]$，$K = [[1, 0], [0, 1], [-1, 0]]$，$V = [[10], [20], [30]]$。
>
> - 分数 $S = QK^T = [1, 0, -1]$；缩放（这里 $d_k = 2$，$\sqrt{2} \approx 1.414$）得约 $[0.707, 0, -0.707]$；
> - softmax：$e^{0.707} \approx 2.028$，$e^0 = 1$，$e^{-0.707} \approx 0.493$，和 ≈ 3.521，权重 $\approx [0.576, 0.284, 0.140]$；
> - 输出 $O \approx 0.576 \times 10 + 0.284 \times 20 + 0.140 \times 30 \approx 5.76 + 5.68 + 4.20 = 15.64$。注意最相似的键（第一个）拿到了最大权重，输出偏向其对应值 10——符合“按相关性取用”的直觉。

掩码的两个关键边界（必须说明）

- **因果掩码（causal mask）**：自回归训练时，位置 i 只能看 $j \le i$。实现上令 $M_{ij} = 0$（当 $j \le i$）、$M_{ij} = -\infty$（当 $j > i$），防止“偷看未来”。
- **绝不能整行全遮**：若某个查询行的所有键都被设为 $-\infty$，则该行 softmax 是 $\exp(-\infty)/\sum\exp(-\infty) = 0/0$，结果为 **NaN/未定义**。实现时必须保证**每个查询行至少有一个允许位置**（例如因果掩码下，第 1 个位置至少能看自己）。这是注意力实现里最易踩的坑。

多头、位置编码与预训练（保留并深化）

- **多头注意力**：把 Q, K, V 线性投影到多个子空间，各自独立做上面的 5 步再拼接，让模型在不同表示子空间分别建立关系。
- **位置编码**补回顺序信息（注意力本身对输入排列不敏感）；**残差连接 + 层归一化**帮助信息与前向/反向梯度稳定传播。
- **预训练目标应分别说明**：掩码语言模型（MLM）根据上下文恢复被遮符号；自回归语言模型把序列概率分解为

$$p(x_{1:T}) = \prod_{t=1}^{T} p(x_t \mid x_{<t}).$$

  微调目标与下游评估须与预训练目标区分开。
- 课件介绍 ELMo、BERT、GPT、编码器—解码器与 RLHF。本书只保留稳定机制说明，不把某个版本的参数量或排名写成通用事实。RLHF 等人工反馈对齐通常含监督微调、偏好/奖励建模、策略优化等环节，不能简化为“模型知道了人的真实意图”。

10.6 生成模型与安全边界

GAN：极小极大博弈（保留目标并解释）

GAN 同时训练生成器 G 与鉴别器 D，经典目标为

$$\min_G \max_D \; \mathbb{E}_{x\sim p_{data}}\big[\log D(x)\big] + \mathbb{E}_{z\sim p(z)}\big[\log\big(1 - D(G(z))\big)\big].$$

- **鉴别器** D 尽量把真实样本判为 1、生成样本判为 0（最大化上式）；
- **生成器** G 尽量骗过 D（最小化上式中第二项）。
- 这是**二人零和博弈**，交替优化。它**可能不稳定、出现模式坍塌**（生成样本多样性不足），不能保证有限训练必然达到理想均衡。不要把 GAN 描述成“一定能收敛到完美生成器”。

扩散模型：闭式加噪（保留公式并解释）

扩散模型的前向过程逐步加噪。常用闭式写法

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t}\,\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\,\boldsymbol{\epsilon}, \qquad \boldsymbol{\epsilon} \sim \mathcal{N}(0, I),$$

其中 $\bar{\alpha}_t$ 为各步保真系数之积（随时间递减，噪声占比递增）。

- **含义**：$\mathbf{x}_t$ 是“原图 $\mathbf{x}_0$ 按 $\sqrt{\bar{\alpha}_t}$ 缩放 + 标准高斯噪声按 $\sqrt{1-\bar{\alpha}_t}$ 缩放”的线性组合；当 $\bar{\alpha}_t \to 0$ 时 $\mathbf{x}_t$ 趋近于纯噪声。
- **训练**：网络学习“给定时间 t 和带噪样本 $\mathbf{x}_t$ 时预测噪声 $\boldsymbol{\epsilon}$”。
- **采样**：按所选反向过程逐步去噪，产生数据。
- **边界（务必说明）**：生成的是**学习分布中的新样本**，不保证还原某张特定训练图；也不能忽略时间相关系数 $\bar{\alpha}_t$、而反复直接减同一个噪声——不同 t 的噪声尺度不同，必须按对应系数处理。

对抗样本与安全边界（保留概念定位）

课件末尾讨论对抗样本：输入在给定扰动预算（如 ℓ_∞ 范数界）内做微小变化，可能导致错误预测。应区分白盒、基于分数、基于决策与迁移等威胁模型，并报告扰动范数、预算与评价条件。这里是课程概念整理，**不包含对外部系统的攻击实验。**

> **来源定位（保留）**：自组织映射、RBF 网络、RBM、强化学习网络等在 S16 37–58 页概述性出现，本版记录其定位，但不宣称已完整推导这些扩展算法。S19 中应用图片与早期平台列表保留在来源材料中，尚未逐项写成经过核实的现状说明。

10.7 小结、常见误区与练习

一页速查（本章核心公式）

主题	公式	维度要点
前向一层	$\mathbf{z}^{(l)} = W^{(l)}\mathbf{a}^{(l-1)} + \mathbf{b}^{(l)},\ \mathbf{a}^{(l)} = \phi_l(\mathbf{z}^{(l)})$	$W^{(l)} \in \mathbb{R}^{d_l \times d_{l-1}}$，$\mathbf{a}^{(l)} \in \mathbb{R}^{d_l}$
隐藏层误差	$\boldsymbol{\delta}^{(l)} = \left[(W^{(l+1)})^T \boldsymbol{\delta}^{(l+1)}\right] \odot \phi_l'(\mathbf{z}^{(l)})$	输出 $\mathbb{R}^{d_l}$
权重梯度	$\partial J / \partial W^{(l)} = \boldsymbol{\delta}^{(l)} (\mathbf{a}^{(l-1)})^T$	外积得 $\mathbb{R}^{d_l \times d_{l-1}}$
输出误差（softmax+CE）	$\boldsymbol{\delta}^{(L)} = \mathbf{p} - \mathbf{y}$	$\mathbb{R}^K$，需 one-hot
CNN 输出尺寸	$L_{out} = \lfloor (L_{in} + 2P - F)/S \rfloor + 1$	二维对高宽各算一次
CNN 参数量	$C_{out}(F_h F_w C_{in} + 1)$	不含空间尺寸
RNN 误差	$\boldsymbol{\delta}_t = (W_o^T \mathbf{e}_t + W_h^T \boldsymbol{\delta}_{t+1}) \odot \phi'(\mathbf{u}_t)$	末态 $\boldsymbol{\delta}_{T+1} = 0$
RNN 共享梯度	$\partial J / \partial W_h = \sum_t \boldsymbol{\delta}_t \mathbf{h}_{t-1}^T$	必须按时间求和
注意力	$\mathrm{Attention}(Q,K,V) = \mathrm{softmax}(QK^T/\sqrt{d_k} + M)V$	$Q \in \mathbb{R}^{n_q \times d_k}, V \in \mathbb{R}^{n_k \times d_v}$
扩散闭式	$\mathbf{x}_t = \sqrt{\bar{\alpha}_t}\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\boldsymbol{\epsilon}$	$\boldsymbol{\epsilon} \sim \mathcal{N}(0, I)$

常见误区汇总（编者总结）

1. **“多层 = 非线性”**：错。层间无激活时，多层线性等价于单层线性。
2. **“换 ReLU 就解决梯度消失”**：错。ReLU 缓解但不根除，且带来死单元。
3. **“卷积层参数随图像变大而变多”**：错。权重共享使参数量与空间尺寸无关。
4. **“CNN 平移不变”**：应为“平移等变”；不变性需池化/训练共同塑造。
5. **“截断 BPTT 是精确 BPTT”**：错。它是有限窗近似，改变了梯度估计。
6. **“注意力掩码可整行全遮”**：错。整行 $-\infty$ 使 softmax 未定义（NaN）。
7. **“GAN 必然收敛到完美生成器”**：错。可能不稳定、模式坍塌。
8. **“BP 就是训练”**：错。BP 只算梯度；更新由梯度下降（见第三章）完成。

练习与复算

本章涉及的例题数字（XOR 的 $0, 1, 1, 0$、CNN 的 $28 \times 28 \times 6$ 与参数 456）建议亲手复算一遍，并对照练习与可复现计算中对应条目。完成练习时先遮住解答，自行说明假设、定义符号、写出目标，再逐步计算——尤其要练习“先核对维度、再写公式”的习惯。

练习与可复现计算

题目身份与资料边界

下列题目是**编者自编练习与参考解**，不是教师原题或官方答案。课件中已明确识别到的课堂作业为 S18 21 页“截断深度为 h 的学习”；原页含公式与图形，本版只记录定位，未将不完整转录充作完整原题。各课件示例中的数据表，只有实际核对并执行过的计算才列入验证结果。

练习 1：后验与分类

两类一维高斯的均值分别为 0、2，共同方差为 1，先验为 0.8、0.2。求 0–1 损失下分类边界；第一类先验增加后，它的区域扩大还是缩小？

参考解：相减对数得分为 $-2x+2+\log 4$，边界 $1+\log 4/2 \approx 1.693147$。第一类选取 x 小于边界的部分，区域扩大。改变误判代价后需重新比较条件风险。

练习 2：ML、MAP 与预测

先验 $\theta \sim \mathrm{Beta}(5,5)$，观察到 15 次正面、10 次反面。分别求 ML、MAP 和下一次正面预测概率。

参考解：ML 为 $15/25=0.6$；后验是 $\mathrm{Beta}(20,15)$，MAP 为 $19/33$，后验预测为 $20/35$。后两项不同，因为一个取分布众数，一个积分平均。

练习 3：距离与特征缩放

比较 $(3,3)$ 与 $(1,2)$ 的欧氏、曼哈顿、切比雪夫距离以及余弦相似度。若仅把第一维乘 100，各种距离是否保持原值？

参考解：原值依次为 $\sqrt{5}$、3、2、$9/\sqrt{90}$。仅缩放一个坐标通常都会改变这些量，余弦对整体正缩放不敏感，但并不对任意逐坐标缩放不敏感。

练习 4：回归手算

用直线拟合 $(0,1),(1,2),(2,2)$。求斜率、截距、残差和 MSE，并检验残差与常数列、输入列正交。

参考解：斜率 $1/2$，截距 $7/6$；残差 $(-1/6,1/3,-1/6)$；MSE 为 $1/18$。残差和为零，与 $(0,1,2)$ 内积也为零。

练习 5：聚类与局部最优

对一维点 0、2、8、10，初始中心 0、8，执行一次分配和均值更新。为什么目标下降不证明结果是全局最优？

参考解：分配为前两个点和后两个点，中心改为 1、9，目标由 8 降至 4。交替步骤只对当前固定的另一组变量求最优，整体目标非凸；一般不能从单调下降推出全局最优。

练习 6：PCA 与标签

若样本在水平方向变化很大，但标签只由竖直方向的细微差异决定，保留第一主成分是否一定能分类？

参考解：不能。PCA 只最大化输入方差，不使用标签；分类相关方向可能被删去。应按任务验证，或比较监督降维。

练习 7：序列求和与最大化

在 HMM 前向算法中，为什么对所有前驱状态求和？把求和改成最大值后，输出的是什么？

参考解：前向概率要累计所有互斥状态路径的概率，因此求和；改成最大值并保存前驱，计算最可能整条路径，即 Viterbi。它不是各时刻独立选择后验最大状态。

练习 8：BP 维度检查

当前层宽度为 3，前层宽度为 5。写出 W、$\boldsymbol{\delta}$ 和 $\partial J/\partial W$ 的维度。

参考解：分别是 3×5、3×1 和 3×5，梯度为 $\boldsymbol{\delta}\mathbf{a}_{prev}^{T}$。换成反过来的外积会得到错误尺寸。

执行计算复核

在 `教材` 目录运行：

```
python scripts/verify_math.py
python scripts/figures.py
node scripts/build.mjs
node scripts/check.mjs
```

Python 数学检查需要 NumPy，PDF 盘点需要 pypdf，图表脚本只用标准库。已固定的手算输入不涉及随机种子。数学检查包括解析边界代回、最小二乘正交性、K-means 单点转移恒等式、HMM 穷举对照、logistic 与小型网络 BP 的有限差分。执行结果分别存入 `math-report.json` 与 `build-report.json`；这些检查不能替代全课程数学审校。

核心知识点索引

编号是维护用的稳定锚点；本表收录当前正文核心节，不代表全部课件细节已穷尽。重要程度是编者的学习组织判断，不是教师考试重点。来源“对应”仍需结合覆盖表的验收状态。

编号	知识点	章节	重要程度	本版深度	来源页段
ml-01-01	1.1 人工智能背景与机器学习的发展	01	核心 / 支撑	概念与方法	S01 1–7；S01 8–32；S01 33–41
ml-01-02	1.2 机器学习研究的问题：分类、回归与无监督学习	01	核心 / 支撑	概念与方法	S01 42–54
ml-01-03	1.3 课件的建模过程：数据、模型、误差与学习	01	核心 / 支撑	概念与方法	S01 55–64
ml-01-04	1.4 编者补充：为什么训练误差不够	01	核心 / 支撑	概念与方法	
ml-01-06	1.6 本章要点回顾：从七问到三元组	01	核心 / 支撑	概念与方法	
ml-02-01	2.1 先验、似然、后验与证据	02	核心 / 支撑	推导与例子	S02 1–3；S02 4–7；S02 8–10
ml-02-02	2.2 从后验到决策	02	核心 / 支撑	概念与方法	S02 11–14；S03 1–5
ml-02-03	2.3 朴素贝叶斯如何降低估计难度	02	核心 / 支撑	概念与方法	S03 6–17；S03 18–18
ml-02-04	2.4 高斯分类器：为什么边界有时是直线	02	核心 / 支撑	概念与方法	S03 19–30；S03 31–32
ml-02-05	2.5 极大似然估计	02	核心 / 支撑	推导与例子	S03 42–47
ml-02-06	2.6 完整后验、MAP 与后验预测	02	核心 / 支撑	推导与例子	S03 33–41；S03 48–51；S03 52–53
ml-02-08	2.8 从本章到后续章节：贝叶斯视角的延伸	02	核心 / 支撑	概念与方法	
ml-03-01	3.1 从特征到超平面	03	核心 / 支撑	概念与方法	S05 1–5；S05 6–28
ml-03-02	3.2 相似性与样本统计	03	核心 / 支撑	概念与方法	S05 29–37
ml-03-03	3.3 评价分类结果	03	核心 / 支撑	概念与方法	S05 38–41
ml-03-04	3.4 感知机：错了以后朝正确方向移动	03	核心 / 支撑	概念与方法	S06 1–9；S06 10–27

编号	知识点	章节	重要程度	本版深度	来源页段
ml-03-05	3.5 Fisher 线性鉴别：投影后类间远、类内紧	03	核心 / 支撑	推导与例子	S06 28–44
ml-03-06	3.6 Logistic：把线性分数变成概率	03	核心 / 支撑	推导与例子	S06 45–60
ml-03-07	3.7 三个方法放在一起	03	核心 / 支撑	概念与方法	S05 42–49；S06 61–62
ml-03-08	3.8 数值演练：Fisher 解的小例题	03	核心 / 支撑	推导与例子	
ml-03-09	3.9 数值演练：Logistic 的一步梯度下降	03	核心 / 支撑	推导与例子	
ml-03-10	3.10 本章要点回顾	03	核心 / 支撑	概念与方法	
ml-04-01	4.1 决策树：一连串简单问题组成复杂边界	04	核心 / 支撑	概念与方法	S23 1–7；S23 8–42
ml-04-02	4.2 最近邻：让局部样本决定类别	04	核心 / 支撑	概念与方法	S23 43–59；S23 60–60
ml-04-03	4.3 集成：组合必须保留有用差异	04	核心 / 支撑	概念与方法	S24 1–13
ml-04-04	4.4 AdaBoost：逐轮关注难样本	04	核心 / 支撑	推导与例子	S24 14–26
ml-04-05	4.5 SVM：选择几何间隔最大的面	04	核心 / 支撑	推导与例子	S24 27–41
ml-04-06	4.6 核技巧	04	核心 / 支撑	概念与方法	S24 42–49；S24 50–51
ml-05-01	5.1 回归预测的是数值	05	核心 / 支撑	概念与方法	S10 1–17
ml-05-02	5.2 正规方程为什么成立	05	核心 / 支撑	概念与方法	S10 18–20
ml-05-03	5.3 高斯误差连接最小二乘与 ML	05	核心 / 支撑	概念与方法	S10 21–32
ml-05-04	5.4 MAP 与岭回归	05	核心 / 支撑	推导与例子	S10 33–38
ml-05-05	5.5 非线性输入与偏差—方差	05	核心 / 支撑	概念与方法	S10 39–44；S10 45–50
ml-05-06	5.6 本章小结与练习	05	核心 / 支撑	概念与方法	
ml-06-01	6.1 没有标签时，"一类"是什么	06	核心 / 支撑	概念与方法	S25 1–18

编号	知识点	章节	重要程度	本版深度	来源页段
ml-06-02	6.2 序贯方法与层次聚类	06	核心 / 支撑	概念与方法	S25 19–30；S25 31–48
ml-06-03	6.3 K-means 的两步为何都不会增加目标	06	核心 / 支撑	推导与例子	S25 49–66
ml-06-04	6.4 单点转移的精确变化	06	核心 / 支撑	概念与方法	S25 67–71
ml-06-05	6.5 如何评价结果	06	核心 / 支撑	概念与方法	S25 72–76
ml-06-06	6.6 收敛、初始化与常见陷阱	06	核心 / 支撑	概念与方法	
ml-07-01	7.1 选择原特征还是构造新特征	07	核心 / 支撑	概念与方法	S11 1–12；S12 1–12
ml-07-02	7.2 子集生成与评价必须区分	07	核心 / 支撑	概念与方法	S11 13–25；S11 26–37；S11 38–49
ml-07-03	7.3 PCA 从最大投影方差推出	07	核心 / 支撑	推导与例子	S12 13–38
ml-07-04	7.4 中心化、标准化、SVD 与 LDA	07	核心 / 支撑	概念与方法	S12 39–43
ml-07-05	7.5 KPCA、LLE 和非负矩阵分解	07	核心 / 支撑	推导与例子	S12 44–56
ml-07-06	7.6 方法对照与选择指南	07	核心 / 支撑	概念与方法	
ml-08-01	8.1 熵是平均意外程度	08	核心 / 支撑	概念与方法	S13 1–7；S13 8–13
ml-08-02	8.2 条件熵、互信息与 KL	08	核心 / 支撑	概念与方法	S13 19–27
ml-08-03	8.3 最大熵是有约束的保守推断	08	核心 / 支撑	推导与例子	S13 14–18；S13 35–40
ml-08-04	8.4 条件最大熵与 logistic 的联系	08	核心 / 支撑	推导与例子	S13 28–34
ml-08-05	8.5 数值例题、常见误区与跨章链接	08	核心 / 支撑	概念与方法	
ml-09-01	9.1 图首先是一组分解与独立性假设	09	核心 / 支撑	概念与方法	S14 1–13
ml-09-02	9.2 三种局部结构与 d 分离	09	核心 / 支撑	概念与方法	S14 14–27
ml-09-03	9.3 马尔可夫随机场	09	核心 / 支撑	概念与方法	S14 28–40

编号	知识点	章节	重要程度	本版深度	来源页段
ml-09-04	9.4 学习、精确推断与采样	09	核心 / 支撑	概念与方法	S14 41–59；S14 60–69；S15 1–13；S15 14–28
ml-09-05	9.5 HMM：用动态规划求序列概率	09	核心 / 支撑	推导与例子	S15 29–47；S15 48–60；S15 61–70
ml-09-06	9.6 CRF：直接建模条件序列分布	09	核心 / 支撑	概念与方法	S15 71–80
ml-09-07	9.7 本章速查与常见误区	09	核心 / 支撑	概念与方法	
ml-10-01	10.1 为什么多层网络需要非线性	10	核心 / 支撑	概念与方法	S16 1–23；S16 24–34；S16 35–58；S16 59–60；S17 1–10；S17 43–48
ml-10-02	10.2 BP 是高效组织链式法则	10	核心 / 支撑	推导与例子	S17 11–42；S19 1–20
ml-10-03	10.3 CNN：局部连接和权重共享	10	核心 / 支撑	概念与方法	S17 49–72
ml-10-04	10.4 RNN：共享参数的时间展开	10	核心 / 支撑	概念与方法	S18 1–9；S18 10–20；S18 21–21；S18 22–28
ml-10-05	10.5 注意力、Transformer 与预训练	10	核心 / 支撑	概念与方法	S19 21–41；S19 42–44；S19 45–51
ml-10-06	10.6 生成模型与安全边界	10	核心 / 支撑	概念与方法	S19 52–62；S19 63–69；S19 70–74
ml-10-07	10.7 小结、常见误区与练习	10	核心 / 支撑	概念与方法	

资料清单与版本说明

版本取舍

本年度 S01、S02、S03、S05、S06 是前三章主来源。往年同章文件作为比较版本，第四至十章使用往年资料，不能替代尚未收到的本年度课件。页码一律为 PDF 物理页码。哈希完整值见下表与本地 sources/manifest.json。

教材与仓库的发布状态见项目 README；不根据构建成功推断线上发布成功。参考项目的两个链接曾尝试访问，但读取失败，因此未声称检查过其源码。工程依据任务文件中的明确要求独立建立。

PDF 清单

ID	文件	角色	页数	SHA-256
S01	1 Chapter 1 Introduction 20260911.pdf	本年度课件	64	`a6da3b8a421932522e652fe220425aeebab5d74011b97885e0723d22c19a54e6`
S02	1 Chapter 2 Bayesian Learning -1 20260911.pdf	本年度课件	14	`0d4011e4856838e6957c308722829c625ab0010546b01b983cd0057f948cf784`
S03	2 Chapter 2 Bayesian Learning-2 20260918.pdf	本年度课件	53	`0f367a798c9fa4f914f97a967879086336f2acd42a8bf59835a70ddf2fd7adfd`
S04	2012.李航.统计学习方法.pdf	参考书	251	`c6a89c77eeeb897caa7e10db6ec8272cbac31d43a2c545b9e4c9235493f3bcd1`
S05	3 Chapter 3 Linear Classifiers-1 20261009.pdf	本年度课件	49	`af1aff997027160b506e8e227c0df840c0b7ba0f7b794d9ba15609559a6b163d`
S06	4-6 Chapter 3 Linear Classifiers-2 20261016.pdf	本年度课件	62	`8147d955f1a3919416bf4bcdb82a5b9240ea11a9c6a3ddcf4a5021b387654e97`
S07	Pattern Recognition And Machine Learning Bishop-.pdf	参考书	703	`9b9fe4adb00c95e7edf6071169175e1d3dcbb09eae3e681b43689ce4af60ebbf`
S08	往年课件/1 Chapter 1 Introduction.pdf	往年课件	57	`98fd21141f6f60d822857ae051c4e0286441032e0415998d8b3ad27cab0a1c02`
S09	往年课件/1 Chapter 2 Bayesian Learning -1.pdf	往年课件	14	`c89336d07c7b2a398b08bc970113a6f2f7be02d9ce8166440638f8471ca1e82f`
S10	往年课件/10 Chapter 5 Regression.pdf	往年课件	50	`6a3a30ea9529c4091f05ea069077313dff4eb4686645a806b7c612e69269bba7`
S11	往年课件/11 Chapter 7 Feature Selection & Extraction-1.pdf	往年课件	49	`396d4567e1333794bd4ed932529eb64acc328e28619348123c7797641c7e2044`

ID	文件	角色	页数	SHA-256
S12	往年课件/12 Chapter 7 Feature Selection & Extraction-2.pdf	往年课件	56	`44d860ddc3d7f284a5195f81874e6da50a24b6081c40a93c390ca2aa600c46e3`
S13	往年课件/13 Chapter 8 Information-Theoretic Models.pdf	往年课件	40	`48da235f408abc944723ead3b32114796ec7d9203468f0baca464e2954371131`
S14	往年课件/14 Chapter 9 Probabilistic Graphical Model-1.pdf	往年课件	69	`06b8917ff1f643b09f2fc921f36f6b956285854ec6ed7c2e900df798f47366b8`
S15	往年课件/15 Chapter 9 Probabilistic Graphical Model-2.pdf	往年课件	80	`72627349e6491515728ff72d157dc69f2df34cc80e5b37edce9051864cddf854`
S16	往年课件/16 Chapter 10 Neural Network and Deep Learning-1.pdf	往年课件	60	`772c42d8bb6b4908f3c69a7356d05be5656844bb3306b9625fdbff73a4637bf2`
S17	往年课件/17 Chapter 10 Neural Network and Deep Learning-2.pdf	往年课件	72	`e9ccdbb28dc18d9207a1f91e66f7b783ee6c64b5ee575ceb14e960df80191465`
S18	往年课件/18 Chapter 10 Neural Network and Deep Learning-3.pdf	往年课件	28	`fa0330fcbc772202060c434dda0530452d08787060a044d380d9f11b5756d910`
S19	往年课件/19 Chapter 10 Neural Network and Deep Learning-4.pdf	往年课件	74	`2ea3eaa8007ed7a1f5f26b0e464a70e8bdb2fee497220bfb30901d184080b975`
S20	往年课件/2-3 Chapter 2 Bayesian Learning-2.pdf	往年课件	53	`7975fbd1ead1d087f79355f0244d4f6714e3ba63f057cf42d2bcdf3ca5fb6618`
S21	往年课件/3-4 Chapter 3 Linear Classifiers-1.pdf	往年课件	49	`a7820b1ab0e0f1a86c01a6fae3cabcc2c68a46e186d0f191326c06d37b5a32f3`
S22	往年课件/5-6 Chapter 3 Linear Classifiers-2.pdf	往年课件	62	`88e40498c24654c6c062ca1a7cba03c795b454c32d8982fa17f3f7a81fe7702d`
S23	往年课件/7 Chapter 4 Nonlinear Classifier-1.pdf	往年课件	60	`f4b7607de73e99f06cbff510035c4ccc3b0798f50297c89a67f5bb3aa9397d21`
S24	往年课件/8 Chapter 4 Nonlinear Classifier-2.pdf	往年课件	51	`677747e73f2737fcb3669bf861c61e627cb123812b636a9bb75dae6dfc0e5ba1`
S25	往年课件/9 Chapter 6 Clustering.pdf	往年课件	76	`a1470393ac24997a4c15bea21001c2e708eb47e797b3ba502ee2723b457604f2`
S26	机器学习_周志华.pdf	参考书	442	`5a9e9a8ddde2ecb7015b7f9fc53af12e44385bbf7965be9ec304c454a24500c4`
S27	模式识别（第二版）边肇祺.pdf	参考书	352	`ec6508f0c44e69ae4b634d3347d4470b8c238786d38cc42b2f5a2b6c76da33c5`

非 PDF 资料

已有贝叶斯 Markdown 笔记保留原样，仅作比对，不作为未经核实的外部引用依据；原笔记的 Obsidian 返回链接不复制到本站。课堂板书照片已单独查看，其共同协方差高斯边界推导对应第二章 2.4，并补充了可逆性前提。ZIP 是往年课件压缩包，解压目录已存在，未重复解压或删除。三个中文参考书文本层不完整，不能据其页码声称完成书本核对；Bishop 有文本层，但本版未完整研读全书。

参考书仅为可用资源，不作为本版所有编者解释的逐条外部出处。原课件与参考书不复制进网站发布目录。

来源覆盖与视觉核对记录

有映射不等于已经逐项验收。 下表为主题页段到正文的初步对应；逐物理页状态另存 `sources/page-coverage.csv`。文字已批量提取，但不能据此认定所有图片公式、原始案例或扫描页均已阅读完整。

“已视觉抽查”只用于实际打开查看的原页。其他页是待视觉复核；休息、目录与参考页不要求编写独立知识点。四本参考书均不是逐页教学覆盖对象。

来源	PDF 页段	正文对应	处理说明
S01	1–7	ml-01-01	课程信息；考试日期冲突；内容验收待完成
S01	8–32	ml-01-01	背景；产品列表外部事实待核实；内容验收待完成
S01	33–41	ml-01-01	学习定义与背景；内容验收待完成
S01	42–54	ml-01-02	任务与建模流程；内容验收待完成
S01	55–64	ml-01-03	课程大纲与参考资料；内容验收待完成
S02	1–3	ml-02-01	封面与目录；内容验收待完成
S02	4–7	ml-02-01	天气例；内容验收待完成
S02	8–10	ml-02-01	概率基础；内容验收待完成
S02	11–14	ml-02-02	判别与参考文献；内容验收待完成
S03	1–5	ml-02-02	回顾；半朴素仅提及；内容验收待完成
S03	6–17	ml-02-03	朴素贝叶斯；西瓜表待逐格复核；内容验收待完成
S03	18–18	ml-02-03	休息页；内容验收待完成
S03	19–30	ml-02-04	高斯判别与二次例；内容验收待完成
S03	31–32	ml-02-04	休息与目录；内容验收待完成
S03	33–41	ml-02-06	参数后验与Beta共轭；内容验收待完成
S03	42–47	ml-02-05	ML与高斯估计；内容验收待完成
S03	48–51	ml-02-06	MAP；内容验收待完成
S03	52–53	ml-02-06	小结与参考文献；内容验收待完成
S05	1–5	ml-03-01	封面与章节导言；内容验收待完成
S05	6–28	ml-03-01	向量空间与超平面；内容验收待完成
S05	29–37	ml-03-02	距离、散度、数值例；内容验收待完成
S05	38–41	ml-03-03	评价；检验仅提及；内容验收待完成
S05	42–49	ml-03-07	线性可分、多类策略与参考文献；内容验收待完成
S06	1–9	ml-03-04	导言、增广和梯度下降；内容验收待完成
S06	10–27	ml-03-04	感知机准则、算法与例子；内容验收待完成

来源	PDF 页段	正文对应	处理说明
S06	28–44	ml-03-05	Fisher判别与休息页；内容验收待完成
S06	45–60	ml-03-06	logistic与softmax；内容验收待完成
S06	61–62	ml-03-07	小结与参考文献；内容验收待完成
S08	1–57	同章主来源 S01	往年比对版；不宣称逐页完全一致
S09	1–14	同章主来源 S02	往年比对版；不宣称逐页完全一致
S10	1–17	ml-05-01	问题与评价；房价原例已核对；内容验收待完成
S10	18–20	ml-05-02	最小二乘；内容验收待完成
S10	21–32	ml-05-03	高斯ML与梯度例；25–31页已核对；内容验收待完成
S10	33–38	ml-05-04	MAP与正则；内容验收待完成
S10	39–44	ml-05-05	基函数与多项式；内容验收待完成
S10	45–50	ml-05-05	偏差方差与参考文献；内容验收待完成
S11	1–12	ml-07-01	动机与定义；内容验收待完成
S11	13–25	ml-07-02	子集生成；内容验收待完成
S11	26–37	ml-07-02	可分性；部分概率距离未完整转录；内容验收待完成
S11	38–49	ml-07-02	三种框架与Relief；Filter原表已核对；内容验收待完成
S12	1–12	ml-07-01	线性变换、投影与分解；内容验收待完成
S12	13–38	ml-07-03	PCA重构与方差推导；内容验收待完成
S12	39–43	ml-07-04	SVD、LDA；内容验收待完成
S12	44–56	ml-07-05	KPCA、LLE、NMF与小结；内容验收待完成
S13	1–7	ml-08-01	概述；内容验收待完成
S13	8–13	ml-08-01	熵与微分熵；内容验收待完成
S13	14–18	ml-08-03	最大熵与高斯；内容验收待完成
S13	19–27	ml-08-02	条件熵、互信息、KL；内容验收待完成
S13	28–34	ml-08-04	条件最大熵；内容验收待完成
S13	35–40	ml-08-03	五状态例与文献；内容验收待完成
S14	1–13	ml-09-01	DAG与草坪例；概率表与四问已核对；内容验收待完成
S14	14–27	ml-09-02	d分离与马尔可夫毯；内容验收待完成
S14	28–40	ml-09-03	MRF、RBM与图像去噪；内容验收待完成
S14	41–59	ml-09-04	学习、推断与变量消去；内容验收待完成
S14	60–69	ml-09-04	信念传播与参考文献；内容验收待完成
S15	1–13	ml-09-04	前向采样；内容验收待完成

来源	PDF 页段	正文对应	处理说明
S15	14–28	ml-09-04	Gibbs采样；内容验收待完成
S15	29–47	ml-09-05	HMM定义与三问题；内容验收待完成
S15	48–60	ml-09-05	前向后向与期望；内容验收待完成
S15	61–70	ml-09-05	Viterbi、学习；信封例已核对；内容验收待完成
S15	71–80	ml-09-06	CRF与小结；内容验收待完成
S16	1–23	ml-10-01	历史与应用；事实未逐项核实；内容验收待完成
S16	24–34	ml-10-01	神经元、损失与优化；内容验收待完成
S16	35–58	ml-10-01	网络族概述；扩展模型未完整推导；内容验收待完成
S16	59–60	ml-10-01	重点与参考文献；内容验收待完成
S17	1–10	ml-10-01	多层网络；内容验收待完成
S17	11–42	ml-10-02	BP与梯度推导；内容验收待完成
S17	43–48	ml-10-01	激活、XOR、逼近；定理细节待核对；内容验收待完成
S17	49–72	ml-10-03	CNN、池化与参考文献；内容验收待完成
S18	1–9	ml-10-04	递归结构与能力；定理细节待核对；内容验收待完成
S18	10–20	ml-10-04	RNN与BPTT；内容验收待完成
S18	21–21	ml-10-04	课堂作业仅给截断深度h标题；已视觉核对；内容验收待完成
S18	22–28	ml-10-04	连续训练、任务结构与文献；内容验收待完成
S19	1–20	ml-10-02	梯度、ReLU与视觉应用图；内容验收待完成
S19	21–41	ml-10-05	语言表示、注意力、预训练；内容验收待完成
S19	42–44	ml-10-05	历史平台列表；内容验收待完成
S19	45–51	ml-10-05	语言模型与RLHF；参数列表未核实；内容验收待完成
S19	52–62	ml-10-06	GAN与应用；内容验收待完成
S19	63–69	ml-10-06	扩散模型；内容验收待完成
S19	70–74	ml-10-06	模型安全与参考文献；内容验收待完成
S20	1–53	同章主来源 S03	往年比对版；不宣称逐页完全一致
S21	1–49	同章主来源 S05	往年比对版；不宣称逐页完全一致
S22	1–62	同章主来源 S06	往年比对版；不宣称逐页完全一致
S23	1–7	ml-04-01	导言与非线性方法；内容验收待完成
S23	8–42	ml-04-01	树、划分、剪枝；西瓜原例已局部核对；内容验收待完成
S23	43–59	ml-04-02	近邻、快速检索、压缩与拒绝；内容验收待完成
S23	60–60	ml-04-02	参考文献；内容验收待完成

来源	PDF 页段	正文对应	处理说明
S24	1–13	ml-04-03	组合、Bagging与随机森林；内容验收待完成
S24	14–26	ml-04-04	AdaBoost；三轮原例已核对；内容验收待完成
S24	27–41	ml-04-05	最大间隔、对偶、KKT；内容验收待完成
S24	42–49	ml-04-06	核与软间隔；内容验收待完成
S24	50–51	ml-04-06	小结与参考文献；内容验收待完成
S25	1–18	ml-06-01	定义、相似性与评价；内容验收待完成
S25	19–30	ml-06-02	序贯与增强；内容验收待完成
S25	31–48	ml-06-02	层次与聚类数；关键例页已核对；内容验收待完成
S25	49–66	ml-06-03	K均值迭代图；49–63页已核对；内容验收待完成
S25	67–71	ml-06-04	单点转移；内容验收待完成
S25	72–76	ml-06-05	30点原数据例已核对；参考文献；内容验收待完成

建设与验收记录

本版交付的性质

这是持续修订中的教材初稿。2026-10-30 已针对“正文与 PPT 不对齐、课件例题缺失、图示不足”完成前三章第一轮纠偏，并继续恢复第四至十章的关键往年课件原例；尚未达到全资料逐页视觉核对及完整教材最终验收，不能将本报告视为最终验收通过证明。

资料范围

共盘点 27 份 PDF、2990 个物理页，其中 5 份本年度课件共 242 页，18 份往年课件与本年度课件合计 1242 页，另有 4 本参考书。已保存全部文件 SHA-256 与逐页提取文本。中文参考书多数页面缺少可用文本层，后续使用时需逐页视觉阅读或 OCR，不能仅依据提取结果。

前三章采用 2026 版本，第四至十章采用文件夹“往年课件”中的版本，封面日期主要跨 2025–2026。往年文件名与新文件相同的章节没有直接认定为完全一致。保留课件十章结构，按概念依赖补写推导，建立 54 个稳定核心知识点锚点；该数字不表示全部讲授细节均已独立编号。

正文与来源的区分

章节开头列出主要来源页段。编者新增了一维高斯先验移动例、最小二乘小数据例、K-means 手算、碰撞结构条件概率例和 XOR 网络构造等。公式推导、边界条件和自编练习属于教学解释，不是教师标准答案。原有贝叶斯笔记保留，未照搬其未经核实的外部教材对应或吴恩达课程引用。

发现并处理了以下问题：绪论考试日期与学年冲突；余弦相似度的名称与“距离”混用；感知机当前点修正与全局误差的混淆；PCA 中心化与标准化的混用；HMM 局部发射假设不等于后验只依赖本词。没有擅自更改原课件。

检查结果与门禁

项目	当前结果	解释
资料盘点与哈希	已执行	27 份 PDF；另记录非 PDF 原始文件
逐页文字提取	已执行	保存文本，不等于实际全页阅读或公式覆盖通过
原页视觉检查	抽查 187 页	包括前三章本年度课件及第四至十章关键往年原例页；未查看页仍为 pending
全来源知识覆盖	**未通过最终验收**	后续原图、数据表、程序或作业细节仍需核对
数学数值检查	38 项通过	新增决策树、AdaBoost、K-means、草坪网络、信封 HMM 与 CNN 核算；不等于全书证明审校
公式静态渲染	构建检查	KaTeX 在构建时执行，输出本地 HTML 与 MathML
链接与稳定锚点	自动检查	具体计数记录于本地 check-report.json
页面实际视觉检查	见本地预览记录	自动构建不能代替桌面与手机检查
线上部署	配置 GitHub Pages 自动发布	用户已授权公开部署；以部署工作流及线上 version.json 为准

项目	当前结果	解释
学生学习实验	未执行	作者自查不能等同真实学习效果验证

2026-10-30 课件对齐纠偏记录

- 第一章恢复 S01 46 页“年轻人/老年人分类”、47 页房价回归的 13 个训练点与 90 m² 问题、49–52 页颜色/形状/大小聚类，并把 42–54 页的建模流程恢复为主线；原有泛化与数据划分改标“编者补充”。
- 第二章补回 S03 13–17 页完整西瓜朴素贝叶斯例题，包括 17 行训练表、离散频数、连续高斯密度和最终比较。独立核算发现课件第 17 页的“好瓜”分数 0.038 与第 14–16 页显示因子乘积 0.0629 不一致；坏瓜分数 6.80×10^{-5} 可复现，分类结论不变。该差异已显式保留，未伪造教师答案。
- 第三章补回 S06 23–27 页两个感知机课堂例题，并将 S05 47 页二叉树比对扩写为“训练 $K(K-1)/2$ 个两两模型、测试淘汰树比较 $K-1$ 次”的分阶段解释，补充四分类图与非传递性限制。
- 本轮视觉查看 31 个本年度课件物理页（含复核页），对应覆盖表状态为 `spot-checked`；其余页仍保持 `pending`，没有因文本抽取而冒充视觉验收。

2026-10-30 第四至十章例题纠偏记录

- 第四章恢复 S23 37–39 页的 17 个西瓜样本、根节点信息增益和最终决策树；恢复 S24 23–26 页三轮 AdaBoost 的 p_1, p_2, p_3、样本权重与组合分类器。
- 第五章将 S10 4 页的 13 个房价训练点设为本章主例，补齐正规方程统计量、参数和 90 m² 预测；S10 25–31 页的直线与损失等高线作为参数空间解释。
- 第六章补回 S25 36 页五对象嵌套划分，以及 S25 72–75 页 30 个西瓜样本的一轮 K-means 初始化、完整分组和新中心。
- 第七章补回 S11 40–43 页两类三维数据与七个特征子集的 Fisher 型评分，说明单变量排名不能替代子集评价。
- 第八章原有高斯最大熵与五状态最大熵例已经保留，本轮视觉复核 S13 17、35–39 页，没有用新的自编题替换。
- 第九章补回 S14 8–13 页草坪贝叶斯网络的四问四答，以及 S15 69–70 页信封 HMM 的五步前向概率与 Viterbi 路径。
- 第十章补回 S17 56–62 页 7×7 输入、3×3 核的滑窗尺寸和参数解释；S18 21 页只有“截断深度为 h”作业标题，正文只补通用推导，未伪造教师数值答案。
- 本轮新增视觉核对 118 个往年课件物理页；连同既有记录，覆盖表现有 187 页为 `spot-checked`，其余页继续保持 `pending`。

图表审计

现有 21 张静态 SVG。此前 13 张覆盖高斯、Beta、sigmoid、K-means、PCA、d 分离及前三章纠偏；本轮新增 8 张为西瓜决策树、三轮 AdaBoost、房价回归、30 点 K-means、Filter 子集评分、草坪贝叶斯网络、信封 HMM 和卷积滑窗。每图只承担一个主要任务，均由确定性脚本生成，未使用随机样本冒充证明。

21 个 SVG 的 XML 生成、站点复制、引用与链接检查均已通过。本轮 8 张新增 SVG 已用无界面 Chrome 实际渲染为 760×360 PNG 并逐张查看；修复了房价图虚线路径默认填充产生的黑色三角。此前未做像素复核的旧图仍保留相应待办，不把自动结构检查等同全站视觉通过。

没有添加复杂交互：当前内容用静态图即可解释，避免把推导与多个模型塞入一屏。全文搜索和主题切换只是阅读工具；断开 JavaScript 后，正文、公式、导航与图表仍由静态 HTML 保留。

尚未关闭的内容事项

- 本年度第四至十章课件尚未提供；不能宣称本年度整门课程讲授范围已覆盖。

- 西瓜表、AdaBoost 多轮示例、特征子集统计表、草坪概率表与信封 HMM 已完成第一轮恢复；仍需核对随机森林原图、Gibbs 采样完整逐轮表、层次聚类全部距离图、LeNet 连接表及其余课件原有图形。
- 需继续补齐课件提及但正文仅概述的内容，特别是部分概率可分性指标、通用逼近定理的假设、扩展网络族，以及只给标题而未给教师答案的课堂作业边界说明。
- 课堂板书照片已核对其高斯边界推导；三本中文扫描参考书未进行全面 OCR 或逐页阅读。
- 绪论与深度学习中的产品清单、排名、历史细节和平台链接没有逐项外部核实，不作为已核实的现状引用。
- 参考项目网页与 GitHub 的读取均失败，因此工程没有声称复用其实现或完成源码审计。

这些事项已写入来源覆盖表与项目进度。后续应按页段补充，不应仅增加知识点数量后宣布完成。

本地预览记录

已在实际浏览器查看首页与贝叶斯章的正文、数学和高斯图，测试全文搜索“共轭”可定位相关页面，测试深浅色切换。本轮又用 Chrome 实际渲染并逐张查看 8 张新增 SVG，发现并修复房价图虚线路径的默认黑色填充。当前浏览器接口未提供已确认的视口缩放能力，因此**手机与窄屏实际显示仍未验收**；无 JavaScript 阅读依据静态输出结构检查，未做浏览器禁用脚本实测。

更新与维护

项目中的文件如何协作

`docs/` 是唯一正文源；`site/` 完全由脚本生成。`sources/manifest.json` 记录 PDF 身份与哈希，`sources/page-coverage.csv` 逐页记录文字、视觉和正文状态，`sources/knowledge.json` 提供稳定知识点索引。原始资料位于项目上一级，只读使用。

构建使用本地 marked 与 KaTeX，将数学编译进 HTML；无需网页运行时加载公式库，也无需 CDN。CSS、脚本、字体、图表一起打包，支持普通静态托管及直接打开本地页面。

新增课件流程

1. 把新课件保存在课程目录，保留文件名中的版本日期，不覆盖旧版。
2. 运行 `python scripts/inspect_sources.py`，先检查 `sources/changes.json`，保存本轮差异记录。脚本为新文件追加来源 ID，已有 ID 不重新排序。
3. 对比新增 / 变更页，逐页阅读定义、推导、图表、代码与作业；公式文本不完整时渲染原页，记录实际已查看的物理页码。
4. 更新受影响正文、`scripts/indexes.py` 中的人工页段映射、视觉状态和未完成事项；新版不能无理由覆盖旧版独有知识。
5. 重新生成索引、图表，执行数学检查、网站构建与链接检查；再做实际页面检查。
6. 内容有意识删改时，记录数学或教学理由，再审查并更新 `content-baseline.json`；不得自动重建基线来绕过失败。
7. 保存进度和验证结果。有 Git 仓库后再审查差异并提交；确认不包含原书、课件、缓存和敏感资料后部署。

基线的作用与局限

当前基线检查稳定锚点、章节长度的大幅减少和行间公式数量下降。它能发现一些意外删除，不能判断等长替换是否正确，也不能证明内容完整。来源覆盖审校仍是独立门禁。新增内容不应通过复制模板填充长度。

GitHub Pages 自动部署

当前仓库启用 `.github/workflows/pages.yml`，并保留 `deploy/github-pages.yml` 模板。仓库 Pages 来源设置为 GitHub Actions，`main` 更新后自动发布。构建输出为 `site/`，不包括上一级原始 PDF。公开网址为 机器学习课程教材。

CI 先安装 Python / Node 依赖，重建图表与索引，执行数学检查、构建和链接检查，再上传静态产物。线上 `version.json` 包含构建提交 SHA 和 UTC 构建时间。发布仍不代表内容最终验收通过；首页的初稿与版本边界应保留，直至相关内容门禁关闭。